

Econometría Aplicada I

Repaso 2: Variables Aleatorias Continuas

ANGELO DÍAZ

UNIVERSIDAD DE SANTIAGO DE CHILE
DEPARTAMENTO DE ECONOMÍA
FACULTAD DE ADMINISTRACIÓN Y ECONOMÍA

Resumen

- ① Variables aleatorias continuas.
 - Ideas previas, soporte y probabilidad puntual.
 - Densidad (PDF) y distribución acumulada (CDF).
- ② Distribución uniforme.
- ③ Esperanza y varianza.
- ④ Distribución normal y estandarización.

Conexión con la Clase 1

En la Clase 1 calculamos probabilidades y esperanzas sumando sobre los valores de una variable discreta.

$$\pi_X(x) = \mathbb{P}(X = x), \quad F_X(x) = \mathbb{P}(X \leq x).$$

La pregunta de esta clase

¿Cómo calculamos probabilidades cuando modelamos tiempos, distancias u otras magnitudes que pueden variar continuamente?

- La CDF conserva su definición.
- Para variables con densidad, calculamos probabilidades mediante **áreas e integrales**.

Variable aleatoria continua (v.a.c)


Definición

Si una variable aleatoria X toma un continuo de valores (es decir puede tomar infinitos valores en un intervalo determinado o definido), no está distribuída de forma discreta.

Formalmente se define que una v.a sería una v.a.c si la función de distribución asociada es continua.

Variable aleatoria continua: intuición

Considere una rueda ideal cuyo resultado X puede tomar cualquier valor entre 0 y 1.



Un modelo continuo

Los intervalos pueden tener probabilidad positiva, aunque cada valor individual tenga probabilidad cero.

Si la rueda es uniforme,

$$P(0,2 \leq X \leq 0,4) = 0,2 \quad \text{y} \quad P(X = 0,3) = 0.$$

Una medición redondeada representa un intervalo de valores del modelo continuo.

Variable aleatoria continua: ideas previas

La pregunta

Suponga que una rueda ideal entrega un resultado X en el intervalo $[0, 1]$. Queremos describir la probabilidad de sus posibles resultados.

Entre 0 y 1 existen infinitos valores posibles:

$$0, \quad 0,1, \quad 0,25, \quad 0,3001, \quad \dots$$

En una variable discreta usamos una función de masa:

$$\pi_X(x) = P(X = x).$$

Esta estrategia asigna probabilidades a valores individuales. La pregunta es si puede describir una rueda que puede detenerse en cualquier punto del intervalo.

Por qué una PMF no describe una rueda continua

Intento de asignar probabilidad positiva a cada punto

Suponga que cada valor posible de la rueda recibe una probabilidad positiva. Elija N valores distintos, cada uno con probabilidad al menos $p > 0$.

La probabilidad de obtener alguno de esos N valores sería al menos:

$$Np.$$

Si elegimos suficientes valores, $Np > 1$, lo que contradice que una probabilidad debe estar entre 0 y 1. Esto se debe a que siempre podemos elegir un N suficientemente grande.

Por tanto, una distribución continua no puede asignar masa positiva a cada valor exacto del intervalo.

Valores exactos e intervalos

En un modelo continuo con densidad f_X , las probabilidades se calculan mediante áreas:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

Para un valor exacto c , el intervalo no tiene ancho:

$$P(X = c) = \int_c^c f_X(x) dx = 0.$$

Idea

Cada valor individual tiene probabilidad cero, pero un intervalo puede tener probabilidad positiva porque tiene ancho y, por tanto, área.

Que $P(X = 0,3) = 0$ no significa que observar 0,3 sea imposible. Significa que un punto aislado no ocupa área bajo la densidad.

Más información: distribuciones continuas y discretas

Variable aleatoria continua: definición

Variable aleatoria continua (v.a.c.). Hansen (2022)

Si $X \sim F_X$ y $F_X(x)$ es continua, entonces X es una variable aleatoria continua.

O también podemos usar la siguiente definición:

Variable aleatoria absolutamente continua. Bertsekas y Tsitsiklis (2008)

Existe una función $f_X(x)$, llamada función de densidad de probabilidad (PDF), tal que para todo conjunto medible B :

$$P(X \in B) = \int_B f_X(x) dx.$$

La segunda definición permite calcular probabilidades mediante áreas bajo la densidad.

Propiedades de una densidad (PDF)

Dos condiciones

$$f_X(x) \geq 0, \quad \int_{-\infty}^{\infty} f_X(x) dx = 1.$$

Para $a < b$:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(x) dx.$$

- La no negatividad asegura probabilidades no negativas.
- El área total igual a uno normaliza la distribución.
- La integral asigna a intervalos disjuntos áreas que se suman.

Soporte y extremos de un intervalo

En una variable discreta, el soporte reúne los valores con masa positiva:

$$P(X = x) > 0.$$

En una variable continua con densidad, todos los valores exactos tienen probabilidad cero. Por eso necesitamos otra idea de soporte.

Soporte

Un punto x pertenece al soporte si cualquier intervalo abierto que contenga a x tiene probabilidad positiva.

Ejemplo: si $X \sim U(0, 1)$, el soporte es $[0, 1]$.

$$P(X = 0) = 0, \quad P(X = 0,4) = 0,$$

pero 0 y 0,4 pertenecen al soporte porque cualquier vecindad suya contiene valores posibles de X .

Como los puntos extremos tienen probabilidad cero:

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b).$$

Función de distribución acumulada (CDF)

La misma definición de la Clase 1

$$F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(t) dt.$$

- $F_X(x)$ acumula el área hasta el umbral x .
- $0 \leq F_X(x) \leq 1$ y F_X es no decreciente.
- Sus límites en $-\infty$ y $+\infty$ son 0 y 1.
- Para variables con densidad, F_X es continua: no tiene saltos.

Usamos t dentro de la integral para distinguirlo del límite superior x .

PDF y CDF: relación e interpretación

	PDF: $f_X(x)$	CDF: $F_X(x)$
Interpretación	Densidad local	Probabilidad acumulada
Valores	No negativos	Entre 0 y 1
Probabilidad	Área en intervalo	Diferencia de niveles

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a).$$

Además, donde f_X es continua:

$$F'_X(x) = f_X(x).$$

En general, esta igualdad vale casi en todas partes. La CDF puede tener esquinas, por ejemplo en los extremos de una uniforme.

Distribución uniforme

Definición

Si $X \sim U(a, b)$, con $a < b$, su densidad es


$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{en otro caso.} \end{cases}$$

- El soporte es $[a, b]$.
- Intervalos de igual longitud dentro del soporte tienen igual probabilidad.
- Si $a \leq c < d \leq b$, entonces

$$\mathbb{P}(c \leq X \leq d) = \frac{d-c}{b-a}.$$

Uniforme: una densidad puede ser mayor que uno

Para $X \sim U(0, 1/3)$, la altura es $1/(1/3) = 3$.




$$\text{Área total} = \text{base} \times \text{altura} = \frac{1}{3} \times 3 = 1.$$

La altura 3 es una densidad. El área 1 es una probabilidad.

Uniforme: probabilidad de un intervalo

Mantenemos $X \sim U(0, 1/3)$. Queremos $\mathbb{P}(0 \leq X \leq 1/5)$.



$$\mathbb{P}(0 \leq X \leq 1/5) = \int_0^{1/5} 3 \, dx = [3x]_0^{1/5} = \frac{3}{5} = 0,6.$$

Uniforme: construcción de la CDF

Para $X \sim U(a, b)$, acumulamos el área desde la izquierda.

1 Si $x < a$, aún no acumulamos área: $F_X(x) = 0$.

2 Si $a \leq x \leq b$:

$$F_X(x) = \int_a^x \frac{1}{b-a} dt = \frac{x-a}{b-a}.$$


3 Si $x > b$, acumulamos toda el área: $F_X(x) = 1$.

Resultado

$$F_X(x) = \begin{cases} 0, & x < a, \\ (x-a)/(b-a), & a \leq x \leq b, \\ 1, & x > b. \end{cases}$$

Uniforme: lectura gráfica de la CDF

Para $X \sim U(0, 1/3)$, $F_X(x) = 3x$ cuando $0 \leq x \leq 1/3$.



La misma probabilidad por dos caminos

Sea $X \sim U(0, 1/3)$. Calculemos $\mathbb{P}(1/10 < X \leq 1/5)$.

Camino 1: área bajo la PDF

$$\int_{1/10}^{1/5} 3 \, dx = 3 \left(\frac{1}{5} - \frac{1}{10} \right) = \frac{3}{10}.$$

Camino 2: diferencia de la CDF

$$F_X(1/5) - F_X(1/10) = \frac{3}{5} - \frac{3}{10} = \frac{3}{10}.$$

Ambos caminos entregan 0,3. Cambiar $<$ por $\leq$ en los extremos no altera este resultado.

Ejemplo aplicado: tiempo de espera

Supuesto del ejemplo: el tiempo de espera T , en minutos, sigue una distribución $U(0, 10)$.

- Esperar entre 2 y 5 minutos:

$$\mathbb{P}(2 \leq T \leq 5) = \frac{5 - 2}{10} = 0,3.$$

- Esperar más de 7 minutos:

$$\mathbb{P}(T > 7) = 1 - F_T(7) = 1 - \frac{7}{10} = 0,3.$$

- Esperar exactamente 5 minutos: $\mathbb{P}(T = 5) = 0$.

Mediciones redondeadas

Registrar “5 minutos” al redondear al minuto más cercano corresponde a $4,5 \leq T < 5,5$, cuya probabilidad es 0,1.

Cuantiles

La función de distribución acumulada responde una pregunta:

$$F_X(x) = P(X \leq x).$$

Dado un valor x , la CDF indica qué proporción de la distribución queda por debajo de ese valor.

Un cuantil invierte la pregunta:

$$q_p = \inf\{x : F_X(x) \geq p\}.$$

Dada una proporción p , el cuantil q_p indica el valor que deja al menos esa proporción por debajo.

Dos preguntas inversas

Valor x $\xrightarrow{F_X}$ probabilidad acumulada p

Probabilidad acumulada p $\xrightarrow{q_p}$ valor umbral x

La definición de cuantil

Para $0 < p < 1$, el cuantil de orden p es:

$$q_p = \inf\{x : F_X(x) \geq p\}.$$

Interpretación

q_p es el menor valor para el cual la probabilidad acumulada alcanza o supera p .

En una distribución continua con CDF estrictamente creciente:

$$F_X(q_p) = p.$$

Por ejemplo:

$q_{0,5}$ es la mediana. Deja el 50 % de la distribución bajo o igual a ese valor.

$q_{0,9}$ es el percentil 90. Deja el 90 % de la distribución bajo o igual a ese valor.

Cuantiles de una distribución uniforme

Sea: $X \sim U(a, b)$, $a < b$.

Su CDF es:

$$F_X(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x > b. \end{cases}$$

Para encontrar el cuantil de orden p , resolvemos:

$$F_X(q_p) = p.$$

Dentro del soporte:

$$\frac{q_p - a}{b - a} = p.$$

Por tanto: $q_p = a + p(b - a)$ El cuantil avanza una fracción p de la distancia entre a y b .

Ejemplo: tiempos de espera uniformes

Suponga que:


$$T \sim U(0, 10).$$

El soporte va desde 0 hasta 10 minutos. Como:

$$q_p = 0 + p(10 - 0) = 10p,$$

obtenemos:

$$q_{0,2} = 2, \quad q_{0,5} = 5, \quad q_{0,9} = 9.$$



Interpretación del cuantil 0,9

Para:

$$T \sim U(0, 10),$$

tenemos:

$$q_{0,9} = 9.$$

Esto significa:

$$P(T \leq 9) = 0,9.$$

Interpretación

El 90 % de los tiempos de espera no supera 9 minutos.

La cola superior

Si:

$$P(T \leq 9) = 0,9,$$

entonces la probabilidad restante es:

$$P(T > 9) = 1 - 0,9 = 0,1.$$

Interpretación

El 10 % de los tiempos de espera supera 9 minutos.

El cuantil separa una proporción acumulada de la cola restante.

Cuantiles, percentiles y mediana

Conclusión

Un cuantil es un valor de la variable asociado a una probabilidad acumulada.

$$q_{0,5}$$

es la mediana: deja el 50 % de los valores bajo o igual a ella.

$$q_{0,9}$$

es el percentil 90: deja el 90 % de los valores bajo o igual a él.

Los deciles, cuartiles y percentiles son cuantiles.

Actividad: cuantiles de una uniforme

Sea:

$$Y \sim U(20, 80).$$

Calcule:

$$q_{0,25}, \quad q_{0,5}, \quad q_{0,95}.$$

Pista

Para $Y \sim U(a, b)$:

$$q_p = a + p(b - a).$$

Actividad: interpretar un cuantil

Para la misma variable:

$$Y \sim U(20, 80),$$

interprete:

$$q_{0,95}.$$

Complete:

$$P(Y \leq q_{0,95}) = \underline{\hspace{2cm}}$$

$$P(Y > q_{0,95}) = \underline{\hspace{2cm}}$$

¿Qué porcentaje de los valores supera el percentil 95?

Esperanza: de la suma a la integral

La idea de promedio ponderado de la Clase 1 se mantiene.

Discreta:
$$\mathbb{E}[X] = \sum_j \tau_j \pi_X(\tau_j),$$

Con densidad:
$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x) dx.$$

Interpretación

$\mathbb{E}[X]$ es el centro de gravedad de la distribución. Mientras la distribución no cambie, es un número fijo, aunque X sea aleatoria.

Para una esperanza finita exigimos $\mathbb{E}[|X|] = \int |x| f_X(x) dx < \infty$.

Esperanza de una función y momentos

La esperanza de $g(X)$ se calcula con la densidad de X :

$$\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

- Primer momento: $\mathbb{E}[X]$.
- Segundo momento: $\mathbb{E}[X^2] = \int x^2 f_X(x) dx$.
- En general, $\mathbb{E}[g(X)]$ y $g(\mathbb{E}[X])$ son distintos.

Linealidad, como en la Clase 1

$$\mathbb{E}[c + dX] = c + d\mathbb{E}[X].$$

La linealidad de la esperanza no requiere independencia.

Las fórmulas de esperanzas finitas suponen integrabilidad absoluta.

Varianza y desviación estándar

Sea $\mu = \mathbb{E}[X]$ y suponga que $\mathbb{E}[X^2] < \infty$.

Varianza

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 f_X(x) dx.$$

$$\boxed{\text{Var}(X) = \mathbb{E}[X^2] - \mu^2.}$$

La desviación estándar es $\sigma_X = \sqrt{\text{Var}(X)}$.

- Si X se mide en minutos, la varianza se mide en minutos².
- σ_X se mide en minutos: es la raíz de la desviación cuadrática media respecto de μ .

Propiedades de la varianza

Para constantes c, d y variables con segundos momentos finitos:

$$\text{Var}(c) = 0, \quad \boxed{\text{Var}(c + dX) = d^2 \text{Var}(X).}$$

La varianza no es un operador lineal

Sumar una constante desplaza la distribución, sin cambiar su dispersión. Multiplicar por d cambia la varianza por un factor d^2 .

Para dos variables:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y).$$

Aquí $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$. Si X y Y son independientes, la covarianza es cero y las varianzas se suman.

Uniforme: cálculo de la esperanza

Para $X \sim U(a, b)$:

$$\begin{aligned}\mathbb{E}[X] &= \int_a^b x \frac{1}{b-a} dx \\ &= \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} \\ &= \frac{(b-a)(b+a)}{2(b-a)} = \boxed{\frac{a+b}{2}}.\end{aligned}$$

Ejemplo: uniforme entre 0 y 1/3

Si $X \sim U(0, 1/3)$, entonces $\mathbb{E}[X] = 1/6$. Es el punto medio del intervalo.

Uniforme: cálculo de la varianza

Primero obtenemos el segundo momento:


$$\mathbb{E}[X^2] = \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b = \frac{a^2 + ab + b^2}{3}.$$

Luego restamos el cuadrado de la esperanza:

$$\begin{aligned}\text{Var}(X) &= \frac{a^2 + ab + b^2}{3} - \left(\frac{a+b}{2} \right)^2 \\ &= \frac{4(a^2 + ab + b^2) - 3(a+b)^2}{12} \\ &= \boxed{\frac{(b-a)^2}{12}}.\end{aligned}$$

Para $U(0, 1/3)$: $\text{Var}(X) = 1/108$ y $\sigma_X = 1/\sqrt{108} \approx 0,0962$.

Uniforme: media y mediana



Para $X \sim U(0, 1/3)$:

$$\mathbb{E}[X] = 1/6, \quad F_X(1/6) = 1/2.$$

Simetría

La simetría de la uniforme hace coincidir media y mediana. En otras distribuciones pueden diferir.

Ejemplo aplicado: costo del tiempo de espera

Si $T \sim U(0, 10)$, entonces

$$\mathbb{E}[T] = 5, \quad \text{Var}(T) = \frac{100}{12} = \frac{25}{3}.$$

Supuesto: el costo en pesos es $C = 500 + 200T$.

$$\mathbb{E}[C] = 500 + 200(5) = 1500 \text{ pesos},$$

$$\text{Var}(C) = 200^2 \frac{25}{3} = \frac{1\,000\,000}{3} \text{ pesos}^2,$$

$$\sigma_C = \frac{1000}{\sqrt{3}} \approx 577,35 \text{ pesos}.$$

Interpretación

El costo fijo de 500 pesos aumenta la media, pero no cambia la dispersión del costo.

Distribución normal: motivación

La normal es un modelo simétrico con forma de campana, muy utilizado en estadística y econometría.

Su papel en la inferencia

Bajo condiciones apropiadas, las sumas o medias estandarizadas pueden aproximarse por una normal. Por ejemplo, el teorema central del límite clásico considera observaciones independientes e idénticamente distribuidas con varianza finita y positiva.

- Tener una muestra grande no vuelve normales los datos originales.
- La normalidad es un supuesto o una aproximación que debe evaluarse.
- Los retornos logarítmicos tampoco son necesariamente normales ni estacionarios.

Distribución normal: definición y notación

Normal con media μ y varianza σ^2

Escribimos $X \sim N(\mu, \sigma^2)$, donde $\mu \in \mathbb{R}$ y $\sigma > 0$.


$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma}\right)^2\right], \quad x \in \mathbb{R}.$$

$$\mathbb{E}[X] = \mu, \quad \text{Var}(X) = \sigma^2, \quad \sigma_X = \sigma.$$

- μ ubica el centro de la distribución.
- σ determina su dispersión.
- Media y mediana coinciden en μ .

En toda esta clase, el segundo parámetro de $N(\mu, \sigma^2)$ es la **varianza**.

Normal: efecto de la media y la desviación



Normal estándar y estandarización

Una escala común

Si $X \sim N(\mu, \sigma^2)$, entonces

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

$$\mathbb{E}[Z] = \frac{\mathbb{E}[X] - \mu}{\sigma} = 0, \quad \text{Var}(Z) = \frac{\text{Var}(X)}{\sigma^2} = 1.$$

- Restar μ centra la variable en cero.
- Dividir por σ mide distancias en desviaciones estándar.

Toda variable con varianza finita y positiva puede estandarizarse. La variable estandarizada es normal si la original es normal.

Normal: PDF, CDF y probabilidades

Para $Z \sim N(0, 1)$, usamos dos símbolos diferentes:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}, \quad \Phi(z) = \int_{-\infty}^z \phi(t) dt.$$

Cálculo de probabilidades

$$\mathbb{P}(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right).$$

- ϕ es una densidad y Φ es una probabilidad acumulada.
- Evaluamos Φ con una tabla o con software.
- Por simetría, $\Phi(-z) = 1 - \Phi(z)$.

Normal: ejemplo resuelto


Modelo hipotético: un puntaje $X \sim N(100, 15^2)$. Queremos la probabilidad de un puntaje entre 85 y 115.

$$\begin{aligned}\mathbb{P}(85 \leq X \leq 115) &= \mathbb{P}\left(\frac{85 - 100}{15} \leq Z \leq \frac{115 - 100}{15}\right) \\ &= \mathbb{P}(-1 \leq Z \leq 1) \\ &= \Phi(1) - \Phi(-1) \\ &\approx 0,84134 - 0,15866 \approx \boxed{0,6827}.\end{aligned}$$

Interpretación

Aproximadamente el 68,27 % de los puntajes del modelo está a una desviación estándar o menos de la media.

Normal: probabilidad como área



Normal: colas y cuantiles

En el mismo modelo, $X \sim N(100, 15^2)$:

Cola superior

$$\mathbb{P}(X > 130) = \mathbb{P}(Z > 2) = 1 - \Phi(2) \approx 0,0228.$$

Percentil 95

Buscamos $q_{0,95}$ tal que $\mathbb{P}(X \leq q_{0,95}) = 0,95$.

$$q_{0,95} = \mu + \sigma \Phi^{-1}(0,95) \approx 100 + 15(1,6449) = 124,67.$$

El 5 % de los puntajes del modelo supera aproximadamente 124,67.

Normal: regla 68–95–99,7

Si $X \sim N(\mu, \sigma^2)$:

Intervalo	Probabilidad aproximada
$[\mu - \sigma, \mu + \sigma]$	68,27 %
$[\mu - 2\sigma, \mu + 2\sigma]$	95,45 %
$[\mu - 3\sigma, \mu + 3\sigma]$	99,73 %

Alcance de la regla

Estas proporciones corresponden a la distribución normal. Una variable con colas más pesadas puede tener mucha más probabilidad en los extremos.

Un intervalo central de probabilidad 95 % usa aproximadamente $\mu \pm 1,96\sigma$.

Ideas clave de la Clase 2

- **PDF:** una altura $f_X(x)$ permite calcular probabilidades mediante áreas.
- **CDF:** $F_X(x) = \mathbb{P}(X \leq x)$ acumula probabilidad.
- **Continuas con densidad:** $\mathbb{P}(X = x) = 0$ y los extremos no cambian la probabilidad de un intervalo.
- **Momentos:** la esperanza mide el centro y la varianza mide dispersión cuadrática.
- **Normal:** $N(\mu, \sigma^2)$ se estandariza restando μ y dividiendo por σ .

Intuición: Ley de los grandes números y Teorema central del límite

Suponga que observamos ingresos:

$$X_1, X_2, \dots, X_n.$$

Cada muestra entrega una media:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Si repitiéramos la encuesta, cambiarían las observaciones y también cambiaría la media muestral.

La pregunta

¿Qué ocurre con $\bar{X}_n$ cuando la muestra contiene cada vez más observaciones?

La ley de los grandes números y el teorema central del límite responden preguntas distintas sobre esa media.

Ley de los grandes números

Si $X_1, \dots, X_n$ son observaciones i.i.d. y:

$$\mu = E[X_i],$$

entonces:

$$\bar{X}_n \xrightarrow{p} \mu.$$

Interpretación

Al aumentar n , es cada vez menos probable que la media muestral esté muy lejos de la media poblacional.

Para cualquier tolerancia $\varepsilon > 0$:


$$P\left(\left|\bar{X}_n - \mu\right| > \varepsilon\right) \longrightarrow 0.$$

Por qué el promedio se estabiliza

Cada observación puede ser alta o baja. Al promediarlas, las desviaciones positivas y negativas tienden a compensarse.

Si las observaciones son independientes y tienen varianza σ^2 :

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$



La dispersión de la media disminuye cuando n aumenta.

Lo que la ley no afirma

La ley de los grandes números no dice que cada observación nueva acerque necesariamente la media a μ .

Una trayectoria puede alejarse temporalmente de la media poblacional:

$\bar{X}_{20}$ puede estar más lejos de μ que $\bar{X}_{19}$.

Lo que sí afirma

Para muestras grandes, la probabilidad de observar una media muy alejada de μ se vuelve pequeña.

La ley habla de la probabilidad entre muchas muestras posibles, no de una trayectoria que deba moverse siempre en una sola dirección.

Teorema central del límite

La ley de los grandes números dice que la media se concentra cerca de μ .

El teorema central del límite agrega información sobre la forma de su error:

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

Interpretación


Después de centrar la media en μ y dividirla por su error estándar, la distribución del resultado se aproxima a una normal estándar.

Equivalentemente, para n suficientemente grande:


$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

El TCL no vuelve normales los datos

Suponga que los ingresos individuales tienen una distribución asimétrica.



Ingresos individuales
asimétricos



Medias muestrales
aproximadamente normales

El TCL se refiere a la distribución de $\bar{X}_n$ entre muestras repetidas. No afirma que los datos originales sean normales.

Ley de grandes números y TCL

Ley de los grandes números

$$\bar{X}_n \xrightarrow{p} \mu$$

Explica por qué la media se acerca a μ .

Justifica usar $\bar{X}_n$ para estimar μ .

Teorema central del límite

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1)$$

Explica cómo se distribuye el error de la media.

Justifica errores estándar, intervalos de confianza y pruebas.

Idea

La ley explica la precisión creciente de la media. El TCL describe la forma de la incertidumbre que queda.

De probabilidad a regresión

Hasta ahora hemos trabajado con variables aleatorias, distribuciones y muestras.

La regresión conecta estas ideas con una pregunta empírica:

¿Cómo cambia Y cuando cambia X ?

Ejemplo

Y : ingreso mensual.

X : años de educación.

Más adelante estimaremos una relación entre ambas variables usando datos.

La conexión con la Clase 1

En Clase 1 definimos la esperanza condicional:

$$m(x) = E[Y \mid X = x].$$

Esta función responde:

¿Cuál es el ingreso promedio entre personas con $X = x$?

Si X corresponde a años de educación:

$$E[Y \mid X = 12]$$

es el ingreso promedio entre personas con 12 años de educación.

Objeto central

La regresión busca resumir o aproximar la función

$$E[Y \mid X = x].$$

La función de esperanza condicional

La función:

$$m(x) = E[Y \mid X = x]$$

puede tener cualquier forma.

Por ejemplo, el ingreso promedio podría aumentar con la educación, pero no necesariamente a una tasa constante.

$$m(x) = \begin{cases} \text{crece lentamente para niveles bajos de } x, \\ \text{crece más rápido para niveles altos de } x. \end{cases}$$

MCO propone una aproximación lineal:

$$E[Y \mid X = x] \approx \alpha + \beta x.$$

La recta de mejor aproximación lineal

En la población, buscamos los valores α y β que minimizan:

$$E[(Y - \alpha - \beta X)^2].$$

Definimos:

$$(\alpha_0, \beta_0) = \arg \min_{\alpha, \beta} E[(Y - \alpha - \beta X)^2].$$

Interpretación

La recta $\alpha_0 + \beta_0 X$ es la mejor predicción lineal de Y usando X , según el error cuadrático medio.

Esta idea extiende el resultado de Clase 1:

$$E[Y | X]$$

minimiza el error cuadrático entre todas las funciones de X .

El error de regresión

Definimos el residuo poblacional:

$$U = Y - \alpha_0 - \beta_0 X.$$

Entonces:

$$Y = \alpha_0 + \beta_0 X + U.$$

Como la recta minimiza el error cuadrático medio:

$$E[U] = 0, \quad E[XU] = 0.$$

Interpretación

El residuo recoge la parte de Y que la aproximación lineal basada en X no logra explicar.

Esto no implica todavía que β_0 tenga una interpretación causal.



De la población a la muestra

En la población no conocemos α_0 ni β_0 .

Observamos una muestra:

$$(X_1, Y_1), \dots, (X_n, Y_n).$$

MCO reemplaza la esperanza poblacional por un promedio muestral:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \frac{1}{n} \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2.$$

Interpretación

MCO elige la recta que deja la menor suma de residuos al cuadrado en la muestra observada.

La conexión con la Clase 2

La Clase 2 explicó por qué las medias muestrales pueden aprender sobre valores poblacionales.

Bajo muestreo i.i.d. y condiciones regulares:

$$\frac{1}{n} \sum_{i=1}^n X_i Y_i \xrightarrow{p} E[XY],$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{p} E[X^2].$$

La ley de los grandes números permite que los momentos muestrales se aproximen a los momentos poblacionales.

Por eso, bajo condiciones apropiadas:

$$\hat{\beta} \xrightarrow{p} \beta_0.$$

El TCL y la incertidumbre de MCO

La consistencia dice que $\hat{\beta}$ se acerca a β_0 cuando n crece.

El teorema central del límite agrega una aproximación para su error:

$$\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} N(0, V_{\beta}).$$

Esto permite construir:

errores estándar, intervalos de confianza, pruebas de hipótesis.

Ruta del curso

Clase 1: esperanza condicional y predicción.

Clase 2: muestra, LGN y TCL.

Luego: MCO, consistencia e inferencia.

Asociación, predicción y causalidad

MCO puede describir una asociación entre X e Y :

$$\hat{\beta} > 0$$

indica que, en la muestra, valores mayores de X se asocian con valores mayores de Y .

Pero una interpretación causal requiere condiciones adicionales.

Ejemplo

La relación entre educación e ingreso puede estar afectada por experiencia, habilidad, contexto familiar u otras variables no observadas.

Más adelante estudiaremos qué supuestos o diseños permiten interpretar un coeficiente de regresión como efecto causal.

Referencias

Bertsekas, D. P. and Tsitsiklis, J. N. (2008). *Introduction to Probability*. Athena Scientific.

Hansen, B. (2022). *Probability and Statistics for Economists*. Princeton University Press.

Material base: *Tema 1.2: Repaso Estadística VA Continua*, Robinson Dettoni (2025). Adaptación docente para esta clase: Angelo Díaz.