

# Econometría Aplicada I

## Estructura de Datos y Distribución Muestral

ANGELO DÍAZ

UNIVERSIDAD DE SANTIAGO DE CHILE  
DEPARTAMENTO DE ECONOMÍA  
FACULTAD DE ADMINISTRACIÓN Y ECONOMÍA

# Estructura de los datos

Diferentes estructuras de datos ameritan distintos tratamientos en su análisis.

Las principales estructuras son:

**Corte Transversal:** muestra de individuos, familias, ciudades, empresas, países, entre otros, tomada en un punto específico del tiempo.

| Obs.     | País      | Desempleo | PIB p/c  | Inflación |
|----------|-----------|-----------|----------|-----------|
| 1        | Rep. Dom. | 14.9      | 152      | 6         |
| 2        | España    | 12.3      | 100      | 4         |
| 3        | Haití     | 6.5       | 92       | 5         |
| $\vdots$ | $\vdots$  | $\vdots$  | $\vdots$ | $\vdots$  |
| $n$      | Grecia    | 20.4      | 200      | 9         |

# Ejemplos de datos de corte transversal

Los datos de **corte transversal** observan muchas unidades en un mismo período (o en un período muy cercano).

- **Encuestas de hogares:**

- CASEN: ingresos, empleo, educación y características del hogar.
- Encuesta de Presupuestos Familiares (EPF): gasto y consumo de los hogares.
- Encuesta Nacional de Empleo (ENE): situación laboral de las personas.

- **Bases administrativas:**

- Registros de trabajadores y empresas en un año determinado.
- Matrículas y resultados académicos de estudiantes en un período.
- Registros de establecimientos de salud, colegios o municipios.

**Series de Tiempo:** conjunto de datos ordenados en el tiempo, comúnmente dependientes. Por ejemplo, datos macroeconómicos de un país.

| Año  | Desempleo | PIB p/c | Inflación |
|------|-----------|---------|-----------|
| 2000 | 6.9       | 152     | 5.0       |
| 2001 | 7.3       | 165     | 4.4       |
| 2002 | 6.5       | 192     | 4.1       |
| ⋮    | ⋮         | ⋮       | ⋮         |
| 2017 | 7.4       | 199     | 4.9       |

# Ejemplos de datos de series de tiempo

Los datos de **series de tiempo** observan una misma unidad a lo largo de distintos períodos.

## ■ Datos macroeconómicos:

- PIB trimestral de Chile.
- Tasa de desempleo mensual.
- Inflación mensual medida por el IPC.
- Tipo de cambio peso/dólar diario.

## ■ Datos financieros y empresariales:

- Precio diario de una acción.
- Ventas mensuales de una empresa.
- Producción mensual de una industria.
- Tasa de interés a lo largo del tiempo.

## Característica importante

A diferencia de un corte transversal, el **orden temporal importa**: las observaciones de distintos períodos pueden estar relacionadas entre sí.

# Estructura de los datos

**Panel:** serie de tiempo de base(s) de datos de corte transversal.

| Año  | Obs. | Escolaridad | Salario | Mujer |
|------|------|-------------|---------|-------|
| 2001 | 1    | 9           | 0       | 1     |
| 2001 | 2    | 12          | 600     | 1     |
| 2001 | 3    | 12          | 0       | 0     |
| ⋮    | ⋮    | ⋮           | ⋮       | ⋮     |
| 2002 | 1    | 10          | 0       | 1     |
| 2002 | 2    | 12          | 620     | 1     |
| 2002 | 3    | 12          | 400     | 0     |
| ⋮    | ⋮    | ⋮           | ⋮       | ⋮     |
| 2017 | 1    | 12          | 800     | 1     |
| 2017 | 2    | 14          | 2000    | 1     |
| 2017 | 3    | 12          | 900     | 0     |

# Ejemplos de datos de panel en Chile

En Chile existen distintas encuestas que siguen a los mismos individuos u hogares a través del tiempo.

## ■ Encuesta de Protección Social (EPS):

- Sigue a individuos en distintas rondas.
- Contiene información sobre empleo, ingresos, cotizaciones, pensiones, salud y características del hogar.
- Permite estudiar trayectorias laborales y previsionales.

## ■ Encuesta Panel CASEN:

- Sigue a los mismos hogares e individuos en distintos años.
- Incluye información sobre ingresos, pobreza, empleo, educación, vivienda y composición del hogar.
- Permite estudiar movilidad de ingresos y entradas y salidas de la pobreza.

## ■ Encuesta Longitudinal de Primera Infancia (ELPI):

- Sigue a niños y sus hogares a medida que los niños crecen.
- Contiene información sobre desarrollo infantil, educación, características familiares y condiciones socioeconómicas.

### Característica importante

En datos de panel tenemos dos dimensiones: **unidad** y **tiempo**. Esto permite estudiar diferencias entre unidades y también cambios dentro de una misma unidad.

Comúnmente se asume que una población sigue una distribución de probabilidad

$$F(x; \theta),$$

donde la forma de la distribución  $F$  es conocida, pero sus características son desconocidas y están representadas por  $\theta$ , llamado(s) **parámetro(s)**.

Los **estadísticos** son cualquier función conocida de una muestra aleatoria, los que se utilizan para estadística inferencial.

# Estimadores y valor estimado

Un **estimador** es un estadístico (una variable aleatoria) que describe cómo obtener un **valor estimado** (un valor real, puntual) de un parámetro poblacional.

## Ejemplo:

La media muestral

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

es un estimador de la media poblacional  $\mu$ .

Si tomamos una muestra aleatoria desde una población y obtenemos los valores

$$4, 8, 2, 6,$$

entonces el valor estimado de  $\mu$  es

$$\bar{y} = \frac{20}{4} = 5.$$

Note la diferencia entre  $\bar{Y}$ , la variable aleatoria, y  $\bar{y}$ , el valor que toma dicha variable aleatoria.

# Estimadores puntuales e intervalos de confianza

El propósito del muestreo es usar sus datos para aproximar valores poblacionales.

Por ejemplo, podemos:

- aproximar el valor de un parámetro en la población mediante el valor de un **Estimador Puntual**, y/o
- encontrar un intervalo de valores que contenga al parámetro poblacional con un cierto nivel de confianza, es decir, un **Intervalo de Confianza (IC)**.

## Algunos estimadores puntuales:

Además de la media muestral  $\bar{X}$  como estimador puntual de la media poblacional  $\mu$ , existen otros estimadores puntuales. Por ejemplo:

- $\hat{p}$ , la proporción muestral, es un estimador puntual de  $\pi$ , la proporción poblacional;
- $s$ , la desviación estándar muestral, es un estimador puntual de  $\sigma$ , la desviación estándar poblacional.

$\bar{Y}$  es el estimador natural de la media. Pero:

- 1 ¿Cuáles son las propiedades de  $\bar{Y}$ ?
- 2 ¿Por qué debemos usar  $\bar{Y}$  en lugar de algún otro estimador?

Por ejemplo, podríamos considerar:

- $Y_1$  (la primera observación),
- tal vez pesos desiguales — no promedio simple,
- la mediana de  $(Y_1, \dots, Y_n)$ .

El punto de partida es la **distribución muestral de  $\bar{Y}$** .

# 1. La distribución muestral de $\bar{Y}$

$\bar{Y}$  es una variable aleatoria, y sus propiedades están determinadas por su distribución muestral.

- Los individuos en la muestra se eligen al azar.
- Por tanto, los valores de  $(Y_1, \dots, Y_n)$  son aleatorios.
- Por tanto, las funciones de  $(Y_1, \dots, Y_n)$  son aleatorias: si se hubiera extraído una muestra diferente, habrían tomado un valor diferente.
- La distribución de  $\bar{Y}$  en diferentes muestras posibles de tamaño  $n$  se denomina **distribución de muestreo de  $\bar{Y}$** .
- La media y la varianza de  $\bar{Y}$  son la media y la varianza de su distribución muestral,  $\mathbb{E}(\bar{Y})$  y  $\text{Var}(\bar{Y})$ .
- El concepto de la distribución muestral sustenta toda la econometría.

# Cosas que queremos saber sobre la distribución muestral

- ¿Cuál es la media de  $\bar{Y}$ ?
  - Si  $\mathbb{E}(\bar{Y}) = \mu$ , entonces es un estimador insesgado de  $\mu$ .
- ¿Cuál es la varianza de  $\bar{Y}$ ?
  - ¿Cómo depende  $\text{Var}(\bar{Y})$  de  $n$ ?
- ¿Se acerca a  $\mu$  cuando  $n$  es grande?
  - Ley de los Grandes Números:  $\bar{Y}$  es un estimador consistente de  $\mu$ .
- $\bar{Y} - \mu$  aparece con forma de campana para  $n$  grande. ¿Es esto generalmente cierto?
  - De hecho,  $\bar{Y} - \mu$  se distribuye de manera aproximadamente normal para  $n$  grande (Teorema del Límite Central).

# Media y varianza de la distribución muestral de $\bar{Y}$

$$\mathbb{E}(\bar{Y}) = \mu, \quad \text{Var}(\bar{Y}) = \frac{\sigma^2}{n}.$$

## Implicancias:

- 1  $\bar{Y}$  es un estimador insesgado de  $\mu$ , es decir,  $\mathbb{E}(\bar{Y}) = \mu$ .
  - 2  $\text{Var}(\bar{Y})$  es inversamente proporcional a  $n$ .
- La dispersión de la distribución muestral es proporcional a

$$\frac{1}{\sqrt{n}}.$$

- Por lo tanto, la incertidumbre de muestreo asociada con  $\bar{Y}$  es proporcional a  $1/\sqrt{n}$ .
- Muestras más grandes implican menos incertidumbre, pero esta decrece según la raíz cuadrada de  $n$ .

# La distribución muestral de $\bar{Y}$ cuando $n$ es grande

Para tamaños de muestra pequeños, la distribución de  $\bar{Y}$  es complicada, pero si  $n$  es grande, la distribución de muestreo es simple.

- 1 A medida que  $n$  aumenta, la distribución de  $\bar{Y}$  se centra más estrechamente alrededor de  $\mu$  (**Ley de los Grandes Números**).
- 2 Además, la distribución de  $\bar{Y} - \mu$  se vuelve normal (**Teorema del Límite Central**).

# Ley de los Grandes Números

Un estimador es **consistente** si la probabilidad de que caiga dentro de un intervalo del verdadero valor de la población tiende a uno a medida que aumenta el tamaño de la muestra.

Si  $(Y_1, \dots, Y_n)$  son i.i.d. y  $\sigma^2 < \infty$ , entonces  $\bar{Y}$  es un estimador consistente de  $\mu$ , es decir:

$$\mathbb{P}(|\bar{Y} - \mu| < \varepsilon) \rightarrow 1 \quad \text{cuando } n \rightarrow \infty.$$

Esto se puede escribir como

$$\bar{Y} \xrightarrow{p} \mu,$$

donde “ $\bar{Y} \xrightarrow{p} \mu$ ” significa “converge en probabilidad a  $\mu$ ”.

Matemáticamente, dado que

$$\text{Var}(\bar{Y}) = \frac{\sigma^2}{n} \rightarrow 0 \quad \text{cuando } n \rightarrow \infty,$$

se tiene que

$$\mathbb{P}(|\bar{Y} - \mu| < \varepsilon) \rightarrow 1.$$

# Teorema del Límite Central (CLT)

Si  $(Y_1, \dots, Y_n)$  son i.i.d. y  $0 < \sigma^2 < \infty$ , entonces cuando  $n$  es grande, la distribución de  $\bar{Y}$  está bien aproximada por una distribución normal.

- $\bar{Y}$  se distribuye aproximadamente como

$$\bar{Y} \approx N\left(\mu, \frac{\sigma^2}{n}\right).$$

- La variable estandarizada

$$\frac{\sqrt{n}(\bar{Y} - \mu)}{\sigma}$$

se distribuye aproximadamente como  $N(0, 1)$ .

- Es decir,

$$\frac{\bar{Y} - \mathbb{E}(\bar{Y})}{\sqrt{\text{Var}(\bar{Y})}} = \frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \approx N(0, 1).$$

- Cuanto más grande es  $n$ , mejor es la aproximación.