

Econometría Aplicada I

Modelo de Regresión Lineal Simple

ANGELO DÍAZ

UNIVERSIDAD DE SANTIAGO DE CHILE
DEPARTAMENTO DE ECONOMÍA
FACULTAD DE ADMINISTRACIÓN Y ECONOMÍA

Idea central de la clase

Pregunta guía: ¿cómo usamos datos para estudiar la relación entre dos variables económicas?

En econometría rara vez nos interesa solamente describir una variable de forma aislada. Usualmente queremos analizar relaciones como:

- educación y salario;
- tamaño de curso y rendimiento;
- gasto en publicidad y ventas;
- experiencia laboral y remuneraciones;
- tasa de interés e inversión.

Mensaje clave

Una regresión no es solo una recta ajustada a los datos: es una forma de resumir cómo cambia el valor esperado de una variable cuando cambia otra variable, bajo supuestos explícitos.

De la pregunta económica a la relación entre variables

La regresión lineal simple comienza con una pregunta empírica. Antes de estimar, necesitamos definir qué variable queremos explicar, qué variable usamos como explicación y qué tipo de interpretación buscamos: asociación, predicción o causalidad.

Pregunta económica y objeto de estudio

Antes de estimar una regresión necesitamos formular una pregunta económica.

Ejemplos

- ¿Cómo cambia el salario esperado con los años de educación?
- ¿Existe una relación entre gasto en publicidad y ventas?
- ¿Los cursos más pequeños tienen mejor rendimiento académico?
- ¿La experiencia laboral se asocia con salarios más altos?

Una buena pregunta empírica debe identificar:

- una unidad de análisis;
- una variable dependiente Y ;
- una variable explicativa X ;
- una relación poblacional que se desea conocer.

De la pregunta al modelo

Elemento	Ejemplo: educación y salario
Pregunta económica	¿Cómo se relaciona la educación con el salario?
Unidad de análisis	Persona trabajadora
Variable dependiente	Y : salario mensual
Variable explicativa	X : años de educación
Relación de interés	$\mathbb{E}(Y \mid X)$
Modelo inicial	$Y_i = \beta_0 + \beta_1 X_i + u_i$

Idea clave

La regresión lineal simple traduce una pregunta económica en una relación estadística estimable entre dos variables.

Asociación, predicción y causalidad

Asociación

Dos variables se mueven juntas.

Ejemplo: mayor educación suele observarse junto a mayor salario.

Predicción

Usamos X para anticipar Y .

Ejemplo: usar publicidad para predecir ventas.

Causalidad

Queremos saber si cambiar X modifica Y .

Ejemplo: estimar si reducir tamaño de curso mejora rendimiento.

Advertencia

Una regresión simple puede mostrar asociación y ser útil para predicción, pero no necesariamente identifica un efecto causal.

La primera imagen: datos en un plano

Supongamos que observamos una muestra:

$$(Y_i, X_i), \quad i = 1, \dots, n.$$

Cada punto del diagrama representa una unidad de análisis.


Ejemplo

Cada punto puede representar una persona, donde:

$$Y_i = \text{salario}_i, \quad X_i = \text{educ}_i.$$

Conexión

El diagrama de dispersión sugiere una relación, pero todavía no nos dice cómo estimarla ni cómo interpretarla.



Función de Esperanza Condicional (CEF)

El objeto **poblacional** que queremos entender

Antes de estimar una recta, debemos identificar qué relación poblacional queremos aproximar. El objeto central será la media condicional de Y dado X , también llamada CEF (Conditional Expectation Function).

La relación condicional

La pregunta econométrica no es solamente:

$$\mathbb{E}(Y),$$

sino:

$$\mathbb{E}(Y \mid X = x).$$

Interpretación

$\mathbb{E}(Y \mid X = x)$ representa el valor promedio esperado de Y entre las unidades con $X = x$.


Ejemplo

Si Y es salario y X son años de educación, entonces

$$\mathbb{E}(Y \mid X = 12)$$



es el salario promedio esperado entre personas con 12 años de educación.

- Suponga que queremos estudiar los salarios
- Generalmente podemos observar la densidad de los salarios
- Donde la media será igual a $E(\log(\text{salarios})) = 2,95$



Media condicional

- Son las distribuciones igual para hombres o mujeres?
- Son las distribuciones igual para distintos tipos de personas?



Función de Esperanza Condicional

La Función de Esperanza Condicional se define como:

$$m(x) = \mathbb{E}(Y \mid X = x).$$

- Es una función de x .
- Resume la relación promedio entre Y y X .
- Es un objeto **poblacional**, no muestral.
- Puede ser lineal o no lineal.

Idea clave

La CEF describe la parte sistemática del comportamiento promedio de Y asociada a X .

Ejemplo: CEF y salarios

Supongamos que Y es salario mensual y X años de educación.

Años de educación	Salario esperado
x	$\mathbb{E}(Y \mid X = x)$
10	700
12	850
14	1.000
16	1.160
18	1.300

Lectura

La CEF asigna a cada valor de educación un salario promedio esperado.

Cuidado

La tabla describe diferencias promedio. Todavía no afirma que la educación cause esas diferencias.

Propiedad de descomposición

Toda variable Y puede escribirse como:

$$Y = \underbrace{\mathbb{E}(Y \mid X)}_{\text{parte sistemática asociada a } X} + \underbrace{u}_{\text{parte no explicada por } X}.$$

- La CEF resume lo que podemos predecir sistemáticamente usando X .
- El término u contiene lo que no queda explicado por X .

Interpretación econométrica

El error no es necesariamente un “error de medición”: representa factores no incluidos explícitamente en la relación condicional.

Qué puede contener el error

En una ecuación simple de salarios:

$$\text{salario}_i = \beta_0 + \beta_1 \text{educ}_i + u_i,$$

el término u_i puede contener:

- habilidad no observada;
- experiencia laboral;
- calidad de la educación;
- redes laborales;
- sector económico;
- comuna o región;
- motivación, esfuerzo y preferencias;
- errores de medición.

Problema central

Si estos factores no observados están relacionados con X_i , la interpretación de β_1 puede ser problemática.

Propiedad de predicción

Queremos predecir Y usando una función de X :

$$g(X).$$

El error cuadrático medio de predicción es:

$$\mathbb{E} \left[(Y - g(X))^2 \right].$$

Resultado fundamental

La función que minimiza el error cuadrático medio es:

$$g(X) = \mathbb{E}(Y \mid X).$$

Idea clave

La CEF es el mejor predictor de Y dado X , cuando usamos pérdida cuadrática.

Explicación: Propiedad de predicción

- Supongamos que queremos predecir y , dado un valor de x
- Podemos definir cualquier predictor como una función $g(\cdot)$ que depende de x ($g(x)$).
- Entonces, el error de predicción se define como:

$$y - g(x)$$

- La magnitud del error de predicción, es la expectativa del error al cuadrado:

$$E((y - g(x))^2)$$

- Objetivo: Minimizar el error.

Explicación: Propiedad de predicción

- Recuerde: $y = E(y|x) + u$ y $E(y|x) = \mu(x)$.
- $$\begin{aligned} E((y - g(x))^2) &= E((E(y|x) + u - g(x))^2) \\ &= E((\mu(x) + u - g(x))^2) \\ &= \\ E(u^2) + 2E(u * (\mu(x) - g(x))) &+ E((\mu(x) - g(x))^2) \\ &= E(u^2) + E((\mu(x) - g(x))^2) \\ &\geq E(u^2) \end{aligned}$$
- La única forma que $E(u^2) + E((\mu(x) - g(x))^2) = E(u^2)$, es cuando $\mu(x) = g(x)$
- En este sentido, la CEF minimiza el error de predicción

De la CEF a una aproximación estimable

La CEF puede tener cualquier forma. Para construir un primer modelo econométrico, restringimos la relación a una función lineal en parámetros. Esta restricción nos lleva al mejor predictor lineal.

Por qué una aproximación lineal

La CEF poblacional puede ser compleja:

$$m(x) = \mathbb{E}(Y \mid X = x).$$

En un primer curso de econometría trabajamos con una aproximación lineal:

$$L(Y \mid X) = \beta_0 + \beta_1 X.$$

Ventajas

- Es simple de estimar.
- Tiene interpretación económica directa.
- Permite desarrollar inferencia estadística.
- Es la base para modelos más generales.

Cuidado

Lineal no significa necesariamente que la verdadera relación poblacional sea exactamente una recta.

Mejor Predictor Lineal (Best Linear Predictor - BLP)

Buscamos la mejor aproximación lineal de Y usando X :

$$L(Y \mid X) = \beta_0 + \beta_1 X.$$

Los parámetros poblacionales resuelven:

$$(\beta_0, \beta_1) = \arg \min_{b_0, b_1} \mathbb{E} \left[(Y - b_0 - b_1 X)^2 \right].$$

Idea clave

El mejor predictor lineal no es una estimación muestral. Es una relación poblacional definida en términos de momentos poblacionales.

Coeficientes del Mejor Predictor Lineal

Bajo condiciones regulares:

$$\beta_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \quad \beta_0 = \mathbb{E}(Y) - \beta_1 \mathbb{E}(X).$$

Interpretación

La pendiente poblacional depende de la covarianza entre X e Y , escalada por la varianza de X .

Conexión

MCO reemplazará estos momentos poblacionales por sus versiones muestrales.

CEF lineal y BLP

Existen dos casos importantes:

Caso 1: la CEF es lineal

Si

$$\mathbb{E}(Y | X) = \beta_0 + \beta_1 X,$$

entonces la CEF y el mejor predictor lineal coinciden.

Caso 2: la CEF no es lineal

Si la CEF no es lineal, el BLP entrega la mejor aproximación lineal en términos de error cuadrático medio.

Mensaje

La regresión lineal puede ser entendida como un modelo exacto de la media condicional o como una aproximación lineal útil.

Linealidad en parámetros

En econometría, “lineal” usualmente significa **lineal en parámetros**.

Función	¿Lineal en parámetros?
$\beta_0 + \beta_1 X$	Sí
$\beta_0 + \beta_1 X^2$	Sí
$\beta_0 + \beta_1 \log(X)$	Sí
$\beta_0 + \beta_1^2 X$	No
$\beta_0 + \exp(\beta_1 X)$	No

Idea clave

El modelo puede ser no lineal en variables, pero seguir siendo lineal en los parámetros.

Del objeto poblacional a un modelo econométrico

Ahora pasamos desde la CEF y el mejor predictor lineal al modelo poblacional de regresión simple. Este modelo separa una parte sistemática, explicada por X , y una parte no observada, contenida en el error.

Modelo poblacional

El modelo de regresión lineal simple se escribe como:

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, \dots, n.$$

- Y_i : variable dependiente.
- X_i : variable explicativa.
- β_0 : intercepto poblacional.
- β_1 : pendiente poblacional.
- u_i : error poblacional.

Idea clave

β_0 y β_1 son parámetros poblacionales desconocidos. La muestra se usa para estimarlos.

Interpretación del intercepto

En el modelo

$$Y_i = \beta_0 + \beta_1 X_i + u_i,$$

el intercepto β_0 representa el valor esperado de Y cuando $X = 0$, si el modelo lineal es válido en ese punto.

Interpretación

$$\mathbb{E}(Y \mid X = 0) = \beta_0.$$

Cuidado

El intercepto no siempre tiene una interpretación económica relevante, especialmente si $X = 0$ está fuera del rango observado o no tiene sentido económico.

Interpretación de la pendiente

La pendiente β_1 mide cómo cambia el valor esperado de Y cuando X aumenta en una unidad:

$$\Delta \mathbb{E}(Y \mid X) = \beta_1 \Delta X.$$

Si $\Delta X = 1$, entonces:

$$\Delta \mathbb{E}(Y \mid X) = \beta_1.$$

Ejemplo

Si Y es salario mensual en miles de pesos y X son años de educación, $\beta_1 = 65$ significa que un año adicional de educación se asocia con 65 mil pesos más de salario mensual esperado.

Interpretación predictiva versus causal

Interpretación predictiva

β_1 resume cómo cambia el valor esperado de Y entre unidades con distinto valor de X .

No requiere afirmar que X cause Y .

Interpretación causal

β_1 mide el efecto de cambiar X sobre Y , manteniendo todo lo demás constante.

Requiere supuestos más fuertes.

Mensaje central: precaución

La regresión simple no garantiza causalidad. Para una interpretación causal, el error debe no estar sistemáticamente relacionado con X .

Error poblacional y residuo muestral

Error poblacional

$$u_i = Y_i - \beta_0 - \beta_1 X_i.$$

- No observable.
- Depende de los parámetros verdaderos.
- Contiene factores omitidos.

Residuo muestral

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

- Observable después de estimar.
- Depende de $\hat{\beta}_0, \hat{\beta}_1$.
- Mide errores de ajuste en la muestra.

Cuidado

El residuo es una aproximación muestral construida después de estimar. No es igual al error poblacional.

¿Cómo elegir la recta que mejor ajusta los datos?

Una vez formulado el modelo poblacional, necesitamos estimar sus parámetros. El método de Mínimos Cuadrados Ordinarios (MCO) elige la recta que minimiza la suma de residuos cuadrados.

Recta estimada

La recta de regresión estimada es:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i.$$

El residuo muestral es:

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

Interpretación

$\hat{Y}_i$ es el valor ajustado o predicho de Y_i usando la recta estimada.

Idea clave

La estimación reemplaza la relación poblacional desconocida por una relación muestral observable.

Criterio de Mínimos Cuadrados Ordinarios

MCO elige $\hat{\beta}_0$ y $\hat{\beta}_1$ para resolver:

$$\min_{b_0, b_1} \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

Equivalentemente:

$$\min_{b_0, b_1} \sum_{i=1}^n \hat{u}_i^2.$$

Idea clave

MCO elige la recta que minimiza la suma de errores de predicción al cuadrado dentro de la muestra.

MCO: intuición geométrica

Supongamos que observamos una nube de puntos:

$$(Y_i, X_i), \quad i = 1, \dots, n.$$

Queremos elegir una recta:

$$\hat{Y}_i = b_0 + b_1 X_i,$$

que represente lo mejor posible la relación entre X e Y .

Pregunta

Entre todas las rectas posibles, ¿cuál debemos escoger?

Respuesta de MCO

Escogemos la recta que deja los residuos más pequeños en conjunto, penalizando más los errores grandes.

Distancia vertical entre dato y recta

Para cada observación i , la diferencia entre el valor observado y el valor ajustado es:

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

Como

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$

entonces:

$$\hat{u}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i.$$

Interpretación

El residuo $\hat{u}_i$ es una distancia vertical entre el punto observado y la recta estimada. Nosotros estamos interesados en la distancia geométrica $|\hat{u}_i|$.

Idea gráfica


MCO busca una recta que haga pequeñas, en conjunto, esas distancias verticales.

Representación gráfica de los residuos

Cada punto observado tiene asociado un residuo:

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

- Si $Y_i > \hat{Y}_i$, el residuo es positivo.
- Si $Y_i < \hat{Y}_i$, el residuo es negativo.
- Si $Y_i = \hat{Y}_i$, el residuo es cero.



Lectura

Los residuos miden errores de ajuste **dentro de la muestra.**

Por qué no minimizar la suma simple de residuos

Una opción inicial podría ser minimizar:

$$\sum_{i=1}^n \hat{u}_i.$$

Pero esta medida tiene un problema: residuos positivos y negativos pueden cancelarse.

Ejemplo

Si una recta genera residuos

$$10, -10, 8, -8,$$

la suma simple es cero, aunque la recta comete errores grandes.

Conclusión

No basta sumar residuos. Necesitamos una función que mida el tamaño del error sin cancelaciones.

Por qué minimizar residuos cuadrados

MCO minimiza:

$$\sum_{i=1}^n \hat{u}_i^2.$$

Razones

- Evita cancelaciones entre residuos positivos y negativos.
- Penaliza con mayor fuerza los errores grandes.
- Entrega una solución matemática simple.
- Se conecta con la idea de mejor predictor bajo error cuadrático medio.

Idea clave

MCO no busca que todos los residuos sean cero; busca que la suma de sus cuadrados sea lo más pequeña posible.

Rectas candidatas y función objetivo

Cada par de valores (b_0, b_1) define una recta distinta:

$$\hat{Y}_i = b_0 + b_1 X_i.$$

Cada recta genera una suma de residuos cuadrados:

$$SRC(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

Problema de elección

MCO compara todas las rectas posibles y selecciona aquella con menor SRC .

Notación

A veces esta suma se denota como SSR, RSS, SSE o SCR, dependiendo del texto.

MCO como problema de optimización

Definimos la función objetivo:

$$S(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

El estimador MCO es el par:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} S(b_0, b_1).$$

Interpretación

$\hat{\beta}_0$ y $\hat{\beta}_1$ son los valores que hacen mínima la suma de residuos cuadrados.

Conexión

Estimamos una relación poblacional desconocida usando un criterio de ajuste muestral.

Condiciones de primer orden

Para encontrar el mínimo, derivamos $S(b_0, b_1)$ respecto de b_0 y b_1 .

$$S(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

Las condiciones de primer orden son:

$$\frac{\partial S(b_0, b_1)}{\partial b_0} = 0, \quad \frac{\partial S(b_0, b_1)}{\partial b_1} = 0.$$

Objetivo

Resolver estas dos ecuaciones nos permitirá obtener las fórmulas de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Primera condición: derivada respecto de b_0

Partimos de:

$$S(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

Derivando respecto de b_0 :

$$\frac{\partial S}{\partial b_0} = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 X_i).$$

En el óptimo:

$$-2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Por lo tanto:

$$\sum_{i=1}^n \hat{u}_i = 0.$$

Implicancia de la primera condición

La primera condición implica:

$$\sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Expandiendo:

$$\sum_{i=1}^n Y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n X_i = 0.$$

Dividiendo por n :

$$\bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{X} = 0.$$

Entonces:

$$\boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}}$$

Interpretación de la primera condición

La condición

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

implica que la recta MCO pasa por el punto de medias:

$$(\bar{X}, \bar{Y}).$$

Lectura geométrica

La recta estimada siempre cruza el centro muestral de los datos.

Propiedad muestral

La media de los valores ajustados coincide con la media de la variable dependiente:

$$\overline{\hat{Y}} = \bar{Y}.$$

Segunda condición: derivada respecto de b_1

Derivando respecto de b_1 :

$$\frac{\partial S}{\partial b_1} = -2 \sum_{i=1}^n X_i (Y_i - b_0 - b_1 X_i).$$

En el óptimo:

$$-2 \sum_{i=1}^n X_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Por lo tanto:

$$\sum_{i=1}^n X_i \hat{u}_i = 0.$$

Interpretación

Los residuos MCO no están correlacionados muestralmente con X .

Sustitución del intercepto

Sabemos que:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Sustituimos en la segunda condición:

$$\sum_{i=1}^n X_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Entonces:

$$\sum_{i=1}^n X_i [Y_i - \bar{Y} + \hat{\beta}_1 \bar{X} - \hat{\beta}_1 X_i] = 0.$$

Reordenando:

$$\sum_{i=1}^n X_i [(Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X})] = 0.$$

Derivación de la pendiente MCO

Desde:

$$\sum_{i=1}^n X_i \left[(Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X}) \right] = 0,$$

se obtiene equivalentemente:

$$\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) - \hat{\beta}_1 \sum_{i=1}^n (X_i - \bar{X})^2 = 0.$$

Luego:

$$\hat{\beta}_1 \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}).$$

Estimador MCO de la pendiente

Por lo tanto, la pendiente estimada es:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Interpretación

El numerador mide la covariación muestral entre X e Y . El denominador mide la variación muestral de X .

Idea clave

La pendiente es grande cuando X e Y se mueven juntos intensamente, en relación con la variación de X .

Estimador MCO del intercepto

Una vez obtenida $\hat{\beta}_1$, el intercepto se calcula como:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Interpretación

El intercepto ajusta la altura de la recta para que pase por el punto $(\bar{X}, \bar{Y})$.

Lectura

La pendiente define la inclinación de la recta; el intercepto define su nivel.

Ejemplo: cálculo de la pendiente

Salario	Años educ.	$x_i - \bar{x}$	$y_i - \bar{y}$	Producto	$(x_i - \bar{x})^2$
3,10	11	-1,9	-4,8	9,3	3,7
3,24	12	-0,9	-4,6	4,3	0,9
3,00	11	-1,9	-4,9	9,4	3,7
6,00	8	-4,9	-1,9	9,3	24,3
5,30	12	-0,9	-2,6	2,4	0,9
8,75	16	3,1	0,9	2,7	9,4
11,25	18	5,1	3,4	17,1	25,7
5,00	12	-0,9	-2,9	2,7	0,9
3,60	12	-0,9	-4,3	4,0	0,9
18,18	17	4,1	10,3	41,9	16,5
6,25	16	3,1	-1,6	-5,0	9,4
8,13	13	0,1	0,2	0,0	0,0
8,77	12	-0,9	0,9	-0,8	0,9
5,50	12	-0,9	-2,4	2,2	0,9
22,20	12	-0,9	14,3	-13,4	0,9
				86,0	98,9

$$\bar{y} = 7,8847, \quad \bar{x} = 12,9333, \quad \hat{\beta}_1 = \frac{86,0}{98,9}.$$

Ejemplo: modelo estimado

A partir de los cálculos anteriores:

$$\hat{\beta}_1 = \frac{86,044}{98,9333} \approx 0,8697.$$

$$\hat{\beta}_0 = 7,88 - 0,8697(12,9333) \approx -3,36.$$

Por tanto, el modelo estimado es:

$$\boxed{\hat{Y}_i = -3,36 + 0,87X_i}.$$

Resumen de la derivación

El problema MCO es:

$$\min_{b_0, b_1} \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2.$$

Las condiciones de primer orden entregan:

$$\sum_{i=1}^n \hat{u}_i = 0, \quad \sum_{i=1}^n X_i \hat{u}_i = 0.$$

De estas condiciones se obtiene:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Condición para poder estimar la pendiente

El denominador de $\hat{\beta}_1$ es:

$$\sum_{i=1}^n (X_i - \bar{X})^2.$$

Para poder estimar la pendiente necesitamos:

$$\sum_{i=1}^n (X_i - \bar{X})^2 > 0.$$

Interpretación

Debe existir variación muestral en X . Si todos los individuos tienen el mismo valor de X , no hay información para estimar cómo cambia Y cuando cambia X .

Lectura económica de la fórmula

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

Qué captura

- Si $X_i > \bar{X}$ y $Y_i > \bar{Y}$, la pendiente será positiva.
- Si $X_i > \bar{X}$ y $Y_i < \bar{Y}$, la pendiente será negativa.
- Si no hay patrón sistemático entre X e Y , la pendiente estará cerca de cero.

Conclusión

La pendiente MCO resume la dirección e intensidad de la relación lineal muestral entre X e Y .

MCO: solución muestral, interpretación poblacional

MCO entrega una recta estimada:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i.$$

Pero el objetivo econométrico es aprender sobre la relación poblacional:

$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

Mensaje clave

La derivación de MCO nos dice cómo calcular $\hat{\beta}_0$ y $\hat{\beta}_1$. Los supuestos econométricos nos dirán cuándo esos estimadores son buenos para aprender sobre β_0 y β_1 .

Propiedades algebraicas de MCO

En la muestra, los residuos MCO cumplen:

$$\sum_{i=1}^n \hat{u}_i = 0, \quad \sum_{i=1}^n X_i \hat{u}_i = 0, \quad \bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}.$$

Interpretación

La recta estimada pasa por el punto $(\bar{X}, \bar{Y})$, y los residuos no tienen correlación muestral con el regresor.

Cuidado [importante]

Estas son propiedades algebraicas de la estimación, no garantizan por sí solas causalidad ni ausencia de sesgo poblacional.

¿Qué tan bien resume la recta la variación observada?

Una vez estimada la regresión, debemos evaluar qué parte de la variación de Y queda resumida por la recta, qué parte queda en los residuos y cómo interpretar correctamente las medidas de ajuste.

Valores observados, ajustados y residuos

Para cada observación:

$$Y_i = \hat{Y}_i + \hat{u}_i.$$

- Y_i : valor observado.
- $\hat{Y}_i$: valor ajustado por la regresión.
- $\hat{u}_i$: residuo.

Lectura

Un residuo positivo indica que el valor observado de Y_i está por sobre el valor predicho por la recta.

Descomposición de la variación

La variación total de Y alrededor de su media puede descomponerse en (restemos $\bar{Y}$):

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n \hat{u}_i^2.$$

Nombre	Expresión	Interpretación
SCT	$\sum (Y_i - \bar{Y})^2$	Variación total
SCE	$\sum (\hat{Y}_i - \bar{Y})^2$	Variación explicada
SCR	$\sum \hat{u}_i^2$	Variación residual

Idea clave

La regresión divide la variación observada de Y en una parte explicada por la recta y una parte no explicada.

Coeficiente de determinación R^2

El R^2 se define como:

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

Interpretación

R^2 mide la proporción de la variación muestral de Y explicada linealmente por X .

Ejemplo

Si $R^2 = 0,42$, entonces el 42 % de la variación muestral de Y es explicada por la regresión lineal con X .

Qué no dice el R^2

Advertencias

- Un R^2 alto no prueba causalidad.
- Un R^2 bajo no invalida necesariamente una pregunta causal.
- El R^2 no indica si el modelo está correctamente especificado.
- El R^2 no mide la importancia económica del coeficiente.
- Debemos ser cautelosos ya que R^2 generalmente aumenta con el número de variables.

Lectura econométrica

El R^2 es una medida de ajuste muestral, no una medida de validez causal.

Error estándar de la regresión

El error estándar de la regresión mide la dispersión típica de los residuos:

$$SER = \sqrt{\frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2}.$$

Interpretación

El SER mide el tamaño típico del error de predicción dentro de la muestra, en las mismas unidades de Y .

Comparación

Mientras R^2 es una proporción, el SER está medido en unidades de la variable dependiente.

¿Cuándo podemos confiar en la estimación?

MCO siempre produce una recta. Pero para interpretar esa recta como una buena aproximación poblacional necesitamos supuestos. El más importante será la **media condicional cero**.

Supuestos de mínimos cuadrados

Para regresión simple, seguiremos tres supuestos básicos:

1 **Media condicional cero:**

$$\mathbb{E}(u_i \mid X_i) = 0.$$

2 **Muestreo i.i.d.:**

$$(Y_i, X_i), \quad i = 1, \dots, n,$$

son independientes e idénticamente distribuidos.

3 **Ausencia de outliers extremos:** los valores extremos de X e Y son poco probables.

Idea clave

Los supuestos conectan la recta estimada en la muestra con la relación poblacional que queremos conocer.

Media condicional cero

El supuesto central es:

$$\mathbb{E}(u_i \mid X_i) = 0.$$

Interpretación

Para cada valor de X , los factores no observados contenidos en u tienen promedio cero. Esto implica que el error no tiene un componente sistemático asociado a X .

Lectura

Si X está relacionado con factores omitidos que afectan Y , este supuesto falla.

Media condicional cero y causalidad

Para una interpretación causal de β_1 , necesitamos que:

$$\mathbb{E}(u_i \mid X_i) = 0.$$

En palabras

Los factores no observados que afectan Y no deben estar sistemáticamente relacionados con X .

Ejemplo

En una ecuación de salarios, si la habilidad afecta salario y además está correlacionada con educación, entonces educación estará correlacionada con el error.

Conclusión

En ese caso, la pendiente estimada no puede interpretarse directamente como el efecto causal de la educación.

Variable omitida y sesgo

Supongamos que el verdadero modelo es:

$$Y_i = \beta_0 + \beta_1 X_i + \gamma Z_i + v_i,$$

pero estimamos:

$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

Entonces:

$$u_i = \gamma Z_i + v_i.$$

Sesgo por variable omitida

Si Z_i afecta Y_i y está correlacionada con X_i , entonces:

$$\text{Cov}(X_i, u_i) \neq 0.$$

Lectura

La regresión simple puede confundir el efecto de X con el efecto de otros factores omitidos.

Muestreo i.i.d.

El supuesto de muestreo i.i.d. establece que:

$$(Y_1, X_1), \dots, (Y_n, X_n)$$

proviene de la misma población y son independientes entre unidades.

Interpretación

Cada observación entrega información nueva sobre la población.

Ejemplo

Si cada observación es una persona seleccionada aleatoriamente desde una población de trabajadores, el supuesto puede ser razonable.

Outliers extremos


MCO puede ser sensible a observaciones extremas.

Problema

Un punto con un valor extremo de X puede tener alta influencia sobre la pendiente estimada.

Puede:

- cambiar la recta estimada;
- alterar el R^2 ;
- afectar inferencia.



Ejemplo (Wooldridge)

Supongamos que queremos predecir el salario de un CEO usando el desempeño de la empresa.

- s : sueldo anual del CEO, en miles de dólares.
- r : rendimiento promedio de las acciones en los últimos tres años, medido en porcentaje.

Modelo:

$$s = \beta_0 + \beta_1 r + u.$$

β_1 mide el cambio promedio en el sueldo cuando el retorno aumenta en un punto porcentual, manteniendo lo demás constante.

Ejemplo (Cont.)

Con una muestra de 209 CEOs se obtiene

$$\hat{s} = 963 + 18,5r, \quad R^2 = 0,0132.$$

- Si $r = 0$, el sueldo predicho es 963 mil dólares anuales.
- Un aumento de un punto porcentual en el rendimiento se asocia con un aumento de 18,5 mil dólares en el sueldo predicho.

Ejemplo (Cont.)

Si $r = 30$,

$$\hat{s} = 963 + 18,5(30) = 1518.$$

- La predicción es aproximadamente 1,5 millones de dólares anuales.
- El $R^2 = 0,0132$ indica que 1,32 % de la variación muestral del sueldo es explicada por el rendimiento.
- Un R^2 bajo no implica, por sí solo, que el estimador de β_1 tenga malas propiedades estadísticas.

Modelo original: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.

- Si $y^* = cy$, entonces $\hat{\beta}_0^* = c\hat{\beta}_0$ y $\hat{\beta}_1^* = c\hat{\beta}_1$.
- Si $x^* = cx$, entonces $\hat{\beta}_0^* = \hat{\beta}_0$ y $\hat{\beta}_1^* = \hat{\beta}_1/c$.

Si cambiamos simultáneamente las unidades, $y^* = c_1 y$ y $x^* = c_2 x$, entonces

$$\hat{y}^* = c_1 \hat{\beta}_0 + \frac{c_1}{c_2} \hat{\beta}_1 x^*.$$

Por tanto,

$$\hat{\beta}_0^* = c_1 \hat{\beta}_0, \quad \hat{\beta}_1^* = \frac{c_1}{c_2} \hat{\beta}_1.$$

El R^2 no depende de las unidades de medida.

Unidades de medida: ejemplo

Si

$$\widehat{wage} = -0,9 + 0,54 educ,$$

y $wage$ está medido en dólares por hora, al medirlo en centavos ($wage_c = 100wage$) obtenemos

$$\boxed{\widehat{wage_c} = -90 + 54 educ}.$$

Unidades de medida: ejemplo

Partimos de

$$\hat{s} = 963,19 + 18,5r, \quad R^2 = 0,0132,$$

donde r está medido en porcentaje. Si $r_1 = r/100$, entonces

$$\hat{s} = 963,19 + 1850r_1.$$

La interpretación económica no cambia: un aumento de un punto porcentual equivale a $\Delta r_1 = 0,01$.

Unidades de medida: ejemplo

Si además medimos el salario en cientos de dólares, $s_{100} = 10s$, entonces

$$\widehat{s_{100}} = 9631,9 + 18500r_1, \quad R^2 = 0,0132.$$

Incorporación de no linealidades

Es fácil incorporar no linealidades mediante transformaciones de las variables. Por ejemplo,

$$\log(wage) = \beta_0 + \beta_1 educ + u.$$

Si $\Delta u = 0$,

$$\% \Delta wage \approx 100 \beta_1 \Delta educ.$$

Ejemplo:

$$\widehat{\log(wage)} = 0,584 + 0,083 educ.$$

Un año adicional de educación se asocia aproximadamente con un aumento de 8,3 % en el salario.

Modelo de elasticidad constante

Un modelo log-log para salario de CEOs y ventas es

$$\log(salary) = \beta_0 + \beta_1 \log(sales) + u.$$

Estimando por MCO:

$$\widehat{\log(salary)} = 4,822 + 0,257 \log(sales).$$

El coeficiente 0,257 es la elasticidad estimada: un aumento de 1 % en ventas se asocia aproximadamente con un aumento de 0,257 % en el salario del CEO.

Tabla resumen: modelos con log

Modelo	Variable dependiente	Variable independiente	Interpretación de β_1
Nivel-nivel	y	x	$\Delta y = \beta_1 \Delta x$
Nivel-log	y	$\log(x)$	$\Delta y \approx (\beta_1/100) \times$ cambio porcentual en x
Log-nivel	$\log(y)$	x	cambio porcentual en $y \approx 100\beta_1 \Delta x$
Log-log	$\log(y)$	$\log(x)$	cambio porcentual en $y \approx \beta_1 \times$ cambio porcentual en x

Propiedades estadísticas de los estimadores MCO

- La media muestral es un estadístico y, por tanto, una variable aleatoria.
- En una muestra aleatoria satisface propiedades exactas y asintóticas que también serán centrales para estudiar los estimadores MCO.

La media muestral

Propiedades exactas:

$$\mathbb{E}(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{1}{n} \text{Var}(X).$$

Propiedades asintóticas:

$$\bar{X} \xrightarrow{p} \mathbb{E}(X),$$

y por el Teorema Central del Límite,

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sqrt{\text{Var}(X)}} \xrightarrow{d} N(0, 1).$$

Supuestos del modelo de regresión lineal simple

- 1 **RLS.1 Linealidad en parámetros:** $y = \beta_0 + \beta_1 x + u$.
- 2 **RLS.2 Muestreo aleatorio:** $\{(x_i, y_i) : i = 1, \dots, n\}$ es una muestra aleatoria.
- 3 **RLS.3 Variación muestral de x :** x no es constante en la muestra.
- 4 **RLS.4 Media condicional cero:** $\mathbb{E}(u \mid x) = 0$.

Bajo RLS.2 y RLS.4, $\mathbb{E}(u_i \mid x_i) = 0$ y, bajo muestreo aleatorio, la condición puede expresarse respecto del conjunto de regresores observados.

Propiedades de $\hat{\beta}_1$ bajo RLS.1–RLS.4

- $\mathbb{E}(\hat{\beta}_1) = \beta_1$ (insesgadez).
- La varianza de $\hat{\beta}_1$ disminuye con el tamaño muestral, bajo condiciones regulares.
- En muestras grandes, $\hat{\beta}_0$ y $\hat{\beta}_1$ tienen distribuciones aproximadamente normales.
- Los estimadores MCO son consistentes.

Recuerde: Ley de Esperanzas Iteradas

Un caso utilizado continuamente en econometría es

$$\mathbb{E}(Y) = \mathbb{E}_X[\mathbb{E}(Y \mid X)].$$

Es decir, la esperanza de la esperanza condicional es la esperanza incondicional.

Ejemplo: sea G el género. Entonces,

$$\begin{aligned}\mathbb{E}[\log(\textit{salarío})] &= \mathbb{E}[\log(\textit{salarío}) \mid G = \textit{hombre}] \mathbb{P}(G = \textit{hombre}) \\ &\quad + \mathbb{E}[\log(\textit{salarío}) \mid G = \textit{mujer}] \mathbb{P}(G = \textit{mujer}).\end{aligned}$$

Conditioning Theorem

Al condicionar en X , cualquier función de X puede tratarse como constante:

$$\mathbb{E}(X \mid X) = X, \quad \mathbb{E}(g(X) \mid X) = g(X).$$

Si la esperanza existe,

$$\mathbb{E}(g(X)Y \mid X) = g(X)\mathbb{E}(Y \mid X),$$

y por esperanzas iteradas,

$$\mathbb{E}[g(X)Y] = \mathbb{E}[g(X)\mathbb{E}(Y \mid X)].$$

La pendiente puede escribirse como

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x})u_i}{STC_x} = \beta_1 + \frac{1}{STC_x} \sum_{i=1}^n d_i u_i,$$

donde

$$d_i = x_i - \bar{x}, \quad STC_x = \sum_{i=1}^n (x_i - \bar{x})^2.$$

Además,

$$\hat{\beta}_0 = \beta_0 + (\beta_1 - \hat{\beta}_1)\bar{x} + \bar{u}.$$

Condicionando en los valores observados de x :

$$\begin{aligned}\mathbb{E}(\hat{\beta}_1 \mid X) &= \beta_1 + \frac{1}{STC_x} \sum_{i=1}^n d_i \mathbb{E}(u_i \mid X) \\ &= \beta_1.\end{aligned}$$

La última igualdad utiliza el supuesto de media condicional cero ($\mathbb{E}(u \mid x) = 0$).

Insesgadez de los estimadores MCO

- La insesgadez es una propiedad de la distribución muestral, no de una estimación particular.
- En una muestra concreta, $\hat{\beta}_1$ puede estar lejos de β_1 .
- Para evaluar precisión necesitamos estudiar la dispersión de la distribución del estimador.
- La medida principal será la varianza, o su raíz cuadrada: la desviación estándar.

De la estimación puntual a la incertidumbre

Los coeficientes estimados son variables aleatorias porque dependen de la muestra. Por eso no basta con reportar $\hat{\beta}_1$: necesitamos su error estándar, una prueba de hipótesis y un intervalo de confianza.

Los estimadores son variables aleatorias

El estimador de la pendiente es:

$$\hat{\beta}_1.$$

Pero $\hat{\beta}_1$ depende de la muestra:

$$(Y_1, X_1), \dots, (Y_n, X_n).$$

Si tomáramos otra muestra, obtendríamos otro valor de $\hat{\beta}_1$.

Idea clave

Así como $\bar{Y}$ tiene distribución muestral, $\hat{\beta}_1$ **también tiene distribución muestral.**

Error estándar de $\hat{\beta}_1$

El error estándar mide la incertidumbre muestral de la pendiente estimada:

$$SE(\hat{\beta}_1).$$

Interpretación

Un error estándar pequeño indica que $\hat{\beta}_1$ sería relativamente estable entre muestras repetidas.

Conexión

La estimación puntual responde: ¿cuál es el efecto estimado? El error estándar responde: **¿qué tan precisa es esa estimación?**

Prueba t para la pendiente

Queremos evaluar:

$$H_0 : \beta_1 = 0$$

frente a:

$$H_1 : \beta_1 \neq 0.$$

El estadístico t es:

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)}.$$

Lectura

El estadístico t mide cuántos errores estándar separan a $\hat{\beta}_1$ del valor planteado bajo la hipótesis nula.

El p -value mide la probabilidad de observar evidencia tan extrema como la obtenida, suponiendo que H_0 es verdadera.

Regla usual

Si

$$p\text{-value} < 0,05,$$

rechazamos H_0 al 5 %.

Cuidado

Un p -value pequeño no prueba causalidad. Solo entrega evidencia estadística contra una hipótesis sobre un parámetro.

Intervalo de confianza para β_1

Un intervalo de confianza aproximado al 95 % es:

$$\hat{\beta}_1 \pm 1,96 \cdot SE(\hat{\beta}_1).$$

Interpretación

Entrega un rango de valores plausibles para la pendiente poblacional β_1 .

Ejemplo

Si

$$\hat{\beta}_1 = 65, \quad SE(\hat{\beta}_1) = 10,$$

entonces:

$$IC_{95\%} = [45,4, 84,6].$$

Significancia estadística y económica

Significancia estadística

Pregunta si el coeficiente estimado es distinguible de cero considerando su incertidumbre.

$$p\text{-value} < 0,05$$

Significancia económica

Pregunta si la magnitud del coeficiente es relevante para el fenómeno, política o decisión.

Idea clave

Un coeficiente puede ser estadísticamente significativo y económicamente pequeño. También puede ser económicamente relevante, pero imprecisamente estimado.

Interpretar antes que calcular

La regresión se aprende interpretando. La siguiente actividad busca que los estudiantes distingan coeficiente, ajuste, inferencia y causalidad.

Actividad en clases

Trabajen en parejas durante 10 minutos.

Un investigador estima:

$$\widehat{\text{salario}}_i = 280 + 62 \text{educ}_i, \quad R^2 = 0,42.$$

Además:

$$SE(\hat{\beta}_1) = 8.$$

Respondan:

- 1 Interprete $\hat{\beta}_1 = 62$.
- 2 Calcule el estadístico t para $H_0 : \beta_1 = 0$.
- 3 ¿La pendiente parece estadísticamente significativa al 5 %?
- 4 Interprete $R^2 = 0,42$.
- 5 ¿Puede concluir que aumentar educación causa mayores salarios?

Hoy aprendimos que:

- 1 La regresión simple nace de una pregunta económica sobre dos variables.
- 2 La CEF, $\mathbb{E}(Y \mid X)$, es el objeto poblacional central.
- 3 El modelo lineal simple aproxima esa relación mediante:

$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

- 4 MCO estima la recta que minimiza la suma de residuos cuadrados.
- 5 R^2 mide ajuste, no causalidad.
- 6 La media condicional cero es el supuesto clave.
- 7 La inferencia sobre β_1 usa error estándar, prueba t , p -value e intervalo de confianza.

Bibliografía principal

- Stock, J. H. y Watson, M. W. (2012). *Introducción a la econometría*. 3ª edición. Madrid: Pearson Educación.
- Wooldridge, J. M. (2010). *Introducción a la econometría: un enfoque moderno*. 4ª edición. México: Cengage Learning.

Lectura sugerida para este tema

- Stock y Watson: Capítulo 4, regresión lineal con regresor único.
- Stock y Watson: Capítulo 5, contrastes de hipótesis e intervalos de confianza con regresor único.
- Wooldridge: Capítulo 2, modelo de regresión simple.

Estas notas son una adaptación de las slides del profesor Cliff Bahamondes Poblete.