Econometría Aplicada I

Modelo de Regresión Lineal Simple

Angelo Díaz

Universidad de Santiago de Chile
Departamento de Economía
Facultad de Administración y Economía

Idea central de la clase

Pregunta guía: ¿cómo usamos datos para estudiar la relación entre dos variables económicas?

En econometría rara vez nos interesa solamente describir una variable de forma aislada. Usualmente queremos analizar relaciones como:

- educación y salario;
- tamaño de curso y rendimiento;
- gasto en publicidad y ventas;
- experiencia laboral y remuneraciones;
- tasa de interés e inversión.

Mensaje clave

Una regresión no es solo una recta ajustada a los datos: es una forma de resumir cómo cambia el valor esperado de una variable cuando cambia otra variable, bajo supuestos explícitos.

Motivación

De la pregunta económica a la relación entre variables

La regresión lineal simple comienza con una pregunta empírica. Antes de estimar, necesitamos definir qué variable queremos explicar, qué variable usamos como explicación y qué tipo de interpretación buscamos: asociación, predicción o causalidad.

Pregunta económica y objeto de estudio

Antes de estimar una regresión necesitamos formular una pregunta económica.

Ejemplos

- ¿Cómo cambia el salario esperado con los años de educación?
- ¿Existe una relación entre gasto en publicidad y ventas?
- ¿Los cursos más pequeños tienen mejor rendimiento académico?
- ¿La experiencia laboral se asocia con salarios más altos?

Una buena pregunta empírica debe identificar:

- una unidad de análisis;
- una variable dependiente Y;
- una variable explicativa X;
- una relación poblacional que se desea conocer.

De la pregunta al modelo

Elemento	**Ejemplo: educación y salario**
Pregunta económica	¿Cómo se relaciona la educación con el salario?
Unidad de análisis	Persona trabajadora
Variable dependiente	Y: salario mensual
Variable explicativa	X: años de educación
Relación de interés	$\mathbb{E}(Y \mid X)$
Modelo inicial	$Y_i = \beta_0 + \beta_1 X_i + u_i$

Idea clave

La regresión lineal simple traduce una pregunta económica en una relación estadística estimable entre dos variables.

Asociación, predicción y causalidad

Asociación

Dos variables se mueven juntas.

Ejemplo: mayor educación suele observarse junto a mayor salario.

Predicción

Usamos X para anticipar Y.

Ejemplo: usar publicidad para predecir ventas.

Causalidad

Queremos saber si cambiar X modifica Y.

Ejemplo: estimar si reducir tamaño de curso mejora rendimiento.

Advertencia

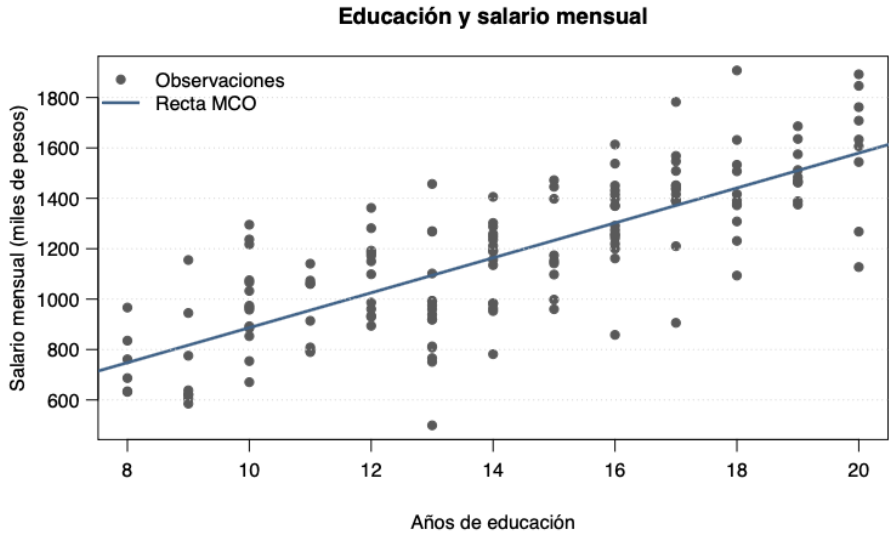
Una regresión simple puede mostrar asociación y ser útil para predicción, pero no necesariamente identifica un efecto causal.

La primera imagen: datos en un plano

Supongamos que observamos una muestra:

$$(Y_i, X_i), \qquad i = 1, \ldots, n.$$

Cada punto del diagrama representa una unidad de análisis.



Ejemplo

Cada punto puede representar una persona, donde:

$$Y_i = \text{salario}_i, \qquad X_i = \text{educ}_i.$$

Conexión

El diagrama de dispersión sugiere una relación, pero todavía no nos dice cómo estimarla ni cómo interpretarla.

Función de Esperanza Condicional (CEF)

El objeto **poblacional** que queremos entender

Antes de estimar una recta, debemos identificar qué relación poblacional queremos aproximar. El objeto central será la media condicional de Y dado X, también llamada CEF (Conditional Expectation Function).

La relación condicional

La pregunta econométrica no es solamente:

$$\mathbb{E}(Y),$$

sino:

$$\mathbb{E}(Y \mid X = x).$$

Interpretación

$\mathbb{E}(Y \mid X = x)$ representa el valor promedio esperado de Y entre las unidades con $X = x$.

Ejemplo

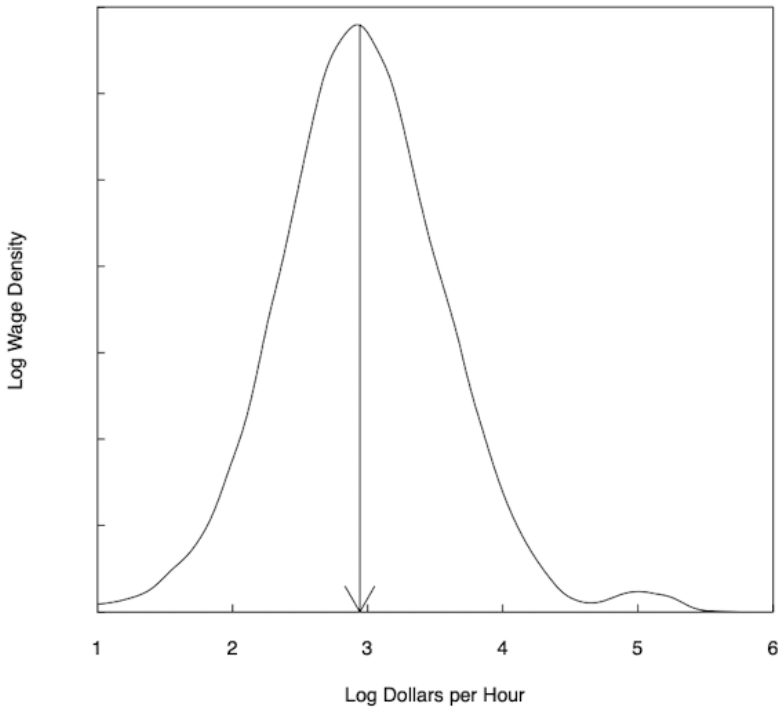
Si Y es salario y X son años de educación, entonces

$$\mathbb{E}(Y \mid X = 12)$$

es el salario promedio esperado entre personas con 12 años de educación.

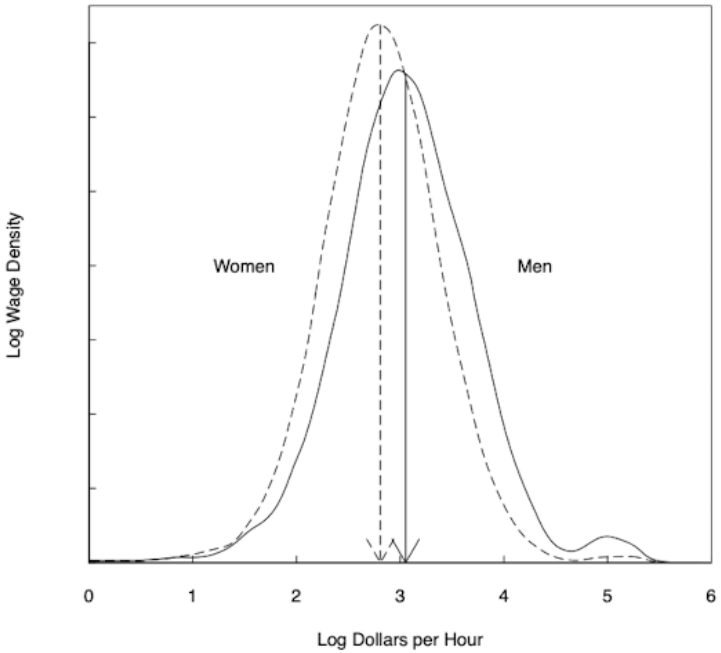
Media

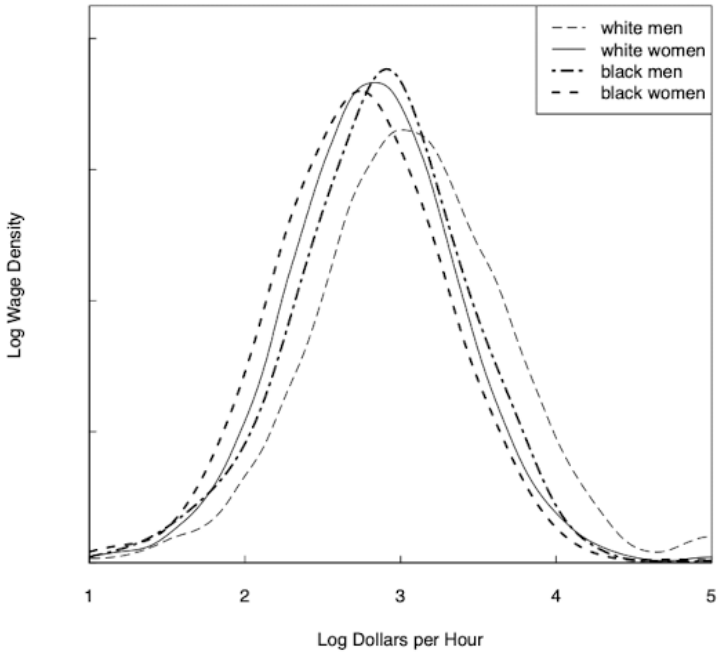
- Suponga que queremos estudiar los salarios
- Generalmente podemos observar la densidad de los salarios
- Donde la media será igual a $E(log(salarios)) = 2{,}95$



Media condicional

- Son las distribuciones igual para hombres o mujeres?
- Son las distribuciones igual para distintos tipos de personas?





Función de Esperanza Condicional

La Función de Esperanza Condicional se define como:

$$m(x) = \mathbb{E}(Y \mid X = x).$$

- Es una función de x.
- Resume la relación promedio entre Y y X.
- Es un objeto **poblacional**, no muestral.
- Puede ser lineal o no lineal.

Idea clave

La CEF describe la parte sistemática del comportamiento promedio de Y asociada a X.

Ejemplo: CEF y salarios

Supongamos que Y es salario mensual y X años de educación.

Años de educación x	**Salario esperado** $\mathbb{E}(Y \mid X = x)$
10	700
12	850
14	1.000
16	1.160
18	1.300

Lectura

La CEF asigna a cada valor de educación un salario promedio esperado.

Cuidado

La tabla describe diferencias promedio. Todavía no afirma que la educación cause esas diferencias.

Propiedad de descomposición

Toda variable Y puede escribirse como:

$$Y = \underbrace{\mathbb{E}(Y \mid X)}_{\text{parte sistemática asociada a } X} + \underbrace{u}_{\text{parte no explicada por } X}.$$

- La CEF resume lo que podemos predecir sistemáticamente usando X.
- El término u contiene lo que no queda explicado por X.

Interpretación econométrica

El error no es necesariamente un "error de medición": representa factores no incluidos explícitamente en la relación condicional.

Qué puede contener el error

En una ecuación simple de salarios:

$$\text{salario}_i = \beta_0 + \beta_1 \text{educ}_i + u_i,$$

el término u_i puede contener:

- habilidad no observada;
- experiencia laboral;
- calidad de la educación;
- redes laborales;
- sector económico;
- comuna o región;
- motivación, esfuerzo y preferencias;
- errores de medición.

Problema central

Si estos factores no observados están relacionados con X_i, la interpretación de β_1 puede ser problemática.

Propiedad de predicción

Queremos predecir Y usando una función de X:

$$g(X).$$

El error cuadrático medio de predicción es:

$$\mathbb{E}\left[(Y - g(X))^2\right].$$

Resultado fundamental

La función que minimiza el error cuadrático medio es:

$$g(X) = \mathbb{E}(Y \mid X).$$

Idea clave

La CEF es el mejor predictor de Y dado X, cuando usamos pérdida cuadrática.

Explicación: Propiedad de predicción

- Supongamos que queremos predecir y, dado un valor de x
- Podemos definir cualquier predictor como una función $g(.)$ que depende de x ($g(x)$).
- Entonces, el error de predicción se define como:

$$y - g(x)$$

- La magnitud del error de predicción, es la expectativa del error al cuadrado:

$$E((y - g(x))^2)$$

- Objetivo: Minimizar el error.

Explicación: Propiedad de predicción

- Recuerde: $y = E(y|x) + u$ y $E(y|x) = \mu(x)$.
- $$\begin{aligned} E((y - g(x))^2) &= E((E(y|x) + u - g(x))^2) \\ &= E((\mu(x) + u - g(x))^2) \\ &= \\ E(u^2) + 2E(u * (\mu(x) - g(x))) + E((\mu(x) - g(x))^2) \\ &= E(u^2) + E((\mu(x) - g(x))^2) \\ &\geq E(u^2) \end{aligned}$$
- La única forma que $E(u^2) + E((\mu(x) - g(x))^2) = E(u^2)$, es cuando $\mu(x) = g(x)$
- En este sentido, la CEF minimiza el error de predicción

Mejor Predictor Lineal

De la CEF a una aproximación estimable

La CEF puede tener cualquier forma. Para construir un primer modelo econométrico, restringimos la relación a una función lineal en parámetros. Esta restricción nos lleva al mejor predictor lineal.

Por qué una aproximación lineal

La CEF poblacional puede ser compleja:

$$m(x) = \mathbb{E}(Y \mid X = x).$$

En un primer curso de econometría trabajamos con una aproximación lineal:

$$L(Y \mid X) = \beta_0 + \beta_1 X.$$

Ventajas

- Es simple de estimar.
- Tiene interpretación económica directa.
- Permite desarrollar inferencia estadística.
- Es la base para modelos más generales.

Cuidado

Lineal no significa necesariamente que la verdadera relación poblacional sea exactamente una recta.

Mejor Predictor Lineal (Best Linear Predictor - BLP)

Buscamos la mejor aproximación lineal de Y usando X:

$$L(Y \mid X) = \beta_0 + \beta_1 X.$$

Los parámetros poblacionales resuelven:

$$(\beta_0, \beta_1) = \arg \min_{b_0, b_1} \mathbb{E}\left[(Y - b_0 - b_1 X)^2\right].$$

Idea clave

El mejor predictor lineal no es una estimación muestral. Es una relación poblacional definida en términos de momentos poblacionales.

Coeficientes del Mejor Predictor Lineal

Bajo condiciones regulares:

$$\beta_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \qquad \beta_0 = \mathbb{E}(Y) - \beta_1 \mathbb{E}(X).$$

Interpretación

La pendiente poblacional depende de la covarianza entre X e Y, escalada por la varianza de X.

Conexión

MCO reemplazará estos momentos poblacionales por sus versiones muestrales.

CEF lineal y BLP

Existen dos casos importantes:

Caso 1: la CEF es lineal

Si

$$\mathbb{E}(Y \mid X) = \beta_0 + \beta_1 X,$$

entonces la CEF y el mejor predictor lineal coinciden.

Caso 2: la CEF no es lineal

Si la CEF no es lineal, el BLP entrega la mejor aproximación lineal en términos de error cuadrático medio.

Mensaje

La regresión lineal puede ser entendida como un modelo exacto de la media condicional o como una aproximación lineal útil.

Linealidad en parámetros

En econometría, "lineal" usualmente significa **lineal en parámetros**.

Función	**¿Lineal en parámetros?**
$\beta_0 + \beta_1 X$	Sí
$\beta_0 + \beta_1 X^2$	Sí
$\beta_0 + \beta_1 \log(X)$	Sí
$\beta_0 + \beta_1^2 X$	No
$\beta_0 + \exp(\beta_1 X)$	No

Idea clave

El modelo puede ser no lineal en variables, pero seguir siendo lineal en los parámetros.

Modelo de Regresión Lineal Simple

Del objeto poblacional a un modelo econométrico

Ahora pasamos desde la CEF y el mejor predictor lineal al modelo poblacional de regresión simple. Este modelo separa una parte sistemática, explicada por X, y una parte no observada, contenida en el error.

Modelo poblacional

El modelo de regresión lineal simple se escribe como:

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \qquad i = 1, \ldots, n.$$

- Y_i: variable dependiente.
- X_i: variable explicativa.
- β_0: intercepto poblacional.
- β_1: pendiente poblacional.
- u_i: error poblacional.

Idea clave

β_0 y β_1 son parámetros poblacionales desconocidos. La muestra se usa para estimarlos.

Interpretación del intercepto

En el modelo

$$Y_i = \beta_0 + \beta_1 X_i + u_i,$$

el intercepto β_0 representa el valor esperado de Y cuando $X = 0$, si el modelo lineal es válido en ese punto.

Interpretación

$$\mathbb{E}(Y \mid X = 0) = \beta_0.$$

Cuidado

El intercepto no siempre tiene una interpretación económica relevante, especialmente si $X = 0$ está fuera del rango observado o no tiene sentido económico.

Interpretación de la pendiente

La pendiente β_1 mide cómo cambia el valor esperado de Y cuando X aumenta en una unidad:

$$\Delta \mathbb{E}(Y \mid X) = \beta_1 \Delta X.$$

Si $\Delta X = 1$, entonces:

$$\Delta \mathbb{E}(Y \mid X) = \beta_1.$$

Ejemplo

Si Y es salario mensual en miles de pesos y X son años de educación, $\beta_1 = 65$ significa que un año adicional de educación se asocia con 65 mil pesos más de salario mensual esperado.

Interpretación predictiva versus causal

Interpretación predictiva

β_1 resume cómo cambia el valor esperado de Y entre unidades con distinto valor de X.
No requiere afirmar que X cause Y.

Interpretación causal

β_1 mide el efecto de cambiar X sobre Y, manteniendo todo lo demás constante.
Requiere supuestos más fuertes.

Mensaje central: precaución

La regresión simple no garantiza causalidad. Para una interpretación causal, el error debe no estar sistemáticamente relacionado con X.

Error poblacional y residuo muestral

Error poblacional

$$u_i = Y_i - \beta_0 - \beta_1 X_i.$$

- No observable.
- Depende de los parámetros verdaderos.
- Contiene factores omitidos.

Residuo muestral

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

- Observable después de estimar.
- Depende de $\hat{\beta}_0, \hat{\beta}_1$.
- Mide errores de ajuste en la muestra.

Cuidado

El residuo es una aproximación muestral construida después de estimar. No es igual al error poblacional.

Estimación por MCO

¿Cómo elegir la recta que mejor ajusta los datos?

Una vez formulado el **modelo poblacional**, necesitamos estimar sus **parámetros**. El método de Mínimos Cuadrados Ordinarios (MCO) elige la recta que minimiza la suma de residuos cuadrados.

Recta estimada

La recta de regresión estimada es:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i.$$

El residuo muestral es:

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

Interpretación

$\hat{Y}_i$ es el valor ajustado o predicho de Y_i usando la recta estimada.

Idea clave

La estimación reemplaza la relación poblacional desconocida por una relación muestral observable.

Criterio de Mínimos Cuadrados Ordinarios (MCO)

MCO elige $\hat{\beta}_0$ y $\hat{\beta}_1$ para resolver:

$$\min_{b_0,b_1} \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2.$$

Equivalentemente:

$$\min_{b_0,b_1} \sum_{i=1}^{n} \hat{u}_i^2.$$

Idea clave

MCO elige la recta que minimiza la suma de errores de predicción al cuadrado dentro de la muestra.

MCO: intuición geométrica

Supongamos que observamos una nube de puntos:

$$(Y_i, X_i), \qquad i = 1, \ldots, n.$$

Queremos elegir una recta:

$$\hat{Y}_i = b_0 + b_1 X_i,$$

que represente lo mejor posible la relación entre X e Y.

Pregunta

Entre todas las rectas posibles, ¿cuál debemos escoger?

Respuesta de MCO

Escogemos la recta que deja los residuos más pequeños en conjunto, penalizando más los errores grandes.

Distancia vertical entre dato y recta

Para cada observación i, la diferencia entre el valor observado y el valor ajustado es:

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

Como

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$

entonces:

$$\hat{u}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i.$$

Interpretación

El residuo $\hat{u}_i$ es una distancia vertical entre el punto observado y la recta estimada. Nosotros estamos interesados en la distancia geométrica $|\hat{u}_i|$.

Idea gráfica

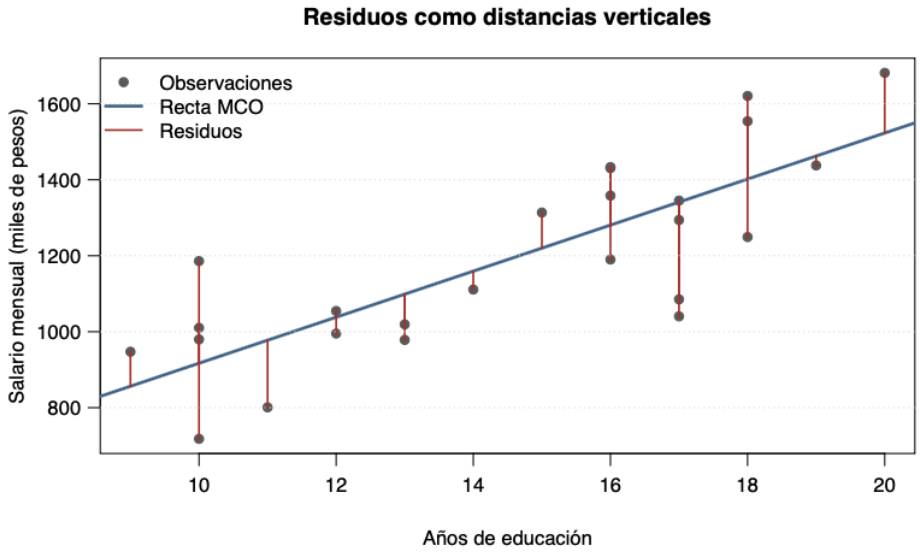
MCO busca una recta que haga pequeñas, en conjunto, esas distancias verticales.

Representación gráfica de los residuos

Cada punto observado tiene asociado un residuo:

$$\hat{u}_i = Y_i - \hat{Y}_i.$$

- Si $Y_i > \hat{Y}_i$, el residuo es positivo.
- Si $Y_i < \hat{Y}_i$, el residuo es negativo.
- Si $Y_i = \hat{Y}_i$, el residuo es cero.



Lectura

Los residuos miden errores de ajuste **dentro de la muestra**.

Por qué no minimizar la suma simple de residuos

Una opción inicial podría ser minimizar:

$$\sum_{i=1}^{n} \hat{u}_i.$$

Pero esta medida tiene un problema: residuos positivos y negativos pueden cancelarse.

Ejemplo

Si una recta genera residuos

$$10,\ -10,\ 8,\ -8,$$

la suma simple es cero, aunque la recta comete errores grandes.

Conclusión

No basta sumar residuos. Necesitamos una función que mida el tamaño del error sin cancelaciones.

Por qué minimizar residuos cuadrados

MCO minimiza:

$$\sum_{i=1}^{n} \hat{u}_i^2.$$

Razones

- Evita cancelaciones entre residuos positivos y negativos.
- Penaliza con mayor fuerza los errores grandes.
- Entrega una solución matemática simple.
- Se conecta con la idea de mejor predictor bajo error cuadrático medio.

Idea clave

MCO no busca que todos los residuos sean cero; busca que la suma de sus cuadrados sea lo más pequeña posible.

Rectas candidatas y función objetivo

Cada par de valores (b_0, b_1) define una recta distinta:

$$\hat{Y}_i = b_0 + b_1 X_i.$$

Cada recta genera una **suma de residuos cuadrados**:

$$SRC(b_0, b_1) = \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2.$$

Problema de elección

MCO compara todas las rectas posibles y selecciona aquella con menor SRC.

Notación

A veces esta suma se denota como SSR, RSS, SSE o SCR, dependiendo del texto.

MCO como problema de optimización

Definimos la función objetivo:

$$S(b_0, b_1) = \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2.$$

El estimador MCO es el par:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} S(b_0, b_1).$$

Interpretación

$\hat{\beta}_0$ y $\hat{\beta}_1$ son los valores que hacen mínima la suma de residuos cuadrados.

Conexión

Estimamos una relación poblacional desconocida usando un criterio de ajuste muestral.

Condiciones de primer orden

Para encontrar el mínimo, derivamos $S(b_0, b_1)$ respecto de b_0 y b_1.

$$S(b_0, b_1) = \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2.$$

Las condiciones de primer orden son:

$$\frac{\partial S(b_0, b_1)}{\partial b_0} = 0, \qquad \frac{\partial S(b_0, b_1)}{\partial b_1} = 0.$$

Objetivo

Resolver estas dos ecuaciones nos permitirá obtener las fórmulas de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Primera condición: derivada respecto de b_0

Partimos de:

$$S(b_0, b_1) = \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2.$$

Derivando respecto de b_0:

$$\frac{\partial S}{\partial b_0} = -2 \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i).$$

En el óptimo:

$$-2 \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Por lo tanto:

$$\sum_{i=1}^{n} \hat{u}_i = 0.$$

Implicancia de la primera condición

La primera condición implica:

$$\sum_{i=1}^{n}(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Expandiendo:

$$\sum_{i=1}^{n} Y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^{n} X_i = 0.$$

Dividiendo por n:

$$\bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{X} = 0.$$

Entonces:

$$\boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}}$$

Interpretación de la primera condición

La condición

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

implica que la recta MCO pasa por el punto de medias:

$$(\bar{X}, \bar{Y}).$$

Lectura geométrica

La recta estimada siempre cruza el centro muestral de los datos.

Propiedad muestral

La media de los valores ajustados coincide con la media de la variable dependiente:

$$\overline{\hat{Y}} = \bar{Y}.$$

Segunda condición: derivada respecto de b_1

Derivando respecto de b_1:

$$\frac{\partial S}{\partial b_1} = -2\sum_{i=1}^{n} X_i(Y_i - b_0 - b_1 X_i).$$

En el óptimo:

$$-2\sum_{i=1}^{n} X_i(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Por lo tanto:

$$\sum_{i=1}^{n} X_i \hat{u}_i = 0.$$

Interpretación

Los residuos MCO no están correlacionados muestralmente con X.

Sustitución del intercepto

Sabemos que:

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Sustituimos en la segunda condición:

$$\sum_{i=1}^{n} X_i (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0.$$

Entonces:

$$\sum_{i=1}^{n} X_i \left[Y_i - \bar{Y} + \hat{\beta}_1 \bar{X} - \hat{\beta}_1 X_i \right] = 0.$$

Reordenando:

$$\sum_{i=1}^{n} X_i \left[(Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X}) \right] = 0.$$

MCO: centrar la variable explicativa

1. Partimos de la condición de primer orden:

$$\sum_{i=1}^{n} X_i \left[(Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X}) \right] = 0.$$

2. Las desviaciones respecto de la media suman cero:

$$\sum_{i=1}^{n} (Y_i - \bar{Y}) = 0, \qquad \sum_{i=1}^{n} (X_i - \bar{X}) = 0, \qquad Note\ que \sum_{i=1}^{n} X_i = n\bar{X}.$$

3. Por tanto, la suma del corchete también es cero:

$$\begin{aligned} \sum_{i=1}^{n} \left[(Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X}) \right] &= \sum_{i=1}^{n} (Y_i - \bar{Y}) - \hat{\beta}_1 \sum_{i=1}^{n} (X_i - \bar{X}) \\ &= 0 - \hat{\beta}_1 \cdot 0 = 0. \end{aligned}$$

MCO: distribuir y reordenar la ecuación

4. Sustituimos $X_i = (X_i - \bar{X}) + \bar{X}$ y distribuimos:

$$0 = \sum_{i=1}^{n}(X_i - \bar{X})\left[(Y_i - \bar{Y}) - \hat{\beta}_1(X_i - \bar{X})\right]$$

$$+ \bar{X}\underbrace{\sum_{i=1}^{n}\left[(Y_i - \bar{Y}) - \hat{\beta}_1(X_i - \bar{X})\right]}_{=0 \text{ por el paso 3}}.$$

5. El segundo término vale cero. Expandimos el primero:

$$\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y}) - \hat{\beta}_1 \sum_{i=1}^{n}(X_i - \bar{X})^2 = 0.$$

6. Pasamos el segundo término al lado derecho:

$$\boxed{\hat{\beta}_1 \sum_{i=1}^{n}(X_i - \bar{X})^2 = \sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}$$

Estimador MCO de la pendiente

Por lo tanto, la pendiente estimada es:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

Interpretación

El numerador mide la covariación muestral entre X e Y. El denominador mide la variación muestral de X.

Idea clave

La pendiente es grande cuando X e Y se mueven juntos intensamente, en relación con la variación de X.

Estimador MCO del intercepto

Una vez obtenida $\hat{\beta}_1$, el intercepto se calcula como:

$$\boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}}$$

Interpretación

El intercepto ajusta la altura de la recta para que pase por el punto $(\bar{X}, \bar{Y})$.

Lectura

La pendiente define la inclinación de la recta; el intercepto define su nivel.

Ejemplo: cálculo de la pendiente

Salario	**Años educ.**	$x_i - \bar{x}$	$y_i - \bar{y}$	Producto	$(x_i - \bar{x})^2$
3,10	11	-1,9	-4,8	9,3	3,7
3,24	12	-0,9	-4,6	4,3	0,9
3,00	11	-1,9	-4,9	9,4	3,7
6,00	8	-4,9	-1,9	9,3	24,3
5,30	12	-0,9	-2,6	2,4	0,9
8,75	16	3,1	0,9	2,7	9,4
11,25	18	5,1	3,4	17,1	25,7
5,00	12	-0,9	-2,9	2,7	0,9
3,60	12	-0,9	-4,3	4,0	0,9
18,18	17	4,1	10,3	41,9	16,5
6,25	16	3,1	-1,6	-5,0	9,4
8,13	13	0,1	0,2	0,0	0,0
8,77	12	-0,9	0,9	-0,8	0,9
5,50	12	-0,9	-2,4	2,2	0,9
22,20	12	-0,9	14,3	-13,4	0,9
				86,0	98,9

$$\bar{y} = 7{,}8847, \qquad \bar{x} = 12{,}9333, \qquad \hat{\beta}_1 = \frac{86{,}0}{98{,}9}.$$

Ejemplo: modelo estimado

A partir de los cálculos anteriores:

$$\hat{\beta}_1 = \frac{86{,}044}{98{,}9333} \approx 0{,}8697.$$

$$\hat{\beta}_0 = 7{,}88 - 0{,}8697(12{,}9333) \approx -3{,}36.$$

Por tanto, el modelo estimado es:

$$\boxed{\hat{Y}_i = -3{,}36 + 0{,}87X_i}.$$

Resumen de la derivación

El problema MCO es:

$$\min_{b_0,b_1} \sum_{i=1}^{n} (Y_i - b_0 - b_1 X_i)^2.$$

Las condiciones de primer orden entregan:

$$\sum_{i=1}^{n} \hat{u}_i = 0, \qquad \sum_{i=1}^{n} X_i \hat{u}_i = 0.$$

De estas condiciones se obtiene:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n} (X_i - \bar{X})^2}, \qquad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Condición para poder estimar la pendiente

El denominador de $\hat{\beta}_1$ es:

$$\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

Para poder estimar la pendiente necesitamos:

$$\sum_{i=1}^{n}(X_i - \bar{X})^2 > 0.$$

Interpretación

Debe existir variación muestral en X. Si todos los individuos tienen el mismo valor de X, no hay información para estimar cómo cambia Y cuando cambia X.

Lectura económica de la fórmula

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}.$$

Qué captura

- Si $X_i > \bar{X}$ y $Y_i > \bar{Y}$, la pendiente será positiva.
- Si $X_i > \bar{X}$ y $Y_i < \bar{Y}$, la pendiente será negativa.
- Si no hay patrón sistemático entre X e Y, la pendiente estará cerca de cero.

Conclusión

La pendiente MCO resume la dirección e intensidad de la relación lineal muestral entre X e Y.

MCO: solución muestral, interpretación poblacional

MCO entrega una recta estimada:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i.$$

Pero el objetivo econométrico es aprender sobre la relación poblacional:

$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

Mensaje clave

La derivación de MCO nos dice cómo calcular $\hat{\beta}_0$ y $\hat{\beta}_1$. Los supuestos econométricos nos dirán cuándo esos estimadores son buenos para aprender sobre β_0 y β_1.

Propiedades algebraicas de MCO

En la muestra, los residuos MCO cumplen:

$$\sum_{i=1}^{n} \hat{u}_i = 0, \qquad \sum_{i=1}^{n} X_i \hat{u}_i = 0, \qquad \bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}.$$

Interpretación

La recta estimada pasa por el punto $(\bar{X}, \bar{Y})$, y los residuos no tienen correlación muestral con el regresor.

Cuidado [importante]

Estas son propiedades algebraicas de la estimación, no garantizan por sí solas causalidad ni ausencia de sesgo poblacional.

Bondad de ajuste

¿Qué tan bien resume la recta la variación observada?

Una vez estimada la regresión, debemos evaluar qué parte de la variación de Y queda resumida por la recta, qué parte queda en los residuos y cómo interpretar correctamente las medidas de ajuste.

Valores observados, ajustados y residuos

Para cada observación:

$$Y_i = \hat{Y}_i + \hat{u}_i.$$

- Y_i: valor observado.
- $\hat{Y}_i$: valor ajustado por la regresión.
- $\hat{u}_i$: residuo.

Lectura

Un residuo positivo indica que el valor observado de Y_i está por sobre el valor predicho por la recta.

Descomposición de la variación

La variación total de Y alrededor de su media puede descomponerse en (restemos $\bar{Y}$):

$$\sum_{i=1}^{n}(Y_i - \bar{Y})^2 = \sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^{n}\hat{u}_i^2.$$

Nombre	**Expresión**	**Interpretación**
SCT	$\sum(Y_i - \bar{Y})^2$	Variación total
SCE	$\sum(\hat{Y}_i - \bar{Y})^2$	Variación explicada
SCR	$\sum \hat{u}_i^2$	Variación residual

Idea clave

La regresión divide la variación observada de Y en una parte explicada por la recta y una parte no explicada.

Coeficiente de determinación R^2

El R^2 se define como:

$$R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

Interpretación

R^2 mide la proporción de la variación muestral de Y explicada linealmente por X.

Ejemplo

Si $R^2 = 0{,}42$, entonces el $42\,\%$ de la variación muestral de Y es explicada por la regresión lineal con X.

Qué no dice el R^2

Advertencias

- Un R^2 alto no prueba causalidad.
- Un R^2 bajo no invalida necesariamente una pregunta causal.
- El R^2 no indica si el modelo está correctamente especificado.
- El R^2 no mide la importancia económica del coeficiente.
- Debemos ser cautelosos ya que R^2 generalmente aumenta con el número de variables.

Lectura econométrica

El R^2 es una medida de ajuste muestral, **no una medida de validez causal**.

Error estándar de la regresión

El error estándar de la regresión mide la dispersión típica de los residuos[1]:

$$SER = \sqrt{\frac{1}{n-2}\sum_{i=1}^{n}\hat{u}_i^2}.$$

Interpretación

El SER mide el tamaño típico del error de predicción dentro de la muestra, en las mismas unidades de Y.

Comparación

Mientras R^2 es una proporción, el SER está medido en unidades de la variable dependiente.

[1] $n-2$ porque en la regresión simple hay $n-2$ grados de libertad

Supuestos básicos

¿Cuándo podemos confiar en la estimación?

MCO siempre produce una recta. Pero para interpretar esa recta como una buena aproximación poblacional necesitamos supuestos. El más importante será la **media condicional cero**.

Supuestos de mínimos cuadrados

Para regresión simple, seguiremos tres supuestos básicos:

1. **Media condicional cero:**

$$\mathbb{E}(u_i \mid X_i) = 0.$$

2. **Muestreo i.i.d.:**

$$(Y_i, X_i), \qquad i = 1, \ldots, n,$$

   son independientes e idénticamente distribuidos.

3. **Ausencia de outliers extremos:** los valores extremos de X e Y son poco probables.

Idea clave

Los supuestos conectan la recta estimada en la muestra con la relación poblacional que queremos conocer.

Media condicional cero

El supuesto central es:

$$\mathbb{E}(u_i \mid X_i) = 0.$$

Interpretación

Para cada valor de X, los factores no observados contenidos en u tienen promedio cero. Esto implica que el error no tiene un componente sistemático asociado a X.

Lectura

Si X está relacionado con factores omitidos que afectan Y, este supuesto falla.

Media condicional cero y causalidad

Para una interpretación causal de β_1, necesitamos que:

$$\mathbb{E}(u_i \mid X_i) = 0.$$

En palabras

Los factores no observados que afectan Y no deben estar sistemáticamente relacionados con X.

Ejemplo

En una ecuación de salarios, si la habilidad afecta salario y además está correlacionada con educación, entonces educación estará correlacionada con el error.

Conclusión

En ese caso, la pendiente estimada no puede interpretarse directamente como el efecto causal de la educación.

Variable omitida y sesgo

Supongamos que el verdadero modelo es:

$$Y_i = \beta_0 + \beta_1 X_i + \gamma Z_i + v_i,$$

pero estimamos:

$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

Entonces:

$$u_i = \gamma Z_i + v_i.$$

Sesgo por variable omitida

Si Z_i afecta Y_i y está correlacionada con X_i, entonces:

$$\text{Cov}(X_i, u_i) \neq 0.$$

Lectura

La regresión simple puede confundir el efecto de X con el efecto de otros factores omitidos.

Muestreo i.i.d.

El supuesto de muestreo i.i.d. establece que:

$$(Y_1, X_1), \ldots, (Y_n, X_n)$$

provienen de la misma población y son independientes entre unidades.

Interpretación

Cada observación entrega información nueva sobre la población.

Ejemplo

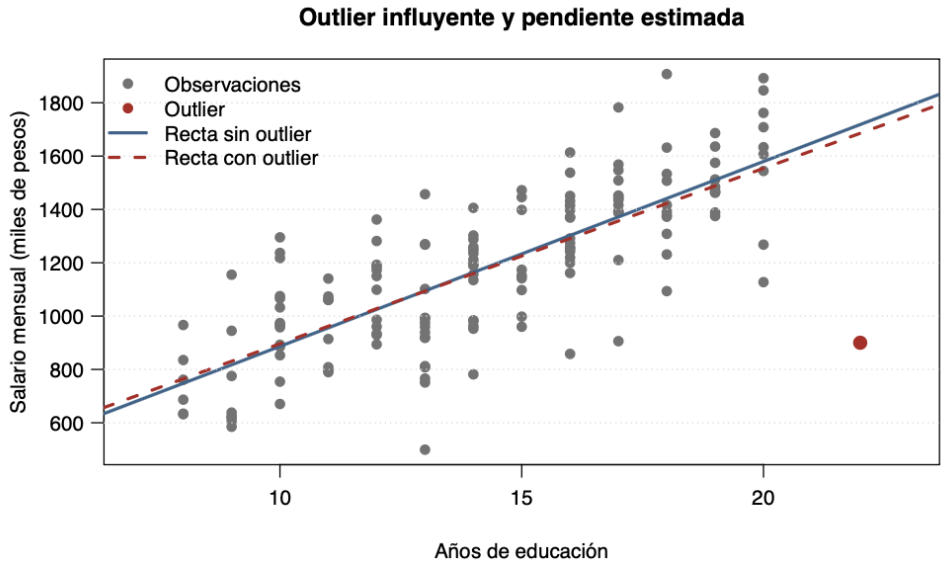
Si cada observación es una persona seleccionada aleatoriamente desde una población de trabajadores, el supuesto puede ser razonable.

Outliers extremos

MCO puede ser sensible a observaciones extremas.

Problema

Un punto con un valor extremo de X puede tener alta influencia sobre la pendiente estimada.



Puede:

- cambiar la recta estimada;
- alterar el R^2;
- afectar inferencia.

Ejemplo (Wooldridge)

Supongamos que queremos predecir el salario de un CEO usando el desempeño de la empresa.

- s: sueldo anual del CEO, en miles de dólares.
- r: rendimiento promedio de las acciones en los últimos tres años, medido en porcentaje.

Modelo:

$$s = \beta_0 + \beta_1 r + u.$$

β_1 mide el cambio promedio en el sueldo cuando el retorno aumenta en un punto porcentual, manteniendo lo demás constante.

Ejemplo (Cont.)

Con una muestra de 209 CEOs se obtiene

$$\hat{s} = 963 + 18{,}5r, \qquad R^2 = 0{,}0132.$$

- Si $r = 0$, el sueldo predicho es 963 mil dólares anuales.
- Un aumento de un punto porcentual en el rendimiento se asocia con un aumento de 18,5 mil dólares en el sueldo predicho.

Ejemplo (Cont.)

Si $r = 30$,

$$\hat{s} = 963 + 18{,}5(30) = 1518.$$

- La predicción es aproximadamente 1,5 millones de dólares anuales.
- El $R^2 = 0{,}0132$ indica que 1,32 % de la variación muestral del sueldo es explicada por el rendimiento.
- Un R^2 bajo no implica, por sí solo, que el estimador de β_1 tenga malas propiedades estadísticas.

Unidades de medida: ¿cómo afectan a los coeficientes?

Modelo original: $\widehat{Y} = \widehat{\beta}_0 + \widehat{\beta}_1 X$

Caso 1: Cambiamos las unidades de Y

Si $Y^* = cY$, entonces:

$$\widehat{\beta}_0^* = c\widehat{\beta}_0, \qquad \widehat{\beta}_1^* = c\widehat{\beta}_1$$

Ejemplo: Si el salario pasa de pesos a miles de pesos ($c = 1/1000$), tanto el intercepto como la pendiente se dividen por 1000.
Intuición: Cambia la escala de los valores que queremos explicar, por lo que ambos coeficientes cambian.

Caso 2: Cambiamos las unidades de X

Si $X^* = cX$, entonces:

$$\widehat{\beta}_0^* = \widehat{\beta}_0, \qquad \widehat{\beta}_1^* = \frac{\widehat{\beta}_1}{c}$$

Ejemplo: Si la experiencia laboral pasa de años a meses ($c = 12$), la pendiente se divide por 12, pero el intercepto permanece igual.
Intuición: La pendiente mide el cambio en Y ante una unidad adicional de X. Si cambia el tamaño de esa unidad, también cambia la pendiente.

Unidades de medida

Si cambiamos simultáneamente las unidades, $y^* = c_1 y$ y $x^* = c_2 x$, entonces

$$\hat{y}^* = c_1 \hat{\beta}_0 + \frac{c_1}{c_2} \hat{\beta}_1 x^*.$$

Por tanto,

$$\hat{\beta}_0^* = c_1 \hat{\beta}_0, \qquad \hat{\beta}_1^* = \frac{c_1}{c_2} \hat{\beta}_1.$$

El R^2 **no depende** de las unidades de medida.

Unidades de medida: ejemplo

Si

$$\widehat{wage} = -0{,}9 + 0{,}54\, educ,$$

y $wage$ está medido en dólares por hora, al medirlo en centavos ($wage_c = 100 wage$) obtenemos

$$\boxed{\widehat{wage_c} = -90 + 54\, educ}.$$

Unidades de medida: ejemplo

Partimos de

$$\hat{s} = 963{,}19 + 18{,}5r, \qquad R^2 = 0{,}0132,$$

donde r está medido en porcentaje. Si $r_1 = r/100$, entonces

$$\hat{s} = 963{,}19 + 1850r_1.$$

La interpretación económica no cambia: un aumento de un punto porcentual equivale a $\Delta r_1 = 0{,}01$.

Unidades de medida: ejemplo

Si además medimos el salario en cientos de dólares, $s_{100} = 10s$, entonces

$$\widehat{s_{100}} = 9631{,}9 + 18500r_1, \qquad R^2 = 0{,}0132.$$

Incorporación de no linealidades

Es fácil incorporar no linealidades mediante transformaciones de las variables. Por ejemplo,

$$\log(wage) = \beta_0 + \beta_1 educ + u.$$

Si $\Delta u = 0$,

$$\%\Delta wage \approx 100\beta_1 \Delta educ.$$

Ejemplo:

$$\widehat{\log(wage)} = 0{,}584 + 0{,}083 educ.$$

Un año adicional de educación se asocia aproximadamente con un aumento de 8,3 % en el salario.

Modelo de elasticidad constante

Un modelo log-log para salario de CEOs y ventas es

$$\log(salary) = \beta_0 + \beta_1 \log(sales) + u.$$

Estimando por MCO:

$$\widehat{\log(salary)} = 4{,}822 + 0{,}257 \log(sales).$$

El coeficiente 0,257 es la elasticidad estimada: un aumento de 1 % en ventas se asocia aproximadamente con un aumento de 0,257 % en el salario del CEO.

Tabla resumen: modelos con log

Modelo	**Variable dependiente**	**Variable independiente**	**Interpretación de β_1**
Nivel-nivel	y	x	$\Delta y = \beta_1 \Delta x$
Nivel-log	y	$\log(x)$	$\Delta y \approx (\beta_1/100)\times$ cambio porcentual en x
Log-nivel	$\log(y)$	x	cambio porcentual en $y \approx 100\beta_1 \Delta x$
Log-log	$\log(y)$	$\log(x)$	cambio porcentual en $y \approx \beta_1 \times$ cambio porcentual en x

Propiedades estadísticas de los estimadores MCO

- La media muestral es un estadístico y, por tanto, una variable aleatoria.
- En una muestra aleatoria satisface propiedades exactas y asintóticas que también serán centrales para estudiar los estimadores MCO.

La media muestral

Propiedades exactas:

$$\mathbb{E}(\bar{X}) = \mu, \qquad \text{Var}(\bar{X}) = \frac{1}{n}\,\text{Var}(X).$$

Propiedades asintóticas:

$$\bar{X} \xrightarrow{p} \mathbb{E}(X),$$

y por el Teorema Central del Límite,

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sqrt{\text{Var}(X)}} \xrightarrow{d} N(0, 1).$$

Supuestos del modelo de regresión lineal simple

1. **RLS.1 Linealidad en parámetros:** $y = \beta_0 + \beta_1 x + u$.
2. **RLS.2 Muestreo aleatorio:** $\{(x_i, y_i) : i = 1, \ldots, n\}$ es una muestra aleatoria.
3. **RLS.3 Variación muestral de x:** x no es constante en la muestra.
4. **RLS.4 Media condicional cero:** $\mathbb{E}(u \mid x) = 0$.

Bajo RLS.2 y RLS.4, $\mathbb{E}(u_i \mid x_i) = 0$ y, bajo muestreo aleatorio, la condición puede expresarse respecto del conjunto de regresores observados.

Propiedades de $\hat{\beta}_1$ bajo RLS.1–RLS.4

- $\mathbb{E}(\hat{\beta}_1) = \beta_1$ (insesgadez).
- La varianza de $\hat{\beta}_1$ disminuye con el tamaño muestral, bajo condiciones regulares.
- En muestras grandes, $\hat{\beta}_0$ y $\hat{\beta}_1$ tienen distribuciones aproximadamente normales.
- Los estimadores MCO son consistentes.

Recuerde: Ley de Esperanzas Iteradas

Un caso utilizado continuamente en econometría es

$$\boxed{\mathbb{E}(Y) = \mathbb{E}_X[\mathbb{E}(Y \mid X)]}.$$

Es decir, la esperanza de la esperanza condicional es la esperanza incondicional.
Ejemplo: sea G el género. Entonces,

$$\begin{aligned}\mathbb{E}[\log(salario)] = \mathbb{E}[\log(salario) \mid G = hombre]\mathbb{P}(G = hombre) \\ + \mathbb{E}[\log(salario) \mid G = mujer]\mathbb{P}(G = mujer).\end{aligned}$$

Conditioning Theorem

Al condicionar en X, cualquier función de X puede tratarse como constante:

$$\mathbb{E}(X \mid X) = X, \qquad \mathbb{E}(g(X) \mid X) = g(X).$$

Si la esperanza existe,

$$\mathbb{E}(g(X)Y \mid X) = g(X)\mathbb{E}(Y \mid X),$$

y por esperanzas iteradas,

$$\mathbb{E}[g(X)Y] = \mathbb{E}[g(X)\mathbb{E}(Y \mid X)].$$

Insesgadez de los estimadores MCO

La pendiente puede escribirse como

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^{n}(x_i - \bar{x})u_i}{STC_x} = \beta_1 + \frac{1}{STC_x}\sum_{i=1}^{n} d_i u_i,$$

donde

$$d_i = x_i - \bar{x}, \qquad STC_x = \sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Además,

$$\hat{\beta}_0 = \beta_0 + (\beta_1 - \hat{\beta}_1)\bar{x} + \bar{u}.$$

Insesgadez de $\hat{\beta}_1$

Condicionando en los valores observados de x:

$$\begin{aligned}\mathbb{E}(\hat{\beta}_1 \mid X) &= \beta_1 + \frac{1}{STC_x}\sum_{i=1}^{n} d_i \mathbb{E}(u_i \mid X) \\ &= \beta_1.\end{aligned}$$

La última igualdad utiliza el supuesto de media condicional cero ($\mathbb{E}(u \mid x) = 0$).

Insesgadez de los estimadores MCO

- La insesgadez es una propiedad de la distribución muestral, no de una estimación particular.
- En una muestra concreta, $\hat{\beta}_1$ puede estar lejos de β_1.
- Para evaluar precisión necesitamos estudiar la dispersión de la distribución del estimador.
- La medida principal será la varianza, o su raíz cuadrada: la desviación estándar.

De la estimación puntual a la incertidumbre

Los coeficientes estimados son variables aleatorias porque dependen de la muestra. Por eso no basta con reportar $\hat{\beta}_1$: necesitamos su error estándar, una prueba de hipótesis y un intervalo de confianza.

Los estimadores son variables aleatorias

El estimador de la pendiente es:

$$\hat{\beta}_1.$$

Pero $\hat{\beta}_1$ depende de la muestra:

$$(Y_1, X_1), \ldots, (Y_n, X_n).$$

Si tomáramos otra muestra, obtendríamos otro valor de $\hat{\beta}_1$.

Idea clave

Así como $\bar{Y}$ tiene distribución muestral, $\hat{\beta}_1$ **también tiene distribución muestral**.

Error estándar de $\hat{\beta}_1$

El error estándar mide la incertidumbre muestral de la pendiente estimada:

$$SE(\hat{\beta}_1).$$

Interpretación

Un error estándar pequeño indica que $\hat{\beta}_1$ sería relativamente estable entre muestras repetidas.

Conexión

La estimación puntual responde: ¿cuál es el efecto estimado? El error estándar responde: **¿qué tan precisa es esa estimación?**

Varianzas de los estimadores MCO

Calculamos la varianza de los estimadores MCO bajo un supuesto adicional que se conoce como supuesto de homoscedasticidad.

Supuesto RLS.5 (homoscedasticidad)

$$\text{Var}(u|x) = \sigma^2$$

- Este supuesto establece que la varianza del término de error u condicionada a x, es constante, es decir no depende de x.
- El supuesto RLS.5 no juega ningún papel en la insesgadez de $\hat{\beta}_0$ y $\hat{\beta}_1$.
- Añadimos el supuesto RLS.5 para simplificar el cálculo de la varianza de los estimadores MCO.
- Cuando $\text{Var}(u|x)$ depende de x se dice que los errores son heteroscedásticos.
- Puesto que el supuesto RLS.4 establece que $\mathbb{E}(u|x) = 0$ y puesto que $\text{Var}(u|x) = \mathbb{E}(u^2|x) - (\mathbb{E}(u|x))^2$, RLS.5 se puede escribir como $\mathbb{E}(u^2|x) = \sigma^2$
- El supuesto RLS.5 también se puede escribir como $\text{Var}(y|x) = \sigma^2$

Varianzas de los estimadores MCO

Bajo los supuestos RLS.1 a RLS.5:

$$\text{Var}(\hat{\beta}_1|x) = \frac{\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\sigma^2}{STC_x} = \frac{\sigma^2}{(n-1)S_x^2}$$

$$\text{Var}(\hat{\beta}_0|x) = \frac{\sigma^2 \sum_{i=1}^{n} x_i^2}{n\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

- Cuanto mayor es la varianza del término de error, σ^2, mayor es la varianza de β_1. Si la varianza de los factores no observables que afectan a y es muy grande, es más difícil estimar β_1 con precisión.
- Cuanto mayor es la varianza de las x_i menor es la varianza de β_1. Si las x_i tienen muy poca dispersión es muy difícil estimar β_1 con precisión.
- Un aumento del tamaño muestral también aumenta la variación total de las x_i, por tanto, la varianza de $\hat{\beta}_1$ disminuye.

Estimación de la varianza del término de error

- Las varianzas de los estimadores dependen de la varianza del término de error, σ^2, que es un parámetro desconocido.
- Para poder estimar la varianza de los estimadores tenemos que obtener un estimador de σ^2.
- σ^2 es la varianza del término de error u, que coincide con la esperanza de u^2 (ya que $\mathbb{E}(u) = 0$).
- ¿Se puede utilizar la media muestral de los errores al cuadrado $\frac{1}{n}\sum_{i=1}^{n} u_i^2$ cómo estimador de σ^2? ¡Los errores no son observables!.

Varianzas de los estimadores MCO

- Lo que sí se puede calcular son los residuos $\hat{u}_i$
- Podemos definir el siguiente estimador de σ^2: $\frac{1}{n}\sum_{i=1}^{n}\hat{u}_i^2$. El problema es que es sesgado.
- El estimador insesgado de σ^2 es $\hat{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}\hat{u}_i^2$

  Esto se debe a que:

$$E[\sum_i \hat{u}_i^2 | x] = (n-k)\sigma^2$$

  Donde k es el número de parámetros y $n-k$ son los grados de libertad. En este caso β_0 y β_1.

Varianzas de los estimadores MCO

- Utilizando $\hat{\sigma}^2$, se definen las varianzas estimadas de $\hat{\beta}_1$ y $\hat{\beta}_0$ como:

$$\widehat{\text{Var}}(\hat{\beta}_1|x) = \frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\hat{\sigma}^2}{STC_x}$$

$$\widehat{\text{Var}}(\hat{\beta}_0|x) = \frac{\hat{\sigma}^2 \sum_{i=1}^{n} x_i^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Varianzas de los estimadores MCO: Demostración

- Recordemos la expresión de $\hat{\beta}_1$ en función de los errores del modelo es

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^{n}(x_i - \bar{x})u_i}{STC_x}$$

- La varianza es condicional a las x_i, por tanto, $(x_i - \bar{x})$, $i = 1, 2, .., n$, $STC_x = \sum_{i=1}^{n}(x_i - \bar{x})^2$ son no aleatorias, y β_1 tampoco es aleatorio.
- El supuesto RLS.2 implica que los errores u_i son independientes.
- Utilizamos las siguientes propiedades de la varianza:
  - La varianza de la suma de variables aleatorias independientes es la suma de las varianzas.
  - La varianza de una constante por una variable aleatoria es la constante al cuadrado por la varianza de la variable aleatoria
  - La varianza de la suma de una variable aleatoria y una constante es la varianza de la variable aleatoria

Varianzas de los estimadores MCO: Demostración

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^{n}(x_i - \bar{x})u_i}{STC_x}$$

$$\mathrm{Var}(\hat{\beta}_1) = \mathrm{Var}\left(\beta_1 + \frac{\sum_{i=1}^{n}(x_i - \bar{x})u_i}{STC_x}\right)$$

$$\mathrm{Var}(\hat{\beta}_1) = \mathrm{Var}(\beta_1) + \mathrm{Var}\left(\frac{\sum_{i=1}^{n}(x_i - \bar{x})u_i}{STC_x}\right)$$

$$\mathrm{Var}(\hat{\beta}_1) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2 \,\mathrm{Var}(u_i)}{STC_x^2}$$

$$\mathrm{Var}(\hat{\beta}_1) = \frac{\sigma^2 \sum_{i=1}^{n}(x_i - \bar{x})^2}{\left[\sum_{i=1}^{n}(x_i - \bar{x})^2\right]^2}$$

(Reemplazando σ^2 por su estimación $\hat{\sigma}^2$)

$$\mathrm{Var}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\hat{\sigma}^2}{(n-1)S_x^2}$$

Errores Estándar

- El error estándar de $\hat{\beta}_1$ ($se(\hat{\beta}_1)$) es:

$$se(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{(n-1)S_x^2}}$$

  Donde $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ es el error estándar de la regresión (EER).
- $se(\hat{\beta}_1)$ es un estimador de la desviación estándar de $\hat{\beta}_1$ y por tanto una medida de su precisión.
- $se(\hat{\beta}_1)$ es una variable aleatoria que toma valores distintos para distintas muestras.
- Para una muestra concreta tanto $\hat{\beta}_1$ y el error estándar $se(\hat{\beta}_1)$ son un número.
- Los errores estándar juegan un papel fundamental al hacer inferencia.

Heteroscedasticidad

El término de error de nuestro modelo de regresión es homocedástico si la varianza de la distribución condicional de u_i dado X_i, $\text{Var}(u_i|X_i = x)$, es constante para todas las observaciones de nuestra muestra:

$$\text{Var}(u_i|X_i = x) = \sigma^2 \qquad \forall i = 1, ..., n$$

Si en cambio hay dependencia de la varianza condicional de u_i en X_i, el término de error se dice que es heterocedástico. Entonces escribimos

$$\text{Var}(u_i|X_i = x) = \sigma_i^2 \qquad i = 1, ..., n$$

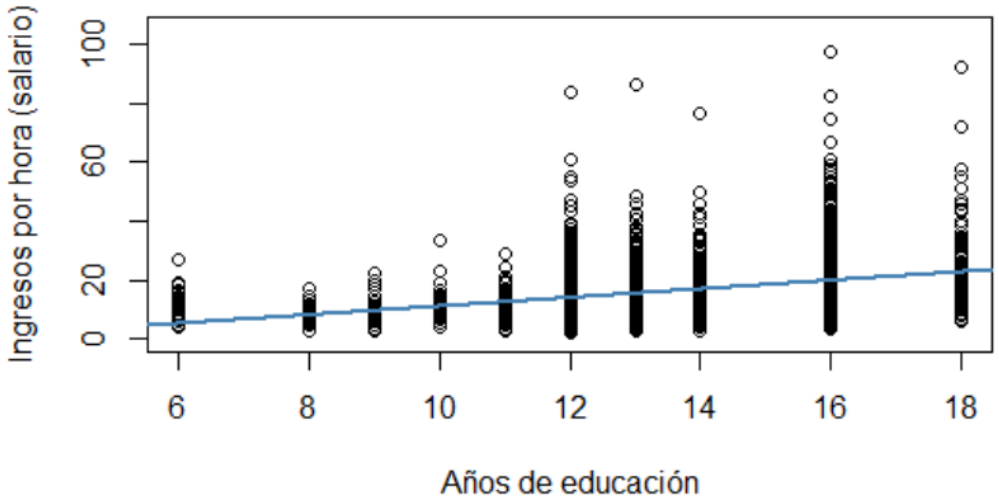
Heteroscedasticidad: Ejemplo

- Pensemos de nuevo en el valor económico de la educación.
- Parece plausible que los ingresos de los trabajadores mejor educados tengan una mayor dispersión que los de los trabajadores poco calificados: una educación sólida no es garantía de un salario alto, por lo que incluso los trabajadores altamente calificados aceptan empleos de bajos ingresos. Sin embargo, tienen más probabilidades de cumplir con los requisitos para empleos bien remunerados que los trabajadores con menor educación, para quienes las oportunidades en el mercado laboral son mucho más limitadas.
- Para verificar esto empíricamente podemos utilizar datos reales sobre los ingresos por hora y el número de años de educación de los empleados de Current Population Survey (CPS) de 1999.

Heteroscedasticidad: Ejemplo

$$\widehat{salary} = -3{,}13 + 1{,}47\, educat$$

t :	$[-3{,}27]$	$[21{,}02]$
σ :	$[0{,}95]$	$[0{,}07]$



La gráfica indica que hay heterocedasticidad. La dispersión de los ingresos por hora en torno a esa función aumenta claramente con el nivel de educación, es decir, la varianza de la distribución de los ingresos aumenta. En otras palabras: la varianza de los errores (los errores cometidos al explicar los ingresos por educación) aumenta con la educación, de modo que los errores de regresión son heterocedásticos.

¿Deberíamos preocuparnos por la heterocedasticidad?

- Las fórmulas derivadas anteriormente de la varianza y errores estándar de los estimadores se realizaron bajo el supuesto de homocedasticidad.
- De hecho, cuando existe heterocedasticidad las fórmulas de la desviación estándar del estimador $se(\hat{\beta}_1)$ es inconsistente para el valor verdadero de $\sigma_{\hat{\beta}_1}$.
- La implicación es que los estadísticos t calculados no siguen una distribución normal estándar, ni siquiera en muestras grandes. Esta cuestión puede invalidar la inferencia para la prueba de hipótesis: debemos ser cautelosos al hacer afirmaciones sobre la significancia de los coeficientes de regresión sobre la base de los estadísticos t si es dudoso que se mantenga el supuesto de homocedasticidad.

Cálculo de errores estándar robustos a la heterocedasticidad

Estimaciones consistentes de $\sigma_{\hat{\beta}_1}$ bajo heterocedasticidad se consigue cuando se utiliza el siguiente estimador robusto.

$$SE(\hat{\beta}_1) = \sqrt{\frac{1}{n} \cdot \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 \hat{u}_i^2}{\left[\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right]^2}}$$

Las estimaciones del error estándar calculadas de esta manera también se denominan errores estándar de Eicker-Huber-White; el artículo citado con más frecuencia sobre este tema es el de White (1980).

¿Cuán graves son las implicaciones de utilizar errores estándar de homocedasticidad únicamente en presencia de heterocedasticidad? La respuesta es, depende. Como se mencionó anteriormente, corremos el riesgo de sacar conclusiones erróneas al realizar inferencia.

Existen ciertas funciones de Python que sirven para ese propósito. En Stata en el comando `regress` se utiliza el argumento `robust` para el cálculo de errores robustos.

Ejemplo simulación

Tomamos

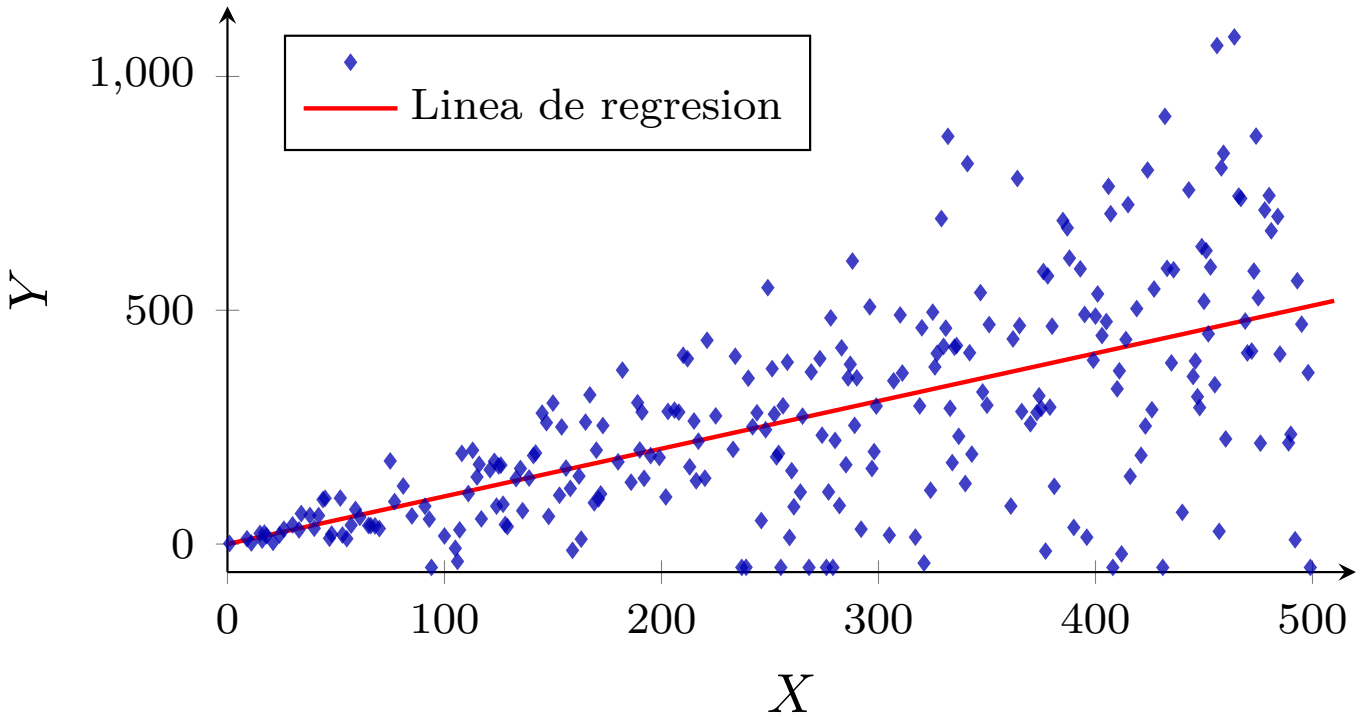
$$Y_i = \beta_1 \cdot X_i + u_i, \qquad u_i \sim N(0, 0{,}36 \cdot X_i^2)$$

con $\beta_1 = 1$ como el proceso generador de datos. Claramente, aquí se viola el supuesto de homocedasticidad ya que la varianza de los errores es una función no lineal y creciente de X_i, pero los errores tienen media cero y son i.i.d. tal que las suposiciones hechas no son violadas. Como antes estamos interesados en estimar β_1.

Código en R

```
set.seed(905)
# genera datos heteroscedasticos
X <- 1:500
Y <- rnorm(n = 500, mean = X, sd = 0.6 * X)
# estima un modelo de regresion simple
reg <- lm(Y ~ X)
# graficar los datos
plot(x = X, y = Y, pch = 19, col = "steelblue", cex = 0.8)
# agrega linea de regresion
abline(reg, col = "red", lwd = 1.5)
legend("topleft","Linea de regresion", col = "red", lwd = 1.5)
```

Ejemplo simulación



La gráfica muestra que los datos son heterocedásticos ya que la varianza de Y crece con X.

Ejemplo simulación

- A continuación realizamos una prueba de significancia de la hipótesis nula (verdadera) $H_0 : \beta_1 = 1$ dos veces, una vez usando la fórmula de error estándar de homocedasticidad únicamente y otra vez con la versión robusta (esto se verá luego en el curso cómo realizarlo, por el momento solo tome la idea básica de realizar pruebas de hipótesis).
- Este es un buen ejemplo de lo que puede salir mal si ignoramos la heterocedasticidad: para el conjunto de datos disponible, el método predeterminado rechaza la hipótesis nula $\beta_1 = 1$, a pesar de que es verdad. Cuando se utiliza la fórmula robusta del error estándar, la prueba no rechaza la hipótesis nula.

Prueba t para la pendiente

En el modelo $Y_i = \beta_0 + \beta_1 X_i + u_i$, contrastamos

$$H_0 : \beta_1 = \beta_{1,0} \qquad \text{frente a} \qquad H_1 : \beta_1 \neq \beta_{1,0}.$$

Estadístico observado

$$t_{\text{obs}} = \frac{\widehat{\beta}_1 - \beta_{1,0}}{\text{SE}(\widehat{\beta}_1)} = \frac{\text{distancia al valor nulo}}{\text{incertidumbre de la estimación}}.$$

Si $\widehat{\beta}_1 = 10$, $\text{SE}(\widehat{\beta}_1) = 4$ y $\beta_{1,0} = 0$:

$$t_{\text{obs}} = \frac{10 - 0}{4} = 2{,}5.$$

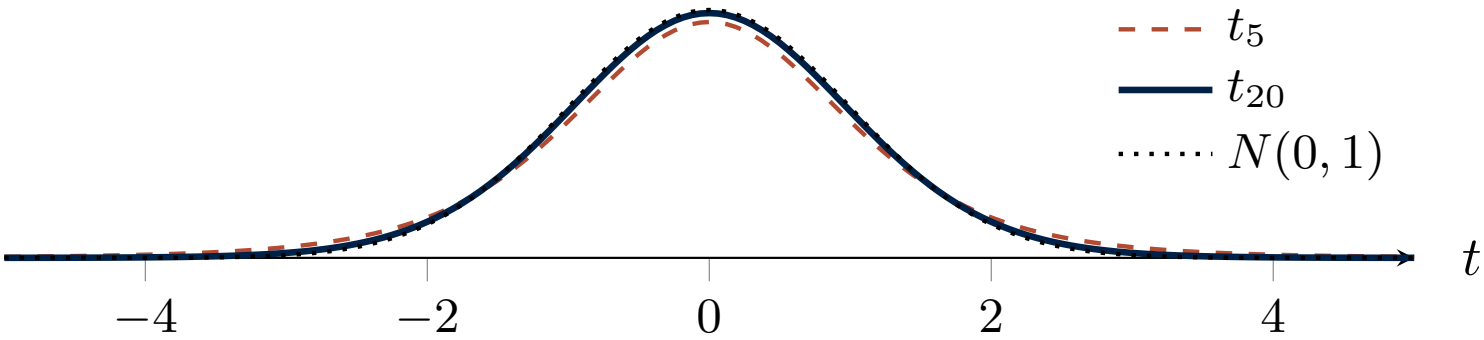
La pendiente estimada está **2,5 errores estándar por encima de cero**.

El signo indica la dirección. La magnitud $|t_{\text{obs}}|$ mide la distancia estandarizada.

La distribución t bajo H_0

En regresión simple, el modelo clásico normal implica

$$T = \frac{\widehat{\beta}_1 - \beta_{1,0}}{\mathrm{SE}(\widehat{\beta}_1)} \sim t_{n-2} \quad \text{bajo } H_0.$$



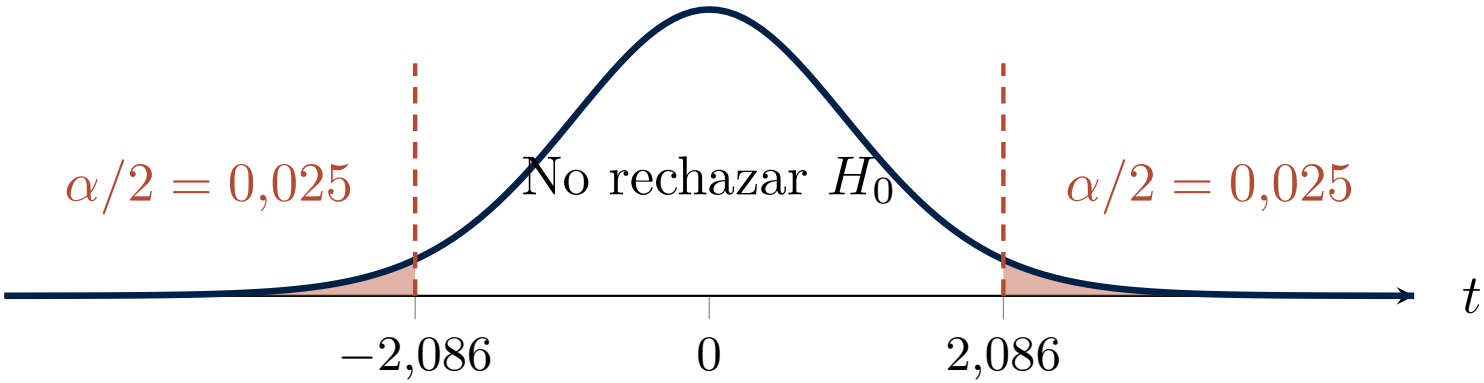
Menos grados de libertad: colas más pesadas. Al aumentar los grados de libertad, la t se aproxima a la normal (recuerde que los grados de libertad son $\nu = n - k$).

Resultado exacto si $\mathbf{u} \mid X \sim N(\mathbf{0}, \sigma^2 I)$, con diseño de rango completo y error estándar clásico. Con errores robustos, la justificación usual es asintótica. En regresión múltiple: $n - k - 1$ g.l., con k regresores e intercepto.

Prueba bilateral: zonas de rechazo

$$H_0 : \beta_1 = 0, \qquad H_1 : \beta_1 \neq 0, \qquad \alpha = 0{,}05, \quad \nu = 20.$$

El 5 % se reparte entre las dos colas: **2,5 % en cada una**.

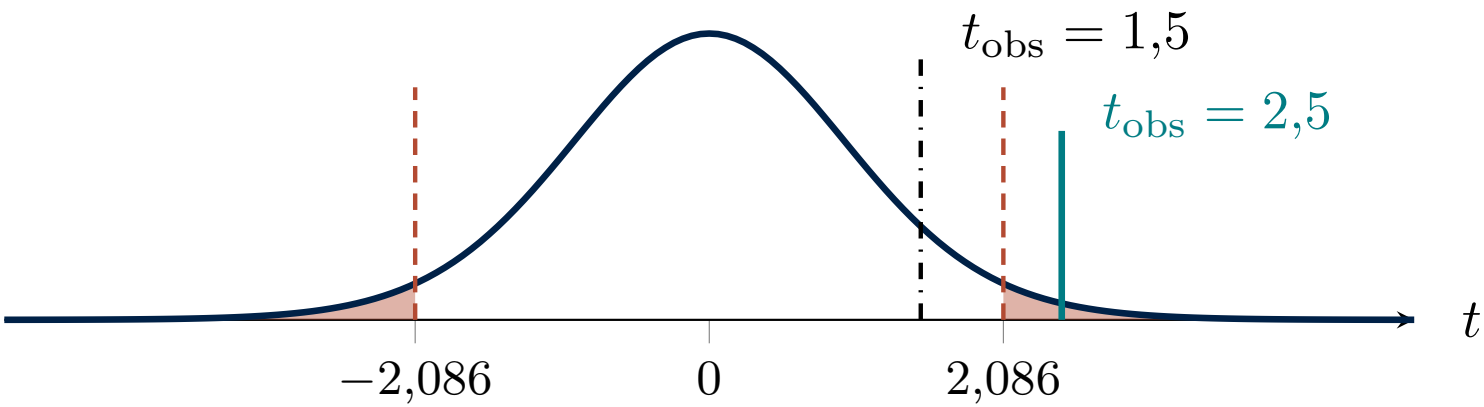


Rechazar H_0 si $|t_{\text{obs}}| \geq t_{20;\,0{,}975} = 2{,}086$.

$t_{\nu;q}$ denota el cuantil con probabilidad acumulada q. Las colas continúan hasta $\pm\infty$. α se fija antes de observar los datos.

El estadístico observado en el gráfico

La zona de rechazo está fijada por $\alpha = 5\,\%$ y $\nu = 20$.



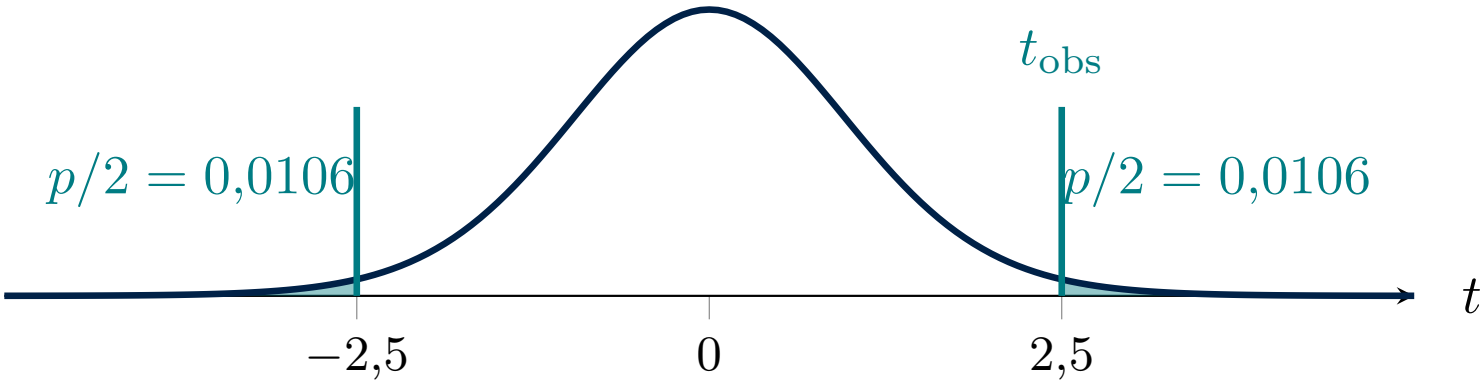
Resultado posible	Comparación	Decisión al 5 %
$t_{\text{obs}} = 2{,}5$	$2{,}5 > 2{,}086$	Rechazar H_0
$t_{\text{obs}} = 1{,}5$	$1{,}5 < 2{,}086$	No rechazar H_0

Son resultados de dos muestras posibles. Un estadístico $t_{\text{obs}} = -2{,}5$ también llevaría al rechazo bilateral.

El p-valor bilateral: el área más extrema

Suponiendo H_0, medimos la probabilidad de un estadístico al menos tan alejado de cero como el observado.

$$p = P_{H_0}(|T| \geq |t_{\text{obs}}|) = 2\,[1 - F_{20}(|t_{\text{obs}}|)].$$

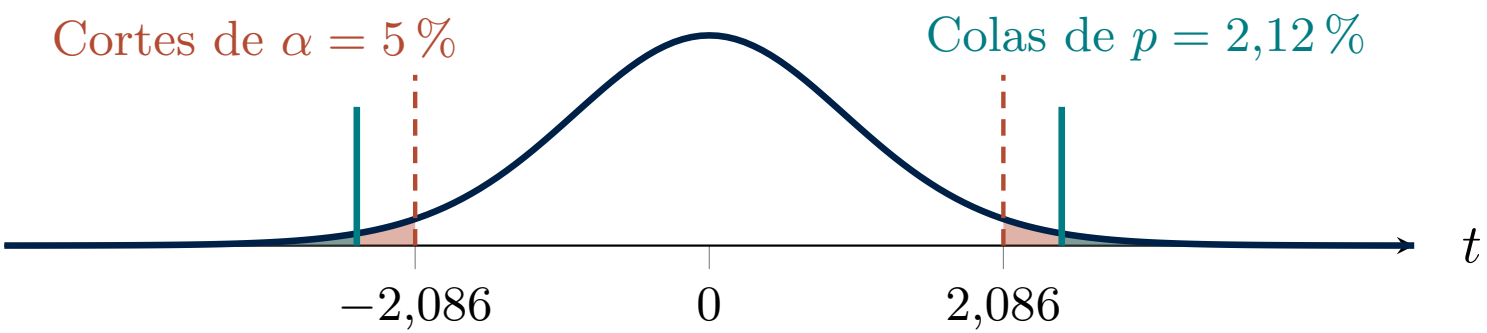


$$\boxed{t_{\text{obs}} = 2{,}5 \quad \Longrightarrow \quad p = 0{,}0212 \;\; (2{,}12\,\%).}$$

F_{20} es la función de distribución acumulada de t_{20}. El p-valor se calcula bajo H_0 y no representa $P(H_0 \mid \text{datos})$.

p-valor y α: una misma decisión

Para $\nu = 20$ y $t_{\text{obs}} = 2{,}5$, el p-valor bilateral es 0,0212.



Nivel elegido	Comparación	Decisión
$\alpha = 0{,}05$	$p = 0{,}0212 < 0{,}05$	Rechazar H_0
$\alpha = 0{,}01$	$p = 0{,}0212 > 0{,}01$	No rechazar H_0

$$p \leq \alpha \iff |t_{\text{obs}}| \geq t_{\nu;1-\alpha/2}.$$

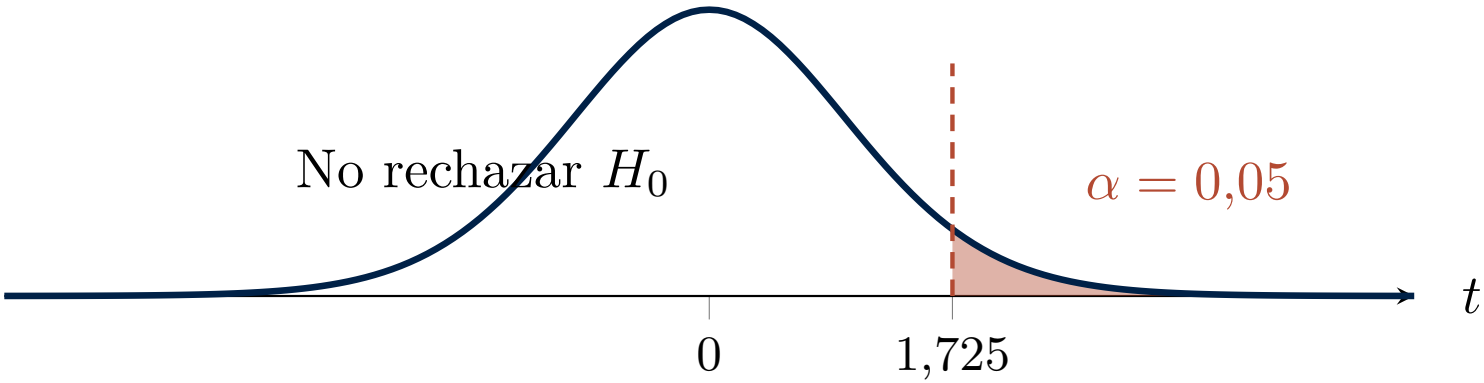
El p-valor es el menor nivel de significancia al que se rechazaría H_0. Para decidir, usamos el nivel elegido antes del análisis.

Prueba unilateral derecha: rechazo

Si la pregunta es si la pendiente es positiva, planteamos

$$H_0 : \beta_1 \leq 0, \qquad H_1 : \beta_1 > 0.$$

Bajo la frontera $\beta_1 = 0$, con $\nu = 20$, el 5 % va a la **cola derecha**.



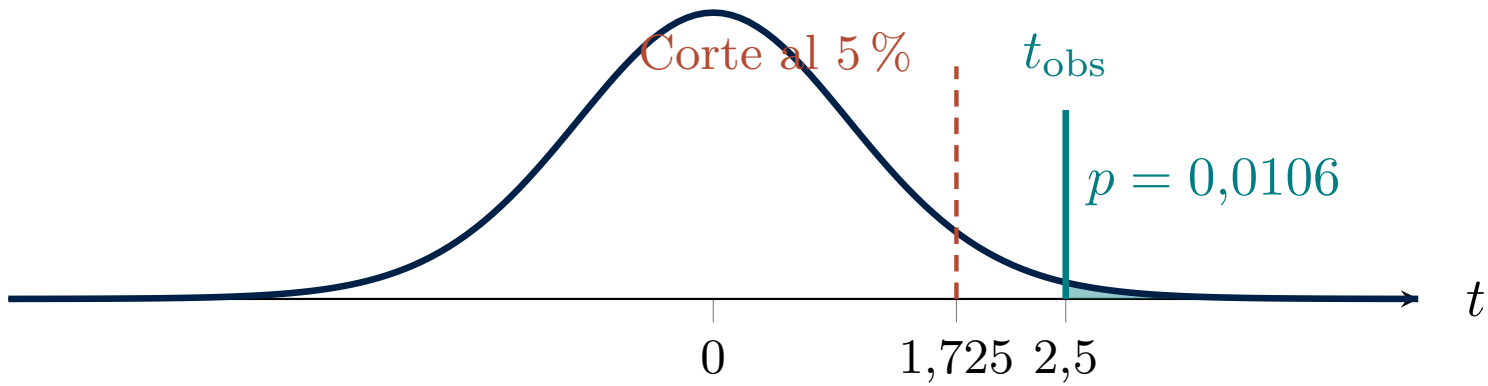
Rechazar H_0 si $t_{\text{obs}} \geq t_{20;\,0{,}95} = 1{,}725$.

La dirección de H_1 debe responder a la pregunta económica y fijarse antes de ver el signo estimado.

Prueba unilateral derecha: p-valor

Para $H_1 : \beta_1 > 0$ y $t_{\text{obs}} = 2{,}5$, contamos solo resultados a la derecha del observado.

$$p = P_{\beta_1=0}(T \geq t_{\text{obs}}) = 1 - F_{20}(t_{\text{obs}}).$$



Decisión

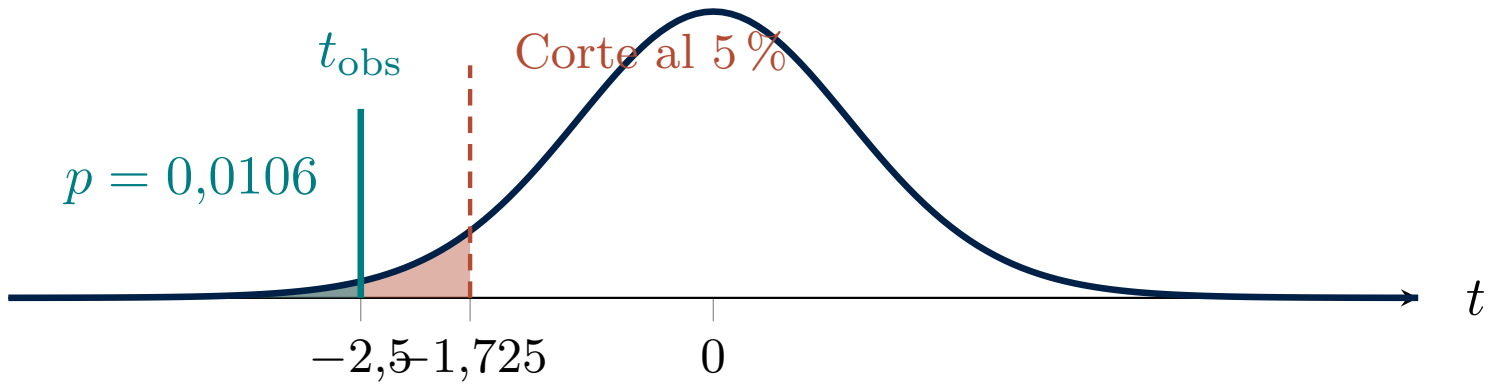
$0{,}0106 < 0{,}05$: rechazamos H_0 al 5 %. El mismo resultado tiene p bilateral $= 0{,}0212$ porque esa prueba suma ambas colas.

Prueba unilateral izquierda

$$H_0 : \beta_1 \geq 0, \qquad H_1 : \beta_1 < 0, \qquad \nu = 20, \quad \alpha = 0{,}05.$$

Rechazamos si $t_{\text{obs}} \leq -1{,}725$. Para $t_{\text{obs}} = -2{,}5$:

$$p = P_{\beta_1=0}(T \leq -2{,}5) = F_{20}(-2{,}5) = 0{,}0106.$$



Rechazamos H_0: el resultado cae en la cola izquierda y $p < \alpha$.

El color terracota marca la región de rechazo. El verde marca las observaciones al menos tan extremas como t_{obs}.

La alternativa determina el p-valor

Con los mismos 20 g.l., cambiar H_1 cambia qué resultados cuentan como evidencia extrema.

Alternativa	$t_{\text{obs}} = 2{,}5$	$t_{\text{obs}} = -2{,}5$
$H_1 : \beta_1 \neq 0$	0,0212	0,0212
$H_1 : \beta_1 > 0$	0,0106	0,9894
$H_1 : \beta_1 < 0$	0,9894	0,0106

El signo también importa

Dividir el p-valor bilateral por dos funciona para una prueba unilateral **cuando el signo observado coincide con la alternativa**. En la dirección opuesta, el p-valor es grande.

Elegir una cola después de ver el resultado altera la regla de prueba y su control del error tipo I.

Ejemplo numérico: una pendiente precisa

Retomamos $\widehat{\beta}_1 = 65$ y $\mathrm{SE}(\widehat{\beta}_1) = 10$. Para el cálculo exacto, **suponemos** $n = 22$ en regresión simple.

$$H_0 : \beta_1 = 0, \qquad H_1 : \beta_1 \neq 0, \qquad \nu = 22 - 2 = 20.$$

Cálculo y decisión al 5 %

$$t_{\text{obs}} = \frac{65 - 0}{10} = 6{,}5, \qquad 6{,}5 > 2{,}086.$$

$$p = 2[1 - F_{20}(6{,}5)] \approx 0{,}00000246 < 0{,}05.$$

Rechazamos H_0 por ambos métodos.

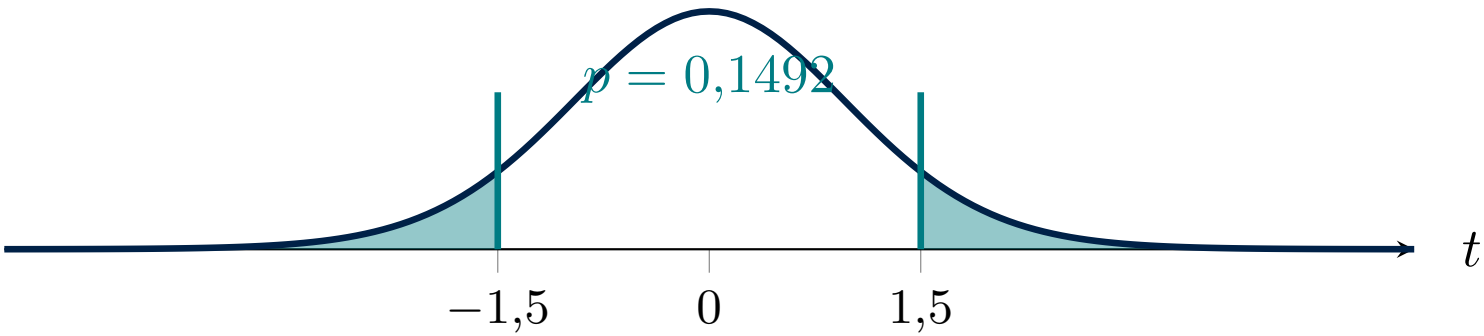
Interpretación: la estimación está 6,5 errores estándar por encima de cero. Hay evidencia estadística de una pendiente distinta de cero.

La conclusión usa los supuestos de la prueba. Por sí sola, la significancia estadística no establece una relación causal.

Ejemplo numérico: no rechazar H_0

Ahora $\widehat{\beta}_1 = 6$, $\mathrm{SE}(\widehat{\beta}_1) = 4$ y $\nu = 20$.

$$H_0 : \beta_1 = 0, \qquad H_1 : \beta_1 \neq 0, \qquad t_{\text{obs}} = \frac{6}{4} = 1{,}5.$$



No rechazamos al 5 %: $p = 0{,}1492 > 0{,}05$ y $1{,}5 < 2{,}086$.

Interpretación

La muestra no aporta evidencia suficiente para distinguir la pendiente de cero al nivel elegido. Esto no demuestra que $\beta_1 = 0$.

Conexión con el intervalo de confianza

Con el mismo modelo y error estándar, el IC bilateral al 95 % es

$$\widehat{\beta}_1 \pm t_{\nu;\,0{,}975}\ \mathrm{SE}(\widehat{\beta}_1).$$

Ejemplo: $\widehat{\beta}_1 = 65$, SE $= 10$ y $\nu = 20$

$$65 \pm 2{,}086 \cdot 10 = [44{,}14\,;\ 85{,}86].$$

El intervalo excluye cero. La prueba bilateral de $H_0 : \beta_1 = 0$ rechaza al 5 %.

Para muestras grandes, $t_{\nu;\,0{,}975} \approx 1{,}96$ y recuperamos la aproximación de las diapositivas originales:

$$65 \pm 1{,}96 \cdot 10 = [45{,}4\,;\ 84{,}6].$$

La equivalencia corresponde a una prueba bilateral y un IC construidos con el mismo método. En el caso límite, $p = \alpha$ sitúa el valor nulo en un extremo del IC.

Significancia estadística y económica

Significancia estadística

¿La estimación se distingue de cero dada su incertidumbre?

$$|t_{\text{obs}}| \text{ grande}, \qquad p \text{ pequeño}.$$

Depende de la magnitud estimada y del error estándar.

Significancia económica

¿La magnitud del coeficiente importa para la decisión?

Requiere conocer las unidades, la escala y el contexto económico.

Un efecto muy pequeño puede estimarse con mucha precisión. Un efecto relevante puede tener un error estándar grande.

Causalidad

Para una interpretación causal también se necesitan supuestos de identificación, como la media condicional cero del error.

Actividad en clases

Trabajen en parejas durante 10 minutos. Un investigador estima

$$\widehat{salario}_i = 280 + 62\, educ_i, \qquad R^2 = 0{,}42, \qquad \mathrm{SE}(\widehat{\beta}_1) = 8.$$

Para este ejercicio: salario mensual en miles de pesos, educación en años, $n = 22$ y supuestos clásicos normales.

1. Interpreten $\widehat{\beta}_1 = 62$ y $R^2 = 0{,}42$.
2. Para $H_0 : \beta_1 = 0$ frente a $H_1 : \beta_1 \neq 0$, calculen t_{obs} y los grados de libertad.
3. Dibujen la distribución bajo H_0, las zonas de rechazo al 5 % y la posición de t_{obs}.
4. ¿Qué área representa el p-valor? ¿Se rechaza H_0?
5. ¿Qué falta para concluir que la educación causa mayores salarios?

Actividad: solución y lectura económica

Pendiente: un año adicional de educación se asocia con 62 mil pesos más de salario mensual estimado.

Ajuste: la recta explica el 42 % de la variación muestral del salario alrededor de su media.

Prueba bilateral

$$\nu = 22 - 2 = 20, \qquad t_{\text{obs}} = \frac{62}{8} = 7{,}75.$$

$$|t_{\text{obs}}| > 2{,}086, \qquad p = 2[1 - F_{20}(7{,}75)] \approx 1{,}90 \times 10^{-7}.$$

Rechazamos H_0 al 5 %. El área del p-valor suma las dos colas más allá de $-7{,}75$ y $7{,}75$.

Causalidad: la regresión y el p-valor no bastan. Debemos justificar, entre otros supuestos, que educación no esté correlacionada con factores omitidos del salario.

Lectura de una prueba t

1. La hipótesis alternativa define si miramos una o dos colas.
2. El estadístico t mide la distancia al valor nulo en errores estándar.
3. La región de rechazo tiene probabilidad α bajo H_0 en una prueba exacta. Ese es el error tipo I: rechazar una hipótesis nula verdadera.
4. El p-valor mide, bajo H_0, la probabilidad de resultados al menos tan extremos como el observado.
5. Comparar p con α y comparar t con los valores críticos produce la misma decisión.

Al interpretar

No rechazar deja incertidumbre sobre el parámetro. Rechazar requiere todavía evaluar la magnitud económica y los supuestos para una lectura causal.

Referencias base del curso

Bibliografía principal

- Stock, J. H. y Watson, M. W. (2012). *Introducción a la econometría*. 3.ª edición. Madrid: Pearson Educación.
- Wooldridge, J. M. (2010). *Introducción a la econometría: un enfoque moderno*. 4.ª edición. México: Cengage Learning.

Lectura sugerida para este tema

- Stock y Watson, capítulo 4: regresión lineal con regresor único.
- Stock y Watson, capítulo 5: contrastes de hipótesis e intervalos de confianza con regresor único.
- Wooldridge, capítulo 2: modelo de regresión simple.

Estas notas son una adaptación de las slides del profesor Cliff Bahamondes Poblete, según la atribución del material original.