Econometría Aplicada I

Modelo de Regresión Lineal Multiple

Angelo Díaz

Universidad de Santiago de Chile
Departamento de Economía
Facultad de Administración y Economía

Modelo de Regresión Lineal Múltiple

- Hasta ahora hemos considerado el modelo de regresión con una variable explicativa x.
- El análisis de regresión lineal múltiple es útil pues nos permite controlar explícitamente por otros factores que afectan a y. Esto es muy importante sobre todo porque no trabajamos con datos experimentales.
- Adicionalmente, si añadimos más factores al modelo, entonces más variación de y puede ser explicada.
- Otra ventaja es que el análisis de regresión mútiple nos permite explorar formas funcionales más ricas.
- Aunque nuestro interés fundamental es el efecto concreto de una determinada variable x_1 sobre un fenómeno económico y, generalmente entran en juego factores adicionales $x_2, ..., x_k$.
- Dichos factores adicionales están, generalmente, relacionados con x_1.
- Recordemos que todos los factores no incorporados al modelo están contenidos en el error del modelo, u.

Modelo de Regresión Lineal Múltiple

- En la medida en que x_1 esté correlacionado con $x_2, ..., x_k$, en el modelo simple, el término inobservable no verificará $\mathbb{E}(u|x_1) = 0$.
- En tal caso, debemos incorporar los factores adicionales $x_2, ..., x_k$ al modelo para poder aislar el efecto causal de dicha variable.
- El modelo poblacional con k variables explicativas puede ser escrito:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + ... + \beta_k x_k + u$$

- Desde que tenemos k variables explicativas y el intercepto, tenemos $k + 1$ parámetros desconocidos que queremos estimar utilizando un muestra aleatoria de $(x_1, x_2, ..., x_k, y)$.
- La interpretación de u sigue siendo la misma: todos aquellos factores que afectan a y pero que no están incluidas en el modelo.
- β_0 es el término constante o intercepto.
- $\beta_1, \beta_2, ..., \beta_k$ se denominan parámetros de pendiente.
- β_j refleja la variación en y ante un aumento de una unidad en x_j, manteniendo fijas $x_1, ..x_{j-1}, x_{j+1}, ..., x_k$, además de los factores incluidos en u.

Ejemplo

- Considere el modelo para determinar el sueldo de un CEO:

$$\log(w) = \beta_0 + \beta_1 \log(ventas) + \beta_2\, ant + \beta_3\, ant^2 + u$$

  donde *ventas* representa el volumen de ventas de la empresa y *ant* es la antiguedad del CEO en la empresa.
- En este caso $k = 3$.
- Note que aunque la variable de antiguedad está al cuadrado, el modelo sigue siendo lineal en los parámetros.
- La clave es:

$$\mathbb{E}(u|x_1, ..., x_k) = 0$$

- Esta premisa de independencia en media implica que ninguna de las variables explicativas $x_1, ..., x_k$ está correlacionada con el error.
- Adicionalmente, implica que la relación funcional entre las variables dependiente y regresoras está correctamente especificada.
- Si alguna de estas x_j está correlacionada con u para alguna j entonces se rompe el supuesto.
- En principio se permiten correlaciones entre las $x_1, ..., x_k$. Es decir, las variables explicativas no tienen qué ser independientes en media entre ellas.

Modelo de Regresión Lineal Múltiple: Estimación

- Veremos como estimar los parámetros del modelo utilizando una muestra aleatoria, $(x_{1i}, x_{2i}, .., x_{ki}, y_i) : i = 1, 2, .., n$, de la población.
- Dado que estos datos proceden de la población definida por el modelo de regresión, para cada observación i, podemos establecer que:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + ... + \beta_k x_{ki} + u_i$$

- Igual que en modelo de regresión simple, el método de estimación por MCO consiste en elegir como estimadores de $\beta_0, \beta_1, \beta_2, ..., \beta_k$ los valores de $b_0, b_1, ..., b_k$ que minimizan la suma de los cuadrados de los residuos, donde los residuos se definen de forma análoga al caso de regresión simple.
- Es decir, se minimiza:

$$\sum_{i=1}^{n} (y_i - b_0 - b_1 x_{1i} - ... - b_k x_{ki})^2$$

- Los coeficientes estimados se obtienen igualando a cero las derivadas parciales.

Forma Matricial

- Dado que regresores (primer subíndice) y observaciones (segundo subíndice) están ordenados en esa forma, podemos reacomodarlos en forma de matriz.
- Definamos

$$X = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{k,1} \\ 1 & x_{1,2} & \cdots & x_{k,2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{k,n} \end{pmatrix}$$

- es la matriz que contiene toda la información sobre las variables explicativas.
- En la primera columna hay sólo 1's porque al coeficiente de intercepto, β_0 lo acompaña un 1.

Forma Matricial

- Usando exactamente la misma lógica, apilamos la información sobre y y u.
- Por tanto:

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \qquad u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}, \qquad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

- Podemos escribir el modelo en forma matricial como:

$$y = X\beta + u$$

Forma Matricial

- Los estimadores MCO minimizan los residuos al cuadrado:

$$\hat{\beta} = \underset{b \in \mathbb{R}^{k+1}}{\text{argmin}} \; SRC = \underset{b \in \mathbb{R}^{k+1}}{\text{argmin}} \; (y - Xb)'(y - Xb)$$

- Entonces:

$$\hat{\beta} = (X'X)^{-1}X'y$$

- Es decir,

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} = (X'X)^{-1}X'y$$

Regresión Lineal Múltiple: un ejemplo usando matrices

Se desea estudiar el consumo de petróleo destinado a calefacción requerido por las familias. Se cree que los grados de temperatura y el grado de aislamiento del desván explican el consumo. Se tomó una muestra de 15 familias, desde donde se extrajo la siguiente información:

Y	X_2	X_3
275,3	40	3
363,8	27	3
164,3	40	10
40,8	73	6
94,3	64	6
230,9	34	6
366,7	9	6
300,6	8	10

Y	X_2	X_3
237,8	23	10
121,4	63	3
31,4	65	10
203,5	41	6
441,1	21	3
323,0	38	3
52,5	58	10

Y: consumo mensual de petróleo (galones). X_2: temperatura promedio diaria (°F). X_3: cantidad de aislamiento en el desván (pulgadas).

Regresión Lineal Múltiple: un ejemplo usando matrices

Las matrices principales son:

$$Y = \begin{pmatrix} 275,3 \\ 363,8 \\ 164,3 \\ 40,8 \\ 94,3 \\ 230,9 \\ 366,7 \\ 300,6 \\ 237,8 \\ 121,4 \\ 31,4 \\ 203,5 \\ 441,1 \\ 323,0 \\ 52,5 \end{pmatrix} \qquad X = \begin{pmatrix} 1 & 40 & 3 \\ 1 & 27 & 3 \\ 1 & 40 & 10 \\ 1 & 73 & 6 \\ 1 & 64 & 6 \\ 1 & 34 & 6 \\ 1 & 9 & 6 \\ 1 & 8 & 10 \\ 1 & 23 & 10 \\ 1 & 63 & 3 \\ 1 & 65 & 10 \\ 1 & 41 & 6 \\ 1 & 21 & 3 \\ 1 & 38 & 3 \\ 1 & 58 & 10 \end{pmatrix}$$

Regresión Lineal Múltiple: un ejemplo usando matrices

Las matrices principales son:

$$(X'X)^{-1} = \begin{pmatrix} 0,66 & -0,01 & -0,05 \\ -0,01 & 0,00 & -0,00 \\ -0,05 & -0,00 & 0,01 \end{pmatrix} \qquad (X'Y) = \begin{pmatrix} 3{,}247,40 \\ 98{,}060,10 \\ 18{,}057,00 \end{pmatrix}$$

$$\hat{\beta} = (X'X)^{-1}X'Y = \begin{pmatrix} 562,1510 \\ -5,4366 \\ -20,0123 \end{pmatrix}$$

$$\hat{Y}_i = 562{,}15 - 5{,}44X_{1i} - 20{,}01X_{2i}$$

- Por simplicidad, imagine que tenemos sólo dos variables explicativas ($k = 2$) y estimamos el modelo:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$

- El intercepto es la predicción para y cuando $x_1 = x_2 = 0$.
- Los estimadores $\hat{\beta}_1$ y $\hat{\beta}_2$ serían los efectos parciales.
- Note que podemos escribir el modelo como

$$\Delta\hat{y} = \hat{\beta}_1 \Delta x_1 + \hat{\beta}_2 \Delta x_2$$

de esta forma podemos ver el efecto de un cambio parcial sobre $\hat{y}$.

- Por ejemplo, si x_2 la dejamos constante ($\Delta x_2 = 0$)

$$\Delta\hat{y} = \hat{\beta}_1 \Delta x_1$$

- La misma lógica aplica para k variables explicativas:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + ... + \hat{\beta}_k x_k$$

- Entonces, el coeficiente de x_1 mide el cambio en $\hat{y}$ debido a un cambio en una unidad en x_1, manteniendo todo lo demás constante.
- Es decir

$$\Delta\hat{y} = \hat{\beta}_1 \Delta x_1$$

  manteniendo $x_2, ..., x_k$ fijos.
- Recuerde que esto también se lee controlando por los otros factores.

Ejemplo

- Queremos predecir el promedio general de calificaciones en la universidad ($colGPA$), a partir del promedio general de calificaciones en el bachillerato ($hsGPA$) y de la calificación en el examen de admisión (ACT).

$$\widehat{colGPA} = 1{,}29 + 0{,}453 hsGPA + 0{,}0094 ACT.$$

- Note que el intercepto, en este caso, no tiene en sí ningún significado.
- con ACT constante, cada punto más en $hsGPA$ se relaciona con 0,453 adicional en el promedio general de la universidad.
- si $hsGPA$ permanece constante, un cambio de 10 puntos en el examen de admisión (ACT) tendrá un efecto sobre $colGPA$ de menos de una décima de punto (en la muestra la puntuación promedio del examen de admisión es de 24 con una desviación estándar menor a tres).
- Centrándose en el análisis de regresión simple que relaciona $colGPA$ sólo con ACT se obtiene:

$$\widehat{colGPA} = 2{,}4 + 0{,}0271 ACT.$$

El coeficiente de ACT es casi el triple del estimado antes.

Cambiar Simultáneamente más de una variable independiente

- La ecuación estimada para explicar $\log(wage)$ en términos de la educación en años ($educ$), años de experiencia en el mercado laboral ($exper$) y años de antiguedad en el empleo actual ($tenure$) es:

$$\log(wage) = 0{,}284 + 0{,}092educ + 0{,}0041exper + 0{,}022tenure.$$

- El coeficiente estimado para $tenure$ indica que, si mantenemos constantes los años de formación y los años de experiencia laboral, un año más de experiencia en la empresa actual predice un incremento del 2,2 % $(100 * 0{,}022)$ en el salario por hora.
- Si queremos obtener el efecto estimado sobre $wage$ cuando una persona permanece un año más en una misma empresa: tanto $exper$ como $tenure$ aumentan en un año. El efecto total (manteniendo $educ$ constante) es

$$\Delta \log(wage) = 0{,}0041\Delta exper + 0{,}022\Delta tenure = 0{,}0041 + 0{,}022 = 0{,}0261,$$

- En este caso el modelo predice un incremento del 2,61 % $(100 * (0{,}0041 + 0{,}022))$ en el salario por hora.

Unidades de Medida: Ejemplo

- Al igual que en el caso de regresión simple, el valor estimado de los parámetros del modelo de regresión depende de las unidades de medida de la variable dependiente y de las variables explicativas.
- En el ejemplo del salario de los CEO de las empresas, se ha estimado el modelo siguiente:

$$\widehat{salary} = 830{,}63 + 19{,}63roe + 0{,}016sales$$

  donde *salary* es el salario anual en miles de dólares, *roe* es el rendimiento medio (en tanto por ciento) de las acciones de la empresa y *sales* son las ventas de la empresa en millones de dólares.
- En base a este modelo estimado tenemos que un aumento de un punto porcentual en el rendimiento de las acciones de la empresa predice un aumento en el salario del director general de 19,63 miles de dólares (19630 dólares).
- Sea $salary100$ el salario en cientos de dólares:
  $salary100 = 10 * salary$, la nueva regresión estimada es:

$$\widehat{salary100} = 8306{,}3 + 196{,}3roe + 0{,}16sales$$

- Este cambio de unidades supone que tenemos que multiplicar todos los coeficientes estimados por 10

Unidades de Medida: Ejemplo

- Si medimos el rendimiento de las acciones en tanto por uno, ¿Cuáles serían los nuevos coeficientes estimados?
  $roe1 = \frac{1}{100} roe$

$$\widehat{salary1}00 = 8306{,}3 + 19630 roe1 + 0{,}16 sales$$

- Este cambio de unidades supone que tenemos que multiplicar por 100 el coeficiente estimado del rendimiento de las acciones
- Al igual que antes, un aumento en un punto porcentual en el rendimiento de las acciones de la empresa predice un aumento en el salario del director general de $19630 * 0{,}01 = 196{,}3$ cientos de dólares (19630 dólares).

Forma Funcional, Ejemplo 1: Log-Log, Log-Nivel

- Utilizando una muestra de hogares españoles se ha estimado un modelo que relaciona el gasto anual del hogar en vestido y calzado, *gvest* (en miles Euros) con la renta anual del hogar, *renta*, (en miles de Euros), el número de adultos en el hogar, *nad*, y el número de hijos menores de 18 años en el hogar, *nhijos*.

  $$\log(gvest) = -1{,}06 + 0{,}49\log(renta) + 0{,}042 nad + 0{,}088 nhijos$$

- La elasticidad-renta estimada del gasto en vestido y calzado es 0,49.
- Si aumentara en 1 el número de hijos, manteniendo constante el número de adultos y la renta, el modelo estimado predice que el gasto en vestido y calzado aumentaría en un 8,8 % ($100 \times 0{,}088 = 8{,}8$)

Forma Funcional: Términos cuadráticos

- En el siguiente modelo

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + u$$

- ¿Cuál es el efecto parcial de x sobre y en este modelo?
- β_1 no mide el efecto parcial, ya que β_1 sería la variación en y ante un aumento de una unidad en x manteniendo constante x^2 lo cual no es posible.
- Para calcular el efecto parcial tenemos que calcular la derivada:

$$\frac{\partial y}{\partial x} = \beta_1 + 2\beta_2 x$$

- y por tanto el efecto parcial (o efecto marginal) de x sobre y, manteniendo constantes el resto de los factores en u.
- En este modelo, el efecto parcial no es constante, puede ser creciente o decreciente dependiendo del signo de β_2.

Forma Funcional, Ejemplo 2: Términos cuadráticos

- Modificando el modelo de salario:

$$\log(wage) = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 expersq + u$$

  Donde $expersq$ es el cuadrado de los años de experiencia laboral

- El efecto parcial de la experiencia es:

$$\frac{\partial \log(wage)}{\partial exper} = \beta_1 + 2\beta_2 exper$$

- La regresión es la siguiente:

$$\widehat{\log(wage)} = 0{,}128 + 0{,}090 educ + 0{,}041 exper - 0{,}00071 expersq$$

- un aumento de un año en la experiencia laboral predice un incremento en el salario por hora del $100(0{,}041 - 2 * 0{,}00071\, exper)\,\%$.
- Para un individuo con 20 años de experiencia un aumento de un año en la experiencia predice un incremento en el salario por hora del $1{,}26\,\%$ $(100(0{,}041 - 2 * 0{,}00071 * 20) = 1{,}26)$.

Valores Ajustados y Residuos

Consideremos el modelo de regresión lineal múltiple:

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + u_i$$

Una vez estimados los coeficientes por MCO, obtenemos:

Valor ajustado

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_k x_{ik}$$

Es el valor de y_i predicho por el modelo.

Residuo

$$\hat{u}_i = y_i - \hat{y}_i$$

Es la diferencia entre el valor observado y el predicho.

Interpretación:

- Si $\hat{u}_i > 0$, el modelo subestima y_i.
- Si $\hat{u}_i < 0$, el modelo sobreestima y_i.
- Si $\hat{u}_i = 0$, la predicción es exacta.

Propiedades Algebraica

- La suma, y por tanto la media muestral, de los residuos es cero: $\frac{1}{n}\sum_{i=1}^{n}\hat{u}_i = 0$
- El promedio muestral de los residuales es cero por lo que $\bar{y} = \overline{\hat{y}}$. La media de los valores ajustados coincide con la media de los valores observados.
- La covarianza muestral entre cada una de las variables independientes y los residuales de MCO es cero: $\frac{1}{n-1}\sum_{i=1}^{n} x_{ji}\hat{u}_i = 0.$
- Por consiguiente, la covarianza muestral entre los valores ajustados de MCO y los residuales de MCO es cero: $\frac{1}{n-1}\sum_{i=1}^{n} \hat{y}_i\hat{u}_i = 0.$
- El punto $(\bar{x}_1, \bar{x}_2, ..., \bar{x}_k, \bar{y})$ se encuentra siempre sobre la línea de regresión de MCO.

Propiedades algebráicas de MCO - Explicación

El método de Mínimos Cuadrados Ordinarios selecciona los coeficientes que minimizan:

$$\min_{\beta_0,\ldots,\beta_k} \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{k} \beta_j x_{ij} \right)^2$$

Equivalentemente:

$$\min_{\beta_0,\ldots,\beta_k} \sum_{i=1}^{n} u_i^2$$

Condiciones de primer orden

En el mínimo, las derivadas respecto de cada coeficiente deben ser iguales a cero:

$$\frac{\partial SRC}{\partial \beta_0} = 0, \qquad \frac{\partial SRC}{\partial \beta_j} = 0$$

para $j = 1, \ldots, k$.

Clave: Las propiedades algebraicas de MCO son consecuencias directas de estas condiciones de minimización.

Propiedad 1: La Suma de los Residuos es Cero

La función objetivo es:

$$SRC = \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{k} \beta_j x_{ij} \right)^2$$

Derivando respecto del intercepto β_0:

$$\frac{\partial SRC}{\partial \beta_0} = -2 \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{k} \beta_j x_{ij} \right)$$

Evaluando en los estimadores MCO:

$$-2 \sum_{i=1}^{n} \hat{u}_i = 0$$

Por lo tanto: $\sum_{i=1}^{n} \hat{u}_i = 0$

Interpretación: La suma de los errores de predicción positivos compensa exactamente la suma de los negativos.

Propiedad 1: La Media de los Residuos es Cero

Sabemos que: $\sum_{i=1}^{n} \hat{u}_i = 0$
Dividiendo ambos lados por el número de observaciones:

$$\frac{1}{n} \sum_{i=1}^{n} \hat{u}_i = 0$$

Por definición de promedio muestral:

Resultado

$$\boxed{\overline{\hat{u}} = 0}$$

¿Qué significa?

- En promedio, los residuos de MCO son cero.
- No significa que todos los residuos sean cero.
- Tampoco significa que el modelo prediga correctamente cada observación.

Importante

Esta propiedad se cumple exactamente en la muestra utilizada para estimar MCO, siempre que el modelo incluya un intercepto.

Propiedad 2: Medias Observadas y Ajustadas

Para cada observación se cumple: $y_i = \hat{y}_i + \hat{u}_i$
Sumando sobre todas las observaciones:

$$\sum_{i=1}^{n} y_i = \sum_{i=1}^{n} \hat{y}_i + \sum_{i=1}^{n} \hat{u}_i$$

Como $\sum_{i=1}^{n} \hat{u}_i = 0$:

$$\sum_{i=1}^{n} y_i = \sum_{i=1}^{n} \hat{y}_i$$

Dividiendo por n:

Segunda propiedad

$$\boxed{\bar{y} = \overline{\hat{y}}}$$

Interpretación:
El modelo MCO reproduce exactamente el promedio de la variable dependiente dentro de la muestra, aunque sus predicciones individuales puedan ser incorrectas.

Propiedad 3: Ortogonalidad con los Regresores

Consideremos la derivada de la suma de cuadrados respecto de un coeficiente β_j:

$$\frac{\partial SRC}{\partial \beta_j} = -2 \sum_{i=1}^{n} x_{ij} \left(y_i - \beta_0 - \sum_{\ell=1}^{k} \beta_\ell x_{i\ell} \right)$$

La condición de primer orden implica:

$$-2 \sum_{i=1}^{n} x_{ij} \hat{u}_i = 0$$

Por lo tanto:

Tercera propiedad

$$\boxed{\sum_{i=1}^{n} x_{ij} \hat{u}_i = 0} \qquad j = 1, \ldots, k$$

Interpretación: Los residuos de MCO son ortogonales a cada variable explicativa utilizada en la estimación. Esta condición se cumple para cada regresor, no solamente para uno de ellos.

Propiedad 3: Covarianza entre X y los Residuos

Recordemos la definición de covarianza muestral:

$$\widehat{\text{Cov}}(x_j, \hat{u}) = \frac{1}{n-1}\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)(\hat{u}_i - \overline{\hat{u}})$$

Dado que $\overline{\hat{u}} = 0$:

$$= \frac{1}{n-1}\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)\hat{u}_i$$

Expandiendo:

$$= \frac{1}{n-1}\left[\underbrace{\sum_{i=1}^{n} x_{ij}\hat{u}_i}_{=0} - \bar{x}_j \underbrace{\sum_{i=1}^{n}\hat{u}_i}_{=0}\right]$$

Resultado

$$\boxed{\widehat{\text{Cov}}(x_j, \hat{u}) = 0}$$

Propiedad 4: Ortogonalidad con Valores Ajustados

Recordemos que: $\hat{y}_i = \hat{\beta}_0 + \sum_{j=1}^{k} \hat{\beta}_j x_{ij}$
Multiplicando por el residuo y sumando:

$$\sum_{i=1}^{n} \hat{y}_i \hat{u}_i = \sum_{i=1}^{n} \left(\hat{\beta}_0 + \sum_{j=1}^{k} \hat{\beta}_j x_{ij} \right) \hat{u}_i$$

Reordenando:

$$= \hat{\beta}_0 \underbrace{\sum_{i=1}^{n} \hat{u}_i}_{=0} + \sum_{j=1}^{k} \hat{\beta}_j \underbrace{\sum_{i=1}^{n} x_{ij} \hat{u}_i}_{=0}$$

En consecuencia:

Cuarta propiedad

$\sum_{i=1}^{n} \hat{y}_i \hat{u}_i = 0; \quad \widehat{\text{Cov}}(\hat{y}, \hat{u}) = 0$

Los valores ajustados y los residuos son ortogonales en la muestra.

Propiedad 5: La Regresión Pasa por las Medias

La ecuación estimada es: $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_k x_{ik}$
Tomando promedios:

$$\overline{\hat{y}} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}_1 + \cdots + \hat{\beta}_k \bar{x}_k$$

Como sabemos que $\overline{\hat{y}} = \bar{y}$:

Quinta propiedad

$$\boxed{\bar{y} = \hat{\beta}_0 + \sum_{j=1}^{k} \hat{\beta}_j \bar{x}_j}$$

Despejando el intercepto:

$$\boxed{\hat{\beta}_0 = \bar{y} - \sum_{j=1}^{k} \hat{\beta}_j \bar{x}_j}$$

Interpretación: Si reemplazamos todos los regresores por sus promedios muestrales, el modelo predice exactamente $\bar{y}$.
En regresión múltiple, esta propiedad corresponde a un hiperplano que pasa por el punto de medias.

Ejemplo Numérico: Regresión Múltiple

Supongamos que tenemos cuatro observaciones y dos variables explicativas:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i$$

Observación	x_1	x_2	y
1	0	0	1
2	1	0	2
3	0	1	3
4	1	1	6

Al estimar por MCO obtenemos:

$$\boxed{\hat{y}_i = 0{,}5 + 2x_{i1} + 3x_{i2}}$$

Por ejemplo, para la observación 2:

$$\hat{y}_2 = 0{,}5 + 2(1) + 3(0) = 2{,}5$$

Por lo tanto, su residuo es:

$$\hat{u}_2 = y_2 - \hat{y}_2 = 2 - 2{,}5 = -0{,}5$$

El modelo sobreestima el valor observado en 0,5 unidades.

Verificando las Propiedades de MCO

Usando $\hat{y}_i = 0{,}5 + 2x_{i1} + 3x_{i2}$:

i	y_i	$\hat{y}_i$	$\hat{u}_i$	$x_{i1}\hat{u}_i$
1	1	0.5	0.5	0
2	2	2.5	-0.5	-0.5
3	3	3.5	-0.5	0
4	6	5.5	0.5	0.5
Suma	12	12	0	0

Propiedad 1: $\sum_{i=1}^{4} \hat{u}_i = 0{,}5 - 0{,}5 - 0{,}5 + 0{,}5 = 0$

Propiedad 2: $\bar{y} = \frac{12}{4} = 3 \qquad \overline{\hat{y}} = \frac{12}{4} = 3$

Propiedad 3:

$$\sum_{i=1}^{4} x_{i1}\hat{u}_i = -0{,}5 + 0{,}5 = 0$$

También se verifica que:

$$\sum_{i=1}^{4} x_{i2}\hat{u}_i = -0{,}5 + 0{,}5 = 0$$

¿Qué NO Implican estas Propiedades?

Hemos demostrado que, en la muestra: $\sum_{i=1}^{n} x_{ij}\hat{u}_i = 0$
Sin embargo, esto NO implica necesariamente que:

$$\mathbb{E}[u_i \mid X_i] = 0$$

Distinción fundamental

- $\hat{u}_i$: residuo calculado después de estimar el modelo.
- u_i: error poblacional, que contiene factores no observados que afectan a y_i.

Por lo tanto:

- Los residuos son ortogonales a los regresores por construcción de MCO.
- Esto no elimina la endogeneidad.
- Puede existir sesgo por variables omitidas, simultaneidad o errores de medición.

Takeaway

Que los residuos no estén correlacionados con X dentro de la muestra NO demuestra que se cumpla el supuesto de exogeneidad.

Ejemplo Regresión Stata

```
. reg lwage educ exper
```

	SS	df	MS
Model	36.9850408	2	18.4925204
Residual	111.344721	523	.212896216
Total	148.329762	525	.28253288

Number of obs	= 526
F(2, 523)	= 86.86
Prob > F	= 0.0000
R-squared	= 0.2493
Adj R-squared	= 0.2465
Root MSE	= .46141

lwage	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
educ	.0979356	.0076224	12.85	0.000	.0829613	.1129099
exper	.0103469	.0015551	6.65	0.000	.0072919	.013402
_cons	.2168543	.108595	2.00	0.046	.0035183	.4301904

Valores Ajustados y Residuos en Stata

```
. predict ygorro  (option xb assumed; fitted values)
. predict residual, resid
. list lwage educ exper ygorro residual in 1/10
```

	lwage	educ	exper	ygorro	residual
1	1.131402	11	2	1.31484	−.1834375
2	1.175573	12	22	1.619714	−.4441411
3	1.098612	11	2	1.31484	−.2162276
4	1.791759	8	44	1.455605	.3361544
5	1.667707	12	7	1.46451	.2031971
6	2.169054	16	9	1.876946	.292108
7	2.420368	18	15	2.134899	.2854691
8	1.609438	12	5	1.443816	.165622
9	1.280934	12	26	1.661102	−.3801679
10	2.900322	17	22	2.109392	.79093

Sumas de cuadrados

- En el modelo de regresión lineal mútiple tenemos las mismas definiciones para las sumas de cuadrados.
- Suma total de cuadrados (STC):

$$STC = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

- Suma explicada de cuadrados (SEC):

$$SEC = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$

- Suma de residuales cuadrados (SRC):

$$SRC = \sum_{i=1}^{n} \hat{u}_i^2$$

Bondad del Ajuste

- Entonces:

$$STC = SEC + SRC$$

- El R-cuadrado de la regresión (a veces llamado coeficiente de determinación), se define como

$$R^2 = \frac{SEC}{STC} = 1 - \frac{SRC}{STC}$$

- El R^2 es el cociente de la variación explicada sobre la variación total.
- El R^2 se interpreta como la proporción de la variación muestral en y que es explicada por la variación en x.
- El $R^2 \in [0, 1]$ dado que la suma explicada no puede ser mayor a la suma total.
- Si multiplicamos $R^2 * 100$ podemos interpretarlo como porcentaje de la variación muestral en y que es explicada por la variación en x.

Bondad del Ajuste

- El R^2 mide la proporción de la variabilidad de la variable dependiente que viene explicada por las variables explicativas del modelo y siempre cumple la condición:
$$0 \leq R^2 \leq 1$$
- El valor del R^2 no puede disminuir (y generalmente aumenta) cuando introducimos una variable explicativa adicional en el modelo. El motivo es que al incluir una variable adicional la STC no varía (ya que solo depende de la variable dependiente) mientras que la SRC disminuye (o permanece constante).
- En ciencias sociales los R^2 bajos son bastante frecuentes, sobre todo cuando, como haremos este curso, trabajamos con datos de corte transversal.
- El hecho de que obtengamos un R^2 bajo no quiere decir que la estimación MCO no sea útil. La estimación MCO puede proporcionar una buena estimación de los efectos parciales de las distintas variables aunque el R^2 sea bajo.

Relacionemos esto con el ejemplo

Sabemos que: $y_i = \hat{y}_i + \hat{u}_i$ y $\bar{y} = \overline{\hat{y}}$

Restando $\bar{y}$:

$$y_i - \bar{y} = (\hat{y}_i - \bar{y}) + \hat{u}_i$$

Elevando al cuadrado y sumando:

$$\sum_{i=1}^{n}(y_i - \bar{y})^2 = \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2 + \sum_{i=1}^{n}\hat{u}_i^2 + 2\sum_{i=1}^{n}(\hat{y}_i - \bar{y})\hat{u}_i$$

El último término es cero porque $\sum \hat{y}_i \hat{u}_i = 0$ y $\sum \hat{u}_i = 0$.

Descomposición fundamental

$$\boxed{SCT = SCE + SCR}$$

$$\underbrace{\sum(y_i - \bar{y})^2}_{SCT} = \underbrace{\sum(\hat{y}_i - \bar{y})^2}_{SCE} + \underbrace{\sum \hat{u}_i^2}_{SCR}$$

La variación total se divide entre la variación explicada y la no explicada por el modelo.

Consecuencia: El Coeficiente de Determinación

A partir de la descomposición: $SCT = SCE + SCR$
Definimos el coeficiente de determinación:

$$\boxed{R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}}$$

Para nuestro ejemplo:

$$SCT = (1-3)^2 + (2-3)^2 + (3-3)^2 + (6-3)^2 = 14$$

$$SCR = 4(0{,}5)^2 = 1$$

Por tanto:

$$R^2 = 1 - \frac{1}{14} \approx 0{,}929$$

Interpretación

El modelo explica aproximadamente el 92,9 % de la variación muestral de y.

Takeaway

Un R^2 elevado no garantiza que los coeficientes estimados sean insesgados, consistentes o que tengan interpretación causal.

Otra interpretación de los estimadores de MCO

- Supongamos que tenemos sólo dos variables explicativas y estimamos el modelo:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2.$$

- El procedimiento usual para calcular $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2$ es resolviendo el sistema de ecuaciones normales. En términos matriciales:

$$\hat{\beta} = (X'X)^{-1} X'y$$

- Otro procedimiento para obtener $\hat{\beta}_1$ es el siguiente:
  - Hacer la regresión de la primera variable independiente, x_1, sobre la segunda variable independiente, x_2: $\hat{x}_{i1} = \hat{\gamma}_0 + \hat{\gamma}_1 x_{i2}$ y obtener los residuos: $\hat{r}_{i1} = x_{i1} - \hat{x}_{i1}$
  - Hacer la regresión simple de y sobre los residuos de la primera estimación. El resultado de esta regresión es:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} \hat{r}_{i1} y_i}{\sum_{i=1}^{n} \hat{r}_{i1}^2} \qquad \text{recuerde que} \quad \frac{1}{n} \sum \hat{r}_{i1} = 0$$

Otra interpretación de los estimadores de MCO (continuación)

- ¿Porqué funciona? $\hat{r}_{i1}$ es x_{i1} después de que los efectos parciales de x_{i2} han sido descontados. $\hat{\beta}_1$ mide la relación muestral entre y y x_1 después de descontar los efectos parciales de x_2.
- $\hat{r}_{i1}$ son la parte de x_{i1} que no está correlacionada con x_{i2}. Es decir, $\hat{r}_1$ es lo que queda de x_1 después de haber depurado el efecto de x_2.

Recuerde el Ejemplo

```
. reg lwage educ exper
```

	SS	df	MS
Model	36.9850408	2	18.4925204
Residual	111.344721	523	.212896216
Total	148.329762	525	.28253288

Number of obs	= 526
F(2, 523)	= 86.86
Prob > F	= 0.0000
R-squared	= 0.2493
Adj R-squared	= 0.2465
Root MSE	= .46141

lwage	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
educ	.0979356	.0076224	12.85	0.000	.0829613	.1129099
exper	.0103469	.0015551	6.65	0.000	.0072919	.013402
_cons	.2168543	.108595	2.00	0.046	.0035183	.4301904

Valores Ajustados y Residuos en Stata

```
. predict ygorro  (option xb assumed; fitted values)
. predict residual, resid
. list lwage educ exper ygorro residual in 1/10
```

	lwage	educ	exper	ygorro	residual
1	1.131402	11	2	1.31484	−.1834375
2	1.175573	12	22	1.619714	−.4441411
3	1.098612	11	2	1.31484	−.2162276
4	1.791759	8	44	1.455605	.3361544
5	1.667707	12	7	1.46451	.2031971
6	2.169054	16	9	1.876946	.292108
7	2.420368	18	15	2.134899	.2854691
8	1.609438	12	5	1.443816	.165622
9	1.280934	12	26	1.661102	−.3801679
10	2.900322	17	22	2.109392	.79093

Ejemplo

```
. reg educ exper
```

	SS	df	MS
Model	361.182951	1	361.182951
Residual	3664.24671	524	6.99283723
Total	4025.42966	525	7.66748506

Number of obs	= 526
$F(1, 524)$	= 51.65
Prob > F	= 0.0000
R-squared	= 0.0897
Adj R-squared	= 0.0880
Root MSE	= 2.6444

educ	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
exper	−.0611132	.0085035	−7.19	0.000	−.0778184	−.044408
_cons	13.60271	.1850242	73.52	0.000	13.23923	13.96619

Ejemplo

```
. predict rgorro, resid
. reg lwage rgorro
```

	SS	df	MS
Model	35.145171	1	35.145171
Residual	113.184591	524	.216001127
Total	148.329762	525	.28253288

Number of obs	= 526
F(1, 524)	= 162.71
Prob > F	= 0.0000
R-squared	= 0.2369
Adj R-squared	= 0.2355
Root MSE	= .46476

lwage	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
rgorro	.0979356	.0076778	12.76	0.000	.0828526	.1130186
_cons	1.623268	.0202645	80.10	0.000	1.583459	1.663078

Ejemplo: C3.5. Wooldridge

```
. reg lwage educ exper tenure
```

	SS	df	MS
Model	46.8741776	3	15.6247259
Residual	101.455574	522	.194359337
Total	148.329751	525	.28253286

Number of obs	= 526
F(3, 522)	= 80.39
Prob > F	= 0.0000
R-squared	= 0.3160
Adj R-squared	= 0.3121
Root MSE	= .44086

lwage	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
educ	.092029	.0073299	12.56	0.000	.0776292	.1064288
exper	.0041211	.0017233	2.39	0.017	.0007357	.0075065
tenure	.0220672	.0030936	7.13	0.000	.0159897	.0281448
_cons	.2843595	.1041904	2.73	0.007	.0796756	.4890435

Ejemplo

```
. reg educ exper tenure
```

	SS	df	MS
Model	407.946311	2	203.973156
Residual	3617.48335	523	6.91679416
Total	4025.42966	525	7.66748506

Number of obs	= 526
F(2, 523)	= 29.49
Prob > F	= 0.0000
R-squared	= 0.1013
Adj R-squared	= 0.0979
Root MSE	= 2.63

educ	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
exper	−.0737851	.0097609	−7.56	0.000	−.0929604	−.0546098
tenure	.0476795	.0183371	2.60	0.010	.011656	.0837031
_cons	13.57496	.1843245	73.65	0.000	13.21286	13.93707

```
. predict rhat, resid
```

Ejemplo

```
. reg lwage rhat
```

	SS	df	MS
Model	30.6376773	1	30.6376773
Residual	117.692074	524	.224603195
Total	148.329751	525	.28253286

Number of obs	= 526
F(1, 524)	= 136.41
Prob > F	= 0.0000
R-squared	= 0.2066
Adj R-squared	= 0.2050
Root MSE	= .47392

lwage	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
rhat	.092029	.0078796	11.68	0.000	.0765495	.1075085
_cons	1.623268	.020664	78.56	0.000	1.582674	1.663863

Comparación entre las Estimaciones de la RLS y la RLM

- Comparemos los resultados de los modelos de RLM y RLS del logaritmo del salario sobre los años de formación y los años de experiencia laboral
- RLM:

$$\widehat{\log(wage)} = 0{,}217 + 0{,}098educ + 0{,}01exper$$

- RLS:

$$\widehat{\log(wage)} = 0{,}584 + 0{,}083educ$$

- En el RLS el coeficiente estimado de *educ* mide la variación porcentual en el salario ante un aumento de un año en la educación, sin mantener constante la experiencia.
- Mientras que en el RLM se mantiene constante la experiencia.
- Dado que hay una correlación negativa entre experiencia laboral y educación, en el RLS un aumento en un año en la educación conlleva una disminución en la experiencia laboral, y como una disminución de la experiencia tiene un efecto negativo sobre el salario, el coeficiente de la RLS es más pequeño que el de la RLM.

Comparación entre las Estimaciones de la RLS y la RLM

- Escriba la regresión simple de y sobre x_1 como $\tilde{y} = \tilde{\beta}_0 + \tilde{\beta}_1 x_1$, y la regresión múltiple como $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$. Existe la siguiente relación entre $\tilde{\beta}_1$ y $\hat{\beta}_1$:

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \tilde{\delta}_1$$

  donde $\tilde{\delta}_1$ es el coeficiente de pendiente de la regresión simple de x_{i2} sobre x_{i1}. Esta ecuación muestra que hay dos casos en los que $\tilde{\beta}_1$ y $\hat{\beta}_1$ son iguales:

  1. El efecto parcial de x_2 sobre $\hat{y}$ es cero en la muestra. Es decir, $\hat{\beta}_2 = 0$.
  2. x_1 y x_2 no están correlacionadas en la muestra. Es decir, $\tilde{\delta}_1 = 0$.

- la fórmula anterior puede emplearse para identificar por qué estas estimaciones pueden ser o muy diferentes o bastante similares.
- Por ejemplo, si $\hat{\beta}_2$ es pequeño, puede esperarse que las estimaciones de β_1 en la regresión simple y en la regresión múltiple sean parecidos.

Comparación entre las Estimaciones de la RLS y la RLM

- Hay dos escenarios donde los modelos coinciden:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1}, \quad \text{y} \quad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + ... + \hat{\beta}_k x_{ik}$$

- El primero es cuando $\hat{\beta}_2 = \hat{\beta}_3 = ... = \hat{\beta}_k = 0$.
- El segundo, cuando x_1 no está correlacionado con ninguna otra variable explicativa en la muestra.
- Si no hay correlación (en la muestra) entonces correr la regresión de y sobre x_1 (modelo simple) produce el mismo estimador que la regresión de y sobre $x_1, ..., x_k$.

Supuestos de MCO - RLM

- **Supuesto RLM.1 (Lineal en los parámetros)**. El modelo poblacional puede expresarse como:

$$y = \beta_0 + \beta_1 x_1 + ... + \beta_k x_k + u,$$

- **Supuesto RLM.2 (Muestreo aleatorio)**. Se tiene una muestra aleatoria de n observaciones, $\{(x_{i1}, x_{i2}, ..., x_{ik}, y_i) : i = 1, 2, ..., n\}$, que sigue el modelo poblacional del supuesto RLM.1. Esto implica que dada una observación obtenida de manera aleatoria de la población, se tiene:

$$y_i = \beta_0 + \beta_1 x_{i1} + ... + \beta_k x_{ik} + u_i,$$

- **Supuesto RLM.3 (No hay colinealidad perfecta)**. En la muestra (y por tanto en la población), ninguna de las variables independientes es constante y no hay ninguna relación lineal exacta entre las variables independientes.
- **Supuesto RLM.4 (Media condicional cero)**. El valor esperado del error u, dados los valores de las variables independientes, es cero:

$$\mathbb{E}(u_t | x_1, .., x_k) = 0$$

Supuestos de MCO - RLM

- El supuesto **RLM.1** establece formalmente el modelo poblacional, que es lineal en parámetros.
- El supuesto **RLM.2** es adecuado en muchas aplicaciones (aunque no en todas) cuando trabajamos con datos de corte transversal. Cuando trabajamos con datos de series temporales las observaciones no son en general independientes y el supuesto RLM.2 no se verifica.
- El supuesto **RLM.3** indica que en regresión mútiple además de necesitar la condición de que los valores observados de las variables explicativas no sean todos iguales, se necesita que no haya ninguna relación lineal exacta entre las variables explicativas.
- Cuando en un modelo de regresión una de las variables explicativas es función lineal de otras, se dice que hay un problema de **colinealidad perfecta**.

Supuestos de MCO - RLM

- El supuesto **RLM.4** puede fallar si la relación entre la variable dependiente y las variables explicativas no se especifica adecuadamente. Por ejemplo si el modelo poblacional incluye como variable explicativa una variable y su cuadrado y no incluimos el cuadrado en la regresión, fallará el supuesto RLM.4.
- El Supuesto **RLM.4** también fallará si se omite un factor importante que está correlacionado con cualquiera de las variables explicativas del modelo.

Insesgamiento de Los Estimadores de MCO

Teorema. (Insesgamiento de los estimadores de MCO). Bajo los supuestos RLM.1 a RLM.4:

$$\mathbb{E}(\hat{\beta}_j) = \beta_j, \qquad j = 0, 1, ..., k.$$

- Generalmente si uno de los cuatro supuestos que hemos considerado no se verifica, el estimador no será insesgado.
- El supuesto **RLM.4** es el supuesto crucial para la insesgadez del estimador MCO. Si este supuesto falla, los estimadores estarán en general sesgados.

Inclusión de Variables Irrelevantes

- Suponga que el siguiente modelo satisface los supuestos RLM.1 a RLM.4 y supongamos que la variable x_3 es irrelevante, es decir que $\beta_3 = 0$:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u,$$

- Puesto que desconocemos el valor de β_3 en la población, estimamos el modelo incluyendo la variable x_3. **¿Cuáles son las consecuencias sobre el estimador MCO de incluir una variable irrelevante en el modelo?**
- Incluir una variable irrelevante no tiene ninguna consecuencia sobre la insesgadez de los estimadores MCO, ya que, si se verifican los supuestos RLM.1 a RLM.4, los estimadores MCO son insesgados cualquiera que sea el valor de los parámetros, lo que incluye el caso en el que uno de los parámetros es cero.
- Pero tiene un costo en términos de la precisión de las estimaciones (menos precisas).

Sesgo de variable omitida: caso sencillo

- Suponga que el verdadero modelo poblacional tiene dos variables explicativas y un término de error:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u,$$

Se asume que este modelo satisface los supuestos RLM.1 a RLM.4. El modelo se estima excluyendo x_2:

$$\tilde{y} = \tilde{\beta}_0 + \tilde{\beta}_1 x_1$$

Tenemos que:

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \tilde{\delta}_1$$

donde $\hat{\beta}_1, \hat{\beta}_2$ son los estimadores de pendiente (si se tuvieran) de la regresión múltiple de y sobre x_1 y x_2 y $\tilde{\delta}_1$ es la pendiente de la regresión simple de x_{i2} sobre x_{i1}. Por lo tanto:

$$\mathbb{E}(\tilde{\beta}_1) = \mathbb{E}(\hat{\beta}_1 + \hat{\beta}_2 \tilde{\delta}_1) = \beta_1 + \beta_2 \tilde{\delta}_1$$

$$Sesgo(\tilde{\beta}_1) = \mathbb{E}(\tilde{\beta}_1) - \beta_1 = \beta_2 \tilde{\delta}_1$$

Resumen de los sesgos en $\tilde{\beta}_1$ cuando x_2 es omitida en la ecuación de estimación (3.40)

	Corr$(x_1, x_2) > 0$	**Corr**$(x_1, x_2) < 0$
$\beta_2 > 0$	Sesgo positivo	Sesgo negativo
$\beta_2 < 0$	Sesgo negativo	Sesgo positivo

Varianza de los estimadores de MCO

- **Supuesto RLM.5: Homocedasticidad.** Dado cualquier valor de las variables explicativas, el error u tiene la misma varianza. En otras palabras:

$$\text{Var}(u|x_1, ..., x_k) = \sigma^2.$$

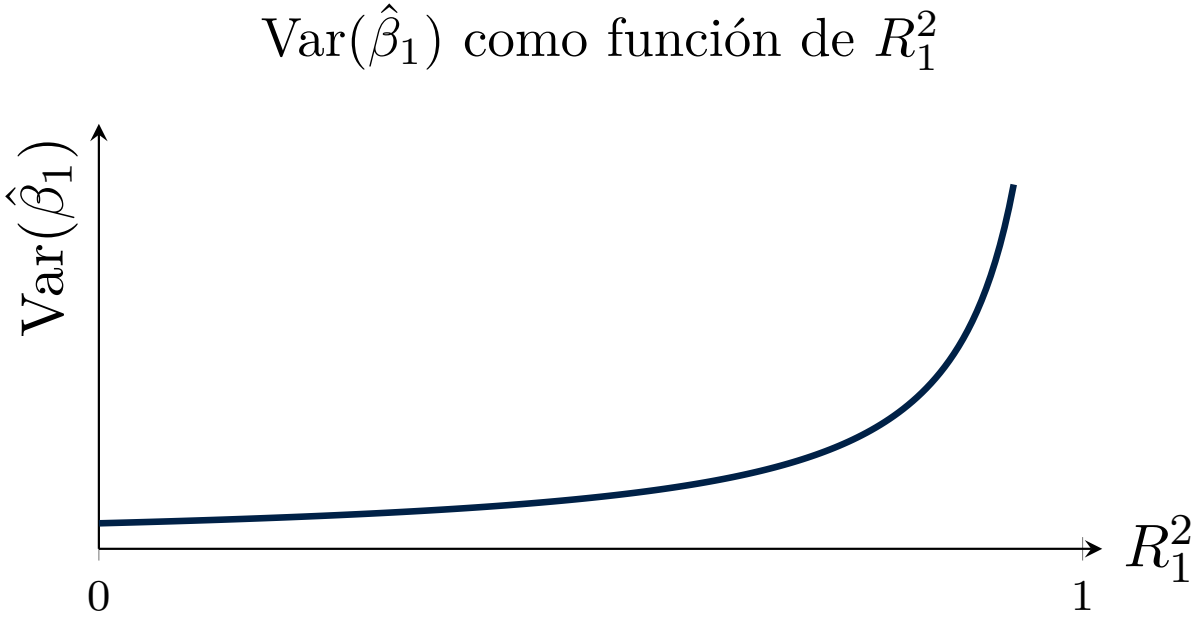
Varianza de los estimadores de MCO

- Bajo los supuestos RLM.1 a RLM.5, condicionales en los valores muestrales de las variables independientes:

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{STC_j(1 - R_j^2)}.$$

  Para $j = 1, 2, ..., k$, donde $STC_j = \sum_{i=1}^{n}(x_{ij} - \bar{x}_j)^2$ y R_j^2 es el R-cuadrado de x_j sobre todas las otras variables independientes, incluyendo un intercepto.
- un σ^2 más grande significa varianzas más grandes para los estimadores de MCO. Si la varianza de las variables no observables que afectan a y es muy grande, es muy difícil estimar los parámetros con precisión.
- Cuanto mayor sea la variación total en x_j, menor será $\text{Var}(\hat{\beta}_j)$. Si la variable x_j tiene muy poca dispersión es muy difícil estimar β_j con precisión.
- Cuanto mayor es el tamaño muestral menor es la varianza de todos los β_j.
- A medida que R_j^2 se aproxima a uno, $\text{Var}(\hat{\beta}_j)$ se hace cada vez más grande.
- Una correlación alta entre las variables explicativas se denomina multicolinealidad.
- Un R_j^2 ‘’cercano” a 1, pero no igual a 1 no supone una violación del supuesto RLM.3.

Varianza de los estimadores de MCO



- Para estimar β_j, lo mejor es tener poca correlación entre x_j y las demás variables independientes.

Varianza de los estimadores de MCO

- Considere el caso de un modelo con dos variables explicativas:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

- En este caso:

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{(n-1)S_{x_1}^2(1-R_1^2)}$$

donde R_1^2 es el R-cuadrado de la regresión de x_1 sobre x_2

- Un valor grande de R_1^2 indica que x_2 explica una gran parte de la variabilidad de x_1 y que por tanto x_1 y x_2 están estrechamente correlacionadas.

Estimación de σ^2

- Al igual que en regresión simple vamos a basar el estimador de la varianza del término de error, σ^2, en la suma de los cuadrados de los residuos.
- Un estimador de σ^2 en el caso general de la regresión múltiple es:

$$\hat{\sigma}^2 = \frac{1}{n-k-1}\sum_{i=1}^{n}\hat{u}_i^2 = \frac{SRC}{n-k-1}$$

- Bajo los supuestos RLM.1 a RLM.5 de Gauss-Markov, $\mathbb{E}(\hat{\sigma}^2) = \sigma^2$.
- A la raíz cuadrada de $\hat{\sigma}^2$, que se denota $\hat{\sigma}$, se le llama error estándar de la regresión (EER)
- $\hat{\sigma}$ es un estimador de la desviación típica del término de error, σ.

Error Estándar de β_j

- Se define la varianza estimada de $\hat{\beta}_j$ como:

$$\widehat{Var}(\hat{\beta}_j) = \frac{\hat{\sigma}^2}{STC_j(1 - R_j^2)}.$$

- Se define el error estándar de $\hat{\beta}_j$ como

$$se(\hat{\beta}_j) = \sqrt{\widehat{Var}(\hat{\beta}_j)} = \frac{\hat{\sigma}}{\sqrt{STC_j(1 - R_j^2)}}.$$

- $se(\hat{\beta}_j)$ es un estimador de la desviación típica de $\hat{\beta}_j$ y por tanto una medida de la precisión de su precisión.

Errores estándar y Unidades de Medida: Ejemplo

- Volvamos al ejemplo del salario de ejecutivos. Los resultados de la estimación incluyendo los errores estándar se suelen presentar de la siguiente forma:

$$\widehat{salary} = 830{,}63 + 19{,}63\, roe + 0{,}016\, sales$$
$$(223{,}91) \qquad (11{,}08) \qquad (0{,}0089)$$

  donde *salary* se mide en miles de dólares, *roe* en tanto por ciento y *sales* en millones de dólares.

- Si medimos ahora el salario en cientos de dólares ($salary100$)

$$\widehat{salary100} = 8306{,}3 + 196{,}3\, roe + 0{,}16\, sales$$
$$(2239{,}1) \qquad (110{,}8) \qquad (0{,}089)$$

- Hay que multiplicar por 10 todos los coeficientes estimados y todos los errores estándar.

Teorema de Gauss-Markov

- Bajo los supuestos RLM.1 a RLM.5, $\hat{\beta}_0, \hat{\beta}_1, ..., \hat{\beta}_k$ son los mejores estimadores lineales insesgados (MELI) de $\beta_0, \beta_1, ..., \beta_k$, respectivamente.