Econometría Aplicada I

Inferencia en el Modelo de Regresión Lineal Múltiple

Angelo Díaz

Universidad de Santiago de Chile
Departamento de Economía
Facultad de Administración y Economía

- Hasta ahora, nuestro modelo nos ha dado un principio para obtener estimadores para los coeficientes β_0 y β_1.
- Adicionalmente, hemos concluido que bajo estos supuestos nuestros estimadores son insesgados y de varianza mínima.
- La pregunta inmediata es cómo decidir si estos estimadores están cerca del verdadero valor.
- Recuerda que los coeficientes de regresión, β_0, β_1, β_2,..., son características desconocidas de las relaciones poblacionales.
- Es decir, nunca podremos conocerlas con total certidumbre.

Recuerdo de RLS

- El resultado que se utilizará es el siguiente:

$$\hat{\beta}_0|x \sim N(\beta_0, V(\hat{\beta}_0|X))$$
$$\hat{\beta}_1|x \sim N(\beta_1, V(\hat{\beta}_1|X))$$

- Donde:

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{STC_1(1 - R_1^2)}.$$

- Usamos este resultado para hacer inferencia sobre β_0 y β_1.
- En particular, intervalos de confianza y pruebas de hipótesis.

- En pocas palabras, probar una hipótesis consta de tres partes.
- En primer lugar, una hipótesis que involucre el parámetro de interés. Siempre hacemos pruebas de hipótesis sobre parámetros.
- En segundo lugar, un estadístico de contraste
- El estadístico de contraste es una función que nos relaciona el estimador y el parámetro relativo a la hipótesis nula.
- El estadístico de contraste, al ser una función del estimador, tiene una distribución muestral.
- Considere el siguiente ejemplo.
- La hipótesis nula (H_0) dice que la media poblacional, μ, es igual a 10:

$$H_0 : \mu = 10$$

- Para conocer la media poblacional habíamos propuesto la media muestral.

- Entonces, lo natural es ver si la media muestral, $\bar{x}$ está cerca de 10.
- Por lo tanto, el estadístico de contraste debe relacionar $\bar{x}$ con el valor de 10.
- La idea es ¿cómo sé que estoy cerca o lejos de 10? Parte de la teoría descansa en formalizar estas ideas de cercanía o lejanía.
- Podríamos proponer, por ejemplo, $|\bar{x} - \mu_{H_0}|$.
- Sin embargo, la varianza en la población podría ser muy alta o muy baja.
- ¿Qué implicancia tiene la varianza sobre $|\bar{x} - \mu_{H_0}|$?

- Recuerde que la media muestral no es robusta.
- Entonces, si hay poca varianza, un valor como $\bar{x} = 11$ podría ser evidencia en contra de $H_0 = 10$.
- Por otro lado, si la varianza poblacional es muy grande, $\bar{x}$ podría ser evidencia a favor de $H_0 = 10$.
- La manera de controlar este efecto es estandarizando la media muestral para tomar en cuenta la varianza poblacional

$$\frac{|\bar{x} - \mu_{H_0}|}{sd(\bar{x})}$$

- Parece ser un estadístico sensato.

- Hemos usado el valor absoluto para medir la distancia.
- Sin embargo, dependerá de la hipótesis alternativa si la prueba es de una o dos colas.
- El estadístico de contraste que hemos postulado tiene en el denominador la desviación estándar.
- Sin embargo, rara vez se conoce el valor de σ.
- Entonces, usaremos el error estándar en vez de la desviación estándar.

- Entonces, el estadístico de contraste viene dado por:

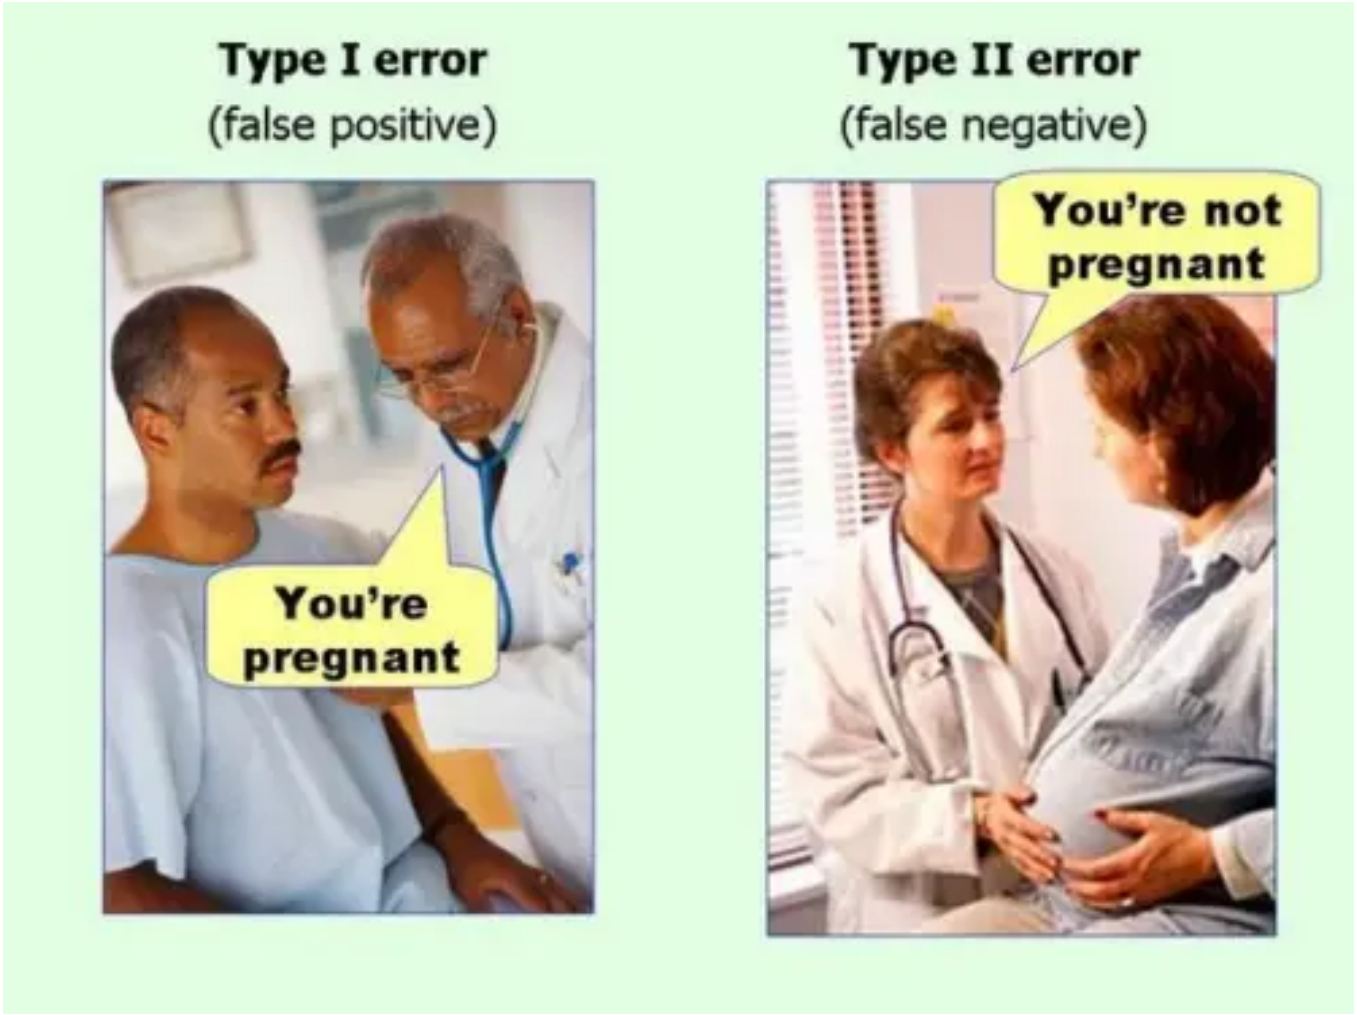
$$\frac{|\bar{x} - \mu_{H_0}|}{\text{ee}(\bar{x})}$$

- En este ejemplo particular, se trataba del estimador de la media.
- Sin embargo, el principio es muy general.
- De hecho, podemos definir el mismo estadístico de contraste para cualquier estimador $\hat{\theta}$ de θ:

$$\frac{|\hat{\theta} - \theta_{H_0}|}{\text{ee}(\hat{\theta})}$$

- A este estadístico se le conoce como Estadístico-t.

- En tercer y último lugar, una regla de decisión.
- Es decir, necesitamos una regla que nos diga si el tamaño del estadístico de contraste es evidencia a favor de la hipótesis nula o no.
- La regla que usaremos siempre será: Si $T_n >$ valor crítico $\Rightarrow$ rechazo H_0
- Recuerde que siempre podemos cometer dos tipos de errores.
- **Error tipo I:** Rechazar H_0 cuando ésta es correcta (falso positivo).
- **Error tipo II:** Aceptar H_0 cuando ésta es falsa (falso negativo).



Acá H_0 : la persona no está embarazada

- En general se considera más grave un error tipo I.
- Por lo tanto, el valor crítico se debe elegir de tal suerte que controlemos la probabilidad de cometer el error tipo I.
- Se estila fijar el error tipo I al 5 % (0.05).

$$
\begin{aligned}
P(\text{cometer error tipo I}) &= P(\text{Rechazar } H_0 \,|\, H_0 \text{ es verdadera}) \\
&= P(T_n > cv \,|\, H_0 \text{ es verdadera}) \\
&= P\left(\frac{|\hat{\theta} - \theta_{H_0}|}{\text{ee}(\hat{\theta})} > cv \,\middle|\, H_0 \text{ es verdadera} \right) \\
&= 0{,}05
\end{aligned}
$$

Pruebas de Hipótesis: Resumen

- Probar una hipótesis en este curso consta de tres partes.
  1. Una hipótesis.
  2. Un estadístico de contraste, T_n.
  3. Una regla de decisión: Si $T_n >$ valor crítico $\rightarrow$ se rechaza H_0.
- donde el valor crítico dependerá de la distribución de T_n bajo H_0.
- Nuestro candidato a estadístico de contraste de hipótesis para un parámetro será siempre un estadístico-t.

Normalidad asintótica de los estimadores MCO

- Bajo los supuestos RLM.1 a RLM.5, los estimadores MCO de los parámetros del modelo de regresión lineal, $\beta_0, \beta_1, ..., \beta_k$, verifican que

$$\sqrt{n}(\hat{\beta}_j - \beta_j) \sim N\left(0, \frac{\sigma^2}{a_j^2}\right) \quad \text{para cada } j = 0, 1, ..., k$$

  Donde $\frac{\sigma^2}{a_j^2}$ es la varianza asintótica de $\sqrt{n}(\hat{\beta}_j - \beta_j)$ y $a_j^2 = \operatorname{plim}\left(\frac{1}{n}\sum_{i=1}^{n} \hat{r}_{ij}^2\right)$. $\hat{r}_{ij}^2$ son los residuales de regresar x_j sobre las otras variables independientes.

- Además $\operatorname{plim} \hat{\sigma}^2 = \sigma^2$ y $\operatorname{plim} n\widehat{\operatorname{Var}}(\hat{\beta}_j) = \frac{\sigma^2}{a_j}$
- Por tanto:

$$\frac{\sqrt{n}(\hat{\beta}_j - \beta_j)}{\sqrt{n\widehat{\operatorname{Var}}(\hat{\beta}_j)}} = \frac{\hat{\beta}_j - \beta_j}{\operatorname{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

Inferencia en grandes muestras

- Dado que la distribución t_{n-k-1} se aproxima a una $N(0,1)$ cuando aumentan sus grados de libertad, con muestras grandes podríamos escribir:

$$\frac{\hat{\beta}_j - \beta_j}{\text{ee}(\hat{\beta}_j)} \sim N(0,1)$$

- En el límite, la distribución t con un número infinito de grados de libertad es una normal estándar, es decir, $t(\infty) = N(0,1)$
- Ejemplo:

$\alpha/2$	$N(0,1)$	$t(40)$	$t(4)$
50 %	0	0	0
5 %	1.64	1.68	2.13
2.5 %	1.96	2.02	2.78
0.5 %	2.57	2.70	4.60

Prueba de hipótesis sobre un solo parámetro poblacional en RLM: la prueba t

- El modelo poblacional puede escribirse como

$$y = \beta_0 + \beta_1 x_1 + ... + \beta_k x_k + u,$$

y se supone que este modelo satisface los supuestos de RLM.

- En grandes muestras y bajo los supuestos RLM.1 a RLM.5:

$$(\hat{\beta}_j - \beta_j)/\operatorname{ee}(\hat{\beta}_j) \sim t_{n-k-1},$$

donde $k+1$ es la cantidad de parámetros desconocidos en el modelo poblacional $y = \beta_0 + \beta_1 x_1 + ... + \beta_k x_k + u$.

- Este resultado permite probar hipótesis en las que intervienen las β_j. En la mayoría de las aplicaciones, el interés principal reside en probar la hipótesis nula:

$$H_0 : \beta_j = 0,$$

- Significa que, una vez que $x_1, x_2, ..., x_{j-1}, x_{j+1}, ..., x_k$ han sido tomadas en cuenta, x_j no tiene ningún efecto sobre el valor esperado de y.

Ejemplo: Ecuación del Salario por Hora

- se obtiene la ecuación estimada

$$\widehat{\log(wage)} = \underset{(0,104)}{0,284} + \underset{(0,007)}{0,092}\, educ + \underset{(0,0017)}{0,0041}\, exper + \underset{(0,003)}{0,022}\, tenure$$

$$n = 526, \qquad R^2 = 0,316$$

- los errores estándar aparecen entre paréntesis debajo de los coeficientes estimados.
- Esta ecuación puede emplearse para probar si en la población el rendimiento de *exper*, controlando *educ* y *tenure* es cero contra la alternativa de que este rendimiento sea positivo.
- Esto se escribe como $H_0 : \beta_{exper} = 0$ versus $H_1 : \beta_{exper} > 0$.

Ejemplo: Ecuación del Salario por Hora (cont.)

- El valor crítico (utilizando la aproximación normal) para 5 % es 1.645, para 4 % es 1.75, para 3 % 1.88, para 2 % es 2,05 y para 1 % es 2.326.
- El estadístico t para β_{exper} es

$$t_{exper} = ,0041/,0017 \approx 2,41$$

- El p-value es 0.008.
- $\hat{\beta}_{exper}$, o $exper$, es estadísticamente significativo a un al nivel 1 %. "$\hat{\beta}_{exper}$ es estadísticamente mayor que cero al nivel de significancia 1 %".

Misma idea: prueba de Hipótesis de Una Cola

- Primero hay que decidirse por un nivel de significancia o probabilidad de rechazar H_0 cuando en realidad es verdadera.
- suponga que se ha decidido usar 5 % como nivel de significancia, ya que este es el nivel más empleado. Por tanto, se estará dispuesto a rechazar de manera equivocada H_0 siendo ésta verdadera 5 % de las veces.
- $t_{\hat{\beta}_j}$ tiene una distribución t bajo H_0 (tiene media cero)
- bajo la alternativa $\beta_j > 0$, el valor esperado de $t_{\hat{\beta}_j}$ es positivo.

Misma idea: Prueba de Hipótesis de Una Cola (cont.)

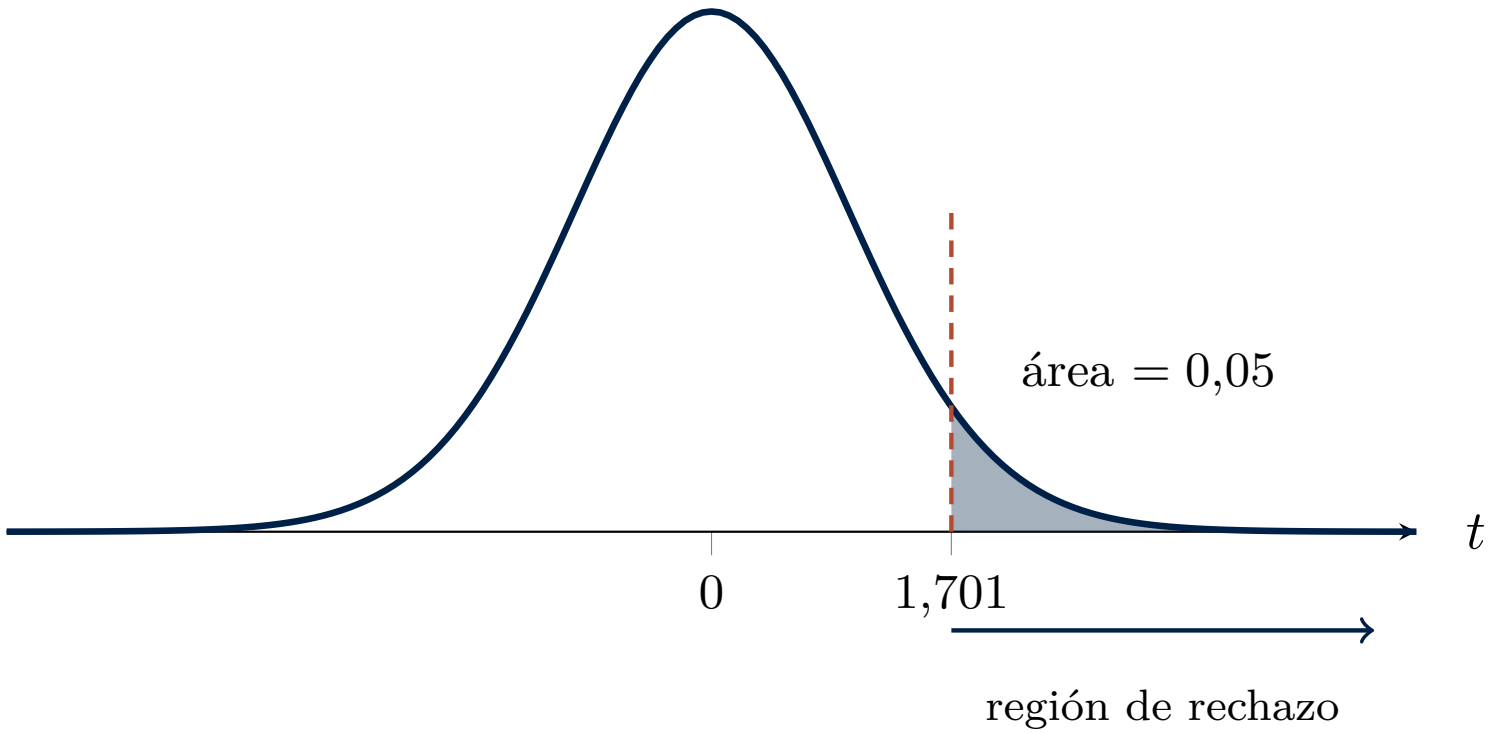
- Por tanto se está buscando un valor positivo "suficientemente grande" de $t_{\hat{\beta}_j}$ que permita rechazar $H_0 : \beta_j = 0$ a favor de $H_1 : \beta_j > 0$.
- La definición de "suficientemente grande", con un nivel de significancia de 5 %, es el percentil 95 de una distribución t con $n - k - 1$ grados de libertad: c. En otras palabras, la regla de rechazo es que al nivel de significancia de 5 % se rechaza H_0 a favor de H_1 si

$$t_{\hat{\beta}_j} > c.$$

- De acuerdo con la elección del valor crítico c, el rechazo de H_0 ocurrirá en 5 % de todas las muestras aleatorias cuando H_0 sea verdadera.

Prueba de Una Cola

Regla de rechazo de 5 % para la alternativa $H_1 : \beta_j > 0$ con 28 g.l.



Ej: Determinantes del promedio de calificaciones (GPA) en la universidad

Suponga el siguiente modelo para explicar el promedio general de calificaciones, GPA, en la universidad (*colGPA*), empleando la cantidad promedio de faltas a clase por semana (*skipped*):

$$\widehat{colGPA} = \underset{(0,33)}{1,39} + \underset{(0,094)}{0,412}\, hsGPA + \underset{(0,011)}{0,015}\, ACT - \underset{(0,026)}{0,083}\, skipped$$

$$n = 141, \qquad R^2 = 0,234.$$

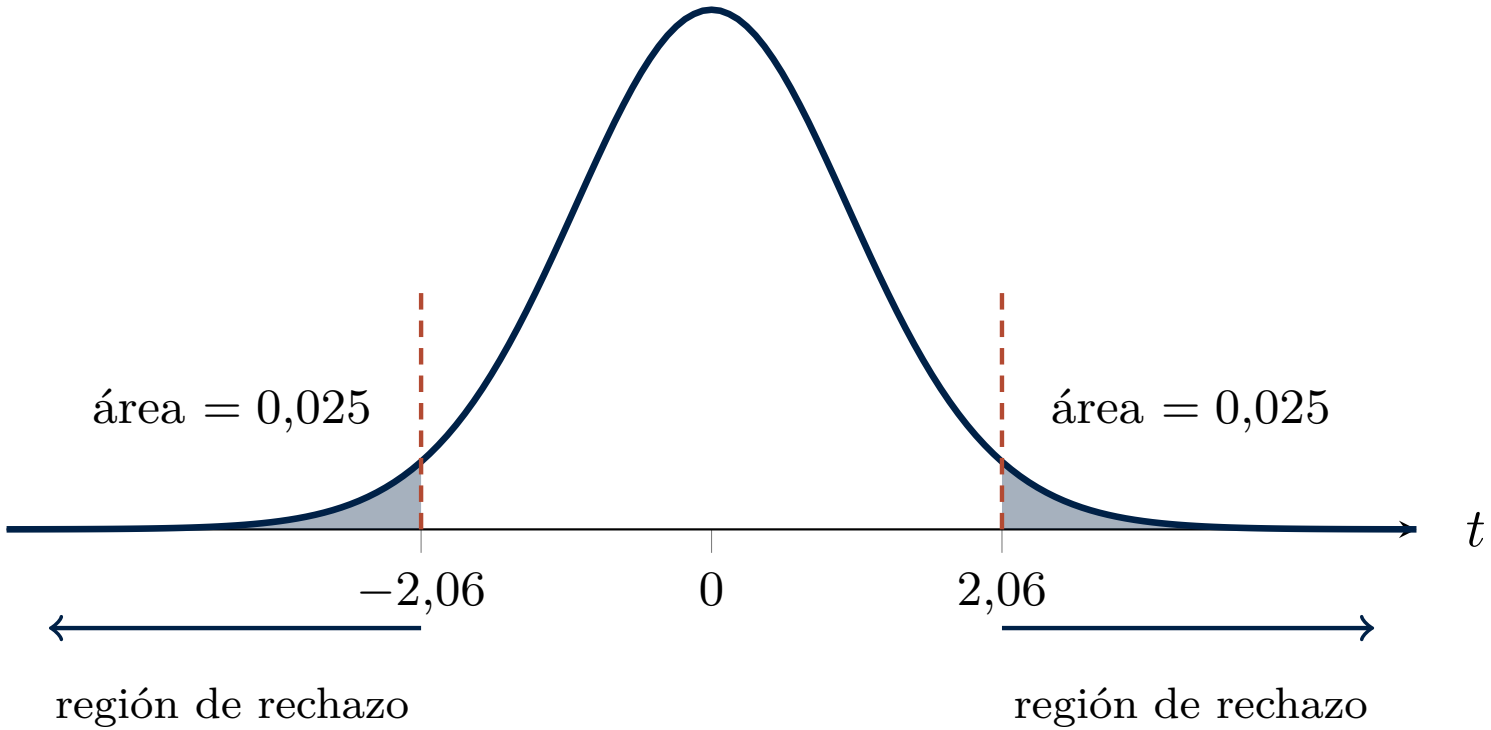
- El valor crítico correspondiente a 5 % es más o menos 1.96, ya que el número de grados de libertad (141 - 4 = 137) es lo suficientemente grande para emplear la aproximación normal estándar. El valor crítico de 1 % es más o menos 2.58.

Ej: Determinantes del promedio de calificaciones (GPA) en la universidad (cont.)

- El estadístico t para $hsGPA$ es 4.38, el cual es significativo a niveles de significancia muy pequeños. Por tanto se dice que "$hsGPA$ es estadísticamente significativa a cualquier nivel de significancia convencional".
- El estadístico t para ACT es 1.36, el cual no es estadísticamente significativa al nivel correspondiente a 10 % en una alternativa de dos colas.
- El coeficiente de *skipped* tiene un estadístico t de $-0{,}083/0{,}026 = -3{,}19$, de manera que *skipped* es estadísticamente significativo al nivel de significancia correspondiente a 1 % ($3{,}19 > 2{,}58$).

Prueba de Dos Colas

Regla de rechazo de 5 % para la alternativa $H_1 : \beta_j \neq 0$ con 25 g.l.



Prueba de Dos Colas

- Cuando la alternativa es de dos colas, lo que interesa es el valor absoluto del estadístico t. La regla de rechazo para H_0

$$|t_{\hat{\beta}_j}| > c,$$

- Cuando se rechaza H_0 al nivel de 5 %, se suele decir que "x_j es estadísticamente significativa, o estadísticamente distinta de cero, al nivel de 5 %".
- Si no se rechaza H_0 se dice que "x_j es estadísticamente no significativa al nivel de 5 %".

Ejemplo: Tests de Hipótesis para un Parámetro

```
. reg lwage educ exper tenure
```

	SS	df	MS
Model	46.8741776	3	15.6247259
Residual	101.455574	522	.194359337
Total	148.329751	525	.28253286

Number of obs	= 526
F(3, 522)	= 80.39
Prob > F	= 0.0000
R-squared	= 0.3160
Adj R-squared	= 0.3121
Root MSE	= .44086

lwage	Coef.	Std. Err.	t	$P>\|t\|$	[95 % Conf.	Interval]
educ	.092029	.0073299	12.56	0.000	.0776292	.1064288
exper	.0041211	.0017233	2.39	0.017	.0007357	.0075065
tenure	.0220672	.0030936	7.13	0.000	.0159897	.0281448
_cons	.2843595	.1041904	2.73	0.007	.0796756	.4890435

Ejemplo

- Considere el siguiente modelo (poblacional)

$$\log(salario) = \beta_0 + \beta_1 priv + \beta_2 pub + \beta_3 exp + u$$

  donde *salario* representa el sueldo promedio por hora de un individuo, *pub* es una variable que mide los años de educación en una universidad pública, *priv* es una variable que mide los años de educación en una universidad privada y u es el error (no observable) del modelo.
- Además de la significancia de los parámetros β_1 y β_2, también podríamos estar interesados en un enunciado sobre la diferencia entre estudiar en universidad pública o privada.
- Es decir, una hipótesis como la siguiente $H_0 : \beta_1 = \beta_2$.
- Bajo la hipótesis nula, un año en una universidad pública tiene el mismo efecto sobre el sueldo que un año en universidad privada (en promedio y manteniendo todo lo demás constante).
- Si la conjetura es que la educación privada incide más sobre el sueldo, entonces la alternativa sería de la forma $H_1 : \beta_1 > \beta_2$

Ejemplo

- Si definiéramos $\theta = \beta_1 - \beta_2$ entonces nuestro problema sería contrastar
  $H_0 : \theta = 0 \quad vs \quad H_1 : \theta > 0$
- El estadístico de contraste

$$T_{\hat{\theta}} = \frac{\hat{\theta} - \theta_{H_0}}{\text{ee}(\hat{\theta})} \sim t_{gl}$$

  Donde $\hat{\theta} = \hat{\beta}_1 - \hat{\beta}_2$
- La regla de decisión: Si $T_{\hat{\theta}} >$ valor crítico entonces rechazo H_0.
- Pero ahora, el error estándar se calcula a partir de la fórmula de varianza:

$$\text{Var}(\hat{\beta}_1 - \hat{\beta}_2) = \text{Var}(\hat{\beta}_1) + \text{Var}(\hat{\beta}_2) - 2\,\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)$$

- Por lo tanto, $\text{ee}(\hat{\theta}) = \sqrt{[\text{ee}(\hat{\beta}_1)]^2 + [\text{ee}(\hat{\beta}_2)]^2 - 2S_{12}}$

Ejemplo

- Supongamos que se estimó el modelo:

$$\widehat{\log(salario)} = \underset{(0,27)}{21,27} - \underset{(0,035)}{0,124}\, priv - \underset{(0,031)}{0,098}\, pub + \underset{(0,008)}{0,019}\, exp$$

$$n = 285, \qquad R^2 = 0,243$$

  con $\text{ee}(\hat{\theta}) = 0,018$.
- entonces, el estadístico de contraste bajo H_0 sería

$$T_{\hat{\theta}} = \frac{0,026}{0,018} \approx 1,44$$

- Para encontrar el valor crítico sólo necesitamos conocer $n - k - 1$ y el nivel de significancia. Supongamos que el nivel de significancia es 5 %.
- Entonces el valor crítico es el percentil 95 de la distribución t_{282}.
- Entonces valor crítico $\approx 1,65$.

Otro Método

- Es mucho más fácil estimar un modelo diferente que proporcione de forma directa el error estándar que interesa
- Se define un parámetro nuevo que es la diferencia entre β_1 y β_2: $\theta_1 = \beta_1 - \beta_2$.
- Lo que se quiere probar es: $H_0 : \theta_1 = 0$ vs $H_1 : \theta_1 > 0$
- se reescribe el modelo de manera que θ_1 aparezca de manera directa en una de las variables independientes
- Dado que $\theta_1 = \beta_1 - \beta_2$, se puede reescribir $\beta_1 = \theta_1 + \beta_2$.

$$\log(salario) = \beta_0 + (\theta_1 + \beta_2)priv + \beta_2 pub + \beta_3 exp + u$$
$$\log(salario) = \beta_0 + \theta_1 priv + \beta_2(priv + pub) + \beta_3 exp + u$$

Intervalos de Confianza

- Sabemos que $\dfrac{\hat{\beta}_j - \beta_j}{\text{ee}(\hat{\beta}_j)}$ tiene una distribución t con $n-k-1$ grados de libertad.
- Por lo tanto, un intervalo de confianza de 95 % está dado por

$$\hat{\beta}_j \pm c \cdot \text{ee}(\hat{\beta}_j)$$

  donde la constante c es el percentil 97.5 en la distribución t_{n-k-1}.
- Si se obtuvieran una y otra y otra muestra aleatoria, y cada vez se calculara el IC en 95 % de las muestras el valor poblacional estaría en el intervalo.
- En la única muestra que se emplea para construir el IC, no se sabe si el parámetro está o no contenida en el intervalo.

Intervalos de confianza

- Cuando $n - k - 1 > 120$, la distribución t_{n-k-1} es lo suficientemente parecida a la distribución normal estándar como para usar el percentil 97.5 de la distribución normal estándar para construir un IC de 95 %:

$$\hat{\beta}_j \pm 1{,}96 \cdot \text{ee}(\hat{\beta}_j)$$

- En general, cuando $n - k - 1 > 50$, el valor de c es tan cercano a 2 que para un intervalo de confianza de 95 % puede emplearse:

$$\hat{\beta}_j \pm 2 \cdot \text{ee}(\hat{\beta}_j)$$

- Se pueden realizar tests de hipótesis de dos colas utilizando los IC.
- Si la hipótesis nula es $H_0 : \beta_j = a_j$, entonces **se rechaza** H_0 contra $H_1 : \beta_j \neq a_j$ al nivel de significancia (por ejemplo) de 5 % si y **sólo si,** a_j **no está en el intervalo de confianza de 95 %.**

Prueba para las restricciones de exclusión

- Hasta ahora sólo hemos hecho pruebas de hipótesis sobre un parámetro o una combinación de los mismos.
- En ambos casos, sin embargo, sólo estamos lidiando con una restricción.
- En ciertas ocasiones también nos gustaría poder probar más de una restricción al mismo tiempo.
- Es decir, contrastar hipótesis múltiples sobre el vector de parámetros $\beta_0, \beta_1, ..., \beta_k$.
- Ahora buscaremos saber si un grupo de variables explicativas tienen o no efecto sobre la variable dependiente una vez que hemos controlado por todo lo demás.

Prueba para las restricciones de exclusión

Considere el siguiente modelo para predecir el sueldo de los jugadores profesionales de baseball en ligas mayores:

$$\log(sueldo) = \beta_0 + \beta_1 years + \beta_2 juegoyear + \beta_3 bat + \beta_4 hr + \beta_5 rb + \epsilon$$

donde *sueldo* es el sueldo anual, *years* representa el número de años jugando en las grandes ligas, *juegoyear* es el promedio de juegos por año, *bat* es el promedio de bateos en su carrera profesional, *hr* es el promedio de home runs por año y *rb* son las carreras por bateo en un año. Imagine que deseamos ver si las estadísticas de desempeño que publica la MLB tienen un efecto sobre el sueldo del jugador una vez que hemos controlado por los años y los juegos por año. Es decir, queremos contrastar la hipótesis

$$H_0 : \beta_3 = 0,\ \beta_4 = 0,\ \beta_5 = 0$$

- La hipótesis nula

$$H_0 : \beta_3 = 0,\ \beta_4 = 0,\ \beta_5 = 0$$

  constituye tres restricciones de exclusión.
- Si H_0 es verdadera, entonces las estadísticas de desempeño que publica la MLB no tienen efecto sobre el $\log(sueldo)$, una vez que hemos controlado por los años y juegos por año.
- De ser así entonces deberíamos excluir estas variables del modelo.
- Este es un ejemplo de pruebas de hipótesis múltiple pues hemos puesto más de una restricción a la vez.

- Si bajo la hipótesis nula las estadísticas de desempeño no afectan al sueldo una vez controlado por años y juegos por año, entonces la alternativa es las estadísticas de desempeño importan.
- Entonces, H_1: H_0 no es verdadera.
- La negación de H_0 es β_3, β_4 o β_5 (o las tres) es diferente de cero.
- El estadístico de contraste debe tomar en cuenta cualquier violación de H_0.

- ¿Cómo deberíamos contrastar estas hipótesis?
- Podríamos estar tentados a contrastar semejante hipótesis usando un estadístico t sobre cada uno de los parámetros β_3, β_4 y β_5 y ver si individualmente son significativas.
- Sin embargo esto no sería lo más adecuado. Recuerde que un estadístico de contraste es una función que pone en relación la hipótesis nula con la muestra.
- Si efectuamos una prueba t para algún parámetro no hay manera de considerar las restricciones para los otros parámetros.

- Para ilustrar estas observaciones estimamos el modelo descrito y obtuvimos lo siguiente:

$$\widehat{\log(sueldo)} = \underset{(0,29)}{11,10} + \underset{(0,0121)}{0,0689}\, years + \underset{(0,0026)}{0,0126}\, juegoyear + \underset{(0,00110)}{0,00098}\, bat + \underset{(0,0161)}{0,0144}\, hr + \underset{(0,0072)}{0,0108}\, rb$$

$$n = 353, \quad SRC = 183,186, \quad R^2 = 0,6278$$

  donde la SRC es la suma de residuales al cuadrado

- Si efectuamos las pruebas de significancia individuales para cada coeficiente de regresión podemos concluir que β_3, β_4 y β_5 no son significativas para un nivel del 5 % y alternativa de dos colas.
- Entonces, basados en un simple estadístico t no deberíamos rechazar H_0.

- Recuerde que nuestro modelo original es

$$\log(sueldo) = \beta_0 + \beta_1 years + \beta_2 juegoyear + \beta_3 bat + \beta_4 hr + \beta_5 rb + \epsilon$$

- El modelo imponiendo la hipótesis nula $H_0 : \beta_3 = 0,\ \beta_4 = 0,\ \beta_5 = 0$:

$$\log(sueldo) = \beta_0 + \beta_1 years + \beta_2 juegoyear + \epsilon$$

- En el contexto de pruebas de hipótesis, el modelo completo se le conoce como el **modelo no restringido**.
- Por otro lado, el modelo bajo la hipótesis nula es el **modelo restringido**.
- Es importante notar que el modelo restringido siempre tiene menos parámetros que el modelo sin restringir.

- Si estimamos el modelo restringido usando los mismos datos obtenemos

$$\log(sueldo) = \underset{(0,11)}{11,22} + \underset{(0,0125)}{0,0713}\, years + \underset{(0,0013)}{0,0202}\, juegoyear$$

$$n = 353, \quad SRC = 198,311, \quad R^2 = 0,5971$$

- Observe que respecto al modelo restringido, la SRC es mayor (198.311 vs 183.186 en el modelo no restringido).
- El R^2 del modelo restringido es menor (0.5971 vs 0.6278 en el modelo no restringido).

- Lo que debemos decidir es si este incremento en SRC de un modelo a otro es evidencia en contra de H_0.
- Recuerda que un estadístico de contraste es una función que relaciona la muestra con la hipótesis nula.
- Entonces, el estadístico de contraste debe estar en función de ambas SRCs.
- Resulta que, para este ejemplo con tres restricciones de exclusión, el estadístico de contraste es

$$F = \frac{(SRC_r - SRC_{nr})/q}{SRC_{nr}/(n-k-1)}$$

  donde SRC_r es la suma de residuales al cuadrado del modelo restringido, mientras que SRC_{nr} es la suma pero del modelo no restringid y q es el número de restricciones.
- Este es el llamado estadístico F y será nuestro estadístico de contraste para hipótesis múltiples.

Prueba para las restricciones de exclusión

Escribamos el siguiente modelo (no restringido):

$$y = \beta_0 + \beta_1 x_1 + ... + \beta_k x_k + u$$

La cantidad de parámetros es $k + 1$. Suponga que se tienen que probar q restricciones de exclusión: La hipótesis nula dice que las últimas q variables independientes tienen coeficientes igual a cero (el orden no importa).

$$H_0 : \beta_{k-q+1} = 0, \ ..., \ \beta_k = 0$$

la cual impone q restricciones de exclusión al modelo. Imponiendo las restricciones bajo H_0, se obtiene el modelo restringido:

$$y = \beta_0 + \beta_1 x_1 + ... + \beta_{k-q} x_{k-q} + u.$$

El estadístico F se define como:

$$F = \frac{(SRC_r - SRC_{nr})/q}{SRC_{nr}/(n-k-1)}$$

F está distribuida como una variable aleatoria F con $(q, n-k-1)$ grados de libertad. H_0 se rechaza a favor de H_1 al nivel de significancia elegido si $F > c$.

Prueba para las restricciones de exclusión

- Empleando el hecho de que

$$SRC_r = STC \cdot (1 - R_r^2) \quad \text{y} \quad SRC_{nr} = STC \cdot (1 - R_{nr}^2)$$

  El estadístico F puede escribirse como:

$$F = \frac{(R_{nr}^2 - R_r^2)/q}{(1 - R_{nr}^2)/(n - k - 1)}$$

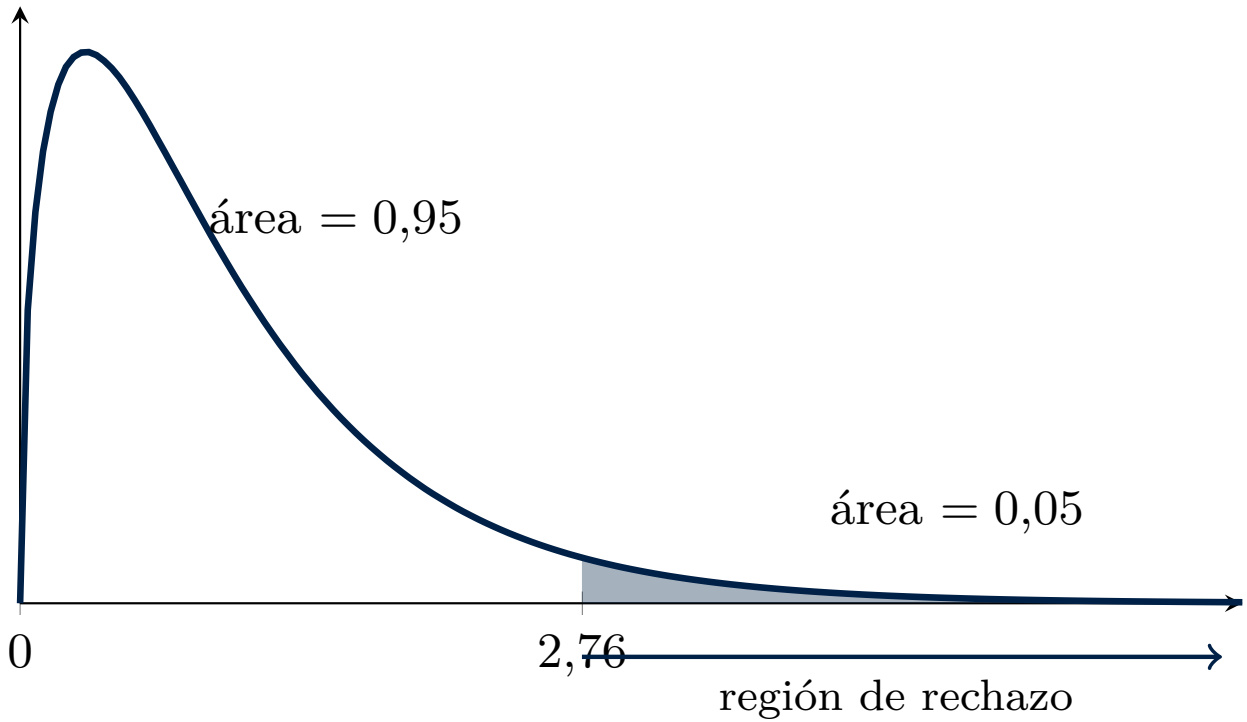
- A esto se le conoce como forma R-cuadrada del estadístico F
- Esta forma no puede emplearse para probar todas las restricciones lineales.

Prueba para las restricciones de exclusión

- H_0 se rechaza a favor de H_1 al nivel de significancia elegido si $F > c$.
- Ahora el valor crítico dependerá de los grados de libertad, del nivel de significancia y del número de restricciones.
- Es decir, el valor crítico será el percentil $(1 - \alpha) * 100$ en la distribución F con $n - k - 1$ grados de libertad.
- Si rechazamos H_0 decimos que $x_{k-q+1}, ..., x_k$ son **conjuntamente significativas** al nivel de confianza que hayamos establecido.
- Es importante notar que como su efecto es conjunto, no podemos distinguir cuál de ellas es la que tiene el efecto parcial sobre y.
- Si no rechazamos H_0 podemos concluir que en conjunto no son significativas y por lo tanto podemos sacarlas del modelo.
- como la distribución F es de una cola entonces la regla de decisión será siempre la misma.

Prueba de Una Cola

Valor crítico correspondiente a 5 % y región de rechazo en la distribución $F_{3,60}$.



Ejemplo: sueldos de la MLB

- Para el ejemplo que vimos, tenemos $q = 3$, $n - k - 1 = 347$
- Entonces el valor crítico al 95 % es 2.60 (al 99 % es 3.78).
- Es decir, el valor crítico será el percentil $(1 - \alpha) * 100$ en la distribución F con q y $n - k - 1$ grados de libertad.
- Por otro lado,

$$F = \frac{198{,}311 - 183{,}186}{183{,}186} \cdot \frac{347}{3} \approx 9{,}55$$

o en la forma R-cuadrado del estadístico F:

$$F = \frac{0{,}6278 - {,}5971}{(1 - 0{,}6278)} \cdot \frac{347}{3} \approx 9{,}55$$

- por lo tanto, se rechaza H_0.
- Es decir, tenemos evidencia en contra de H_0 y podemos concluir que, al 95 % de confianza, las estadísticas de rendimiento reportadas por la MLB sí inciden sobre el sueldo del jugador, en promedio y manteniendo todo lo demás constante.

Relación entre los estadísticos F y t

- ¿Se puede utilizar estadístico F para probar la significancia de una sola variable independiente?
- Para probar la restricción de exclusión de que x_k debe ser eliminada del modelo, se puede tomar como hipótesis nula

$$H_0 : \beta_k = 0 \quad \text{con } q = 1$$

- Para probar esta hipótesis puede emplearse el estadístico t para β_k.
- Se puede demostrar que el estadístico F para probar la exclusión de una sola variable es igual al cuadrado del estadístico t correspondiente.
- Dado que t^2_{n-k-1} tiene una distribución $F_{1,n-k-1}$, los dos métodos conducen al mismo resultado **siempre que la alternativa sea de dos colas**.
- Para la prueba de una sola hipótesis, el estadístico t es más flexible debido a que puede emplearse en pruebas contra alternativas de una cola.

Cálculo de los valores-p para pruebas F

- Como la distribución F depende de los gl tanto en el numerador como en el denominador, es difícil saber qué tan fuerte o qué tan débil es la evidencia contra una hipótesis nula mirando sólo los valores del estadístico F
- En el contexto de una prueba F, el valor-p se define de la manera siguiente:

$$\text{valor-}p = P(\mathcal{F} > F_{obs}),$$

- $\mathcal{F}$ denota una variable aleatoria F con $(q, n-k-1)$ grados de libertad.
- F_{obs} es el valor del estadístico de prueba.
- El valor-p es la probabilidad de observar valores de F por lo menos tan grandes como el observado, dado que la hipótesis nula sea verdadera.
- Por ejemplo, un valor-$p = 0{,}016$ significa que la posibilidad de observar un valor de F tan grande como el encontrado, siendo verdadera la hipótesis nula, es sólo de 1.6 %; en tales casos suele rechazarse H_0.
- Si valor-$p = 0{,}314$, entonces la posibilidad de observar un valor del estadístico F tan grande como el encontrado, siendo verdadera la hipótesis nula, es de 31.4 %

Significancia General de una Regresión

- En un modelo con k variables independientes, la hipótesis nula puede escribirse de la siguiente manera:

$$H_0 : \beta_1 = \beta_2 = ... = \beta_k = 0,$$

- La hipótesis nula establece que ninguna de las variables explicativas tiene efecto sobre y.
- La hipótesis alternativa es que por lo menos uno de los β_j es distinto de cero.
- H_0 también se puede escribir como: $H_0 : \mathbb{E}(y|x) = \mathbb{E}(y)$: conocer los valores de $x_1, x_2, ..., x_k$ no afecta el valor esperado de y.
- Al imponer las k restricciones se obtiene el modelo restringido:

$$y = \beta_0 + u$$

- El R-cuadrado del modelo restringido es cero
- Por tanto el estadístico F puede escribirse como:

$$F = \frac{R^2_{nr}/k}{(1 - R^2_{nr})/(n - k - 1)}$$

Mínimos Cuadrados Restringidos

- Utilizaremos la función de producción de Cobb-Douglas como ejemplo:

$$y = \beta_1 x_2^{\beta_2} x_3^{\beta_3} e^u$$
$$\ln y = \beta_0 + \beta_2 \ln x_2 + \beta_3 \ln x_3 + u$$

  Donde $\beta_0 = \ln \beta_1$, y es producción, x_2 es trabajo y x_3 es capital.
- Imagine que deseamos testear si $\beta_2 + \beta_3 = 1$.
- Por lo tanto, esto es lo que usaremos como restricción.

Mínimos Cuadrados Restringidos

- Así, podríamos elegir una de las siguientes restricciones:

$$\beta_2 = 1 - \beta_3 \qquad \beta_3 = 1 - \beta_2$$

Si usamos la primera, podemos reescribir la función de Cobb-Douglas como:

$$\begin{aligned}
\ln y &= \beta_0 + (1 - \beta_3) \ln x_2 + \beta_3 \ln x_3 + u \\
&= \beta_0 + \ln x_2 + \beta_3 (\ln x_3 - \ln x_2) + u \\
(\ln y - \ln x_2) &= \beta_0 + \beta_3 (\ln x_3 - \ln x_2) + u \\
\ln(y/x_2) &= \beta_0 + \beta_3 \ln(x_3/x_2) + u
\end{aligned}$$

- Realizando la estimación sobre este último modelo, podemos estimar β_2 utilizando la restricción y así garantizar que la suma de los coeficientes estimados sea 1.

Mínimos Cuadrados Restringidos

- Al estimar ambos modelos estudiados utilizando como ejemplo el caso Mexicano entre los años 1955 y 1974 obtenemos los siguientes resultados:

$$\beta_2 = 1 - \beta_3 \quad \text{o} \quad \beta_3 = 1 - \beta_2$$

Si usamos la primera, podemos reescribir la función de Cobb-Douglas como:

$$\ln y = \beta_0 + \beta_2 \ln x_2 + \beta_3 \ln x_3 + u$$

$$\widehat{\ln GDP} = -1{,}65 + 0{,}3397 \ln Labor + 0{,}846 \ln Capital + u$$

$$R^2 = 0{,}9951, \qquad SRC_{nr} = 0{,}0136$$

$$\ln(y/x_2) = \beta_0 + \beta_3 \ln(x_3/x_2) + u$$

$$\widehat{\ln GDP/Labor} = -0{,}4947 + 1{,}0153 \ln(Capital/Labor)$$

$$R^2 = 0{,}9777, \qquad SRC_r = 0{,}0166$$

- Si el ratio Capital/Empleo se incrementa en un 1 %, entonces, en promedio, la productividad del empleo aumentará en un poco más que un 1 %.
- $F = \dfrac{(0{,}0166 - 0{,}0136)/1}{(0{,}0136)/(20-3)} = 3{,}75$, $F_{crítico} = 4$, p-value: 0,062.

Ejemplo

- Supongamos que un investigador quiere probar si los rendimientos de una acción de la empresa (y) muestran sensibilidad unitaria a dos factores (factor x_2 y factor x_3) entre los tres considerados. La regresión se lleva a cabo en 144 observaciones mensuales. La regresión es:

$$y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + \beta_4 x_{4t} + u_t$$

- ¿Cuáles son las regresiones restringida y no restringida?
- Si los dos RSS son 436.1 y 397.2 respectivamente, realice el prueba.
- Sensibilidad unitaria implica $H_0 : \beta_2 = 1$ y $\beta_3 = 1$.
- La regresión restringida es $(y_t - x_{2t} - x_{3t}) = \beta_1 + \beta_4 x_{4t} + u_t$ o dejando $z_t = y_t - x_{2t} - x_{3t}$, la regresión restringida es $z_t = \beta_1 + \beta_4 x_{4t} + u_t$.
- Tenemos: $n = 144$, $k = 4$, $q = 2$, $SRC_r = 436{,}1$, $SRC_{nr} = 397{,}2$.
- Estadístico $F = 6{,}68$. Valor crítico es: $F(2, 140) = 3{,}07$ (5 %) y 4,79 (1 %).
- Conclusión: Rechazar H_0.

R-Cuadrado Ajustado

- Recuerde que el R-cuadrado se calcula de la siguiente forma:

$$R^2 = 1 - (SRC)/(STC)$$
$$R^2 = 1 - (SRC/n)/(STC/n)$$

El R-cuadrado ajustado viene dado por:

$$\bar{R}^2 = 1 - (SRC/(n-k-1))/(STC/(n-1))$$

O también se puede escribir:

$$\bar{R}^2 = 1 - (1-R^2)(n-1)/(n-k-1)$$

- La característica más atractiva del $\bar{R}^2$ es que impone una sanción a la adición de más variables independientes a un modelo.
- Si agregamos un regresor adicional, k aumenta y, a menos que R^2 aumente en una cantidad superior a la de compensación, $\bar{R}^2$ en realidad disminuirá.

Ejemplo: Modelos Hedónicos de Fijación de Precios de Viviendas

- Los modelos hedónicos se utilizan para valorar los activos reales, especialmente la vivienda, y consideran que el activo representa un conjunto de características.
- Des Rosiers y Thérialt (1996) consideran el efecto de varios servicios en los valores de alquiler de edificios y apartamentos en 5 submercados en el área de Quebec de Canadá.
- El valor del alquiler en dólares canadienses por mes (la variable dependiente) es una función de 9 a 14 variables (dependiendo del área considerada). El documento emplea datos de 1990, y para la región de la ciudad de Quebec, hay 13378 observaciones,
- Las estimaciones de coeficientes en sí mismas muestran el precio de alquiler en dólares canadienses por mes de cada característica de la vivienda.
- las 12 variables explicativas son:

Modelos de Precios de Casas Hedónicas: Definiciones de Variables

LnAGE	Log de la edad aparente de la propiedad
NBROOMS	Número de dormitorios
AREABYRM	Área por habitación (en metros cuadrados)
ELEVATOR	Variable Dummy = 1 si el edificio tiene ascensor; 0 en otro caso
BASEMENT	Variable Dummy = 1 si la unidad está ubicada en el piso inferior; 0 e.o.c
OUTPARK	Número de plazas de aparcamiento al aire libre
INDPARK	Número de plazas de aparcamiento interior
NOLEASE	Variable Dummy = 1 si la unidad no tiene contrato de arrendamiento adjunto; 0 e.o.c
LnDISTCBD	Log de la distancia en kilómetros al distrito central de negocios (CBD)
SINGLPAR	Porcentaje de familias monoparentales en el área donde se encuentra el edificio
DSHOPCNTR	Distancia en kilómetros al centro comercial más cercano
VACDIFF1	Diferencia de vacantes entre el edificio y la cifra del censo

Resultados de Precios Hedónicos de Vivienda

Variable dependiente: dólares canadienses por mes

Variable	**Coeficiente**	***t*-ratio**	**signo esperado**
Intercept	282.21	56.09	+
LnAGE	−53.10	−59.71	−
NBROOMS	48.47	104.81	+
AREABYRM	3.97	29.99	+
ELEVATOR	88.51	45.04	+
BASEMENT	−15.90	−11.32	−
OUTPARK	7.17	7.07	+
INDPARK	73.76	31.25	+
NOLEASE	−16.99	−7.62	−
LnDISTCBD	5.84	4.60	−
SINGLPAR	−4.27	−38.88	−
DSHOPCNTR	−10.04	−5.97	−
VACDIFF1	0.29	5.98	−

Notas: R^2 ajustado = 0,651; estadístico F de la regresión = 2082,27.

Fuente: Des Rosiers y Thérialt (1996).

Determinantes de los Ratings Crediticios Soberanos, Cantor and Packer (1996)

- Las calificaciones crediticias soberanas son una evaluación del riesgo de la deuda emitida por los gobiernos.
- Representan una estimación de la probabilidad de que el prestatario no cumpla con su obligación.
- Dos famosas agencias de calificación de Estados Unidos, Moody's y Standard and Poor's proporcionan calificaciones para muchos gobiernos.
- Aunque las dos agencias usan símbolos diferentes para denotar el riesgo dado de un prestatario particular, las calificaciones de las dos agencias son comparables.

Determinantes de los Ratings Crediticios Soberanos, Cantor and Packer (1996) (cont.)

- La calificación más alta ofrecida por las agencias es “triple A”, que Moody’s denota “Aaa” y S&P denota “AAA”. La calificación más baja emitida a un soberano en la muestra de Cantor y Packer fue B3 (Moody’s) o B- (S&P).
- Por lo tanto, el número de grados de calidad de la deuda desde el más alto al más bajo otorgado a los gobiernos en su muestra es 16.
- El objetivo central del artículo de Cantor y Packer es un intento de explicar y modelar cómo las agencias llegaron a sus calificaciones.
- Aunque las calificaciones en sí están disponibles al público, los modelos o métodos utilizados para llegar a ellos no están disponibles públicamente.

Determinantes de los Ratings Crediticios Soberanos, Cantor and Packer (1996)

- Cantor y Packer (1996) obtienen una muestra de calificaciones de deuda pública para cuarenta y nueve países a partir de septiembre de 1995.
- La variable de calificación se cuantifica, de modo que la calidad crediticia más alta (Aaa / AAA) en la muestra recibe una puntuación de 16, mientras que el bono con la calificación más baja en la muestra recibe una puntuación de 1 (B3 / B-).
- Este puntaje forma la variable dependiente. Los factores que se utilizan para explicar la variabilidad en los puntajes de las calificaciones son variables macroeconómicas.
- Todas estas variables incorporan factores que pueden influir en la capacidad y la voluntad de un gobierno de pagar los costos de su deuda.
- Idealmente, el modelo también incluiría proxies para factores sociopolíticos, pero estos son difíciles de medir objetivamente y, por lo tanto, no están incluidos.

Ejemplo: Determinantes de los Ratings Crediticios Soberanos

- Ingreso per cápita (en 1994 dólares estadounidenses, miles). Ingreso per cápita determina la base impositiva, lo que influye en la capacidad del gobierno para aumentar los ingresos.
- Crecimiento del PIB (promedio anual 1991-1994, %). Tasa de crecimiento del PIB mide cuánto más fácil será pagar los costos de la deuda en el futuro.
- Inflación (promedio anual 1992-1994, %). Alta inflación sugiere que el financiamiento monetario inflacionario se utilizará para pagar la deuda cuando el gobierno no está dispuesto o no puede aumentar los ingresos requeridos a través del sistema tributario.
- Saldo fiscal (superávit presupuestario anual promedio del gobierno como proporción de PIB 1992–4, %). Nuevamente, un gran déficit fiscal muestra que el gobierno tiene una capacidad relativamente débil para recaudar ingresos adicionales y pagar los costos de la deuda.

Ejemplo: Determinantes de los Ratings Crediticios Soberanos (cont.)

- Saldo externo (superávit anual promedio en cuenta corriente como proporción del PIB 1992–4, %). Un déficit persistente en cuenta corriente conduce a un aumento del endeudamiento externo, que puede ser insostenible a la larga.
- Deuda externa (deuda en moneda extranjera como proporción de las exportaciones en 1994, %).
- Dummy para desarrollo económico (= 1 para un país clasificado como desarrollado por el FMI, 0 de lo contrario).
- Dummy para el historial de defaults (= 1 si un país ha incumplido, 0 en caso contrario).

Ejemplo: Determinantes de los Ratings Crediticios Soberanos

Explanatory variable (1)	Expected sign (2)	Dependent variable: Average rating (3)	Moody's rating (4)	S&P rating (5)	Difference Moody's/S&P (6)
Intercept	?	1.442	3.408	−0.524	3.932**
		(0.663)	(1.379)	(−0.223)	(2.521)
Per capita income	+	1.242***	1.027***	1.458***	−0.431***
		(5.302)	(4.041)	(6.048)	(−2.688)
GDP growth	+	0.151	0.130	0.171**	−0.040
		(1.935)	(1.545)	(2.132)	(0.756)
Inflation	−	−0.611***	−0.630***	−0.591***	−0.039
		(−2.839)	(−2.701)	(−2.671)	(−0.265)
Fiscal balance	+	0.073	0.049	0.097*	−0.048
		(1.324)	(0.818)	(1.71)	(−1.274)
External balance	+	0.003	0.006	0.001	0.006
		(0.314)	(0.535)	(0.046)	(0.779)
External debt	−	−0.013***	−0.015***	−0.011***	−0.004***
		(−5.088)	(−5.365)	(−4.236)	(−2.133)
Development dummy	+	2.776***	2.957***	2.595***	0.362
		(4.25)	(4.175)	(3.861)	(0.81)
Default dummy	−	−2.042***	−1.63**	−2.622***	1.159***
		(−3.175)	(−2.097)	(−3.962)	(2.632)
Adjusted R^2		0.924	0.905	0.926	0.836

Estadístico t en paréntesis

¿Los Ratings Contienen Información Adicional a la información pública?

- Variable dependiente: ln(spread de rendimiento)=ln(Rendimiento sobre el bono soberano - Rendimiento sobre un bono del Tesoro de EE. UU.).

		Dependent variable: ln (yield spread)		
Variable	Expected sign	(1)	(2)	(3)
Intercept	?	2.105^{***}	0.466	0.074
		(16.148)	(0.345)	(0.071)
Average rating	−	-0.221^{***}		-0.218^{***}
		(−19.175)		(−4.276)
Per capita income	−		−0.144	0.226
			(−0.927)	(1.523)
GDP growth	−		−0.004	0.029
			(−0.142)	(1.227)
Inflation	+		0.108	−0.004
			(1.393)	(−0.068)
Fiscal balance	−		−0.037	−0.02
			(−1.557)	(−1.045)
External balance	−		−0.038	−0.023
			(−1.29)	(−1.008)
External debt	+		0.003^{***}	0.000
			(2.651)	(0.095)
Development dummy	−		-0.723^{***}	−0.38
			(−2.059)	(−1.341)
Default dummy	+		0.612^{***}	0.085
			(2.577)	(0.385)
Adjusted R^2		0.919	0.857	0.914

A Contribution to the Empirics of Economic Growth, The Quarterly Journal of Economics (1992), N. Gregory Mankiw, David Romer and David N. Weil

- La pregunta natural a considerar es si los datos apoyan las predicciones del modelo de Solow sobre los determinantes del nivel de vida.
- Quieren investigar si el ingreso real es más alto en países con tasas de ahorro más altas y menor en países con valores más altos de $n + g + \delta$
- Ingreso per cápita de estado estacionario:

$$\ln\left[\frac{Y}{L}\right] = \ln A(0) + gt + \frac{\alpha}{1-\alpha}\ln(s) - \frac{\alpha}{1-\alpha}\ln(n+g+\delta)$$

- Ellos suponen que g y δ son constantes en todos los países. g refleja principalmente el avance del conocimiento, que no es específico de un país. Y no hay ninguna razón (ni datos) sólida para esperar que las tasas de depreciación varíen mucho entre países.
- $A(0)$ refleja no solo la tecnología, sino también la dotación de recursos, el clima, las instituciones, entre otros, por lo tanto, puede diferir entre países

A Contribution...

- Asumen que $\ln A(0) = a + \epsilon$ donde a es una constante y ϵ es un shock específico al país.
- Por lo tanto, el log del ingreso per cápita en un momento del tiempo:

$$\ln\left(\frac{Y}{L}\right) = a + \frac{\alpha}{1-\alpha}\ln(s) - \frac{\alpha}{1-\alpha}\ln(n+g+\delta) + \epsilon$$

- Suponen que las tasas de ahorro y el crecimiento de la población son independientes de los factores específicos del país que desplazan la función de producción.
- Es decir, asumen que s y n son independientes de ϵ. Esta suposición implica que "podemos estimar la ecuación con mínimos cuadrados ordinarios (MCO)".
- Debido a que la participación del capital en el ingreso α es aproximadamente un tercio, el modelo implica una elasticidad de la renta per cápita con respecto a la tasa de ahorro de aproximadamente 0,5 y una elasticidad con respecto a $(n+g+\delta)$ de aproximadamente $-0{,}5$.

Datos

- Los datos proceden de las cuentas nacionales. El conjunto de datos incluye el ingreso real, el consumo público y privado, la inversión y la población.
- Los datos son anuales y cubren el período 1960-1985.
- n se mide como la tasa promedio de crecimiento de la población en edad de trabajar (15 y 64 años).
- Miden s como la participación promedio de la inversión real en el PIB real. Y/L como el PIB real en 1985 dividido por la población en edad de trabajar en ese año.

Datos (cont.)

- Consideran tres muestras de países:
  - El más completo incluye todos los países para los que se dispone de datos (sin productores de petróleo). Esta muestra consta de 98 países.
  - La segunda muestra excluye países cuyas poblaciones en 1960 eran menos de un millón o cuyas cifras de ingresos reales se basan en muy pocos datos primarios. Esta muestra consta de 75 países.
  - La tercera muestra está formada por los 22 países de la OCDE con poblaciones superiores a un millón. Ventajas: datos parecen ser de alta calidad y es probable que la variación en los factores específicos del país omitidos sea pequeña. Desventajas: pequeño tamaño y descarta gran parte de la variación en las variables de interés.

Resultados

- Se estima la ecuación con y sin imponer la restricción de que los coeficientes de $\ln(s)$ e $\ln(n+g+\delta)$ son iguales en magnitud y de signo opuesto. Suponemos que $g+\delta$ es 0.05.

TABLE I
ESTIMATION OF THE TEXTBOOK SOLOW MODEL

Dependent variable: log GDP per working-age person in 1985			
Sample:	Non-oil	Intermediate	OECD
Observations:	98	75	22
CONSTANT	5.48	5.36	7.97
	(1.59)	(1.55)	(2.48)
ln(I/GDP)	1.42	1.31	0.50
	(0.14)	(0.17)	(0.43)
$\ln(n+g+\delta)$	−1.97	−2.01	−0.76
	(0.56)	(0.53)	(0.84)
$\overline{R}^2$	0.59	0.59	0.01
s.e.e.	0.69	0.61	0.38
Restricted regression:			
CONSTANT	6.87	7.10	8.62
	(0.12)	(0.15)	(0.53)
$\ln(I/GDP) - \ln(n+g+\delta)$	1.48	1.43	0.56
	(0.12)	(0.14)	(0.36)
$\overline{R}^2$	0.59	0.59	0.06
s.e.e.	0.69	0.61	0.37
Test of restriction:			
p-value	0.38	0.26	0.79
Implied α	0.60	0.59	0.36
	(0.02)	(0.02)	(0.15)

Note. Standard errors are in parentheses. The investment and population growth rates are averages for the period 1960–1985. $(g+\delta)$ is assumed to be 0.05.

Resultados

- Los coeficientes de ahorro y crecimiento de la población tienen los signos previstos y, para dos de las tres muestras, son altamente significativos.
- Muestra 1, Estadístico t: $1{,}42/0{,}14 = 10{,}14$.
- Muestra 2, Estadístico t: $1{,}31/0{,}17 = 7{,}7$, el efecto de la Inversión sobre el PIB per cápita es significativo para todos los niveles de significancia usuales en el grupo de los países de desarrollo intermedio. El coeficiente muestra que un incremento de la participación de la inversión en 1 % está asociado con un aumento del PIB per cápita en alrededor de un 1.31 %.
- OECD: Estadístico t: $0{,}5/0{,}43 = 1{,}16$. El efecto de la Inversión sobre el PIB per cápita no es significativo —utilizando niveles de significancia usuales— en el grupo de países de la OCDE.

Resultados

- Las diferencias en el ahorro y el crecimiento demográfico explican una gran fracción de la variación entre países en el ingreso per cápita. En la regresión para la muestra intermedia, por ejemplo, el $\bar{R}^2$ ajustado es 0,59. Las 2 variables en las que se centra el modelo de Solow explican la mayor parte de la variación del ingreso per cápita.

TABLE I
ESTIMATION OF THE TEXTBOOK SOLOW MODEL

Dependent variable: log GDP per working-age person in 1985			
Sample:	Non-oil	Intermediate	OECD
Observations:	98	75	22
CONSTANT	5.48	5.36	7.97
	(1.59)	(1.55)	(2.48)
ln(I/GDP)	1.42	1.31	0.50
	(0.14)	(0.17)	(0.43)
$\ln(n+g+\delta)$	−1.97	−2.01	−0.76
	(0.56)	(0.53)	(0.84)
$\overline{R}^2$	0.59	0.59	0.01
s.e.e.	0.69	0.61	0.38

Resultados

- La restricción de que los coeficientes de $\ln(s)$ y $\ln(n+g+\delta)$ son iguales en magnitud y el signo opuesto no es rechazada en ninguna de las muestras. P-value: 0.38, 0.26, 0.79 en las distintas muestras.

Sample:	Non-oil	Intermediate	OECD
Observations:	98	75	22
CONSTANT	5.48	5.36	7.97
	(1.59)	(1.55)	(2.48)
ln(I/GDP)	1.42	1.31	0.50
	(0.14)	(0.17)	(0.43)
$\ln(n+g+\delta)$	-1.97	-2.01	-0.76
	(0.56)	(0.53)	(0.84)
$\overline{R}^2$	0.59	0.59	0.01
s.e.e.	0.69	0.61	0.38
Restricted regression:			
CONSTANT	6.87	7.10	8.62
	(0.12)	(0.15)	(0.53)
$\ln(I/GDP) - \ln(n+g+\delta)$	1.48	1.43	0.56
	(0.12)	(0.14)	(0.36)
$\overline{R}^2$	0.59	0.59	0.06
s.e.e.	0.69	0.61	0.37
Test of restriction:			
p-value	0.38	0.26	0.79
Implied α	0.60	0.59	0.36
	(0.02)	(0.02)	(0.15)

Modelo de Solow con Capital Humano

$$\ln\left(\frac{Y(t)}{L(t)}\right) = \ln\left(A(0)\right) + gt - \frac{\alpha+\beta}{1-\alpha-\beta}\ln(n+g+\delta)$$
$$- \frac{\alpha}{1-\alpha-\beta}\ln(s_k) + \frac{\beta}{1-\alpha-\beta}\ln(s_h)$$

TABLE II
ESTIMATION OF THE AUGMENTED SOLOW MODEL

Dependent variable: log GDP per working-age person in 1985			
Sample:	Non-oil	Intermediate	OECD
Observations:	98	75	22
CONSTANT	6.89	7.81	8.63
	(1.17)	(1.19)	(2.19)
ln(I/GDP)	0.69	0.70	0.28
	(0.13)	(0.15)	(0.39)
$\ln(n+g+\delta)$	−1.73	−1.50	−1.07
	(0.41)	(0.40)	(0.75)
ln(SCHOOL)	0.66	0.73	0.76
	(0.07)	(0.10)	(0.29)
$\overline{R}^2$	0.78	0.77	0.24
s.e.e.	0.51	0.45	0.33
Restricted regression:			
CONSTANT	7.86	7.97	8.71
	(0.14)	(0.15)	(0.47)
$\ln(I/GDP) - \ln(n+g+\delta)$	0.73	0.71	0.29
	(0.12)	(0.14)	(0.33)
$\ln(SCHOOL) - \ln(n+g+\delta)$	0.67	0.74	0.76
	(0.07)	(0.09)	(0.28)
$\overline{R}^2$	0.78	0.77	0.28
s.e.e.	0.51	0.45	0.32
Test of restriction:			
p-value	0.41	0.89	0.97
Implied α	0.31	0.29	0.14
	(0.04)	(0.05)	(0.15)
Implied β	0.28	0.30	0.37
	(0.03)	(0.04)	(0.12)

Note. Standard errors are in parentheses. The investment and population growth rates are averages for the period 1960–1985. $(g+\delta)$ is assumed to be 0.05. SCHOOL is the average percentage of the working-age population in secondary school for the period 1960–1985.

Supuesto RLM.6: Normalidad

Supuesto RLM.6 (Normalidad)

El error poblacional u es independiente de $x_1, x_2, ..., x_k$ y se distribuye normal con media cero y varianza σ^2:

$$u \sim N(0, \sigma^2)$$

- Los supuestos RLM.1 a RLM.6 se conocen como los supuestos del **modelo lineal clásico** (MLC).
- RLM.6 es más fuerte que los anteriores: implica RLM.4 (media condicional cero) y RLM.5 (homocedasticidad).
- Equivalentemente, bajo el MLC la distribución de y dado x es normal:

$$y \,|\, x_1, ..., x_k \sim N(\beta_0 + \beta_1 x_1 + ... + \beta_k x_k,\ \sigma^2)$$

Consecuencias de RLM.6

- Bajo el MLC, condicional en los valores muestrales de las variables independientes, los estimadores MCO tienen distribución normal:

$$\hat{\beta}_j \sim N(\beta_j,\ \text{Var}(\hat{\beta}_j)) \quad \Rightarrow \quad \frac{\hat{\beta}_j - \beta_j}{\text{sd}(\hat{\beta}_j)} \sim N(0,1)$$

- Como σ es desconocido y se reemplaza por $\hat{\sigma}$, el estadístico t tiene una distribución t exacta, para **cualquier tamaño de muestra**:

$$\frac{\hat{\beta}_j - \beta_j}{\text{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

- Del mismo modo, el estadístico F para q restricciones tiene distribución exacta $F_{q,\,n-k-1}$.
- Por lo tanto, los intervalos de confianza y las pruebas de hipótesis vistos son **exactos** y no solo aproximados.

¿Es razonable el supuesto de normalidad?

- RLM.6 es un supuesto sobre el error u, no sobre y ni sobre las x_j.
- En la práctica suele fallar:
  - variables asimétricas, como salarios o ingresos;
  - variables discretas o acotadas, como el número de arrestos o variables binarias.
- A veces una transformación ayuda: usar $\log(wage)$ en lugar de $wage$ suele acercar la distribución a una normal.
- RLM.6 **no** es necesario para la insesgadez ni para el Teorema de Gauss-Markov.
- En muestras grandes tampoco es necesario: por el Teorema Central del Límite los estimadores MCO son asintóticamente normales y las pruebas t y F son válidas de forma aproximada.

Inferencia en grandes muestras

- Nótese que en el último resultado de la sección anterior tenemos que la distribución es $N(0,1)$ en lugar de ser una t_{n-k-1} como teníamos antes. Esto se debe a que la distribución es solo aproximada mientras que en el tema 4 teníamos que, cuando se verifica también el supuesto RLM.6, la distribución es exactamente una t_{n-k-1}. Desde el punto de vista práctico esta diferencia es irrelevante. De hecho, podríamos escribir

$$\frac{\hat{\beta}_j - \beta_j}{\text{ee}(\hat{\beta}_j)} \sim t_{n-k-1}$$

- ya que la distribución t_{n-k-1} se aproxima a una $N(0,1)$ cuando aumentan sus grados de libertad.

Otros contrastes para muestras grandes: el contraste LM

- Consideremos el modelo de regresión múltiple

$$y = \beta_0 + \beta_1 x_1 + ... + \beta_k x_k + u$$

- En este modelo queremos contrastar si las últimas q variables tienen coeficientes iguales a cero en la población. La hipótesis nula es

$$H_0 : \beta_{k-q+1} = 0, \ .., \ \beta_k = 0$$

Para calcular el estadístico de contraste LM primero estimamos el modelo restringido, es decir el modelo

$$y = \beta_0 + \beta_1 x_1 + ... + \beta_{k-q} x_{k-q} + u$$

y calculamos los residuos que vamos a denotar por $\tilde{u}$.

Otros contrastes para muestras grandes: el contraste LM

- A continuación estimamos por MCO la regresión de los residuos del modelo restringido sobre todas las variables del modelo original y calculamos el R-cuadrado, que denominaremos R_u^2.
- Si la hipótesis nula es cierta, $\tilde{u}$ estará aproximadamente incorrelacionado con todas las variables explicativas, y por tanto R_u^2 debería estar próximo a cero.
- La pregunta es cómo determinar cuándo R_u^2 es suficientemente grande para rechazar la hipótesis nula.
- Se puede demostrar que $LM = nR_u^2 \sim \chi_q^2$ bajo H_0, y por tanto podemos utilizar $LM = nR_u^2$ como estadístico de contraste
- la regla de decisión es:

$$\text{Rechazar } H_0 \text{ a nivel } \alpha \text{ si } LM > \chi_{q,\alpha}^2$$

- Esta regresión de los residuos del modelo restringido sobre todas las variables del modelo original es un ejemplo de lo que se denomina una regresión auxiliar, que es una regresión cuyos coeficientes estimados no tienen ningún interés, pero que tenemos que hacer para calcular un estadístico de contraste.

Ejemplo: Tasa de Crimen

- La base CRIME1 del libro de Wooldridge contiene los datos relativos a arrestos en el año 1986 e información acerca de 2725 hombres nacidos en California en 1960 o en 1961. Cada hombre de la muestra fue arrestado al menos una vez antes de 1986.
- Consideremos el modelo

$$narr86 = \beta_0 + \beta_1 pcnv + \beta_2 ptime86 + \beta_3 qemp86 + \beta_4 avgsen + \beta_5 tottime + u$$

  donde *narr86* es el número de arrestos en 1986, *pcnv* es la proporción de detenciones que culminaron en una condena, *ptime86* son los meses pasados en prisión en 1986, *qemp86* es el número de trimestres en los que el sujeto tuvo un empleo legal en 1986, *avgsen* es la condena promedio cumplida en penas anteriores y *tottime* es el tiempo que el sujeto pasó en la cárcel desde que cumplió 18 años hasta 1986.
- Vamos a utilizar el estadístico LM para contrastar la hipótesis nula de que, controlando por el resto de los factores, *avgsen* y *tottime* no afectan a *narr86*.

Ejemplo: Tasa de Crimen

- Estimamos el modelo restringido

$$narr86 = \beta_0 + \beta_1 pcnv + \beta_2 ptime86 + \beta_3 qemp86 + v$$

  y calculamos los residuos $\tilde{u}$.
- Estimamos la regresión auxiliar de $\tilde{u}$ sobre una constante, *pcnv*, *ptime86*, *qemp86*, *avgsen* y *tottime*.
- El R-cuadrado de esta regresión auxiliar es $R_u^2 = 0{,}001494$.
- El valor del estadístico de contraste en la muestra es $LM = nR_u^2 = 2725 * 0{,}001494 = 4{,}071$.
- el p-valor es $\text{Prob}(\chi^2 > 4{,}071) = 0{,}131$. Por tanto no podemos rechazar H_0 al 10 %.
- También podemos utilizar el estadístico F para hacer el contraste:

$$F = \frac{(1927{,}273 - 1924{,}394)/2}{1924{,}394/2719} = 2{,}034$$

- y el p-valor es $\text{Prob}(F_{2,2719} > 2{,}043) = 0{,}130$. El p-valor es prácticamente el mismo que cuando utilizábamos el contraste LM.