

Econometría I

Tema 1.3: Muestreo y Estimación Estimadores, propiedades, consistencia, LGN y TCL

Cliff Bahamondes Poblete

Ingeniería Comercial mención Economía
Universidad de Santiago de Chile

Abril 2026

- ➊ De la pregunta económica a la población de interés.
- ➋ Población, muestra y muestra aleatoria.
- ➌ Estadístico, estimador y estimación.
- ➍ Propiedades de estimadores:
 - insesgadez,
 - eficiencia,
 - mínima varianza,
 - error cuadrático medio,
 - suficiencia.
- ➎ Consistencia y Ley de los Grandes Números.
- ➏ Teorema Central del Límite y distribución muestral.
- ➐ Aplicación en R y conexión con regresión lineal simple.

Idea central de la clase

Pregunta guía: ¿cómo usamos una muestra para aprender algo sobre una población?

En econometría rara vez observamos toda la población. Por ello, necesitamos:

- ➊ Definir el **parámetro poblacional** de interés.
- ➋ Construir un **estimador** usando la muestra.
- ➌ Evaluar si el estimador tiene buenas propiedades.
- ➍ Medir la **incertidumbre** asociada a la estimación.

Mensaje clave

Estimar no es solo calcular un número: es cuantificar qué tan confiable es ese número como aproximación de un parámetro poblacional.

Motivación

De la pregunta económica al parámetro poblacional

La econometría no comienza con una fórmula, sino con una pregunta empírica.

Antes de estimar, necesitamos definir **qué queremos conocer, sobre qué población y mediante qué variable observable.**

Pregunta económica y objeto de estudio

Antes de estimar, necesitamos formular una pregunta económica o empresarial.

Ejemplos

- ¿Cuál es el ingreso promedio mensual de los hogares?
- ¿Cuál es la productividad promedio de los trabajadores?
- ¿Cuánto gastan, en promedio, los clientes de una empresa?
- ¿La capacitación aumenta la productividad laboral?
- ¿El aumento del salario mínimo afecta el empleo?

Una buena pregunta empírica debe identificar:

- una unidad de análisis;
- una variable de interés;
- una población;
- un parámetro o relación poblacional que se desea conocer.

De la pregunta económica al parámetro

Supongamos que queremos estudiar el ingreso mensual de los hogares.

Elemento	Ejemplo
Pregunta económica	Cuál es el ingreso promedio de los hogares?
Variable	Y : ingreso mensual del hogar
Unidad de análisis	Hogar
Población	Todos los hogares de interés
Parámetro poblacional	$\mu_Y = \mathbb{E}(Y)$
Muestra observada	$Y_1, Y_2, \dots, Y_n$
Estimador natural	$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$

Modelo estadístico mínimo para estimar

Para estudiar una variable económica Y , podemos partir de un modelo estadístico simple:

$$Y_1, Y_2, \dots, Y_n \sim F_Y,$$

donde F_Y representa la distribución poblacional de la variable.

Si nos interesa la media poblacional:

$$\mu_Y = \mathbb{E}(Y),$$

el problema de estimación es construir una regla muestral que aproxime μ_Y .

Supuesto clave inicial

La muestra debe ser informativa sobre la población. En el caso más simple, suponemos que las observaciones son independientes e idénticamente distribuidas:

$$Y_1, \dots, Y_n \text{ son i.i.d.}$$

Población, muestra y muestra aleatoria

¿De dónde provienen los datos que usamos para estimar?

Una vez definida la pregunta económica, debemos precisar la población de interés y el mecanismo mediante el cual observamos una parte de ella.

Esta distinción es central porque toda estimación depende de la **calidad** y **representatividad de la muestra**.

Definición

La **población** es el conjunto de todas las unidades de análisis a las que se refiere una investigación.

Ejemplos de unidades de análisis:

- personas;
- hogares;
- trabajadores;
- empresas;
- comunas;
- países;
- periodos de tiempo.

Cada unidad posee atributos o características observables, que modelamos como variables aleatorias.

Definición

Una **muestra** es un subconjunto de unidades recolectadas desde una población mediante algún procedimiento sistemático.

¿Por qué estudiar una muestra y no la población completa?

- Restricciones de costo.
- Restricciones de tiempo.
- Disponibilidad de datos.
- Imposibilidad práctica de observar toda la población.
- Necesidad de tomar decisiones con información parcial.

Cuidado

Una muestra no representativa puede conducir a estimaciones engañosas, aunque las fórmulas estén correctamente aplicadas.

Muestra aleatoria

Una muestra aleatoria de tamaño n se representa como:

$$Y_1, Y_2, \dots, Y_n.$$

En el caso más simple, asumimos:

$$Y_i \sim F_Y \quad \text{para todo } i,$$

y

Y_i es independiente de Y_j si $i \neq j$.

Interpretación

Cada observación proviene de la misma población y no entrega información mecánica sobre las demás observaciones.

Muestra aleatoria y econometría

En Econometría I, el supuesto de muestra aleatoria será fundamental para estudiar regresión.

En regresión simple observaremos datos del tipo:

$$(Y_i, X_i), \quad i = 1, \dots, n.$$

Una muestra aleatoria implicará que:

$$(Y_1, X_1), \dots, (Y_n, X_n)$$

provienen de la misma población y son independientes entre unidades.

Ejemplo

Si estudiamos salario y educación, cada observación puede representar a una persona:

$$(Y_i, X_i) = (\text{salario}_i, \text{educación}_i).$$

Estadísticos, estimadores y estimaciones

¿Cómo transformamos datos muestrales en información sobre la población?

A partir de una muestra podemos construir funciones de los datos.

Algunas de esas funciones se usan para aproximar parámetros poblacionales desconocidos: esos serán nuestros estimadores.

Definición

Sea $(Y_1, Y_2, \dots, Y_n)$ una muestra aleatoria. Un **estadístico** es cualquier función conocida de la muestra:

$$T = T(Y_1, Y_2, \dots, Y_n).$$

Ejemplos:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i,$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2,$$

$$Y_{(1)} = \min\{Y_1, \dots, Y_n\}.$$

Punto clave

Un estadístico no depende de parámetros desconocidos.

Definición

Un **estimador** es un estadístico usado para aproximar un parámetro poblacional desconocido.

Si el parámetro de interés es θ , un estimador se denota por:

$$\hat{\theta} = T(Y_1, \dots, Y_n).$$

Ejemplos:

Parámetro	Interpretación	Estimador
μ_Y	media poblacional	$\bar{Y}$
σ_Y^2	varianza poblacional	S^2
β_1	pendiente poblacional	$\hat{\beta}_1$
p	proporción poblacional	$\hat{p}$

Estimación

Una vez observada la muestra:

$$y_1, y_2, \dots, y_n,$$

el estimador toma un valor concreto:

$$\hat{\theta} = T(Y_1, \dots, Y_n) \longrightarrow \hat{\theta}_{obs} = T(y_1, \dots, y_n).$$

Definición

La **estimación** es el valor numérico observado de un estimador.

Ejemplo:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

es el estimador de μ_Y , mientras que

$$\bar{y} = 850,000$$

es una estimación particular.

Parámetro, estimador y estimación

Concepto	Interpretación
Parámetro	Característica poblacional desconocida. Ejemplo: μ , σ^2 , β_1 .
Estimador	Regla o función de la muestra. Ejemplo: $\bar{Y}$, S^2 , $\hat{\beta}_1$.
Estimación	Valor numérico observado del estimador. Ejemplo: $\bar{y} = 850,000$.
Error de estimación	Diferencia entre estimador y parámetro: $\hat{\theta} - \theta$.
Error estándar	Desviación estándar del estimador: mide incertidumbre muestral.
Residuo	Diferencia entre valor observado y valor ajustado en regresión: $\hat{u}_i = y_i - \hat{y}_i$.

Ejemplo simple: ingreso promedio

Supongamos que queremos estimar el ingreso mensual promedio de los hogares.

$$\mu_Y = \mathbb{E}(Y)$$

es el parámetro poblacional.

Una muestra de n hogares entrega:

$$Y_1, Y_2, \dots, Y_n.$$

El estimador natural es:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Interpretación

Si la muestra es representativa y suficientemente grande, esperamos que $\bar{Y}$ esté cerca de μ_Y .

Propiedades de los estimadores

No todo estadístico es un buen estimador

Una vez construido un estimador, debemos evaluar si entrega información confiable sobre el parámetro.

Para ello estudiaremos **sesgo, varianza, eficiencia, error cuadrático medio, mínima varianza, suficiencia y consistencia**.

Qué hace bueno a un estimador?

No todo estadístico es un buen estimador.

Para evaluar un estimador $\hat{\theta}$ de un parámetro θ , estudiaremos:

- **Insesgadez:** si el estimador está centrado en el parámetro.
- **Eficiencia:** si el estimador es poco disperso.
- **Mínima varianza:** si alcanza la menor varianza posible dentro de una clase.
- **Error cuadrático medio:** balance entre sesgo y varianza.
- **Suficiencia:** si usa toda la información muestral relevante sobre el parámetro.
- **Consistencia:** si se acerca al parámetro cuando aumenta n .

Idea general

Un buen estimador debe entregar información confiable sobre un objeto poblacional que no observamos directamente.

Definición

Un estimador $\hat{\theta}$ es **insesgado** para θ si:

$$\mathbb{E}(\hat{\theta}) = \theta.$$

Interpretación:

Si repitiéramos muchas veces el muestreo, el promedio de las estimaciones coincidiría con el verdadero parámetro.

Cuidado

Insesgadez no significa que una estimación particular sea igual al parámetro.

Ejemplo:

$$\mathbb{E}(\bar{Y}) = \mu_Y.$$

Por lo tanto, $\bar{Y}$ es un estimador insesgado de μ_Y .

Demostración: insesgadez de la media muestral

Sea $Y_1, \dots, Y_n$ una muestra aleatoria con:

$$\mathbb{E}(Y_i) = \mu_Y.$$

La media muestral es:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Entonces:

$$\mathbb{E}(\bar{Y}) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(Y_i) = \frac{1}{n} \sum_{i=1}^n \mu_Y = \mu_Y.$$

Conclusión

La media muestral está centrada en la media poblacional.

Definición

El sesgo de un estimador $\hat{\theta}$ se define como:

$$Bias(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta.$$

Si:

$$Bias(\hat{\theta}) = 0,$$

entonces el estimador es insesgado. Si:

$$Bias(\hat{\theta}) \neq 0,$$

el estimador tiende a sobreestimar o subestimar sistemáticamente el parámetro.

Interpretación econométrica

El sesgo será central cuando discutamos variables omitidas, endogeneidad y errores de medición.

Definición

Entre dos estimadores insesgados de θ , se dice que $\hat{\theta}_1$ es más eficiente que $\hat{\theta}_2$ si:

$$\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2).$$

Interpretación:

Si ambos estimadores están centrados en el parámetro, preferimos aquel que varía menos entre muestras.

Estimador	Sesgo	Varianza
$\hat{\theta}_1$	0	baja
$\hat{\theta}_2$	0	alta

Conclusión

La eficiencia es una propiedad comparativa.


Simulación: insesgadez y eficiencia

Pregunta: si dos estimadores están centrados en el parámetro, ¿cuál preferimos?

En la simulación se compara:

- la media muestral;
- la mediana muestral.

Ambas pueden estar aproximadamente centradas en μ , pero una puede ser menos dispersa.



Lectura

El estimador más eficiente es aquel con menor varianza muestral entre repeticiones.

Error cuadrático medio

El error cuadrático medio resume dos fuentes de error:

$$ECM(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

Puede descomponerse como:

$$ECM(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2.$$

Interpretación

Un estimador puede ser poco conveniente porque:

- tiene alta varianza;
- tiene sesgo;
- o combina ambas fuentes de error.

Cuidado

Un estimador con pequeño sesgo puede ser preferible a uno insesgado si reduce mucho la varianza. Este trade-off aparece en muchos problemas empíricos.

Descomposición del error cuadrático medio

Sea $\hat{\theta}$ un estimador del parámetro poblacional θ .

El **error cuadrático medio** mide el error esperado al cuadrado:

$$ECM(\hat{\theta}) = \mathbb{E} \left[(\hat{\theta} - \theta)^2 \right].$$

Sumando y restando $\mathbb{E}(\hat{\theta})$ dentro del paréntesis:

$$\hat{\theta} - \theta = \left[\hat{\theta} - \mathbb{E}(\hat{\theta}) \right] + \left[\mathbb{E}(\hat{\theta}) - \theta \right].$$

Por lo tanto:

$$ECM(\hat{\theta}) = \text{Var}(\hat{\theta}) + \left[\text{Bias}(\hat{\theta}) \right]^2.$$

Interpretación

Un estimador puede tener un alto error cuadrático medio porque es muy variable, porque está sesgado, o por ambas razones.

Mínima varianza

Definición

Un estimador insesgado $\hat{\theta}$ es de **mínima varianza** dentro de una clase de estimadores si no existe otro estimador insesgado en esa clase con menor varianza.

Formalmente, si $\tilde{\theta}$ es cualquier otro estimador insesgado de θ :

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta}).$$

Lectura econométrica

En regresión, el Teorema de Gauss-Markov dirá que, bajo ciertos supuestos, MCO es el mejor estimador lineal insesgado: el de menor varianza dentro de la clase de estimadores lineales insesgados.

Información de Fisher

En modelos paramétricos, suponemos que la distribución depende de un parámetro desconocido:

$$Y \sim f(y; \theta).$$

La **información de Fisher** mide cuánta información entrega la muestra sobre θ .

Para una observación:

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(Y; \theta) \right)^2 \right].$$

Para una muestra i.i.d. de tamaño n :

$$I_n(\theta) = nI(\theta).$$

Intuición

A mayor información de Fisher, menor incertidumbre potencial sobre el parámetro.

Cota de Cramér–Rao

La cota de Cramér–Rao establece un límite inferior para la varianza de estimadores insesgados.

Si $\hat{\theta}$ es insesgado para θ , bajo condiciones regulares:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{I_n(\theta)}.$$

Interpretación

No podemos construir un estimador insesgado con varianza arbitrariamente pequeña. La información disponible en los datos impone un límite.

Si un estimador alcanza esta cota, se dice que es eficiente en el sentido de Cramér–Rao.

Definición intuitiva

Un estadístico $T(Y_1, \dots, Y_n)$ es **suficiente** para θ si contiene toda la información de la muestra relevante para estimar θ .

Esto significa que, una vez conocido T , la muestra completa no agrega información adicional sobre θ .

Ejemplo clásico

Si: $Y_i \sim \text{Bernoulli}(p)$, entonces: $T = \sum_{i=1}^n Y_i$ es suficiente para p .

Lectura aplicada

La suficiencia ayuda a entender cuándo un resumen de los datos conserva toda la información relevante para un parámetro.

Ejemplo: distribución exponencial

Supongamos que el tiempo de espera de una persona en una plataforma sigue una distribución exponencial:

$$Y_i \sim \text{Exp}(\lambda).$$

La densidad es:

$$f(y; \lambda) = \lambda e^{-\lambda y}, \quad y \geq 0.$$

La esperanza poblacional es:

$$\mathbb{E}(Y) = \frac{1}{\lambda}.$$

Pregunta

Si queremos estimar el tiempo promedio de espera, qué estimador parece natural?

Ejemplo exponencial: estimadores alternativos

Para estimar la media poblacional:

$$\theta = \mathbb{E}(Y) = \frac{1}{\lambda},$$

podemos considerar varios estimadores.

Estimador 1: media muestral

$$\hat{\theta}_1 = \bar{Y}.$$

Estimador 2: función del mínimo

$$Y_{(1)} = \min\{Y_1, \dots, Y_n\}.$$

En muestras exponenciales, el mínimo también contiene información sobre λ .

Mensaje pedagógico

Que un estadístico contenga información sobre un parámetro no significa que sea el estimador más conveniente. Debemos evaluar sesgo, varianza, ECM y consistencia.

Distribución muestral y error estándar

¿Por qué un estimador tiene incertidumbre?

Un estimador cambia de muestra en muestra.

Por eso no basta con calcular una estimación puntual: también necesitamos **describir la distribución muestral del estimador y medir su incertidumbre mediante el error estándar.**

Distribución muestral de un estimador

Como un estimador depende de una muestra aleatoria, el estimador también es una variable aleatoria.

Si repetimos muchas veces el muestreo:

$$\hat{\theta}^{(1)}, \hat{\theta}^{(2)}, \dots, \hat{\theta}^{(B)},$$

obtendremos distintos valores del estimador.

Definición

La **distribución muestral** de un estimador es la distribución de probabilidad que tendría el estimador bajo muestreo repetido.

Clave

La inferencia estadística se basa en conocer o aproximar esta distribución.

Distribución muestral de la media

Sea $Y_1, \dots, Y_n$ una muestra aleatoria con:

$$\mathbb{E}(Y_i) = \mu_Y, \quad \text{Var}(Y_i) = \sigma_Y^2.$$

La media muestral es:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Entonces:

$$\mathbb{E}(\bar{Y}) = \mu_Y,$$

y, si las observaciones son independientes:

$$\text{Var}(\bar{Y}) = \frac{\sigma_Y^2}{n}.$$

Interpretación


Al aumentar n , la media muestral se vuelve menos variable.

Simulación: distribución muestral de la media

Cada histograma muestra la distribución de muchas medias muestrales simuladas.

Se comparan tres tamaños muestrales:

$$n = 10, \quad n = 50, \quad n = 200.$$



Lectura

Al aumentar n , la distribución de $\bar{Y}$ se concentra alrededor de μ_Y .

Esto anticipa dos resultados:

- consistencia;
- menor error estándar.

Demostración: varianza de la media muestral

Partimos de:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Entonces:

$$\text{Var}(\bar{Y}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n Y_i\right).$$

Sacando la constante:

$$\text{Var}(\bar{Y}) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n Y_i\right).$$

Si las observaciones son independientes:

$$\text{Var}\left(\sum_{i=1}^n Y_i\right) = \sum_{i=1}^n \text{Var}(Y_i) = n\sigma_Y^2.$$

Por lo tanto:

$$\text{Var}(\bar{Y}) = \frac{\sigma_Y^2}{n}.$$

Error estándar

Definición

El **error estándar** de un estimador es la desviación estándar de su distribución muestral.

Para la media muestral:

$$SE(\bar{Y}) = \sqrt{\text{Var}(\bar{Y})} = \frac{\sigma_Y}{\sqrt{n}}.$$

Como σ_Y normalmente es desconocida, usamos:

$$\widehat{SE}(\bar{Y}) = \frac{S_Y}{\sqrt{n}}.$$

Interpretación

El error estándar mide la incertidumbre del estimador, no la dispersión directa de los datos individuales.

Desviación estándar versus error estándar

Concepto	Qué mide
Desviación estándar S_Y	Dispersión de los datos individuales alrededor de la media muestral.
Error estándar $\widehat{SE}(\bar{Y})$	Dispersión esperada de la media muestral entre muestras repetidas.

$$\widehat{SE}(\bar{Y}) = \frac{S_Y}{\sqrt{n}}.$$

Implicancia

Al aumentar el tamaño muestral, no necesariamente disminuye la dispersión individual de Y , pero sí disminuye la incertidumbre sobre μ_Y .

Consistencia y Ley de los Grandes Números

¿Por qué un estimador puede acercarse al parámetro cuando la muestra crece?

Hasta ahora hemos estudiado propiedades de los estimadores en términos de *sesgo, varianza y eficiencia*.

Ahora nos interesa una propiedad central para econometría aplicada:
que el estimador se acerque al parámetro poblacional cuando aumenta el tamaño muestral.

La **Ley de los Grandes Números** nos permitirá entender por qué muchos promedios muestrales se estabilizan alrededor de sus valores poblacionales.

Consistencia

Definición

Un estimador $\hat{\theta}_n$ es **consistente** para θ si, para todo $\varepsilon > 0$:

$$P(|\hat{\theta}_n - \theta| > \varepsilon) \rightarrow 0 \quad \text{cuando } n \rightarrow \infty.$$

También se escribe como:

$$\hat{\theta}_n \xrightarrow{p} \theta,$$

o

$$plim(\hat{\theta}_n) = \theta.$$

Interpretación

Al aumentar el tamaño muestral, es cada vez menos probable que el estimador esté lejos del parámetro.

Insesgadez y consistencia no son lo mismo

Insesgadez es una propiedad de muestras finitas:

$$\mathbb{E}(\hat{\theta}) = \theta.$$

Consistencia es una propiedad asintótica:

$$\hat{\theta}_n \xrightarrow{p} \theta \quad \text{cuando} \quad n \rightarrow \infty.$$

Diferencia central

- Insesgadez: el estimador está correctamente centrado.
- Consistencia: el estimador se concentra alrededor del parámetro al crecer la muestra.

Un estimador puede ser sesgado en muestras pequeñas, pero consistente si su sesgo desaparece cuando aumenta n .

Ley de los Grandes Números

La Ley de los Grandes Números explica por qué los promedios muestrales se vuelven informativos sobre la población.

Si $Y_1, \dots, Y_n$ son i.i.d., con media μ_Y y varianza finita, entonces:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{p} \mu_Y.$$

Interpretación

Al aumentar el tamaño muestral, la media muestral se aproxima en probabilidad a la media poblacional.

Rol en econometría

La Ley de los Grandes Números justifica la consistencia de muchos estimadores construidos como promedios o funciones de promedios.

Simulación: consistencia de una proporción


Supongamos un dado justo de 8 caras.

Queremos estimar:

$$p = P(\text{obtener un } 8) = \frac{1}{8} = 0.125.$$

El estimador acumulado es:

$$\hat{p}_n = \frac{\#\{\text{veces que aparece 8 hasta } n\}}{n}.$$



Lectura

A medida que aumenta n , $\hat{p}_n$ se estabiliza cerca de $p = 1/8$.

Simulación: consistencia de la media muestral

Ahora aplicamos la misma lógica a una variable económica: ingreso mensual.


El estimador acumulado es:

$$\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i.$$

La línea horizontal representa la media poblacional simulada:

$$\mu_Y = \mathbb{E}(Y).$$

Consistencia de la media muestral



Lectura

La media acumulada fluctúa al inicio, pero se estabiliza cerca de μ_Y cuando aumenta el tamaño muestral.

Consistencia de la media muestral

Queremos estimar:

$$\mu_Y = \mathbb{E}(Y).$$

Usamos:

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Por la Ley de los Grandes Números:

$$\bar{Y} \xrightarrow{p} \mu_Y.$$

Conclusión

La media muestral es un estimador consistente de la media poblacional.

Lectura económica

Con muestras grandes y bien recolectadas, el promedio observado entrega una aproximación confiable al promedio poblacional.

Propiedades de límites en probabilidad

Si:

$$\hat{\theta}_n \xrightarrow{P} \theta \quad \text{y} \quad \hat{\gamma}_n \xrightarrow{P} \gamma,$$

entonces:

$$\hat{\theta}_n + \hat{\gamma}_n \xrightarrow{P} \theta + \gamma,$$

$$\hat{\theta}_n - \hat{\gamma}_n \xrightarrow{P} \theta - \gamma,$$

$$\hat{\theta}_n \hat{\gamma}_n \xrightarrow{P} \theta \gamma,$$

$$\frac{\hat{\theta}_n}{\hat{\gamma}_n} \xrightarrow{P} \frac{\theta}{\gamma}, \quad \gamma \neq 0.$$

Utilidad

Estas reglas permiten demostrar consistencia de estimadores más complejos a partir de componentes consistentes.

Función continua y consistencia

Si:

$$\hat{\theta}_n \xrightarrow{p} \theta,$$

y $g(\cdot)$ es una función continua, entonces:

$$g(\hat{\theta}_n) \xrightarrow{p} g(\theta).$$

Ejemplo

Si S^2 es consistente para σ^2 , entonces:

$$S = \sqrt{S^2}$$

es consistente para:

$$\sigma = \sqrt{\sigma^2}.$$

Lectura econométrica

Muchos estimadores econométricos son funciones de promedios, varianzas y covarianzas muestrales.

Teorema Central del Límite

La LGN explica convergencia; el TCL explica inferencia

La Ley de los Grandes Números nos dice que el estimador se acerca al parámetro.

Pero para hacer inferencia necesitamos algo más:
conocer cómo se distribuye el error de estimación.

Ese es el rol del Teorema Central del Límite.

Teorema Central del Límite

Si $Y_1, \dots, Y_n$ son i.i.d., con media μ_Y y varianza finita $0 < \sigma_Y^2 < \infty$, entonces:

$$\frac{\bar{Y} - \mu_Y}{\sigma_Y / \sqrt{n}} \xrightarrow{d} N(0, 1).$$

Equivalente:

$$\sqrt{n}(\bar{Y} - \mu_Y) \xrightarrow{d} N(0, \sigma_Y^2).$$

Interpretación

Aunque la población original no sea normal, la distribución de la media muestral estandarizada se aproxima a una normal cuando n es grande.

LGN versus TCL

	Ley de los Grandes Números	Teorema Central del Límite
Objeto	$\bar{Y}$	$\frac{\bar{Y} - \mu_Y}{\sigma_Y / \sqrt{n}}$
Conclusión	Convergencia a μ_Y	Aproximación normal
Uso	Consistencia	Inferencia
Pregunta que responde	El estimador se acerca al parámetro?	Cómo se distribuye el error de estimación?

Síntesis

La LGN explica por qué estimar funciona; el TCL explica cómo medir la incertidumbre de la estimación.

Normalidad aproximada de la media

Por el Teorema Central del Límite, para n grande:

$$\bar{Y} \approx N\left(\mu_Y, \frac{\sigma_Y^2}{n}\right).$$

Si σ_Y es desconocida, usamos S_Y :

$$\frac{\bar{Y} - \mu_Y}{S_Y/\sqrt{n}} \approx N(0, 1).$$

Base de la inferencia

Esto permite construir intervalos de confianza y pruebas de hipótesis aproximadas.

$$\bar{Y} \pm 1.96 \cdot \frac{S_Y}{\sqrt{n}}$$

es una aproximación usual para un intervalo de confianza al 95 %.


Simulación: Teorema Central del Límite

La variable ingreso original no es normal.

Sin embargo, el TCL establece que:

$$\frac{\bar{Y} - \mu_Y}{\sigma_Y / \sqrt{n}} \approx N(0, 1)$$

cuando n es suficientemente grande.



Lectura

La aproximación normal mejora al aumentar el tamaño muestral.

La curva superpuesta corresponde a la normal estándar.

Inferencia: una vista previa

La inferencia estadística busca responder:

- Qué tan precisa es mi estimación?
- Qué valores del parámetro son compatibles con los datos?
- Existe evidencia estadística contra una hipótesis?

Para ello necesitamos:

- 1 un estimador;
- 2 su error estándar;
- 3 una distribución muestral exacta o aproximada.

Conexión con regresión

La misma lógica se aplicará a $\hat{\beta}_0$, $\hat{\beta}_1$ y, en regresión múltiple, a cada $\hat{\beta}_j$.

Aplicación en R

Visualizar lo que dicen la LGN y el TCL

Ahora pasamos de la formulación teórica a una simulación.

El objetivo no es aprender un modelo nuevo, sino observar cómo se comportan los estimadores cuando repetimos el muestreo muchas veces.

Aplicación empírica: ingreso mensual simulado

Usaremos una simulación para representar una población de ingresos.

Objetivo

Visualizar tres ideas:

- 1 la media muestral cambia de muestra en muestra;
- 2 al aumentar n , la media muestral se concentra alrededor de μ ;
- 3 la media muestral estandarizada se aproxima a una normal.

La variable ingreso suele ser positiva y asimétrica a la derecha. Por eso, simularemos ingresos usando una distribución lognormal.

Uso pedagógico

No nos interesa que el modelo sea realista en todos sus detalles, sino que permita ver con claridad la LGN y el TCL.

Distribución poblacional simulada


El código construye una población simulada de ingresos mensuales.

La distribución es:

- positiva;
- asimétrica a la derecha;
- no normal.

Idea central

Aunque la variable original no sea normal, la media muestral puede tener una distribución aproximadamente normal cuando n es grande.



Código R I: población y primera muestra

```
set.seed(123)
# 1. Creamos una "poblacion" grande de ingresos.
# En la realidad no conocemos la población completa.
N_pop <- 100000
ingreso_pop <- rlnorm(N_pop, meanlog = 13, sdlog = 0.6)

# Parametros poblacionales aproximados
mu_pop <- mean(ingreso_pop)
sigma_pop <- sd(ingreso_pop)
mu_pop
sigma_pop

# 2. Tomamos una muestra aleatoria
n <- 50
muestra <- sample(ingreso_pop, size = n)

# Estimación puntual y error estándar estimado
media_muestral <- mean(muestra)
se_media <- sd(muestra) / sqrt(n)
media_muestral
se_media
```

Código R II: distribución muestral

```
# 3. Simulación: repetir muchas veces el muestreo
B <- 5000
simular_medias <- function(n) {
  replicate(B, mean(sample(ingreso_pop, size = n))) }
medias_10 <- simular_medias(10)
medias_50 <- simular_medias(50)
medias_200 <- simular_medias(200)

# 4. Distribución muestral para distintos tamaños de muestra
par(mfrow = c(1, 3))
hist(medias_10, breaks = 40, main = "n = 10", xlab = "Media muestral")
abline(v = mu_pop, lwd = 2)
hist(medias_50, breaks = 40, main = "n = 50", xlab = "Media muestral")
abline(v = mu_pop, lwd = 2)
hist(medias_200, breaks = 40, main = "n = 200", xlab = "Media muestral")
abline(v = mu_pop, lwd = 2)
par(mfrow = c(1, 1))
```

Código R III: Teorema Central del Límite

```
# 5. Teorema Central del Límite:  
# media muestral estandarizada  
  
z_200 <- (medias_200 - mu_pop) / (sigma_pop / sqrt(200))  
  
hist(z_200,  
     probability = TRUE,  
     breaks = 40,  
     main = "Media estandarizada",  
     xlab = "z")  
  
curve(dnorm(x), add = TRUE, lwd = 2)
```

Lectura esperada

Aunque los ingresos individuales no son normales, la media estandarizada se aproxima a una normal estándar cuando el tamaño muestral es suficientemente grande.

Código R IV: Ley de los Grandes Números

```
# 6. Ley de los Grandes Números:  
# probabilidad de estar lejos de la media poblacional  
  
n_grid <- c(5, 10, 30, 50, 100, 300, 1000)  
epsilon <- 50000  
  
prob_lejos <- sapply(n_grid, function(n) {  
  medias <- simular_medias(n)  
  mean(abs(medias - mu_pop) > epsilon) })  
  
plot(n_grid, prob_lejos,  
     type = "b",  
     xlab = "Tamaño muestral",  
     ylab = "Probabilidad de estar lejos de la media",  
     main = "Ley de los Grandes Números")
```

Lectura esperada

A medida que aumenta n , disminuye la probabilidad de que la media muestral esté lejos de la media poblacional.

Interpretación de la aplicación

Resultado 1: la media muestral varía entre muestras.

$$\bar{Y}^{(1)} \neq \bar{Y}^{(2)} \neq \dots \neq \bar{Y}^{(B)}.$$

Resultado 2: al aumentar el tamaño muestral, la distribución de $\bar{Y}$ se concentra alrededor de μ_Y .

$$\bar{Y} \xrightarrow{P} \mu_Y.$$

Resultado 3: la media estandarizada se aproxima a una normal.

$$\frac{\bar{Y} - \mu_Y}{\sigma_Y / \sqrt{n}} \approx N(0, 1).$$

Conclusión

La simulación muestra visualmente por qué la estadística permite hacer inferencia a partir de muestras.

Puente hacia regresión

De estimar una media a estimar una relación económica

Con la media muestral aprendimos la lógica general:
parámetro, estimador, distribución muestral, error estándar e inferencia.

En regresión aplicaremos exactamente la misma lógica, pero ahora el
parámetro de interés será una pendiente poblacional.

¿Por qué esto importa para regresión?

En regresión lineal simple estudiaremos:

$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

El objetivo será estimar los parámetros poblacionales desconocidos:

$$\beta_0, \quad \beta_1.$$

Usaremos estimadores muestrales:

$$\hat{\beta}_0, \quad \hat{\beta}_1.$$

La misma lógica

- $\hat{\beta}_1$ cambia de muestra en muestra.
- Tiene distribución muestral.
- Tiene error estándar.
- Bajo ciertos supuestos, es consistente y aproximadamente normal en muestras grandes.

Paralelo: media y regresión

Elemento	Media	Regresión
Parámetro	μ_Y	β_0, β_1
Estimador	$\bar{Y}$	$\hat{\beta}_0, \hat{\beta}_1$
Estimación	$\bar{y}$	$\hat{\beta}_{0,obs}, \hat{\beta}_{1,obs}$
Error estándar	$SE(\bar{Y})$	$SE(\hat{\beta}_1)$
Inferencia	IC y test para μ_Y	IC y test para β_1
Pregunta	Cuál es la media?	Cuál es la relación entre X e Y ?

Mensaje

La regresión no abandona la estadística: la generaliza para estudiar relaciones entre variables.

Vista previa: distribución muestral de $\hat{\beta}_1$

En regresión simple estimaremos:


$$Y_i = \beta_0 + \beta_1 X_i + u_i.$$

El parámetro de interés suele ser:

$$\beta_1.$$

Su estimador muestral es:

$$\hat{\beta}_1.$$



Misma lógica

Así como $\bar{Y}$ cambia de muestra en muestra, $\hat{\beta}_1$ también tiene una distribución muestral.

Al aumentar n , la distribución de $\hat{\beta}_1$ se concentra alrededor de β_1 .

Actividad en clases

Trabajen en parejas durante 5 minutos.

A partir de los histogramas generados en R para $n = 10$, $n = 50$ y $n = 200$, respondan:

- 1 ¿Qué ocurre con el centro de la distribución muestral?
- 2 ¿Qué ocurre con la dispersión?
- 3 ¿Qué relación tiene esto con la Ley de los Grandes Números?
- 4 ¿Qué relación tiene esto con el Teorema Central del Límite?

Respuesta esperada

El centro permanece cerca de μ_Y , la dispersión disminuye cuando aumenta n , y la forma de la distribución de la media muestral se aproxima a una normal.

Cierre de la clase

Hoy aprendimos que:

- 1 Un parámetro poblacional es desconocido.
- 2 Un estimador es una regla muestral para aproximarlos.
- 3 La estimación observada cambia de muestra en muestra.
- 4 La distribución muestral permite medir incertidumbre.
- 5 La Ley de los Grandes Números justifica la consistencia.
- 6 El Teorema Central del Límite justifica la inferencia aproximada.

Próxima clase

Aplicaremos esta lógica a la regresión lineal simple: estimaremos e interpretaremos β_0 y β_1 .

Qué debe quedar aprendido

Al finalizar esta clase, los estudiantes deben poder:

- distinguir entre parámetro, estimador y estimación;
- explicar por qué un estimador tiene distribución muestral;
- interpretar el error estándar como medida de incertidumbre;
- diferenciar insesgadez, eficiencia y consistencia;
- explicar verbalmente la Ley de los Grandes Números;
- explicar verbalmente el Teorema Central del Límite;
- conectar estos conceptos con la estimación de coeficientes en regresión.

Idea final

Lo que hicimos con $\bar{Y}$ lo haremos luego con $\hat{\beta}_1$: estimar, medir incertidumbre e interpretar económicamente.

Referencias base del curso

Bibliografía principal

- Stock, J. H. y Watson, M. W. (2012). *Introducción a la econometría*. 3ª edición. Madrid: Pearson Educación.
- Wooldridge, J. M. (2010). *Introducción a la econometría: un enfoque moderno*. 4ª edición. México: Cengage Learning.

Lectura sugerida para esta clase

- Stock y Watson: Capítulo 2, secciones 2.5 y 2.6; Capítulo 3, sección 3.1.
- Wooldridge: Apéndice C, secciones C.1, C.2 y C.3.