

Microeconometría

Revisión MCO

Angelo Díaz

Universidad de Santiago de Chile

September 22, 2026

Contenido

1. Información
2. Introducción
3. Regresión lineal simple
4. Regresión Lineal Múltiple
5. Supuestos MCO
6. Propiedades Asintoticas de los estimadores MCO

Evaluación

- Nombre: Angelo Díaz
- Correo: angelo.diaz@usach.cl
- Tareas: 40%
- Trabajo 60%
 - Pregunta de investigación
 - Por qué es interesante
 - Estado de la literatura
 - Contribución
 - Que metodología usaría y por qué
 - Datos
 - Resultados preliminares (Si es que tienen)
 - Máximo 10 páginas de largo

Bibliografía

1. Wooldridge, J. (2010). Econometric Analysis of Cross Section and Panel Data. Cambridge, Massachusetts; London, England: The MIT Press. Retrieved August 2, 2021, from <http://www.jstor.org/stable/j.ctt5hhcfr>
2. Cameron, A. Colin Trivedi, Pravin K. (2005). Microeconometrics: Methods and Applications. Cambridge University Press
3. Angrist, J.D., Pischke, J. (2008). Mostly Harmless Econometrics: An Empiricist's Companion. Princeton: Princeton University Press.
4. Scott Cunningham (2021). "Casual Inference: The mixtape". Yale: University Press, New Haven London.
5. Bruce E. Hansenn (2017). "Econometrics". University of Wisconsin.

Contenido

1. Información
2. Introducción
3. Regresión lineal simple
4. Regresión Lineal Múltiple
5. Supuestos MCO
6. Propiedades Asintoticas de los estimadores MCO

- El caballo de batalla de trabajos aplicados es MCO
 - Simple,
 - Interpretable y
 - Tiene buenas propiedades bajo supuestos clásicos.
- MCO estima la **proyección lineal** de la variable dependiente sobre los regresores, lo cual equivale a una **aproximación lineal** de la media condicional de la **variable aleatoria**

Variable Aleatoria


Una **variable aleatoria** es un resumen numérico de un resultado aleatorio. La cantidad de veces que falla tu conexión inalámbrica mientras escribes un trabajo final es aleatoria y toma un valor numérico, por lo que es una variable aleatoria

Nosotros nunca sabemos con certeza el valor exacto de una variable económica (ej: salario, consumo, recidivismo). Lo que tenemos son **distribuciones de probabilidad** y queremos aprender sobre ellas usando datos

Algunas variables aleatorias son **discretas** y otras son **continuas**. Como sugieren sus nombres, una variable aleatoria discreta toma solo un conjunto discreto de valores, como 0, 1, 2, . . . , mientras que una variable aleatoria continua adopta un continuo de valores posibles



Media

- Suponga que queremos estudiar los salarios
- Generalmente podemos observar la densidad de los salarios
- Donde la media será igual a $E(\log(\text{salarios})) = 2.95$



Media condicional

- Son las distribuciones igual para hombres o mujeres?
- Son las distribuciones igual para distintos tipos de personas?



Conditional Expectation Function (CEF)

- CEF es una función de un conjunto de variables $(x_1, x_2, \dots, x_k)$
 - Ejemplo: $y = \log(\text{salario})$, dado $\mathbf{x} = (x_1, x_2) = (\text{género}, \text{edad})$
 - $E(y|\mathbf{x}) = \mu(\mathbf{x})$
- $\mu(x)$: entrega el promedio de y cuando cambian los elementos de x
- La CEF es una **variable aleatoria**, ya que es una función de variables aleatorias (x)

Conditional Expectation Function (CEF)

- En econometría (casi siempre) especificamos la CEF como una función de parametros y variables
 - Ejemplo: $E(y|x_1) = \beta_0 + \beta_1 x_1$
 - La CEF no necesariamente es lineal, ni parametrica
- Con un poco de manipulación:
 - El error u se define como la diferencia entre "y" y $E(y|\mathbf{x})$
 - Entonces: $u = y - E(y|\mathbf{x})$

Ley de expectativas iteradas (LEI)

- **Formalmente:** La expectativa incondicional de una variable aleatoria es igual a la expectativa de la expectativa condicional de la variable aleatoria condicionada a alguna otra variable aleatoria.

$$\mathbb{E}(Y) = \mathbb{E}(\mathbb{E}[Y|X])$$

- **Informalmente:** el promedio ponderado de los promedios condicionales es el promedio incondicional

Ejemplo de LEI

- Digamos que quiero saber el salario promedio, pero solo conozco el salario promedio por nivel educativo
- LEI dice que obtenemos lo primero tomando expectativas condicionales por nivel educativo y combinándolas (debidamente ponderadas)

$$\begin{aligned}\mathbb{E}[Wage] &= \mathbb{E}(\mathbb{E}[Wage|Education]) \\ &= \sum_{Education_i} Pr(Education_i) \cdot E[Wage|Education_i]\end{aligned}$$

Persona	Genero	IQ
1	H	120
2	H	115
3	H	110
4	M	130
5	M	125
6	M	120

- $\mathbb{E}[IQ] = 120$
- $\mathbb{E}[IQ|Hombre] = 115$; $\mathbb{E}[IQ|Mujer] = 125$
- LEI: $\mathbb{E}(\mathbb{E}[IQ|Genero]) = (0.5) \times 115 + (0.5) \times 125 = 120$

En conclusión:

$$\mathbb{E}[IQ] = \mathbb{E}(\mathbb{E}[IQ|Sex])$$

Propiedad de descomposición

- Podemos de dividir la variable aleatoria en dos componentes:

$$y = E(y|x) + u$$

- u independiente en media de x ($E(u|x) = E(u)$).
- El error tiene media condicional cero. $E(u|x) = 0$.
- Toda variable aleatoria puede se descopuesta en dos componentes. Un componente que depende de x y otro independiente de x y media condicional cero.

Propiedad de predicción

- Supongamos que queremos predecir y , dado un valor de x
- Podemos definir cualquier predictor como una función $g(.)$ que depende de x ($g(x)$).
- Entonces, el error de predicción se define como:

$$y - g(x)$$

- La magnitud del error de predicción, es la expectativa del error al cuadrado:

$$E((y - g(x))^2)$$

- Objetivo: Minimizar el error.

Propiedad de predicción

- Recuerde: $y = E(y|x) + u$ y $E(y|x) = \mu(x)$.
- $$\begin{aligned} E((y - g(x))^2) &= E((E(y|x) + u - g(x))^2) \\ &= E((\mu(x) + u - g(x))^2) \\ &= E(u^2) + 2E(u * (\mu(x) - g(x))) + E((\mu(x) - g(x))^2) \\ &= E(u^2) + E((\mu(x) - g(x))^2) \\ &\geq E(u^2) \end{aligned}$$
- La única forma que $E(u^2) + E((\mu(x) - g(x))^2) = E(u^2)$, es cuando $\mu(x) = g(x)$
- En este sentido, la CEF minimiza el error de predicción

- CEF puede tomar distintas formas, pero un caso especial es cuando la CEF es lineal en x
- $\mu(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$
- Definimos el mejor predictor lineal como:

$$L(y|x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k = \beta_0 + \mathbf{x}\beta$$

- $\beta = [\text{Var}(x)]^{-1} \text{Cov}(x, y)$
- $\beta_0 = E(y) - E(\mathbf{x})\beta$

- Una de las ventajas cuando CEF es lineal, es la interpretación de sus coeficientes
- Suponga que queremos ver el efecto en nuestra variable dependiente, cuando variamos un de las variables independientes. (asumiendo ceteris paribus)
- Suponga:

$$\mu(x) = \beta_0 + \beta_1 x$$

- Luego:

$$\frac{\partial E(y|x)}{\partial x} = \beta_1$$

Modelo lineal

- Decimos que la CEF es lineal cuando la **verdadera relación poblacional** cumple:

$$y = \beta_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

- Esto es una suposición sobre la realidad (sobre el proceso generador de datos)
- Si es cierta, entonces la función de expectativa condicional está perfectamente descrita por una recta

- Mínimos Cuadrados Ordinarios es un método de estimación que, con datos de muestra (x_i, y_i) , encuentra β_0, β_1 que minimizan la suma de cuadrados de los residuos:

$$\text{Min}_{\beta_0, \beta_1} \sum_i^n (y_i - \beta_0 - \beta_1 x_i)^2$$

- MCO **no define la CEF**, sino que estima los parámetros de un modelo lineal de regresión.

Relación entre CEF lineal y MCO

- Si la CEF es verdaderamente lineal, entonces bajo algunos supuestos clásicos:

$$\hat{\beta}_0 \rightarrow \beta_0; \hat{\beta}_1 \rightarrow \beta_1$$

- Es decir, MCO estima correctamente los parámetros de la verdadera CEF
- Si la CEF **no es lineal**, MCO sigue teniendo sentido: estima la **mejor proyección lineal de la CEF**, la recta que minimiza el error cuadrático medio respecto a la CEF. Pero en ese caso, el modelo lineal ya no es la verdadera CEF, sino una aproximación

Contenido

1. Información
2. Introducción
3. Regresión lineal simple
4. Regresión Lineal Múltiple
5. Supuestos MCO
6. Propiedades Asintoticas de los estimadores MCO

Introducción al modelo de regresión lineal simple

El Modelo de Regresión Lineal Simple nos permite explicar y en términos de x :

$$y = \beta_0 + \beta_1 x + u,$$

donde:


- y es la variable dependiente, explicada, o de respuesta. Aquella que tratamos de explicar o predecir.
- x es la variable independiente, explicativa, o predictora. Representa lo que creemos que afecta a y .
- β_0 y β_1 son parámetros poblacionales.
- u : término de error o perturbación no observable.

Si todos los demás factores contenidos en u se mantienen constantes ($\Delta u = 0$), x tiene un efecto lineal sobre y , es decir:

$$\Delta y = \beta_1 \Delta x, \quad \text{si} \quad \Delta u = 0.$$

Calificaciones y Ratios Estudiantes-profesores

- La calificación es el promedio para todo el distrito de los puntajes en lectura y matemáticas de los alumnos en quinto curso.
- La razón estudiantes-profesores en el total del distrito.



MCO - Como minimizar residuos

- Datos con n observaciones y dos variables aleatorias: $(x_1, \dots, x_n)$ y $(y_1, \dots, y_n)$
- Encontrar la estimación lineal $(\hat{\beta}_0 + \hat{\beta}_1 x)$ que mejor se ajuste a los datos
- $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ es el valor estimado (o ajustado) para i
- El residuo es $\hat{u}_i = y_i - \hat{y}_i$
- Objetivo: minimizar los residuos o la distancia entre la linea (valores estimados) a los datos

MCO - Minimizando residuos

- No nos interesa si el residuo $\hat{u}_i$ es positivo a negativo, queremos que sea pequeño
- Así que lo elevamos al cuadrado: $\hat{u}_i^2$
- ¿Porqué no tomar el valor absoluto? Buenas razones estadísticas, es más difícil trabajar con ellas $|\cdot|$
- Queremos que todos los errores sean pequeños, por eso realmente queremos minimizarlos.
 $\sum_{i=1}^n \hat{u}_i^2$

MCO - Minimizando residuos

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \left(y_i - \hat{\beta}_0 + \hat{\beta}_1 x_i \right)^2$$

- Usando cálculo (derivando con respecto a $\hat{\beta}_0, \hat{\beta}_1$ e igualando a cero):

$$\hat{\beta}_1^* = \frac{\sum_{i=1}^n (x_i - \bar{x}_i)(y_i - \bar{y}_i)}{\sum_{i=1}^n (x_i - \bar{x}_i)^2} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)(y_i - \bar{y}_i)}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)^2} = \frac{\text{Sample covariance (x,y)}}{\text{Sample variance (x)}}$$

$$\hat{\beta}_0^* = \bar{y}_i - \hat{\beta}_1 \bar{x}_i$$

MCO como un estimador

- Hay una población con dos variables aleatorias x y y
- Tomamos una **muestra aleatoria**¹ de tamaño n : $(x_1, x_2, \dots, x_n)$ y $(y_1, y_2, \dots, y_n)$
- Quisiéramos saber como y varia con cambios en x
 - ¿Qué pasa si y se ve afectado por factores distintos de x ?
 - ¿Cuál es la forma funcional que conecta estas dos variables?
 - Si está interesado en el efecto causal de x sobre y , ¿cómo distinguirlo de la mera correlación?

¹En una muestra aleatoria simple, se extraen al azar n objetos de una población y cada objeto tiene la misma probabilidad de ser extraído. El valor de la variable aleatoria Y para el i ésimo objeto extraído aleatoriamente se denota Y_i . Debido a que cada objeto tiene la misma probabilidad de ser extraído y la distribución de Y_i es la misma para todos los i , las variables aleatorias $Y_1, \dots, Y_n$ están distribuidas de forma independiente e idéntica (i.i.d.); es decir, la distribución de Y_i es la misma para todos los $i = 1, \dots, n$, y Y_1 se distribuye independientemente de $Y_2, \dots, Y_n$, etc.

MCO como un estimador de los parámetros del PGD

- Suponemos que el proceso generador de datos (PGD) es:

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

- Es decir, este modelo se cumple en la **población**
- No solo x_i afecta y_i , u_i (llamado el termino de error) también afecta
- No confundir u_i con $\hat{u}_i$
- Suponemos que existe una relación lineal entre y_i y x_i
- Comúnmente nunca observamos β_0 y β_1

- Objetivo: Estimar parámetros desconocidos
- Para aproximar parámetros, utilizamos un **estimador**², que es función de los datos.
- Por lo tanto, el estimador es una variable aleatoria (es una función de una variable aleatoria)
- Inferir algo sobre los parámetros a partir de la distribución del estimador

²El parámetro es un valor exclusivo asociado a la población total mientras que los estimadores están asociados a una muestra tomada de dicha población.

Notación importante

- Las letras griegas (por ejemplo, μ) son la verdad (es decir, parámetros del verdadero PGD)
- Las letras griegas con sombreros (p. ej., $\hat{\mu}$) son estimaciones (es decir, lo que *pensamos* que es la verdad)
- Letras no griegas (por ejemplo, X) denotan muestra/datos
- Letras no griegas con líneas en la parte superior (por ejemplo, $\bar{X}$) denotan cálculos a partir de los datos
- Queremos estimar la verdad, con algunos cálculos a partir de los datos ($\hat{\mu} = \bar{X}$)
- Datos $\longrightarrow$ Cálculos $\longrightarrow$ Estimaciones $\xrightarrow{\text{Esperemos}}$ Verdad
- Ejemplo: $X \longrightarrow \bar{X} \longrightarrow \hat{\mu} \xrightarrow{\text{Esperemos}} \mu$

MCO como estimador de los parámetros del PGD

- Asumiendo que el PGD es:

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

- También asumimos $\mathbb{E}u_i = 0$
 - Sin pérdida de generalidad
- Asumiendo independencia de media $\mathbb{E}(u_i|x_i) = \mathbb{E}(u_i)$ para todos los valores de x
 - Esta es una suposición no trivial, pero démosla por sentada por ahora.
 - Implica que $\mathbb{E}(u_i|x_i) = \mathbb{E}(u_i) = 0$
 - Implica que $\mathbb{E}(u_i x_i) = \mathbb{E}(\mathbb{E}(u_i|x_i)) = 0$

MCO como estimador de los parámetros del PGD

- $\mathbb{E}(y_i|x_i) = \beta_0 + \beta_1 x_i$
- $\mathbb{E}(y_i|x_i)$: función de regresión poblacional o función de expectativa condicional
- Por nuestras suposiciones:
 - $\mathbb{E}(u_i|x_i) = \mathbb{E}(y_i - \beta_0 - \beta_1 x_i) = 0$
 - $\mathbb{E}(u_i x_i) = \mathbb{E}(x_i(y_i - \beta_0 - \beta_1 x_i)) = 0$
- Estas dos condiciones determinan β_0 y β_1

MCO como estimador de los parámetros del PGD

Primera ecuación

$$\mathbb{E}(y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\mathbb{E}y_i - \beta_0 - \beta_1 \mathbb{E}x_i = 0$$

$$\mathbb{E}y_i - \beta_1 \mathbb{E}x_i = \beta_0$$

MCO como estimador de los parámetros del PGD

Segunda ecuación

$$\begin{aligned}\mathbb{E}x_i(y_i - \beta_0 - \beta_1 x_i) &= 0 \\ \mathbb{E}x_i(y_i - (\mathbb{E}y_i - \beta_1 \mathbb{E}x_i) - \beta_1 x_i) &= 0 \\ \mathbb{E}x_i(y_i - \mathbb{E}y_i - \beta_1(x_i - \mathbb{E}x_i)) &= 0 \\ \mathbb{E}x_i(y_i - \mathbb{E}y_i) &= \mathbb{E}x_i \beta_1 (x_i - \mathbb{E}x_i) \\ \mathbb{E}(x_i - \mathbb{E}x_i)(y_i - \mathbb{E}y_i) &= \beta_1 \mathbb{E}(x_i - \mathbb{E}x_i)(x_i - \mathbb{E}x_i) \\ \frac{\mathbb{E}(x_i - \mathbb{E}x_i)(y_i - \mathbb{E}y_i)}{\mathbb{E}(x_i - \mathbb{E}x_i)(x_i - \mathbb{E}x_i)} &= \beta_1 \\ \frac{\text{Covarianza poblacional (x,y)}}{\text{Varianza Poblacional (x)}} &= \beta_1\end{aligned}$$

MCO como estimador de los parámetros del PGD

- Pero no tenemos x y y , ni sabemos $\mathbb{E}y_i$ o $\mathbb{E}x_i$
- Solo tenemos una **muestra aleatoria** de tamaño n : $(x_1, \dots, x_n)$ y $(y_1, \dots, y_n)$
- Los análogos de muestra:
 - $\frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$
 - $\frac{1}{n} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$

MCO como estimador de los parámetros del PGD

Primera ecuación

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0 \\ \frac{1}{n} \sum_{i=1}^n y_i - \hat{\beta}_0 - \hat{\beta}_1 \frac{1}{n} \sum_{i=1}^n x_i &= 0 \\ \bar{y}_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}_i &= 0 \\ \bar{y}_i - \hat{\beta}_1 \bar{x}_i &= \hat{\beta}_0\end{aligned}$$

MCO como estimador de los parámetros del PGD

Segunda ecuación

$$\frac{1}{n} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

$$\frac{1}{n} \sum_{i=1}^n x_i (y_i - (\bar{y}_i - \hat{\beta}_1 \bar{x}_i) - \hat{\beta}_1 x_i) = 0$$

$$\frac{1}{n} \sum_{i=1}^n x_i (y_i - \bar{y}_i + \hat{\beta}_1 (\bar{x}_i - x_i)) = 0$$

$$\frac{1}{n} \sum_{i=1}^n x_i (y_i - \bar{y}_i) = \frac{1}{n} \sum_{i=1}^n x_i (\hat{\beta}_1 (x_i - \bar{x}_i))$$

$$\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)(y_i - \bar{y}_i) = \hat{\beta}_1 \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)(x_i - \bar{x}_i)$$

$$\frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)(y_i - \bar{y}_i)}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_i)^2} = \hat{\beta}_1$$

$$\frac{\text{Covarianza muestral (x,y)}}{\text{varianza muestral (x)}} = \hat{\beta}_1$$

MCO como estimador de los parámetros del PGD

- Muestra los coeficientes MCO como estimador de los parámetros poblacionales (β_0 y β_1)
- Algunas observaciones:
 - Sólo se puede estimar si la varianza muestral de x_i no es cero
 - En otras palabras, si x_i no es constante en todos los valores de i
 - Intuitivamente, la variación en x es lo que nos permite identificar su impacto en y

Contenido

1. Información
2. Introducción
3. Regresión lineal simple
4. Regresión Lineal Múltiple
5. Supuestos MCO
6. Propiedades Asintoticas de los estimadores MCO

Modelo de Regresión Lineal Múltiple

- Hasta ahora hemos considerado el modelo de regresión con una variable explicativa x .
- El análisis de regresión lineal múltiple es útil pues nos permite controlar explícitamente por otros factores que afectan a y . Esto es muy importante sobre todo porque no trabajamos con datos experimentales.
- Adicionalmente, si añadimos más factores al modelo, entonces más variación de y puede ser explicada.
- Otra ventaja es que el análisis de regresión múltiple nos permite explorar formas funcionales más ricas.
- Aunque nuestro interés fundamental es el efecto concreto de una determinada variable x_1 sobre un fenómeno económico y , generalmente entran en juego factores adicionales $x_2, \dots, x_k$.
- Dichos factores adicionales están, generalmente, relacionados con x_1 .
- Recordemos que todos los factores no incorporados al modelo están contenidos en el error del modelo, u .

Modelo de Regresión Lineal Múltiple

- En la medida en que x_1 esté correlacionado con $x_2, \dots, x_k$, en el modelo simple, el término inobservable no cumple $E(u|x_1) = 0$.
- En tal caso, debemos incorporar los factores adicionales $x_2, \dots, x_k$ al modelo para poder aislar el efecto causal de dicha variable.
- El modelo poblacional con k variables explicativas puede ser escrito:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

- Desde que tenemos k variables explicativas y el intercepto, tenemos $k + 1$ parámetros desconocidos que queremos estimar utilizando una muestra aleatoria de $(x_1, x_2, \dots, x_k, y)$.
- La interpretación de u sigue siendo la misma: todos aquellos factores que afectan a y pero que no están incluidas en el modelo.
- β_0 es el término constante o intercepto.
- $\beta_1, \beta_2, \dots, \beta_k$ se denominan parámetros de pendiente.
- β_j refleja la variación en y ante un aumento de una unidad en x_j , manteniendo fijas $x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k$, además de los factores incluidos en u .

Ejemplo

- Considere el modelo para determinar el sueldo de un CEO:

$$\log(w) = \beta_0 + \beta_1 \log(\text{ventas}) + \beta_2 \text{ant} + \beta_3 \text{ant}^2 + u$$

donde *ventas* representa el volumen de ventas de la empresa y *ant* es la antigüedad del CEO en la empresa.

- En este caso $k = 3$.
- Note que aunque la variable de antigüedad está al cuadrado, el modelo sigue siendo lineal en los parámetros.
- La clave es:

$$E(u|x_1, \dots, x_k) = 0$$

- Esta premisa de independencia en media implica que ninguna de las variables explicativas $x_1, \dots, x_k$ está correlacionada con el error.
- Adicionalmente, implica que la relación funcional entre las variables dependiente y regresoras está correctamente especificada.
- Si alguna de estas x_j está correlacionada con u para alguna j entonces se rompe el supuesto.
- En principio se permiten correlaciones entre las $x_1, \dots, x_k$. Es decir, las variables explicativas no tienen que ser independientes en media entre ellas.

Modelo de Regresión Lineal Múltiple: Estimación

- Veremos como estimar los parámetros del modelo utilizando una muestra aleatoria, $(x_{1i}, x_{2i}, \dots, x_{ki}, y_i) : i = 1, 2, \dots, n$, de la población.
- Dado que estos datos proceden de la población definida por el modelo de regresión, para cada observación i , podemos establecer que:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + u_i$$

- Igual que en modelo de regresión simple, el método de estimación por MCO consiste en elegir como estimadores de $\beta_0, \beta_1, \beta_2, \dots, \beta_k$ los valores de $b_0, b_1, \dots, b_k$ que minimizan la suma de los cuadrados de los residuos, donde los residuos se definen de forma análoga al caso de regresión simple.
- Es decir, se minimiza:

$$\sum_{i=1}^n (y_i - b_0 - b_1 x_{1i} - \dots - b_k x_{ki})^2$$

- Los coeficientes estimados se obtienen igualando a cero las derivadas parciales.

Forma Matricial

- Dado que regresores (primer subíndice) y observaciones (segundo subíndice) están ordenados en esa forma, podemos reacomodarlos en forma de matriz.
- Definamos

$$\mathbf{X} = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{k,1} \\ 1 & x_{1,2} & \cdots & x_{k,2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{k,n} \end{pmatrix}$$

- es la matriz que contiene toda la información sobre las variables explicativas.
- En la primera columna hay sólo 1's porque al coeficiente de intercepto, β_0 lo acompaña un 1.

Forma Matricial

- Usando exactamente la misma lógica, apilamos la información sobre y y u .
- Por tanto:

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

- Podemos escribir el modelo en forma matricial como:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$$

Forma Matricial

- Los estimadores MCO minimizan los residuos al cuadrado (SRC):

$$\begin{aligned}\hat{\beta} &= \operatorname{argmin}_{\mathbf{b} \in \mathbb{R}^{k+1}} SRC \\ &= \operatorname{argmin}_{\mathbf{b} \in \mathbb{R}^{k+1}} (\mathbf{y} - \mathbf{X}\mathbf{b})'(\mathbf{y} - \mathbf{X}\mathbf{b})\end{aligned}$$

- Entonces:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

- Es decir,

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

Contenido

1. Información
2. Introducción
3. Regresión lineal simple
4. Regresión Lineal Múltiple
- 5. Supuestos MCO**
6. Propiedades Asintoticas de los estimadores MCO

Supuestos de MCO

- **Supuesto RLM.1 (Lineal en los parámetros).** El modelo poblacional puede expresarse como:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u,$$

- **Supuesto RLM.2 (Muestreo aleatorio).** Se tiene una muestra aleatoria de n observaciones, $\{(x_{i1}, x_{i2}, \dots, x_{ik}, y_i) : i = 1, 2, \dots, n\}$, que sigue el modelo poblacional del supuesto RLM.1. Esto implica que dada una observación obtenida de manera aleatoria de la población, se tiene:

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} + u_i,$$

- **Supuesto RLM.3 (No hay colinealidad perfecta).** En la muestra (y por tanto en la población), ninguna de las variables independientes es constante y no hay ninguna relación lineal exacta entre las variables independientes.
- **Supuesto RLM.4 (Media condicional cero).** El valor esperado del error u , dados los valores de las variables independientes, es cero:

$$E(u|x_1, \dots, x_k) = 0$$

- El **supuesto RLM.1** establece formalmente el modelo poblacional, que es lineal en parámetros.
- El **supuesto RLM.2** es adecuado en muchas aplicaciones (aunque no en todas) cuando trabajamos con datos de corte transversal. Cuando trabajamos con datos de series temporales las observaciones no son en general independientes y el supuesto RLM.2 no se verifica.
- El **supuesto RLM.3** indica que en regresión múltiple además de necesitar la condición de que los valores observados de las variables explicativas no sean todos iguales, se necesita que no haya ninguna relación lineal exacta entre las variables explicativas.
- Cuando en un modelo de regresión una de las variables explicativas es función lineal de otras, se dice que hay un problema de colinealidad perfecta.
- El **supuesto RLM.4** puede fallar si la relación entre la variable dependiente y las variables explicativas no se especifica adecuadamente. Por ejemplo si el **modelo poblacional** incluye como variable explicativa una variable y su cuadrado y no incluimos el cuadrado en la regresión, fallará el supuesto RLM.4.
- El **Supuesto RLM.4** también fallará si se omite un factor importante que está correlacionado con cualquiera de las variables explicativas del modelo.

Insesgamiento de los estimadores de MCO

Teorema. (Insesgamiento de los estimadores de MCO). Bajo los supuestos RLM.1 a RLM.4:

$$E(\hat{\beta}_j) = \beta_j, \quad j = 0, 1, \dots, k.$$

- Generalmente si uno de los cuatro supuestos que hemos considerado no se verifica, el estimador no será insesgado.
- El supuesto RLM.4 es el supuesto crucial para la insesgadez del estimador MCO. Si este supuesto falla, los estimadores estarán en general sesgados.

Insesgamiento de Los Estimadores de MCO

Recuerde:

$$\hat{\beta} = (X'X)^{-1}X'y$$

$$\hat{\beta} = (X'X)^{-1}X'(X\beta + u)$$

$$\hat{\beta} = \beta + (X'X)^{-1}X'u$$

$$E[\hat{\beta}|X] = \beta + (X'X)^{-1}X'E[u|X]$$

Supuesto RLM.4: $E[u|X] = 0$

$$E[\hat{\beta}|X] = \beta$$

Inclusión de variables irrelevantes

- Suponga que el siguiente modelo satisface los supuestos RLM.1 a RLM.4 y supongamos que la variable x_3 es irrelevante, es decir que $\beta_3 = 0$:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u,$$

- Puesto que desconocemos el valor de β_3 en la población, estimamos el modelo incluyendo la variable x_3 . ¿Cuáles son las consecuencias sobre el estimador MCO de incluir una variable irrelevante en el modelo?
- Incluir una variable irrelevante **no tiene ninguna consecuencia sobre la insesgadez** de los estimadores MCO, ya que, si se verifican los supuestos RLM.1 a RLM.4, los estimadores MCO son insesgados cualquiera que sea el valor de los parámetros, lo que incluye el caso en el que uno de los parámetros es cero.
- Pero tiene un **costo en términos de la precisión** de las estimaciones (menos precisas).

Sesgo de variable omitida: caso sencillo

- Suponga que el verdadero modelo poblacional tiene dos variables explicativas y un término de error:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u,$$

Se asume que este modelo satisface los supuestos RLM.1 a RLM.4. El modelo se estima excluyendo x_2 :

$$\tilde{y} = \tilde{\beta}_0 + \tilde{\beta}_1 x_1$$

Tenemos que:

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \tilde{\delta}_1$$

donde $\hat{\beta}_1, \hat{\beta}_2$ son los estimadores de pendiente (si se tuvieran) de la regresión múltiple de y sobre x_1 y x_2 y $\tilde{\delta}_1$ es la pendiente de la regresión simple de x_{i2} sobre x_{i1} . Por lo tanto:

$$E(\tilde{\beta}_1) = E(\hat{\beta}_1 + \hat{\beta}_2 \tilde{\delta}_1) = \beta_1 + \beta_2 \tilde{\delta}_1$$

$$\text{Sesgo}(\tilde{\beta}_1) = E(\tilde{\beta}_1) - \beta_1 = \beta_2 \tilde{\delta}_1$$

Resumen de los sesgos en $\tilde{\beta}_1$ cuando x_2 es omitida en la ecuación de estimación

	$Corr(x_1, x_2) > 0$	$Corr(x_1, x_2) < 0$
$\beta_2 > 0$	Sesgo positivo	Sesgo negativo
$\beta_2 < 0$	Sesgo negativo	Sesgo positivo

- **Supuesto RLM.5: Homocedasticidad.** Dado cualquier valor de las variables explicativas, el error u tiene la misma varianza. En otras palabras:

$$\text{Var}(u|x_1, \dots, x_k) = \sigma^2.$$

Varianza de los estimadores de MCO


- Bajo los supuestos RLM.1 a RLM.5, condicionales en los valores muestrales de las variables independientes:

$$Var(\hat{\beta}_j) = \frac{\sigma^2}{STC_j(1 - R_j^2)}.$$

Para $j = 1, 2, \dots, k$, donde $STC_j = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$ y R_j^2 es el R-cuadrado de x_j sobre todas las otras variables independientes, incluyendo un intercepto.

- un σ^2 más grande significa varianzas más grandes para los estimadores de MCO. Si la varianza de las variables no observables que afectan a y es muy grande, es muy difícil estimar los parámetros con precisión.
- Cuanto mayor sea la variación total en x_j , menor será $Var(\hat{\beta}_j)$. Si la variable x_j tiene muy poca dispersión es muy difícil estimar β_j con precisión.
- Cuanto mayor es el tamaño muestral menor es la varianza de todos los β_j .
- A medida que R_j^2 se aproxima a uno, $Var(\hat{\beta}_j)$ se hace cada vez más grande.
- Una correlación alta entre las variables explicativas se denomina multicolinealidad.
- Un R_j^2 "cercano" a 1, pero no igual a 1 no supone una violación del supuesto RLM.3.

Varianza de los estimadores de MCO



- Para estimar β_j , lo mejor es tener poca correlación entre x_j y las demás variables independientes.

Varianza de los estimadores de MCO

- Considere el caso de un modelo con dos variables explicativas:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$$

- En este caso:

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{(n-1)S_{x_1}^2(1-R_1^2)}$$

donde R_1^2 es el R-cuadrado de la regresión de x_1 sobre x_2 y $S_{x_1}^2$ es la varianza muestral de x_1

- Un valor grande de R_1^2 indica que x_2 explica una gran parte de la variabilidad de x_1 y que por tanto x_1 y x_2 están estrechamente correlacionadas.

Estimación de σ^2

- Al igual que en regresión simple vamos a basar el estimador de la varianza del término de error, σ^2 , en la suma de los cuadrados de los residuos.
- Un estimador de σ^2 en el caso general de la regresión múltiple es:

$$\hat{\sigma}^2 = \frac{1}{n - k - 1} \sum_{i=1}^n \hat{u}_i^2 = \frac{SRC}{n - k - 1}$$

- Bajo los supuestos RLM.1 a RLM.5 de Gauss-Markov, $E(\hat{\sigma}^2) = \sigma^2$.
- A la raíz cuadrada de $\hat{\sigma}^2$, que se denota $\hat{\sigma}$, se le llama error estándar de la regresión (EER)
- $\hat{\sigma}$ es un **estimador de la desviación típica del término de error**, σ .

Error Estándar de β_j

- Se define la varianza estimada de $\hat{\beta}_j$ como:

$$\widehat{Var}(\hat{\beta}_j) = \frac{\hat{\sigma}^2}{STC_j(1 - R_j^2)}.$$

- Se define el error estándar de $\hat{\beta}_j$ (**del estimador**) como

$$se(\hat{\beta}_j) = \sqrt{\widehat{Var}(\hat{\beta}_j)} = \frac{\hat{\sigma}}{\sqrt{STC_j(1 - R_j^2)}}.$$

- $se(\hat{\beta}_j)$ es un estimador de la desviación típica de $\hat{\beta}_j$ y por tanto una medida de la **precisión** de su precisión.

Errores estándar y Unidades de Medida: Ejemplo

- Suponga al ejemplo del salario de ejecutivos. Los resultados de la estimación incluyendo los errores estándar se suelen presentar de la siguiente forma:

$$\widehat{salary} = 830.63 + 19.63 \text{ roe} + 0.016 \text{ sales}$$
$$(223.91) \quad (11.08) \quad (0.0089)$$

donde *salary* se mide en **miles** de dólares, *roe* en tanto por ciento y *sales* en millones de dólares

- Si medimos ahora el salario en **cientos de dólares** (*salary100*)

$$\widehat{salary} = 8306.3 + 196.3 \text{ roe} + 0.16 \text{ sales}$$
$$(2239.1) \quad (110.8) \quad (0.089)$$

- Hay que multiplicar por 10 todos los coeficientes estimados y todos los errores estándar

Teorema de Gauss-Markov

- Bajo los supuestos RLM.1 a RLM.5, $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$ son los **mejores estimadores lineales insesgados** (MELI) de $\beta_0, \beta_1, \dots, \beta_k$, respectivamente
- La presencia de **heterocedasticidad** en los estimadores de MCO no ocasiona sesgo, pero los estimadores ya no son MELI
- Demostración de MELI en pag 116 Wooldridge

Regresión Lineal Múltiple: Inferencia

Para hacer inferencias estadísticas (pruebas de hipótesis, intervalos de confianza), además de los valores esperados y las varianzas, necesitamos conocer las distribuciones muestrales de los $\hat{\beta}_j$ s.

Para hacer esto debemos **suponer** que el término de error tiene una **distribución normal**. Según los supuestos de Gauss Markov, las distribuciones muestrales de los estimadores MCO pueden tener cualquier forma.

- **Supuesto RLM.6: Normalidad.** El error poblacional u es independiente de las variables explicativas y sigue una distribución normal con media 0 y varianza σ^2

$$u \sim N(0, \sigma^2)$$

- El supuesto de normalidad es más fuerte que los supuestos anteriores.
- El supuesto RLM.6 implica que RLM.4, media condicional cero, y RLM.5, homocedasticidad, también se satisfacen.

Contenido

1. Información
2. Introducción
3. Regresión lineal simple
4. Regresión Lineal Múltiple
5. Supuestos MCO
6. Propiedades Asintoticas de los estimadores MCO

Propiedades Asintóticas de los estimadores MCO

- ¿Cuáles son las propiedades asintóticas de los estimadores MCO?
- Asintóticas: “a medida que el tamaño de la muestra, n , aumenta sin límite”
- Estas propiedades son: **consistencia** y **normalidad asintótica**
- Podremos hacer suposiciones de RLM más débiles

Propiedades de muestras finitas de estimadores MCO

- Propiedades de la muestra finita: **insesgadez, eficiencia**
- Estas propiedades son válidas para cualquier tamaño de muestra n
- Los estimadores MCO son:
 - **Insesgados** (bajo los supuestos RLM.1-RLM.4)
 - **MELI** (bajo supuestos RLM.1-RLM5)(Mejor=el más eficiente)
 - Supuesto RLM.6: **Normalidad del término de error**, u , independencia de variables explicativas
- El supuesto de normalidad se utiliza para derivar las distribuciones muestrales de los estimadores MCO para cualquier n
- En condiciones normales, las estadísticas de prueba habituales de t y F siguen distribuciones estándar para cualquier tamaño de muestra

Límite de Probabilidades

Definición: El límite de probabilidad de una secuencia de variables aleatorias es el comportamiento límite de esas variables a medida que el número de observaciones o ensayos tiende al infinito. Representa el comportamiento a largo plazo o asintótico de la secuencia

Convergencia: Cuando una secuencia de variables aleatorias converge en probabilidad, significa que a medida que el tamaño de la muestra aumenta, **la probabilidad de que la secuencia se acerque a cierto valor se acerca a 1**. En otras palabras, las variables aleatorias se concentran cada vez más alrededor de un valor particular

Tipos de Convergencia:

- **Convergencia en Probabilidad (Ley Débil de los Grandes Números):** Esto ocurre cuando la media muestral de una secuencia de variables aleatorias se acerca a la media real a medida que el tamaño de la muestra aumenta. Se denota como:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \epsilon) = 1$$

donde $\bar{X}_n$ es la media muestral, μ es la media real y ϵ es un número positivo pequeño.

- **Convergencia en Distribución (Teorema Central del Límite):** Esto sucede cuando la distribución de la media muestral se aproxima a una distribución normal a medida que el tamaño de la muestra aumenta. Se denota como:

$$\lim_{n \rightarrow \infty} F_n(x) = \Phi(x)$$

donde $F_n(x)$ es la función de distribución acumulativa de la media muestral y $\Phi(x)$ es la función de distribución acumulativa de la distribución normal estándar.

Propiedades asintóticas: consistencia

Definición


Sea W_n un estimador del parámetro poblacional desconocido θ basado en una muestra aleatoria de $\{Y_1, Y_2, \dots, Y_n\}$. Para un número pequeño arbitrario $\epsilon > 0$, a medida que n se vuelve cada vez más grande si se cumple la siguiente condición

$$P(|W_n - \theta| > \epsilon) \rightarrow 0, \quad n \rightarrow \infty$$

entonces, W_n es un estimador consistente para θ : $\text{plim}(W_n) = \theta$.

- Ejemplo: la media aritmética $\bar{x}$ es un estimador consistente de la media poblacional μ
- Ley de los Grandes Números.

Distribuciones muestrales para diferentes tamaños de muestra: $n_1 < n_2 < n_3$



Propiedades asintóticas: consistencia

- Para cada tamaño de muestra n , $\hat{\beta}_j$ tiene una distribución muestral. En otras palabras, las distribuciones muestrales de los estimadores MCO están indexadas por el tamaño de la muestra
- Si $\hat{\beta}_j$ es consistente, a medida que n se hace cada vez más grande, las distribuciones muestrales se vuelven más concentradas alrededor del valor verdadero β_j .
- Cuando $n \rightarrow \infty$, es decir, obtener más y más datos nos acerca al parámetro de interés, β_j . En el límite, la distribución muestral colapsa en un solo punto
- Esto significa que si podemos recopilar más y más datos, podemos hacer que nuestro estimador se acerque arbitrariamente al valor real

Propiedades asintóticas: consistencia

- Si, cuando n tiende al infinito, la distribución muestral no llega a ser más cerca del valor verdadero β entonces se dice que el estimador es **inconsistente**.
- El mismo conjunto de supuestos sobre la inesgadez también implica la consistencia de los estimadores MCO (RLM.1-RLM.4).
- Pero sólo por coherencia, el supuesto RLM.4 (media condicional cero) puede sustituirse por un supuesto más débil: **el término de error no está correlacionado con cada variable explicativa**

Propiedades asintóticas: consistencia

Supuesto RLM.4': Media cero y correlación cero

$$E(u) = 0$$

$$\text{Cov}(x_j, u) = 0, \quad j = 1, 2, \dots, k$$

- Reemplazando RLM.4 con RLM.4', se puede demostrar que los estimadores MCO son consistentes: $\text{plim}(\hat{\beta}_j) = \beta_j$.
- Esta suposición dice que el término de error no está correlacionado con cada x_j .
- El supuesto RLM.4' es más débil que el supuesto RLM.4: el RLM.4 implica el RLM.4' pero lo contrario puede no ser cierto. El RLM.4' no es suficiente para demostrar insesgadez

Intuición

Suponga un modelo donde horas de estudio es igual a x y nota es igual a y

$$y = \beta_0 + \beta_1 x + u$$

Con RLM 4:

Decimos: para cualquier valor de horas x , el error u tiene media cero. Es decir, si miras a todos los estudiantes que estudiaron cualquier hora, el error promedio es cero

- Esto asegura que no hay sesgo en ninguna muestra

Con RLM.4:

Solo decimos: “en promedio en toda la población, x y u no se correlacionan”. Puede pasar que justo en tu muestra pequeña los que estudiaron más tengan también, por casualidad, errores más altos

- El estimador estará sesgado en esa muestra. Pero si tomas muestras cada vez más grandes, el promedio de esas correlaciones aleatorias desaparece, y $\hat{\beta}$ se vuelve consistente

En el modelo de regresión simple, el estimador MCO del parámetro de pendiente se puede escribir como:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1) y_i}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}$$

- Sustituyendo $y = \beta_0 + \beta_1 x_1 + u$ y reorganizando:

$$\hat{\beta}_1 = \beta_1 + \frac{n^{-1} \sum_{i=1}^n (x_{i1} - \bar{x}_1) u_i}{n^{-1} \sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}$$

- Tomando plim:

$$\text{plim} \left(\hat{\beta}_1 \right) = \beta_1 + \frac{\text{Cov}(x_1, u)}{\text{Var}(x_1)}$$

- Por la suposición RLM.4': $\text{Cov}(x_1, u) = 0$, obtenemos

$$\text{plim} \left(\hat{\beta}_1 \right) = \beta_1$$

- Sesgo asintótico:

$$\text{plim} \left(\hat{\beta}_1 \right) - \beta_1 = \frac{\text{Cov}(x_1, u)}{\text{Var}(x_1)}$$

- El signo del sesgo asintótico depende del signo de la covarianza entre x_1 y u . Observe que no es posible estimar $\text{Cov}(x_1, u)$ ya que no podemos observar u .
- Si omitimos una variable importante del modelo, los estimadores MCO serán inconsistentes.