

Inferencia Causal

Variables Instrumentales

Angelo Díaz

Universidad de Santiago de Chile

September 29, 2026

El problema de la endogeneidad

- Se dice que la **endogeneidad** ocurre en un modelo de regresión múltiple si

$$E(X_j u) \neq 0, \quad \text{para algún } j = 1, \dots, k$$

- En general el problema de endogeneidad se refiere a cualquier momento en el que hay una violación a la siguiente suposición

$$\text{Cov}(X_i, u_i) = 0$$

- Ejemplos:
 - Variables omitidas (una variable que está correlacionada con X pero no se observa)
 - Errores de medición (X está medido con error)
 - Causalidad simultánea (X causa Y , Y causa X)
- **Problema:** los parámetros estimados pueden ser inconsistentes.
- Una manera de lidiar con este problema es **variables instrumentales**.

Endogeneidad por variables omitidas

Una **variable omitida** genera endogeneidad cuando afecta a la variable dependiente y, al mismo tiempo, está correlacionada con alguna variable explicativa.

- **Educación y salario:** queremos estimar el efecto de los años de educación sobre el salario, pero no observamos completamente la **habilidad** de la persona.
 - Mayor habilidad puede llevar a obtener más educación.
 - Mayor habilidad también puede generar salarios más altos.
 - Si habilidad queda en el error, entonces educación estará correlacionada con u .
- **Tamaño de la clase y rendimiento escolar:** estudiantes con mayores dificultades pueden ser asignados a clases más pequeñas. Si esas dificultades no son observadas completamente, el tamaño de la clase estará correlacionado con el término de error.
- **Publicidad y ventas:** una empresa puede aumentar su publicidad cuando anticipa una mayor demanda. Si las expectativas de demanda no son observadas, quedan incorporadas en u .

Idea clave

Algo que no observamos afecta tanto a X como a Y .

Endogeneidad por error de medición

Existe **error de medición** cuando la variable que observamos no corresponde exactamente a la verdadera variable de interés.

$$X^{obs} = X^* + v$$

donde X^* es el valor verdadero y v representa el error de medición.

- **Ingreso:** en una encuesta, una persona puede declarar un ingreso distinto de su ingreso verdadero.
- **Horas trabajadas:** un trabajador puede reportar 40 horas semanales aunque realmente haya trabajado 46.
- **Experiencia laboral:** muchas veces se aproxima utilizando edad y educación, pero esta medida puede diferir de la experiencia laboral efectiva.
- **Contaminación:** la contaminación registrada por una estación de monitoreo puede no coincidir con la exposición real de cada individuo.

Idea clave

El investigador observa X con error. Ese error puede terminar formando parte del término de error de la regresión y generar correlación entre X y u .

Endogeneidad por causalidad simultánea

Existe **causalidad simultánea** cuando X afecta a Y , pero Y también afecta a X .

$$X \longrightarrow Y \quad \text{y} \quad Y \longrightarrow X$$

- **Policía y delincuencia:** más policías pueden reducir los delitos, pero una mayor delincuencia también puede provocar que se contraten más policías.
- **Salud e ingreso:** mayores ingresos pueden mejorar la salud, pero una mejor salud también puede aumentar la productividad y los ingresos laborales.
- **Inversión y crecimiento económico:** una mayor inversión puede generar crecimiento, pero una economía que crece también puede atraer más inversión.
- **Publicidad y ventas:** la publicidad puede aumentar las ventas, pero mayores ventas esperadas también pueden llevar a aumentar el gasto en publicidad.

Idea clave

No podemos interpretar directamente la correlación entre X e Y como un efecto causal de X sobre Y , porque ambas variables se determinan conjuntamente.

Ejemplo de endogeneidad por variable omitida

- Algunas veces tenemos un modelo, el cual contiene alguna variable inobservable
- Por lo tanto, esta variable estará en el error
- Ejemplo:

$$\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{habilidad} + \varepsilon$$

- **Posible solución:** usar una variable proxy como IQ
- **Problema:** No siempre se puede encontrar una variable proxy y es difícil defender de que la variable proxy es un buen sustituto de nuestra variable inobservable


Ejemplo de endogeneidad por variable omitida

$$\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{habilidad} + \varepsilon$$

- Como la habilidad no es observable, tenemos que estimar

$$\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + v$$

- Donde $v = \beta_2 \text{habilidad} + \varepsilon$



- ¿Podemos estimar $\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + v$?


Ejemplo de endogeneidad por variable omitida

$$\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{habilidad} + \varepsilon$$

- Como la habilidad no es observable, tenemos que estimar

$$\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + v$$

- Donde $v = \beta_2 \text{habilidad} + \varepsilon$



- ¿Podemos estimar $\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + v$?
 - $\hat{\beta}_1$ es **sesgado**: $E(\hat{\beta}_1) \neq \beta_1$
 - $\hat{\beta}_1$ es **inconsistente**: $\text{plim}(\hat{\beta}_1) \neq \beta_1$
- Posible solución: **Variables instrumentales**

Variables Instrumentales


- Supongamos una regresión MCO simple como la ecuación anterior

$$y = \beta_0 + \beta_1 x + u$$

- Porque $E[u|x] \neq 0$ entonces podemos usar una variable instrumental (z) para obtener una estimación consistente del coeficiente
- Intuitivamente queremos dividir x en dos partes:
 1. Una parte que está correlacionada con el término de error
 2. Una parte que no está correlacionada con el término de error
- Si podemos aislar la variación en x que no está correlacionada con u , entonces podemos usar esta parte para obtener una estimación consistente del efecto causal de x sobre y

Variables Instrumentales

- Debemos encontrar una variable z , que la llamaremos instrumento. Tal que:
 1. z **no** está correlacionado con u : $Cov(z, u) = 0$
 - Difícil de respaldar.
 2. z **está** correlacionada con x : $Cov(z, x) \neq 0$
 - Fácil de observar con la data.
- Intuición



- u no es observable.
 - Queremos ver el efecto de x sobre y
 - Cuando z varía, varía x y luego y cambia
 - z es independiente de u (restricción de exclusión- exogeneidad)
 - z está correlacionado con x
- ¿Cómo se encuentra el instrumento?: **intuición** (difícil tarea)

Ejemplo

$$\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + v$$

- Suponga el ejemplo anterior: Queremos medir el efecto de la educación sobre el salario
- **Problema:** educación es una variable endógena en la ecuación, ya que $E(\text{educ}, v) \neq 0$
- **Posible instrumento en la literatura:** Educación de los padres. Suponga educación del Padre
 1. $\text{Cov}(z, u) = 0$? = discutible.
 2. $\text{Cov}(z, x) \neq 0$

$$\text{educ} = \pi_0 + \pi_1 \text{educPadre} + v$$

- $H_0 : \pi_1 = 0$

Ejemplo: Rendimiento de la educación para mujeres que trabajan

```
. reg lwage educ
```

Source	SS	df	MS	Number of obs	=	428
Model	26.3264193	1	26.3264193	F(1, 426)	=	56.93
Residual	197.001022	426	.462443713	Prob > F	=	0.0000
Total	223.327441	427	.523015084	R-squared	=	0.1179
				Adj R-squared	=	0.1158
				Root MSE	=	.68003

lwage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
educ	.1086487	.0143998	7.55	0.000	.0803451	.1369523
_cons	-.1851968	.1852259	-1.00	0.318	-.5492673	.1788736

Posible problema: Educ es endógeno.

Rendimiento de la educación para mujeres que trabajan

```
. reg educ fatheduc if inlf==1
```

Source	SS	df	MS	Number of obs	=	428
Model	384.841983	1	384.841983	F(1, 426)	=	88.84
Residual	1845.35428	426	4.33181756	Prob > F	=	0.0000
				R-squared	=	0.1726
				Adj R-squared	=	0.1706
Total	2230.19626	427	5.22294206	Root MSE	=	2.0813

educ	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
fatheduc	.2694416	.0285863	9.43	0.000	.2132538	.3256295
_cons	10.23705	.2759363	37.10	0.000	9.694685	10.77942

¿Es un buen instrumento la educ del padre?

Rendimiento de la educación para mujeres que trabajan (otra opción)

```
. reg educ motheduc if inlf==1
```

Source	SS	df	MS	Number of obs	=	428
Model	334.048415	1	334.048415	F(1, 426)	=	75.05
Residual	1896.14785	426	4.45105128	Prob > F	=	0.0000
				R-squared	=	0.1498
				Adj R-squared	=	0.1478
Total	2230.19626	427	5.22294206	Root MSE	=	2.1098

educ	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
motheduc	.2673697	.030863	8.66	0.000	.2067069	.3280325
_cons	10.11449	.3109043	32.53	0.000	9.503396	10.72559

¿Es un buen instrumento la educación de la madre?

¿Cuál será mejor? ¿la educ de la madre o del padre?

Rendimiento de la educación para mujeres que trabajan (otra opción)

```
. reg educ motheduc if inlf==1
```

Source	SS	df	MS	Number of obs	=	428
Model	334.048415	1	334.048415	F(1, 426)	=	75.05
Residual	1896.14785	426	4.45105128	Prob > F	=	0.0000
Total	2230.19626	427	5.22294206	R-squared	=	0.1498
				Adj R-squared	=	0.1478
				Root MSE	=	2.1098

educ	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
motheduc	.2673697	.030863	8.66	0.000	.2067069	.3280325
_cons	10.11449	.3109043	32.53	0.000	9.503396	10.72559

¿Cuál será mejor? ¿la educ de la madre o del padre?.

En la literatura se plantea que probablemente la educación de la madre está relacionada con habilidad de los niños. ¿Cuál es el problema?

Rendimiento de la educación para mujeres que trabajan. (otra opción)

```
. reg educ motheduc if inlf==1
```

Source	SS	df	MS	Number of obs	=	428
Model	334.048415	1	334.048415	F(1, 426)	=	75.05
Residual	1896.14785	426	4.45105128	Prob > F	=	0.0000
				R-squared	=	0.1498
				Adj R-squared	=	0.1478
Total	2230.19626	427	5.22294206	Root MSE	=	2.1098

educ	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
motheduc	.2673697	.030863	8.66	0.000	.2067069	.3280325
_cons	10.11449	.3109043	32.53	0.000	9.503396	10.72559

En la literatura se plantea que probablemente la educación de la madre está más relacionada con habilidad de los niños. **¿Cuál es el problema?:** $Cov(z, u) \neq 0$

Otro ejemplo: Efecto de los inmigrantes sobre los salarios

$$\log(\text{salario de nativos}) = \beta_0 + \beta_1 \text{migrantes} + u$$

- Podría ser que inmigrantes lleguen a lugares que tienen mayor productividad
- Ciclo económico local. Por ej. si una ciudad tiene un boom (ej. minería) y atrae más inmigrantes
- Bartik instrument: se ocupa la migración en periodos pasados
- Probablemente la migración actual está relacionada a la migración de años anteriores
- Se argumenta que la migración de años anteriores no se relaciona con la productividad de los sitios actualmente
- Amplia literatura de este tema

Modelo simple

- Usamos las covarianza poblacional.

$$\text{Cov}(z, y) = \text{Cov}(z, x\beta_1 + u) = \beta_1 \text{Cov}(z, x) + \text{Cov}(z, u)$$

- Asuma $\text{Cov}(z, u) = 0$ y $\text{Cov}(z, x) \neq 0$

$$\beta_1 = \frac{\text{Cov}(z, y)}{\text{Cov}(z, x)}$$

- Método de momentos: Cambiamos momentos poblacionales por momentos muestrales.

$$\hat{\beta}_1 = \frac{N^{-1} \sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{N^{-1} \sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}$$

- $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

¿Qué pasa cuando $z = x$?:

Modelo simple

- Usamos las covarianza poblacional.

$$\text{Cov}(z, y) = \text{Cov}(z, x\beta_1 + u) = \beta_1 \text{Cov}(z, x) + \text{Cov}(z, u)$$

- Asuma $\text{Cov}(z, u) = 0$ y $\text{Cov}(z, x) \neq 0$

$$\beta_1 = \frac{\text{Cov}(z, y)}{\text{Cov}(z, x)}$$

- Método de momentos: Cambiamos momentos poblacionales por momentos muestrales.

$$\hat{\beta}_1 = \frac{N^{-1} \sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{N^{-1} \sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}$$

- $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

¿Qué pasa cuando $z = x$? En este caso x es exógena y el estimador es el mismo que MCO.

- La consistencia de $\hat{\beta}_1$, VI sigue la ley de los grandes números, bajos los supuestos planteados.

$$\hat{\beta}_1 = \beta_1 + \frac{N^{-1} \sum_{i=1}^n (z_i - \bar{z}) u_i}{N^{-1} \sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}$$

Dado que $N^{-1} \sum_{i=1}^n (z_i - \bar{z}) u_i \xrightarrow{p} 0$ si $N \rightarrow \infty$

$$\text{plim}(\hat{\beta}_1) = \beta_1$$

- El estimador VI puede tener un sesgo sustancial en muestras pequeñas y, por lo tanto, las muestras grandes son preferidas

Volvamos al ejemplo anterior

```
. ivregress 2sls lwage (educ = fatheduc)
```

```
Instrumental variables (2SLS) regression
```

Number of obs	=	428
Wald chi2(1)	=	2.85
Prob > chi2	=	0.0914
R-squared	=	0.0934
Root MSE	=	.68778

lwage	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
educ	.0591735	.0350596	1.69	0.091	-.009542	.127889
_cons	.4411034	.4450583	0.99	0.322	-.4311947	1.313402

```
Instrumented: educ  
Instruments: fatheduc
```

Recuerde: MCO 10%

- Recuerde **MCO**:

$$\hat{\beta}_{1,MCO} = \frac{Cov(x, y)}{Var(x)}$$

Sustituyendo $y = \beta_0 + \beta_1 x + u$

$$Cov(x, y) = Cov(x, \beta_0 + \beta_1 x + u) = \beta_1 Var(x) + Cov(x, u)$$

Entonces:

$$\hat{\beta}_{1,MCO} = \beta_1 + \frac{Cov(x, u)}{Var(x)}$$

- Recuerde **VI**:

$$\hat{\beta}_{1,IV} = \frac{Cov(z, y)}{Cov(z, x)}$$

Sustituyendo $y = \beta_0 + \beta_1 x + u$

$$Cov(z, y) = Cov(z, \beta_0 + \beta_1 x + u) = \beta_1 Cov(z, x) + Cov(z, u)$$

Entonces:

$$\hat{\beta}_{1,IV} = \beta_1 + \frac{Cov(z, u)}{Cov(z, x)}$$

- ¿Deberíamos usar siempre VI en vez de MCO?
- Usando $Cov(x, u) = Corr(x, u)\sigma_x\sigma_u$ y $Cov(z, u) = Corr(z, u)\sigma_z\sigma_u$

$$plim\hat{\beta}_{1,MCO} = \beta_1 + \frac{\sigma_u}{\sigma_x} Corr(x, u)$$

y

$$plim\hat{\beta}_{1,VI} = \beta_1 + \frac{\sigma_u}{\sigma_x} \frac{Corr(z, u)}{Corr(z, x)}$$

$$plim \hat{\beta}_{1,MCO} = \beta_1 + \frac{\sigma_u}{\sigma_x} \text{Corr}(x, u)$$

y

$$plim \hat{\beta}_{1,VI} = \beta_1 + \frac{\sigma_u}{\sigma_x} \frac{\text{Corr}(z, u)}{\text{Corr}(z, x)}$$

- Sup: $\text{Corr}(z, u)$ pequeña. La inconsistencia de $\hat{\beta}_{1,VI}$ puede ser grande si $\text{Corr}(z, x)$ es pequeña
- Sup: $\text{Corr}(x, u) \neq 0$, pero que la varianza de x es grande σ_x . Luego podría ser más inconsistente VI que MCO
- Entonces la respuesta es: **No necesariamente** debemos usar VI en vez de MCO
- Va a depende de la relación de $\text{Corr}(x, u)$ y $\frac{\text{Corr}(z, u)}{\text{Corr}(z, x)}$

Modelo: $\log(\text{salario}) = \beta_0 + \beta_1 \text{Educ} + \beta_2 \text{Habilidad} + \epsilon$

Sea: $y = \log(\text{salario})$

$$\hat{\beta}_{1,MCO} = \frac{\text{Cov}(Y, \text{Educ})}{\text{Var}(\text{Educ})} = \frac{E[\beta_0 * \text{Educ} + \beta_1 \text{Educ}^2 + \beta_2 \text{Educ} * H + \epsilon \text{Educ}] - E(\text{Educ}) * E[\beta_0 + \beta_1 \text{Educ} + \beta_2 \text{Habilidad} + \epsilon]}{\text{Var}(\text{Educ})}$$

$$\hat{\beta}_{1,MCO} = \beta_1 + \beta_2 \frac{\text{Cov}(\text{Habilidad}, \text{Educ})}{\text{Var}(\text{Educ})}$$

- Mientras $\text{Cov}(\text{Habilidad}, \text{Educ}) \neq 0$, $\hat{\beta}_1$ será sesgado.

$$\hat{\beta}_{1,VI} = \frac{\text{Cov}(Y, Z)}{\text{Cov}(\text{Educ}, Z)} = \frac{\beta_1 * \text{Cov}(\text{Educ}, Z) + \beta_2 * \text{Cov}(\text{Habilidad}, Z) + \text{Cov}(\epsilon, Z)}{\text{Cov}(\text{Educ}, Z)}$$

$$\hat{\beta}_{1,VI} = \beta_1 + \frac{\beta_2 * \text{Cov}(\text{Habilidad}, Z) + \text{Cov}(\epsilon, Z)}{\text{Cov}(\text{Educ}, Z)}$$

- Si $\text{Cov}(\text{Habilidad}, Z) = 0$ y $\text{Cov}(\epsilon, Z) = 0$, luego $\hat{\beta}_{1,VI} = \beta_1$.
- En este caso sería mejor utilizar VI.

Notación matricial

$$\hat{\beta}_{VI} = (Z'X/N)^{-1}(Z'Y/N) = (Z'X)^{-1}Z'Y$$

- Z y X son de tamaño $N \times K$.
- Y es de tamaño $N \times 1$.

Mínimos cuadrados en dos etapas: caso simple

Nuestra regresión MCO simple: relación causal de interés

$$y_i = \beta_0 + \beta_1 x_i + u_i$$

- Podemos estimar el efecto causal de x_i en y_i en dos etapas

- Primera etapa:** Regresione x_i en z_i y obtenga los valores predichos $\hat{x}_i$, si $cov(z_i, u_i) = 0$, entonces $\hat{x}_i$ contiene la variación de x_i que no esta correlacionada con u_i

$$\hat{x}_i = \hat{\pi}_0 + \hat{\pi}_1 z_i$$

- Segunda etapa:** Regresione y_i en $\hat{x}_i$ para obtener el estimador de mínimos cuadrados en dos etapas (2SLS)

$$\hat{\beta}_{2SLS} = \frac{\sum (y_i - \bar{y})(\hat{x}_i - \bar{\hat{x}})}{\sum (\hat{x}_i - \bar{\hat{x}})^2}$$

Mínimos cuadrados en dos etapas: caso simple

- sabemos que $\bar{\hat{x}} = \hat{\pi}_0 + \hat{\pi}_1 \bar{z}$, entonces

$$\hat{x}_i - \bar{\hat{x}} = \hat{\pi}_1(z_i - \bar{z})$$

- entonces podemos obtener

$$\begin{aligned}\hat{\beta}_{2SLS} &= \frac{\sum (y_i - \bar{y})(\hat{x}_i - \bar{\hat{x}})}{\sum (\hat{x}_i - \bar{\hat{x}})^2} \\&= \frac{\sum (y_i - \bar{y})\hat{\pi}_1(z_i - \bar{z})}{\sum \hat{\pi}_1^2(z_i - \bar{z})^2} \\&= \frac{1}{\hat{\pi}_1} \frac{\sum (y_i - \bar{y})(z_i - \bar{z})}{\sum (z_i - \bar{z})^2} \\&= \frac{\sum (z_i - \bar{z})^2}{\sum (x_i - \bar{x})(z_i - \bar{z})} \times \frac{\sum (y_i - \bar{y})(z_i - \bar{z})}{\sum (z_i - \bar{z})^2} \\&= \frac{\sum (y_i - \bar{y})(z_i - \bar{z})}{\sum (x_i - \bar{x})(z_i - \bar{z})} = \frac{\text{cov}(z, y)}{\text{cov}(z, x)}\end{aligned}$$

Instrumentos débiles

- Una de las condiciones es que

$$\text{Cov}(z, x) \neq 0$$

- **Intuición:** cuanto más explican los instrumentos la variación en x , más información estará disponible para su uso en la regresión VI
- Por el contrario, los instrumentos que explican poca variación en x se denominan **instrumentos débiles**, por lo que existe una correlación muy débil entre x (variable endógena) y z .
- Porque

$$\hat{\beta}_{2SLS} \xrightarrow{p} \beta + \frac{\text{cov}(z, u)}{\text{cov}(z, x)}$$

- Entonces si $\text{cov}(z, x) = 0$, entonces x y z son irrelevantes, el sesgo sería aproximadamente infinito.

Ejemplo peso al nacer y cantidad de cigarros

- Suponga se quiere medir la relación entre el peso al nacer y la cantidad de cigarros que consumen las mujeres

$$\log(\text{peso}) = \beta_0 + \beta_1 \text{paquetes} + u$$

- Donde *paquetes* es cajas de cigarros que una mujer embarazada fuma al día
- Probablemente *paquetes* sea endógeno, ya que la cantidad de cajas de cigarros puede estar relacionada con otros problemas de salud
- Posible instrumento: precio promedio de los cigarros

Evaluando el instrumento

```
. reg paquetes pre_cigarros
```

Source	SS	df	MS	Number of obs	=	1,388
Model	.011648626	1	.011648626	F(1, 1386)	=	0.13
Residual	123.684481	1,386	.089238442	Prob > F	=	0.7179
Total	123.696129	1,387	.089182501	R-squared	=	0.0001
				Adj R-squared	=	-0.0006
				Root MSE	=	.29873

paquetes	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
pre_cigarros	.0002829	.000783	0.36	0.718	-.0012531	.0018188
_cons	.0674257	.1025384	0.66	0.511	-.1337215	.2685728

El coeficiente es pequeño y no estadísticamente significativo

Usando el instrumento

```
. ivregress 2sls l_peso (paquetes = pre_cigarros)
```

Instrumental variables (2SLS) regression	Number of obs	=	1,388
	Wald chi2(1)	=	0.12
	Prob > chi2	=	0.7310
	R-squared	=	.
	Root MSE	=	.93818

l_peso	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
paquetes	2.988676	8.692619	0.34	0.731	-14.04854	20.0259
_cons	4.448136	.9075006	4.90	0.000	2.669468	6.226805

Instrumented: paquetes

Instruments: pre_cigarros

El signo es positivo, pero no estadísticamente significativo
Este es un caso de un instrumento débil

Utilizando más variables - VI de regresión múltiple

- Agreguemos otra variable independiente al modelo

$$\log(\text{salarios}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{habilidad} + u$$

- No tenemos información sobre habilidad y sabemos que probablemente educ está relacionada con la habilidad de las personas
- Por lo tanto, solo podemos estimar el modelo:

$$\log(\text{salarios}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + u$$

- ¿Podemos utilizar **exper** como instrumento de **educ**?

Utilizando más variables - VI de regresión múltiple

- Agreguemos otra variable independiente al modelo

$$\log(\text{salarios}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{habilidad} + u$$

- No tenemos información sobre habilidad y sabemos que probablemente educ está relacionada con la habilidad de las personas
- Por lo tanto, solo podemos estimar el modelo:

$$\log(\text{salarios}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + u$$

- ¿Podemos utilizar **exper** como instrumento de **educ**?
 - **NO**, ya que **exper** ya es una variable explicativa. Necesitamos una variable que no aparezca en la ecuación estructural

Utilizando más variables - VI de regresión múltiple

De hecho, considere un modelo lineal estándar con dos variables explicativas:

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u$$

La variable dependiente y_1 (p. ej. $\log(\text{salarios})$) es claramente endógena, pues está correlacionada con u . Se utiliza z_1 (p. ej. exper) para indicar que esta variable es exógena (z_1 no está correlacionada con u). Se usa y_2 (p. ej. educ) para indicar que se sospecha que esta variable está correlacionada con u

- Necesitamos un instrumento para educación, tal que z_2 .
 - Sea una variable exógena
 - No aparezca en la ecuación estructural inicial
 - z_2 esté relacionado con educación
- Supuestos:
 - $E(u) = 0$
 - $\text{Cov}(\text{exper}, u) = 0$
 - $\text{Cov}(z_2, u) = 0$

VI de regresión múltiple

- Utilizando el método de momentos. Podemos trabajar con las contrapartes muestrales
 - Sea: $y_{i,1} = \log(\text{salarío})$, $z_{i,1} = \text{exper}$
 - $\sum_{i=1}^n (y_{i,1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i,2} - \hat{\beta}_2 z_{i,1}) = 0$
 - $\sum_{i=1}^n z_{i,1} (y_{i,1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i,2} - \hat{\beta}_2 z_{i,1}) = 0$
 - $\sum_{i=1}^n z_{i,2} (y_{i,1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i,2} - \hat{\beta}_2 z_{i,1}) = 0$
- Al resolver el sistema de ecuaciones se pueden obtener los $\hat{\beta}_{VI}$
- ¿Como probamos la correlación parcial entre educ y z_{i2} ?

$$\text{educ} = \pi_0 + \pi_1 z_2 + \pi_2 \text{exper} + v$$

- $\pi_1 \neq 0$

Test: correlación parcial

```
. reg educ fatheduc exper, r
```

Linear regression

```
Number of obs      =      753
F(2, 750)          =      83.77
Prob > F            =      0.0000
R-squared           =      0.2061
Root MSE           =      2.0345
```

educ	Coef.	Robust Std. Err.	t	P> t	[95% Conf. Interval]	
fatheduc	.287546	.0224123	12.83	0.000	.2435477	.3315443
exper	.0287546	.0094504	3.04	0.002	.0102022	.0473069
_cons	9.448243	.2417942	39.08	0.000	8.973569	9.922917

```
. ivregress 2sls lwage exper (educ=fatheduc ), r
```

```
Instrumental variables (2SLS) regression      Number of obs   =          428
                                              Wald chi2(2)    =          17.88
                                              Prob > chi2     =          0.0001
                                              R-squared       =          0.1366
                                              Root MSE       =          .67119
```

lwage	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
educ	.0752157	.0362933	2.07	0.038	.0040822	.1463493
exper	.0155257	.0041051	3.78	0.000	.0074799	.0235716
_cons	.0356114	.4642488	0.08	0.939	-.8742995	.9455223

```
Instrumented:  educ
Instruments:   exper fatheduc
```

Comentarios adicionales: posibles infracciones de MCO

Otros contextos en los que se usa IV

1. Sesgo de variable omitida
2. **Error de medición** en x
3. **Simultaneidad**: x determina y , pero y determina (parte de) x . Ejemplo: Demanda y oferta.
 - BLP model (1995, Econometrica)
 - NEVO, 2001.
 - No el mismo ejemplo, pero similar idea:

$$Q = \beta_0 + \beta_1 p + \dots + \epsilon$$

Mínimos cuadrados en dos Etapas - 2SLS

- Suponga el modelo anterior

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u$$

- y_2 es la variable endógena
- Suponga **dos variables exógenas**: z_2 y z_3 que están correlacionadas con y_2
- **Opción**: Podríamos estimar dos $\hat{\beta}_{1,VI}$ utilizando dos distintos instrumentos
- Ya que cada z_1, z_2 y z_3 no están correlacionadas con u , una combinación lineal de estas variables, tampoco está correlacionada con u
- Asumiendo $E(v) = 0$, $Cov(z_i, u) = 0$ para $i = 1, 2, 3$. Estimamos

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v$$

- La mejor VI de y_2 es la combinación lineal de todos instrumentos

$$y_2^* = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v$$

- Necesitamos $\pi_2 \neq 0$ o $\pi_3 \neq 0$ ¿Por qué?

Mínimos cuadrados en dos Etapas - 2SLS

- Suponga el modelo anterior

$$y_1 = \beta_0 + \beta_1 y_2 + \beta_2 z_1 + u$$

- y_2 es la variable endógena
- Suponga **dos variables exógenas**: z_2 y z_3 que están correlacionadas con y_2
- **Opción**: Podríamos estimar dos $\hat{\beta}_{1,VI}$ utilizando dos distintos instrumentos
- Ya que cada z_1, z_2 y z_3 no están correlacionadas con u , una combinación lineal de estas variables, tampoco está correlacionada con u
- Asumiendo $E(v) = 0$, $Cov(z_i, u) = 0$ para $i = 1, 2, 3$. Estimamos

$$y_2 = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v$$

- La mejor VI de y_2 es la combinación lineal de todos instrumentos

$$y_2^* = \pi_0 + \pi_1 z_1 + \pi_2 z_2 + \pi_3 z_3 + v$$

- Necesitamos $\pi_2 \neq 0$ o $\pi_3 \neq 0$ ¿Por qué?: **Si $\pi_2 = \pi_3 = 0$ entonces el instrumento sería una combinación lineal de z_1 (Multicolinealidad)**

Mínimos cuadrados en dos Etapas - 2SLS

- $H_0 : \pi_2 = 0 \text{ y } \pi_3 = 0$
- Test F.
 - Stata: **test** $z_2 \ z_3$
- Debemos rechazar la hipótesis nula
- Como no conocemos los parámetros poblaciones π_j , debemos estimar estos parámetros

$$\hat{y}_2 = \hat{\pi}_0 + \hat{\pi}_1 z_1 + \hat{\pi}_2 z_2 + \hat{\pi}_3 z_3$$

- Cuando obtenemos el instrumento $\hat{y}_2$

$$\sum_{i=1}^n \hat{y}_2 (y_{i,1} - \hat{\beta}_0 - \hat{\beta}_1 y_{i,2} - \hat{\beta}_2 z_{i,1}) = 0$$

- **Cuando tenemos multiples instrumentos, ocupamos mínimos cuadros en dos etapas - 2SLS**

Mínimos cuadrados en dos Etapas - 2SLS

- Usando 2SLS es fácil tener **más de un instrumento**
- β_{VI} son iguales a β_{2SLS} (cuando hay un solo instrumento)
- Tenemos una primera etapa donde estimamos la variables endógena y_2 sobre los instrumentos
- Obtenemos $\hat{y}_2$
- Luego estimamos y_1 sobre $\hat{y}_2$ y las otras variables exógenas
- Si hacemos las etapas o usamos el comando *ivregress 2sls* deberíamos tener los mismos coeficientes, pero los errores estandar serán distintos, ya que STATA corrige el error de que MCO sólo considera u en error, pero en la segunda etapa, el error es $u + \beta_1 v$
- $y_2 = y_2^* + v$

$$y_1 = \beta_0 + \beta_1(y_2^* + v) + \beta_2 z_1 + u$$

$$y_1 = \beta_0 + \beta_1 y_2^* + \beta_2 z_1 + (u + \beta_1 v)$$

2SLS- Manual (parte 1)

```
. reg educ feduc meduc exper
```

Source	SS	df	MS	Number of obs	=	722
				F(3, 718)	=	113.30
Model	1159.00491	3	386.334969	Prob > F	=	0.0000
Residual	2448.20977	718	3.40976292	R-squared	=	0.3213
				Adj R-squared	=	0.3185
Total	3607.21468	721	5.00307168	Root MSE	=	1.8466

educ	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
feduc	.1629353	.0259027	6.29	0.000	.1120811	.2137895
meduc	.1358188	.0297766	4.56	0.000	.0773593	.1942784
exper	-.1846693	.0167219	-11.04	0.000	-.2174989	-.1518397
_cons	12.61789	.3774979	33.43	0.000	11.87676	13.35902

```
. predict educ_hat, xb
```

```
(213 missing values generated)
```

2SLS- Manual (parte 2)

```
. reg wage educ_hat exper
```

Source	SS	df	MS	Number of obs	=	722
				F(2, 719)	=	29.43
Model	9086513.95	2	4543256.98	Prob > F	=	0.0000
Residual	110988280	719	154364.785	R-squared	=	0.0757
				Adj R-squared	=	0.0731
Total	120074794	721	166539.243	Root MSE	=	392.89

wage	Coefficient	Std. err.	t	P> t	[95% conf. interval]	
educ_hat	140.3843	18.34891	7.65	0.000	104.3604	176.4081
exper	34.53917	5.474841	6.31	0.000	23.79058	45.28775
_cons	-1332.493	301.8409	-4.41	0.000	-1925.088	-739.8981

2SLS- comando

```
. ivregress 2sls wage exper (educ=feduc meduc)
```

```
Instrumental variables 2SLS regression
```

Number of obs	=	722
Wald chi2(2)	=	56.41
Prob > chi2	=	0.0000
R-squared	=	0.0315
Root MSE	=	401.33

wage	Coefficient	Std. err.	z	P> z	[95% conf. interval]	
educ	140.3843	18.74305	7.49	0.000	103.6486	177.12
exper	34.53917	5.592443	6.18	0.000	23.57818	45.50015
_cons	-1332.493	308.3246	-4.32	0.000	-1936.798	-728.1878

```
Instrumented: educ
```

```
Instruments: exper feduc meduc
```

Prueba de endogeneidad

- En general, los errores estandar en 2SLS son más grandes que en MCO.
- Por lo tanto, los estimadores son menos eficientes.
- Debemos preguntarnos si **realmente** necesitamos realizar 2SLS.
- Es decir, ¿es y_2 realmente endógena?

Hausman test

- **Intuición:** tratar de analizar si existe una diferencia entre los estimadores de MCO y VI
- Si no hay diferencia, no necesitamos instrumentos
- El test compara los coeficientes de las variables endógenas
- Suponga una potencial variable endógena

$$T_H = \frac{(\hat{\beta}_{IV} - \hat{\beta}_{OLS})^2}{\hat{V}(\hat{\beta}_{IV} - \hat{\beta}_{OLS})}$$

- Con una distribución $\chi^2(1)$

Durbin-Wu-Hausman (DWH)

- Intuición: vamos comparar β_{MCO} vs β_{2SLS}
- MCO

```
. reg lwage educ exper married black age
```

Source	SS	df	MS	Number of obs	=	935
Model	30.6954671	5	6.13909342	F(5, 929)	=	42.26
Residual	134.960816	929	.145275367	Prob > F	=	0.0000
				R-squared	=	0.1853
				Adj R-squared	=	0.1809
Total	165.656283	934	.177362188	Root MSE	=	.38115

lwage	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
educ	.0679743	.0067271	10.10	0.000	.0547723	.0811763
exper	.0133448	.0038381	3.48	0.001	.0058126	.0208771
married	.1891997	.0407376	4.64	0.000	.1092512	.2691482
black	-.2089377	.0379836	-5.50	0.000	-.2834813	-.134394
age	.0103972	.0048187	2.16	0.031	.0009404	.0198541
_cons	5.223088	.158879	32.87	0.000	4.911285	5.534892

Durbin-Wu-Hausman (DWH)

- Intuición: vamos comparar β_{MCO} vs β_{2SLS}
- 2SLS - Educación del padre como instrumento.
- Parece educ es endógeno, ya que son distintos.

```
. ivregress 2sls lwage exper married black age (educ=feduc)
```

```
Instrumental variables (2SLS) regression      Number of obs   =       741
                                              Wald chi2(5)    =      101.65
                                              Prob > chi2     =      0.0000
                                              R-squared      =      0.0926
                                              Root MSE      =      .39753
```

lwage	Coef.	Std. Err.	z	P> z	[95% Conf. Interval]	
educ	.1325818	.0226118	5.86	0.000	.0882635	.1769002
exper	.0358469	.0080681	4.44	0.000	.0200338	.05166
married	.1866839	.0466756	4.00	0.000	.0952015	.2781663
black	-.1088695	.0547554	-1.99	0.047	-.2161881	-.001551
age	-.0037061	.0074518	-0.50	0.619	-.0183114	.0108993
_cons	4.552925	.2793639	16.30	0.000	4.005382	5.100468

Instrumented: educ

Instruments: exper married black age feduc

Durbin-Wu-Hausman (DWH)

- H_0 : La variable es exógena
- Rechazamos H_0 . Por lo tanto, educ es endógena.

```
. estat endogenous
```

```
Tests of endogeneity
```

```
Ho: variables are exogenous
```

```
Durbin (score) chi2(1) = 10.1371 (p = 0.0015)
```

```
Wu-Hausman F(1,734) = 10.1807 (p = 0.0015)
```

Rechazamos porque $0.0015 < 0.05$

Sobreidentificación

- Si se tienen más instrumentos que los necesarios, se puede probar que si algunos de ellos están correlacionados con el error estructural
- **Intuición de identificación:**
 - Suponga que el número de instrumentos **es igual** al número de variables endógenas ($m = k$)
 - Es como si tuviéramos una llave para una cerradura: si la llave abre, podemos estimar; si no, no hay mucho que hacer
 - Aquí no sobra nada: **no tenemos forma de testear** si ese instrumento realmente es exógeno, porque no hay evidencia adicional con la cual contrastar
 - Con un instrumento para una variable endógena, solo **tenemos la fe** de que el instrumento sea bueno. No podemos comprobarlo dentro del modelo

- **Intuición de sobreidentificación:**

- Supón una variable endógena pero ahora tenemos **dos instrumentos** ($m > k$)
- Eso significa que tenemos dos llaves distintas para la misma cerradura
- Si ambas son válidas, deberían dar la misma estimación de β_1 (en muestras grandes)
- Si dan resultados inconsistentes, sospechamos que al menos una llave es defectuosa
- Cuando tenemos más instrumentos que variables endógenas, podemos usar esa información extra para **poner a prueba la validez de los instrumentos**. Si los instrumentos cuentan la misma historia, todo bien. Si no, el test de sobreidentificación nos avisa que algo anda mal

Sobreidentificación

- Una prueba de sobreidentificación de restricciones hace una regresión de los residuos de una regresión IV o 2SLS en todos los instrumentos en Z . Bajo la hipótesis nula de que todos los instrumentos no están correlacionados con u (**exogeneidad**), la prueba tiene una distribución $\chi^2(r)$ de muestra grande donde r es el número de restricciones de sobreidentificación.
- Bajo el supuesto de i.i.d. errores, esto se conoce como prueba de **Sargan**, y es producido de forma rutinaria por **ivreg2** para estimaciones de IV y 2SLS. También se puede calcular después de la estimación de **ivreg** con el comando **overid**. Después de **ivregress**, el comando **estat overid** proporciona la prueba.

Comando en Stata

```
. ivregress 2sls lwage exper married black age (educ=feduc meduc) , vce(robust)
```

```
Instrumental variables (2SLS) regression      Number of obs   =       722
                                             Wald chi2(5)    =     122.66
                                             Prob > chi2     =     0.0000
                                             R-squared      =     0.0933
                                             Root MSE      =     .39907
```

lwage	Coef.	Robust Std. Err.	z	P> z	[95% Conf. Interval]	
educ	.13491	.0195988	6.88	0.000	.0964971	.173323
exper	.0364796	.0073786	4.94	0.000	.0220178	.0509415
married	.1948513	.0492569	3.96	0.000	.0983095	.291393
black	-.1112809	.0537435	-2.07	0.038	-.2166162	-.0059455
age	-.0058304	.0073913	-0.79	0.430	-.0203171	.0086563
_cons	4.571984	.2501661	18.28	0.000	4.081667	5.0623

```
Instrumented:  educ
```

```
Instruments:  exper married black age feduc meduc
```

Comando en Stata

- H_0 : Los instrumentos son exógenos
- No podemos rechazar H_0
- Si se tienen instrumentos suficientes se dice que el modelo está exactamente identificado
- Si rechazamos H_0 quiere decir al menos uno de los instrumentos no es valido

```
. estat overid
```

```
Test of overidentifying restrictions:
```

```
Score chi2(1)          =  .058275  (p = 0.8092)
```

- Problema: Si rechazamos H_0 no nos dice que instrumento es exógeno