Inferencia Causal

Regresión con una variable dependiente binaria

Angelo Díaz

Universidad de Santiago de Chile

October 13, 2026

Variables binarias

- Existen preguntas donde la respuesta es una variable binaria
- **Ejemplos**: ¿Ahorra? (sí/no); ¿Pasó de curso? (sí/no); ¿Trabaja? (sí/no).
- Usar MCO trae desventajas:
  - Las probabilidades ajustadas pueden ser menores que 0 o mayores que 1
  - El efecto parcial de cualquier variable explicativa es constante
- Usaremos modelos que se ajustan a estas limitaciones: **logit** y **probit**.
- En general, **modelos de respuesta binaria**:

$$P(y = 1 \mid \mathbf{x}) = P(y = 1 \mid x_1, \ldots, x_k)$$

- Son **no lineales**

Enfoque de variable latente

$$y_i^* = x_i'\beta + u_i$$

- y_i^* es **inobservable** (p. ej., el **deseo** de trabajar)
- Nosotros no podemos observar el deseo, pero podemos observar el resultado de que el individuo realice esta decisión (**observamos si el individuo trabajar o no**)
- Como no observamos y^*, **no** podemos estimar el modelo de arriba
- ¿Qué observamos? Observamos el resultado:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0, \\ 0 & \text{si } y_i^* \leq 0. \end{cases}$$

De latente a probabilidad

$$\begin{aligned}\Pr(y = 1 \mid x) &= \Pr(y^* > 0 \mid x) = \Pr(x'\beta + u > 0) \\ &= \Pr(-u < x'\beta) = F(x'\beta)\end{aligned}$$

- La probabilidad depende de la distribución del error
- Donde F es la cdf (función de distribución acumulada) de $-u$, que es igual a la cdf de u por simetría alrededor de cero
- Los supuestos sobre la distribución de los errores va a determinar si el modelo es logit o probit:
  - **Probit**: $u \sim \mathcal{N}(0, 1)$ (*normal estándar*)
  - **Logit**: u tiene distribución *logística*.

Supuesto sobre distribución del error

Probit:

- Asumimos que u_i se distribuye normal, con media cero y $Var(u) = 1$

$$Pr(y = 1|x) = \int_{-\infty}^{x_i'\beta} \frac{1}{\sqrt{2\pi}} exp(-\frac{t^2}{2})dt$$

Logit:

- Asumimos que u_i es distribuido logisticamente, con $Var(u) = \pi^2/3$

$$Pr(y = 1|x) = \frac{exp(x_i'\beta)}{1 + exp(x_i'\beta)}$$

Recuerdo: Bernoulli

Decimos que $Y \sim Bernoulli(p)$ si:

- $P(Y = 1) = p$
- $P(Y = 0) = 1 - p$
- con $0 < p < 1$

Su función de probabilidad se escribe de forma compacta como:

$$P(Y = y) = p^y(1 - p)^{1-y}, \quad y \in \{0, 1\}$$

Máxima verosimilitud

- Estimamos por **máxima verosimilitud (ML)**
- La probabilidad de observar y condicional en x puede ser escrita así:

$$\Pr(y_i \mid x_i) = \{F(x_i'\beta)\}^{y_i}\{1 - F(x_i'\beta)\}^{1-y_i}, \quad y_i \in \{0, 1\}$$

- la **log-likelihood**:

$$\ell_i(\beta) = y_i \log F(x_i'\beta) + (1 - y_i) \log\{1 - F(x_i'\beta)\}$$

- Como $F(\cdot) \in (0, 1)$, la log-verosimilitud está bien definida
- La log-likelihood de la muestra:

$$\mathcal{L}(\beta) = \sum_{i=1}^{N} \ell_i(\beta)$$

Máxima verosimilitud: la intuición

Elegimos los parámetros que hacen más probables los datos observados.

Ejemplo: una misma p para todos

Cuatro observaciones independientes:

$$y = (1, 1, 1, 0).$$

La probabilidad de observar estos datos es

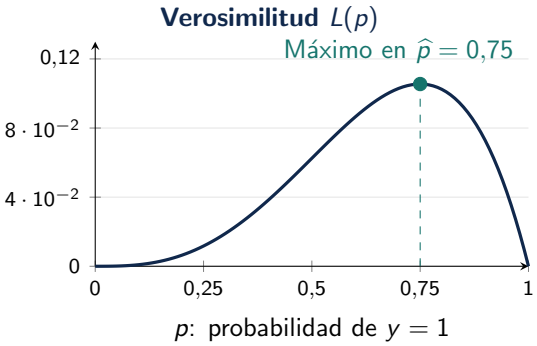
$$\underbrace{p \times p \times p}_{\text{los tres unos}} \times \underbrace{(1-p)}_{\text{el cero}}.$$

$$L(p) = p^3(1-p)$$

$p = 0{,}50 \qquad L = 0{,}0625$

$p = 0{,}75 \qquad L = 0{,}1055 \quad$ (máximo)

$p = 0{,}95 \qquad L = 0{,}0429$



Con covariables, variamos β y obtenemos $p_i = F(x_i'\beta)$.
Maximizar el producto de probabilidades equivale a maximizar la suma de sus logs.

Estimación

El estimador ML se obtiene resolviendo:

$$\hat{\beta} = \mathit{argmax}_{\beta} \mathcal{L}(\beta)$$

En la práctica se deriva $\ell_i(\beta)$ respecto a cada uno de los parametros y se iguala a cero

Efectos marginales

$$\frac{\partial \Pr(y = 1 \mid x)}{\partial x_j} = \frac{\partial F(x'\beta)}{\partial x_j} = F'(x'\beta)\,\beta_j = f(x'\beta)\,\beta_j$$

- Ya no es tan directo como en MCO
- $f(\cdot)$ es la **pdf** correspondiente.
- Note:
  - cdf: función distribución acumulativa
  - pdf: función de densidad de probabilidad
- Note que $F(z)$ es estrictamente creciente, por lo tanto $f(z) > 0 \ \forall z$. Por lo tanto, el efecto parcial, siempre va a depender del signo de β_j
- El efecto **no es constante**: depende de x

Probit

```
. probit work age married children education

Iteration 0:   log likelihood = -1266.2225
Iteration 1:   log likelihood = -1031.4962
Iteration 2:   log likelihood = -1027.0625
Iteration 3:   log likelihood = -1027.0616
Iteration 4:   log likelihood = -1027.0616

Probit regression                                 Number of obs =  2,000
                                                  LR chi2(4)    = 478.32
                                                  Prob > chi2   = 0.0000
Log likelihood = -1027.0616                       Pseudo R2     = 0.1889

------------------------------------------------------------------------------
        work | Coefficient  Std. err.      z    P>|z|     [95% conf. interval]
-------------+----------------------------------------------------------------
         age |   .0347211   .0042293     8.21   0.000     .0264318    .0430105
     married |   .4308575    .074208     5.81   0.000     .2854125    .5763025
    children |   .4473249   .0287417    15.56   0.000     .3909922    .5036576
   education |   .0583645   .0109742     5.32   0.000     .0368555    .0798735
       _cons |  -2.467365   .1925635   -12.81   0.000    -2.844782   -2.089948
------------------------------------------------------------------------------
```

Probit

- **mfx** calcula los efectos marginales en un valor representativo, utilizando los valores promedios $\phi(\bar{x}\hat{\beta})\hat{\beta}$
- Eso significa que **aumentar un año de edad en el "individuo promedio" aumenta la probabilidad de trabajar en 1.17 puntos porcentuales**

```
. mfx

Marginal effects after probit
      y  = Pr(work) (predict)
         =  .71835948
```

variable	dy/dx	Std. Err.	z	P>|z|	[95% C.I.]		X
age	.011721	.00142	8.25	0.000	.008935	.014507	36.208
married*	.150478	.02641	5.70	0.000	.098716	.20224	.6705
children	.1510059	.00922	16.38	0.000	.132939	.169073	1.6445
educat~n	.0197024	.0037	5.32	0.000	.012442	.026963	13.084

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Probit

- edad=20, casado, 1 hijo y 16 años de educación.

```
. mfx, at(20 1 1 16)

Marginal effects after probit
      y  = Pr(work) (predict)
         =  .51558372
```

variable	dy/dx	Std. Err.	z	P>|z|	[95% C.I.]		X
age	.0138412	.00173	8.01	0.000	.010456	.017226	20
married*	.1679752	.02852	5.89	0.000	.112078	.223872	1
children	.1783206	.01149	15.52	0.000	.155796	.200845	1
educat~n	.0232663	.00434	5.36	0.000	.014757	.031776	16

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Probit: **margeff**

- Es un paquete de Stata (Bartus, 2005) que se creó como alternativa más flexible a mfx
- Lo que hace es calcular **Average Marginal Effects** (AME):

$$AME_j = \frac{1}{N} \sum_{i=1}^{N} \phi(x_i' \hat{\beta}) \hat{\beta}$$

- Es decir, calcula el efecto marginal en **cada observación** y luego lo **promedia en la muestra**

Probit: **margeff**

- **margeff** calcula los efectos marginales promedios

```
. margeff

Average marginal effects on Prob(work==1) after probit
```

work	Coef.	Std. Err.	z	P>|z|	[95% Conf.	Interval]
age	.0100768	.0011647	8.65	0.000	.0077941	.0123595
married	.1292759	.0225035	5.74	0.000	.0851698	.173382
children	.1298233	.0068307	19.01	0.000	.1164354	.1432112
education	.0169386	.0031182	5.43	0.000	.010827	.0230502

- En promedio, un año más de edad aumenta la probabilidad de trabajar en 1.01 p.p.
- En cambio, con **mfx** era 0.0117 (1.17 p.p.) porque estaba evaluado en el individuo promedio

Probit: **margins**

- Suponga nos preguntamos, ¿cual sería la **probabilidad de trabajar** para un trabajador promedio (todas las variables promedio)?

```
. margins, atmeans

Adjusted predictions                            Number of obs     =      2,000
Model VCE    : OIM

Expression   : Pr(work), predict()
at           : age             =      36.208 (mean)
               married         =       .6705 (mean)
               children        =      1.6445 (mean)
               education       =      13.084 (mean)
```

	Delta-method					
	Margin	Std. Err.	z	P>|z|	[95% Conf.	Interval]
_cons	.7183595	.0114438	62.77	0.000	.69593	.7407889

Probit: **margins**

- Suponga nos preguntamos, cual sería la probabilidad de trabajar para una persona con **características específicas**:
  - edad=20, soltero, sin hijos y con 16 años de educación.

```
. margins, at(age=20 married=0 children=0 education=16)

Adjusted predictions                            Number of obs     =      2,000
Model VCE    : OIM

Expression   : Pr(work), predict()
at           : age             =          20
               married         =           0
               children        =           0
               education       =          16
```

	Margin	Delta-method Std. Err.	z	P>|z|	[95% Conf.	Interval]
_cons	.2007038	.0289826	6.92	0.000	.1438989	.2575088

Probit: **margins**

```
. margins, at(age= 20) atmeans

Adjusted predictions                            Number of obs     =      2,000
Model VCE    : OIM

Expression   : Pr(work), predict()
at           : age             =          20
               married         =       .6705 (mean)
               children        =      1.6445 (mean)
               education       =      13.084 (mean)
```

	Delta-method					
	Margin	Std. Err.	z	P>|z|	[95% Conf.	Interval]
_cons	.5060696	.0291647	17.35	0.000	.4489079	.5632313

Probit: **margins**

- margins, at(age= (20(1)30)) atmeans

	Margin	Delta-method Std. Err.	z	P>|z|	[95% Conf.	Interval]
_at						
1	.5060696	.0291647	17.35	0.000	.4489079	.5632313
2	.5199133	.0276472	18.81	0.000	.4657259	.5741007
3	.533733	.0261258	20.43	0.000	.4825274	.5849386
4	.5475122	.0246101	22.25	0.000	.4992772	.5957472
5	.5612343	.0231105	24.28	0.000	.5159385	.6065302
6	.5748833	.0216382	26.57	0.000	.5324732	.6172933
7	.588443	.0202053	29.12	0.000	.5488414	.6280447
8	.6018979	.0188253	31.97	0.000	.5650011	.6387948
9	.6152328	.0175128	35.13	0.000	.5809083	.6495573
10	.6284327	.0162842	38.59	0.000	.5965162	.6603491
11	.6414832	.0151569	42.32	0.000	.6117762	.6711902

Logit

```
. logit work age married children education

Iteration 0:   log likelihood = -1266.2225
Iteration 1:   log likelihood = -1040.6658
Iteration 2:   log likelihood = -1027.9567
Iteration 3:   log likelihood = -1027.9145
Iteration 4:   log likelihood = -1027.9144

Logistic regression                             Number of obs     =      2,000
                                                LR chi2(4)        =     476.62
                                                Prob > chi2       =     0.0000
Log likelihood = -1027.9144                     Pseudo R2         =     0.1882
```

work	Coef.	Std. Err.	z	P>|z|	[95% Conf.	Interval]
age	.0579303	.007221	8.02	0.000	.0437773	.0720833
married	.7417775	.1264705	5.87	0.000	.4938998	.9896552
children	.7644882	.0515289	14.84	0.000	.6634935	.865483
education	.0982513	.0186522	5.27	0.000	.0616936	.134809
_cons	-4.159247	.3320401	-12.53	0.000	-4.810034	-3.508461

Logit

- Los comandos para probit también funcionan con logit (la mayoría)

```
. mfx

Marginal effects after logit
      y  = Pr(work) (predict)
         =  .72678588
```

variable	dy/dx	Std. Err.	z	P>|z|	[	95% C.I.	]	X
age	.0115031	.00142	8.08	0.000	.008713	.014293		36.208
married*	.1545671	.02703	5.72	0.000	.101592	.207542		.6705
children	.151803	.00938	16.19	0.000	.133425	.170181		1.6445
educat~n	.0195096	.0037	5.27	0.000	.01226	.02676		13.084

```
(*) dy/dx is for discrete change of dummy variable from 0 to 1
```

Comparación Probit/logit - MCO

- El signo de MCO siempre será igual al signo de probit/logit
- Los efectos marginales de probit/logit son similares a MCO

Bondad de ajuste: medidas seudo-R^2

- Podemos comparar modelos
- **McFadden**:

$$\tilde{R}^2 = 1 - \frac{\ln \mathcal{L}(\hat{\beta})}{\ln \mathcal{L}(\bar{y})}$$

- $\ln \mathcal{L}(\hat{\beta})$: log-verosimilitud maximizada
- $\ln \mathcal{L}(\bar{y})$: log-verosimilitud del modelo con solo constante
- Valores más grandes indican mejor ajuste
- Comando útil: **fitstat**

Intuición del pseudo-R^2 de McFadden

- **Si tu modelo completo no mejora nada respecto al nulo:**
  $\ln \mathcal{L}(\hat{\beta}) \approx \ln \mathcal{L}(\bar{y}) \quad \Rightarrow \quad \tilde{R}^2 \approx 0.$
  $\Rightarrow$ El modelo no explica más que una constante.
- **Si tu modelo mejora mucho:**
  $\ln \mathcal{L}(\hat{\beta})$ es mucho mayor (menos negativo) que $\ln \mathcal{L}(\bar{y})$.
  $\Rightarrow$ La fracción se reduce y $\tilde{R}^2$ se acerca a 1.
- **En la práctica:** valores entre 0.2 y 0.4 ya indican un **buen ajuste** en logit/probit

Criterios de información: AIC

- Akaike's In- formation Criterion (**AIC**)

$$\mathrm{AIC} = 2k - 2\ln(\mathcal{L}),$$

- k: número de parámetros; $\mathcal{L}$ es el valor máximo en la función de verosimilitud
- **Intuición**:
  - El término $2\ln(\mathcal{L})$ recompensa el buen ajuste: cuanto mejor el ajuste, mayor $\ln(\mathcal{L})$ (menos negativo) y por tanto más bajo $-2\ln(\mathcal{L})$
  - El término $2k$ **penaliza la complejidad**: más parámetros $\Rightarrow$ mayor penalización.
- **Regla**: entre modelos estimados sobre **los mismos datos, elige el de AIC más bajo**
- Comando: **estat ic** o **fitstat**

Criterios de información: BIC

- Bayesian Information Criterion (**BIC**)

$$\mathrm{BIC} = k \ln(n) - 2 \ln(\mathcal{L}),$$

- n: tamaño muestral
- La penalización por complejidad crece con n (porque $\ln(n)$). Con muestras grandes, BIC castiga más agregar parámetros que AIC.
- **Intuición**:
  - BIC es más conservador: prefiere modelos más simples, sobre todo cuando n es grande
  - Si el objetivo es **predicción fuera de muestra**, AIC suele ser preferible
- **Regla**: igual que AIC, **más bajo es mejor** (comparando el mismo dataset)
- Comando: **estat ic** o **fitstat**

Test de Hosmer–Lemeshow (HL)

- En el test de Hosmer-Lemeshow, la idea es dividir la muestra en **grupos**. En cada grupo, Ud. compara **frecuencias observadas** de la variable dependiente con las **probabilidadades ajustadas** (fitted probability) entregadas por el modelo, dentro de los subgrupos. Esta comparación se resume en un estadístico de prueba, donde valores pequeños del mismo apoyan la especificación para los parametros del modelo logit en curso.
- La prueba HL es una **prueba de bondad de ajuste** para regresión logística, especialmente para modelos de predicción de riesgo. Una prueba de bondad de ajuste le indica qué tan bien se ajustan sus datos al modelo. Específicamente, la prueba HL **calcula si las tasas de eventos observados coinciden con las tasas de eventos esperadas en los subgrupos de población.**
- Hipótesis:

$$H_0 : \ logit(\pi_i) = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki}, \quad \forall i$$

$$H_A : \ logit(\pi_i) \neq \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki}, \quad \text{para algún } i$$

- La **hipótesis nula** es que las frecuencias observadas son iguales a las probabilidades ajustadas por el modelo (comando **estat gof**)

Test de Hosmer-Lemeshow (HL)

- La hipótesis nula del test HL es:
  - **Las frecuencias observadas son iguales a las probabilidades predichas por el modelo en cada grupo**
  - p-valor alto $\Rightarrow$ No se rechaza H_0
  - Eso significa que, en estos 10 grupos, los eventos observados (Obs_1, Obs_0) son muy cercanos a los esperados (Exp_1, Exp_0)

```
. estat gof, group(10)
note: obs collapsed on 10 quantiles of estimated probabilities.

Goodness-of-fit test after probit model
Variable: work

 Number of observations =  2,000
       Number of groups =     10
Hosmer-Lemeshow chi2(8) =   6.73
           Prob > chi2 = 0.5665
```

Capacidad predictiva del modelo

- **estat classification**
- Evalúa capacidad predictiva de tu modelo binario construyendo una tabla de clasificación según un punto de corte para la probabilidad predicha
- estat classification, cutoff(.5)

estat classification, cutoff(.5)

Probit model for work

Classified	True D	True ~D	Total
+	**1177**	**361**	**1538**
−	**166**	**296**	**462**
Total	**1343**	**657**	**2000**

Classified + if predicted Pr(D) >= .5
True D defined as work != 0

Sensitivity	Pr(+| D)	**87.64%**
Specificity	Pr(−|~D)	**45.05%**
Positive predictive value	Pr(D| +)	**76.53%**
Negative predictive value	Pr(~D| −)	**64.07%**
False + rate for true ~D	Pr(+|~D)	**54.95%**
False − rate for true D	Pr(−| D)	**12.36%**
False + rate for classified +	Pr(~D| +)	**23.47%**
False − rate for classified −	Pr(D| −)	**35.93%**
Correctly classified		**73.65%**