Inferencia Causal

Multinomial

Angelo Díaz

Universidad de Santiago de Chile

November 3, 2026

Modelos: Multinomial

- Anteriormente vimos modelos donde la variable dependiente podía tomar solo dos valores.
- Este modelo considera más de dos posible valores para la variable explicativa.
- La variable dependiente puede ser **odernada** o **desordenada**.
- Por ejemplo, podría ser las diferentes formas para ir a trabajar (desordenadas):
  - Bus,
  - Metro,
  - Caminar,
  - Bicicleta.
- Entonces, $y = \{Bus,\ Metro,\ Caminar,\ Bicicleta\}$
- Ejemplo de variable ordenada: ¿Con cuantas cucharadas de azúcar prefiere el café?.
  - Sin azúcar,
  - 1 cucharada,
  - 2 cucharadas.

Probabilidades y efectos marginales

- La variable de interés y_i es una de las m alternativas.
- Digamos $y_i = j$, donde $j = 1, 2, ..., m$
- El orden de las variables no importa, a menos que para nuestro modelo si importe.
- La probabilidad para el individuo i de elegir la alternativa j, condicional en los regresores x_i es:

$$p_{ij} = Pr[y_i = j] = F_j(x_i, \theta), \quad j = 1, ..., m, \quad i = 1, ..., N$$

- Nuevamente $F(*)$ puede tomar distintas distribuciones lo que va a determinar el modelo. Distintos modelos multinomial (depende de la distribución de los errores).
- Los parametros de modelos Multinomial por lo general no tienen una interpretación directa. Debemos computar los efectos marginales (ME).
- Suponga el ME de un cambio en el regresor k, sobre la probabilidad de la alternativa j:

$$ME_{ijk} = \frac{\partial Pr(y_i = j)}{\partial x_{ik}} = \frac{\partial F_j(x_i, \theta)}{\partial x_{ik}}$$

Máxima verosimilitud

- Función de verosimilitud:

$$L_i(\theta) = p_{i1}^{y_{i1}} \; x ... x \; p_{im}^{y_{im}} = \Pi_{j=1}^{m}[P(Y_i = j|X_i;\theta)]^{y_{ij}}$$

- Donde $y_{ij} = 1$ si $y_i = j$ y 0 en otro caso.
- La función de máxima verosimilitud se puede escribir como:

$$ln \; L(\theta) = \sum_{i=1}^{N}\sum_{j=1}^{m} y_{ij} ln P(Y_i = j|X_i;\theta)$$

- Fijese que suma las probabilidades por individuos y por alternativas.
- $\hat{\theta} \sim N(\theta, [-E\{\partial^2 lnL(\theta)/\partial\theta\partial\theta'\}]^{-1})$ — Se distribuye normal con esa varianza

Ejemplo (Microeconometrics: Methods and applications)

- Elección del modo de pesca.
- y toma los valores 1,2,3 y 4:
  - $y = 1$: Playa
  - $y = 2$: Muelle
  - $y = 3$: Barco privado
  - $y = 4$: Barco arrendado.
- La variable dependiente no está ordenada.
- Note que las variables son alternativas excluyentes.
- Regresores: ingreso del individuo (no varía con el modo de pesca), precio del modo de pesca (varía con el tipo de individuos), tasa de pesca (varía con el tipo de individuos).

Ejemplo: Data

Explanatory Variable	Sub sample Averages $y = 1$ Beach	$y = 2$ Pier	$y = 3$ Private	$y = 4$ Charter	All y Overall
Income ($1,000s per month)	4.052	3.387	4.654	3.881	4.099
Price beach ($)	36	31	138	121	103
Price pier ($)	36	31	138	121	103
Price private ($)	98	82	42	45	55
Price charter ($)	125	110	71	75	84
Catch rate beach	0.28	0.26	0.21	0.25	0.24
Catch rate pier	0.22	0.20	0.13	0.16	0.16
Catch rate private	0.16	0.15	0.18	0.18	0.17
Catch rate charter	0.52	0.50	0.65	0.69	0.63
Sample probability	0.113	0.151	0.354	0.382	1.000
Observations	134	178	418	452	1182

Logit condicional- Cuando los regresores varían

- Fijese que el precio y la tasa de pesca varían por tipo de individuos.
- Generalmente la gente decide pescar donde le sale más barato.
- La relación entre la elección del modo de pesca y la tasa de pesca es menos clara.
- Intuición: probablemente es más importante el precio que la tasa de pesca. Probablemente estamos en un caso de pesca por deporte y no pesca para alimentarse o vender.
- El modelo multinomial logit es llamada modelo de logit condicional.
- La probabilidad del individuo i, de elegir el modo de pesca j es:

$$p_{ij} = Pr[y_i = j] = \frac{exp(\beta_p P_{ij} + \beta_C C_{ij})}{\sum_{k=1}^{4} exp(\beta_p P_{ik} + \beta_p C_{ik})}, \quad j = 1, 2, 3, 4$$

$$p_{ij} = Pr[y_i = j] = \frac{exp(\beta_p P_{ij} + \beta_C C_{ij})}{\sum_{k=1}^{4} exp(\beta_p P_{ik} + \beta_p C_{ik})}, \quad j = 1, 2, 3, 4$$

- P es precio,
- C es la tasa de pesca,
- i es el individuo i.
- j o k son las alternativas de pesca.

Logit condicional (CL)- Cuando los regresores varían

- Basicamente vienen de la maximización de la función de maxima verosimiltud.

$$\frac{\partial L}{\partial \beta_k} = \sum_{i=1}^{N} (y_{ik} - p_{ik}) x_i = 0 \quad k = 1, ..., m$$

- Note que $y_{ik} = 1$ si la persona elige la alternativa k
- Para cada componente de β, la diferencia entre lo que pasó (1 si se eligió k, o 0 si no) y lo que el modelo predijo (p_{ik}) tiene promedio 0 una vez que la ponderas por x_i
- Esa es la versión "momentos = 0" del Maximum Likelihood Estimation (MLE): si el modelo está bien especificado, las predicciones calzan en promedio con los datos dentro de cada conjunto de elección.

Logit condicional (CL)- Cuando los regresores varían

- $\beta_p < 0$
- $\beta_C > 0$

Regressor	Type	Coefficient	CL
Price (P)	Specific	β_P	−0.021
Catch rate (C)	Specific	β_{CR}	0.953

Logit condicional (CL)- Cuando los regresores varían

- Cambio en la probabilidad de un cambio del precio de 100.
- Cambio en la probabilidad de un cambio de 1 en la tasa de pesca.
- Por ejemplo un aumento de 100 en el precio de pescar en la playa, provoca una disminución en la probabilidad de pescar de 27 p.p. Al mismo tiempo aumenta la probabilidad de los otros en 12 p.p, 9 p.p y 7 p.p.
- Mismo analisis para cambios en la tasa de pesca.
- Los efectos marginales miden el efecto sobre variables variables, más que sólo una variable.

	$100 Change in Price of				One-Unit Change in Catch Rate for			
	Beach	**Pier**	**Private**	**Charter**	**Beach**	**Pier**	**Private**	**Charter**
Change in Pr[beach]	−.272	.119	.085	.068	.126	−.055	−.040	−.032
Change in Pr[pier]	.119	−.263	.080	.064	−.055	.122	−.037	−.030
Change in Pr[private]	.080	.080	−.391	.225	−.040	−.037	.182	−.105
Change in Pr[charter]	.068	.064	.225	−.357	−.032	−.030	−.105	.166

Multinomial logit- Regresores invariantes

- Recuerde que el ingreso no varía con el modo de pesca.
- Parece que el modo de pesca cambia cuando aumenta el ingreso. Por ejemplo, pasar de pescar en la playa a pescar en bote privado.

	Sub sample Averages			
Explanatory Variable	$y = 1$ **Beach**	$y = 2$ **Pier**	$y = 3$ **Private**	$y = 4$ **Charter**
Income ($1,000s per month)	4.052	3.387	4.654	3.881

Multinomial logit- Regresores invariantes

$$p_{ij} = Pr[y_i = j] = \frac{exp(\alpha j + \beta_{Ij} I_i)}{\sum_{k=1}^{4} exp(\alpha_k + \beta_{Ik} I_i)}, \quad j = 1, 2, 3, 4$$

- I es ingreso.
- i es el individuo i.
- j o k son las alternativas de pesca.
- **Como el ingreso es invariante a través de las alternativas, el apropiado modelo es multinomial logit**
- Los coeficientes varían a través de las alternativas.
- Como las probabilidades suman zero, necesitamos normalizar los parametros. Por lo tanto, debemos establecer $\alpha_1 = 0$ y $\beta_{I1} = 0$

Multinomial logit

- Como tenemos un grupo base, la interpretación de los coeficientes son respecto al grupo base.
- En este caso el grupo base es pesca en la playa. Por lo tanto, si aumenta el ingreso y $\beta_{I3} > 0$ nos dice que si la gente aumenta su ingreso, aumenta la probabilidad de que usen botes privados en vez de pescar en la playa.
- Los cambios en el ingreso se pueden medir de la siguiente forma:

$$N^{-1} \sum_{i=1}^{N} \frac{\partial p_{ij}}{\partial I_i}$$

- El modelo se estima utilizando $N^{-1} \sum_{i=1}^{N} \hat{p}_{ij}(\hat{\beta}_j - \hat{\bar{\beta}}_i)$
- Donde $\bar{\beta}_i$ es la probabilidad promedio ponderada β_I : $\bar{\beta}_i = \sum_{l=1}^{m} p_{il}\beta_I$

Multinomial logit

Regressor	Type	Coefficient	CL	MNL
Price (P)	Specific	β_P	-0.021	–
Catch rate (C)	Specific	β_{CR}	0.953	–
Intercept	Invariant	α_1 : *Beach*	–	0.0
		α_2 : *Pier*	–	0.814
		α_3 : *Private*	–	0.739
		α_4 : *Charter*	–	1.341
Income (I)	Invariant	β_{I1} : *Beach*	–	0.0
		β_{I2} : *Pier*	–	-0.143
		β_{I3} : *Private*	–	0.092
		β_{I4} : *Charter*	–	-0.032
$-\ln$ L			-1311	-1477
Pseudo-R^2			0.162	0.099

Interpretación de los coeficientes

- Utilizar odds ratios o relative -risk ratios.
- El relative-risk ratio de elegir una alternativa j en vez de la alternativa base (1).

$$\frac{Pr(y_i = j)}{P(y_i = 1)} = exp(x_i' \beta_j)$$

- $exp(x_i' \beta_{jr})$ muestra el cambio proporcional en el riesgo relativo de elegir la alternativa j en vez de la altternativa 1 cuando x_{ir} cambia en una unidad.
- Calcular: $e^{-0.143} = 0.8667540689$
- RRR=0.867 $\Rightarrow$ por cada +1000 en ingreso, las odds se reducen 13.3 p.p (1-0.867)x100 (se multiplican por 0.867)

Predicción de las probabilidades

```
. sum pmlogit1 pmlogit2 pmlogit3 pmlogit4 dbeach dpier dprivate dcharter, separator(4)
```

Variable	Obs	Mean	Std. Dev.	Min	Max
pmlogit1	1,182	.1133672	.0036716	.0947395	.1153659
pmlogit2	1,182	.1505922	.0444575	.0356142	.2342903
pmlogit3	1,182	.3536379	.0797714	.2396973	.625706
pmlogit4	1,182	.3824027	.0346281	.2439403	.4158273
dbeach	1,182	.1133672	.3171753	0	1
dpier	1,182	.1505922	.3578023	0	1
dprivate	1,182	.3536379	.4783008	0	1
dcharter	1,182	.3824027	.4861799	0	1

Predicción de las probabilidades

- Un modelo multinomial ideal, va a predecir perfectamente.
- Por ejemplo pmlogit1 tomaría el valor de 1 para las 134 observaciones donde $y = 1$ y tomaría el valor de 0 para las demás observaciones.
- Se observa que pmlogit1 varía entre 0.0947 a 0.1154. Por lo tanto, este modelo que utiliza **solamente** el ingreso como variable explicativa, no es muy bueno para predecir cuando la gente va a pescar en la playa.

Efectos marginales

- $\frac{\partial p_{ij}}{\partial x_i} = p_{ij}(\beta_j - \bar{\beta}_i)$
- Un aumento de $1000 disminuye en 2 p.p la probabilidad de **pescar en muelle** en vez de en la playa, bote privado o arrendar.

```
. mfx, predict(pr outcome(2))

Marginal effects after mlogit
      y  = Pr(mode==pier) (predict, pr outcome(2))
         =  .14472379
```

variable	dy/dx	Std. Err.	z	P>|z|	[95% C.I.]		X
income	-.0206598	.00487	-4.24	0.000	-.030212	-.011108	4.09934

Mixed logit- Regresores invariantes y variantes

$$Pr[y_i = j] = \frac{exp(\beta_p P_{ij} + \beta_C C_{ij} + \alpha j + \beta_{lj} I_i)}{\sum_{k=1}^{4} exp(\beta_p P_{ik} + \beta_p C_{ik} + \alpha_k + \beta_{lk} I_i)}, \quad j = 1, 2, 3, 4$$

- Esta probabilidad incluye variables que varían con la forma de pesca y variables que no lo hacen.

Mixed logit- Regresores invariantes y variantes

Regressor	Type	Coefficient	CL	MNL	Mixed
Price (P)	Specific	β_P	−0.021	–	−0.025
Catch rate (C)	Specific	β_{CR}	0.953	–	0.358
Intercept	Invariant	α_1 : *Beach*	–	0.0	0.0
		α_2 : *Pier*	–	0.814	0.778
		α_3 : *Private*	–	0.739	0.527
		α_4 : *Charter*	–	1.341	1.694
Income (I)	Invariant	β_{I1} : *Beach*	–	0.0	0.0
		β_{I2} : *Pier*	–	−0.143	−0.128
		β_{I3} : *Private*	–	0.092	0.089
		β_{I4} : *Charter*	–	−0.032	−0.033
$-\ln$ L			−1311	−1477	−1215
Pseudo-R^2			0.162	0.099	0.258

- Fijese que el mixed model tiene una mayor Pseudo-R^2

Mixed logit- Interpretación de los coeficientes

- Sea x_r el regresor con el coeficiente β_r
- El efecto del cambio en x_{rik}, que es el valor de x_r para el individuo i y la alternativa k, es:

$$\frac{\partial p_{ij}}{\partial x_{rik}} = \begin{cases} p_{ij}(1 - p_{ij})\beta_r & \text{si } j = k \\ -p_{ij}p_{ik}\beta_r & \text{si } j \neq k \end{cases}$$

- Si $\beta_r > 0$ el efecto sobre si misma es positivo y el cross-effect ($j \neq k$) es negativo.
- Por lo tanto, si el regresor aumenta para una categoría, luego la categoría es más elegida y las otras menos.
- Precio:
  - El coeficiente es -0.025. Por lo tanto, si aumenta el precio de un modo de pescar, luego la demanda por ese modo disminuye y la de los demás aumenta.
- Tasa de pesca:
  - El coeficiente es 0.358. Por lo tanto, si aumenta la tasa de pesca por un modo de pescar, luego la demanda de ese modo aumenta y la de los otros disminuye.

Mixed logit- Interpretación de los coeficientes

- La interpretación para las variables que no varían (case-specific regressors), tienen una interpretación como antes. Los coeficientes son $-0.033,\ -0.128,\ 0.089$
- Por lo tanto, un aumento del ingreso disminuye la probabilidad de arrendar un bote, y pescar en el muelle, pero aumenta la probabilidad de pescar en bote privado.

Mixed logit- Efectos marginales

- Podemos utilizar el comando **mfx**, con la opción **varlist()** para obtener los efectos marginales de un subconjunto de regresores.
- Ver do-file.
- Un incremento de $1 en el precio de pescar en la playa, disminuye la probabilidad de pescar en la playa en 0.001249.
- Un incremento de $1 en el precio de pescar en el muelle, aumenta la probabilidad de pescar en la playa en 0.000609.

```
. estat mfx, varlist(p)

Pr(choice = beach|1 selected) = .05248806
```

variable	dp/dx	Std. Err.	z	P>|z|	[95% C.I.]		X
p							
beach	-.001249	.000121	-10.29	0.000	-.001487	-.001011	103.42
charter	.000609	.000061	9.97	0.000	.000489	.000729	84.379
pier	.000087	.000016	5.42	0.000	.000055	.000118	103.42
private	.000553	.000056	9.88	0.000	.000443	.000663	55.257

Modelos multinomial ordenados

- Hay variables que tienen un orden natural, por ejemplo estado de salud.
  1. Mala.
  2. Regular.
  3. Buena.
  4. Excelente.
- Aunque pueden ser estimadas utilizando el procedimiento anterior, es mejor tener en cuenta el orden de la variable dependiente.
- Sea y^* una variable latente.

$$y^* = x_i'\beta + u_i$$

- x no incluye el intercepto.

Modelos multinomial ordenados

- La idea es que si y^* excede algún valor, se va moviendo de alternativas.
- Ejemplo: Si $y^* =< \alpha_1$, luego la persona tiene una nivel de salud pobre.
- Si $y^* > \alpha_1$ la persona mejora de salud y tiene una salud regular.
- Así sucesivamente.
- En general
  $y_i = j \;\; si \;\; \alpha_{j-1} < y_i^* =< \alpha_j$
- Donde $\alpha_0 = -\infty$ y $\alpha_m = \infty$

Modelos multinomial ordenados

- La probabilidad de que i elija j es:

$$
\begin{aligned}
Pr[y_i = j] &= Pr[\alpha_{j-1} < y_i^* < \alpha_j] \\
&= Pr[\alpha_{j-1} < x_i'\beta + u_i < \alpha_j] \\
&= Pr[\alpha_{j-1} - x_i'\beta < u_i < \alpha_j - x_i'\beta] \\
&= F(\alpha_j - x_i'\beta) - F(\alpha_{j-1} - x_i'\beta)
\end{aligned}
$$

- Donde F es la cdf de u_i
- Los parametros se obtienen maximizando la función de verosimilitud (log-likelihood).
- Podemos hacer el supuesto de que u posee una distribución logistica o que puede tener una distribución normal estandar. Esto determina la función cdf.

Modelos multinomial ordenados - Efectos marginales

$$\frac{\partial Pr[y_i = j]}{\partial x_i} = \{F'(\alpha_{j-1} - x_i'\beta) - F'(\alpha_j - x_i'\beta)\}\beta$$

- F' es la derivada de F.
- Este término puede ser positivo o negativo.

Ejemplo

- Salud:
  1. y=1: pobre,
  2. y=2: buena,
  3. y=3: excelente.

Estado de salud	Freq.	Percent	Cum.
pobre o regular	523	9.38	9.38
buena	2,034	36.49	45.87
excelente	3,017	54.13	100.00
Total	5,574	100.00	

- Ver do-file.

Estimación

- Como esperado, la salud mejora con el ingreso, empeora con la edad y enfermedades cronicas.

```
. ologit est_salud edad log_ingreso enf_cronicas, nolog

Ordered logistic regression                     Number of obs     =      5,574
                                                LR chi2(3)        =     740.39
                                                Prob > chi2       =     0.0000
Log likelihood = -4769.8525                     Pseudo R2         =     0.0720
```

est_salud	Coef.	Std. Err.	z	P>|z|	[95% Conf.	Interval]
edad	-.0292944	.001681	-17.43	0.000	-.0325891	-.0259996
log_ingreso	.2836537	.0231098	12.27	0.000	.2383593	.3289481
enf_cronicas	-.0549905	.0040692	-13.51	0.000	-.0629661	-.047015
/cut1	-1.39598	.2061301			-1.799987	-.9919722
/cut2	.9513097	.2054301			.5486741	1.353945

Efectos marginales

- La probabilidad de tener una salud excelente disminuye con la edad, enfermedades e incrementa con el ingreso.
- $Edad = -0.0072$: si la edad sube 1 año, $P(salud = 3)$ baja 0.728 p.p.

```
. mfx, predict(outcome(3))

Marginal effects after ologit
      y  = Pr(est_salud==3) (predict, outcome(3))
         =  .53747616
```

variable	dy/dx	Std. Err.	z	P>|z|	[95% C.I.]		X
edad	-.0072824	.00042	-17.43	0.000	-.008101	-.006463	25.5761
log_in~o	.070515	.00575	12.26	0.000	.05924	.08179	8.69693
enf_cr~s	-.0136704	.00101	-13.50	0.000	-.015655	-.011686	11.2053

Efectos marginales

- Cuando lo vemos para el outcome 1: salud mala o regular, las conclusiones son contrarias.

```
. mfx, predict(outcome(1))

Marginal effects after ologit
      y  = Pr(est_salud==1) (predict, outcome(1))
         =  .07603533
```

variable	dy/dx	Std. Err.	z	P>|z|	[95% C.I.]		X
edad	.002058	.00013	15.44	0.000	.001797	.002319	25.5761
log_in~o	-.0199278	.00173	-11.49	0.000	-.023327	-.016528	8.69693
enf_cr~s	.0038633	.00031	12.64	0.000	.003264	.004462	11.2053

Probit Bivariado

- Este es un modelo de dos variables binarias.
- Son dos variables latentes que podrían estar correlacionadas.

$$y_1^* = x_1'\beta_1 + \epsilon_1$$
$$y_2^* = x_2'\beta_2 + \epsilon_2$$

- Donde ϵ_1 y ϵ_2 tiene una distribución normal conjunta (joint normal) con media zero, varianza uno y correlación ρ

$$y_1 = \begin{cases} 1 & \text{si } y_1^* > 0 \\ 0 & \text{si } y_1^* \leqslant 0 \end{cases}$$

$$y_2 = \begin{cases} 1 & \text{si } y_2^* > 0 \\ 0 & \text{si } y_2^* \leqslant 0 \end{cases}$$

- El modelo serían dos modelos separdos si es que $\rho = 0$

Probit Bivariado

- Cuando $\rho \neq 0$ no existe una forma cerrada para la solución de las probabilidades.
- Por ejemplo, suponga la probabilidad de $y_1 = 1$ y $y_2 = 1$

$$
\begin{aligned}
p_{11} &= Pr[y_1 = 1, y_2 = 1] \\
&= Pr[y_1^* > 0, y_2^* > 0] \\
&= Pr[-\epsilon_1 > x_1'\beta_1, -\epsilon_2 > x_2'\beta_2] \\
&= Pr[\epsilon_1 < x_1'\beta_1, \epsilon_2 < x_2'\beta_2] \\
&= \int_{-\infty}^{x_1'\beta_1} \int_{-\infty}^{x_2'\beta_2} \phi(z_1, z_2, \rho) \partial z_1 \partial z_2 \\
&= \Phi(x_1'\beta_1, x_2'\beta_2, \rho)
\end{aligned}
$$

Probit Bivariado

- Se obtiene algo similar para cualquier tipo de valor

$$p_{jk} = Pr[y_1 = j, y_2 = k]$$

$$= \Phi(q_1 x_1' \beta_1, q_2 x_2' \beta_2, \rho)$$

- Donde $q_l = 1$ si $y_l = 1$ y $q_l = -1$ si $y_l = 0$, para todos $l = 1, 2$
- Note que hay 4 posibles resultados:
  - $y_{10},\ y_{01},\ y_{11},\ y_{00}$

Probit Bivariado - Ejemplo

- Considere el caso anterior con nuestra base de salud.
- La variable dmdu es igual a 1 si es que el individuo ha visitado el doctor el año pasado y 0 en otro caso.
- Intuición: Es probable que esta variable tenga alguna relacón con nuestra variable hlthe que es 1 si la persona tiene salud excelente y 0 en otro caso (las variables inobservables)

```
. tab hlthe dmdu
```

hlthe	any MD visit = 1 if mdu > 0		Total
	0	1	
0	826	1,731	2,557
1	1,006	2,011	3,017
Total	1,832	3,742	5,574

Probit Bivariado - Ejemplo

- Correlación:

```
. corr(hlthe dmdu)
(obs=5,574)
```

	hlthe	dmdu
hlthe	**1.0000**	
dmdu	**-0.0110**	**1.0000**

- Aunque hay que hacer estos estadísticos descriptivos el supuesto es sobre los errores.
- Importante: el supuesto es ϵ_1 y ϵ_2 tiene una distribución normal conjunta (joint normal) con media zero, varianza uno y correlación ρ
- De todas formas, estos estadísticos descriptivos nos dice que quizás está poco correlacionado **hlthe** y **dmdu**.

Probit Bivariado - Estimación

```
. biprobit hlthe dmdu edad log_ingreso enf_cronicas, nolog

Bivariate probit regression                     Number of obs     =      5,574
                                                Wald chi2(6)      =     770.00
Log likelihood = -6958.0751                     Prob > chi2       =     0.0000
```

	Coef.	Std. Err.	z	P>|z|	[95% Conf.	Interval]
hlthe						
edad	-.0178246	.0010827	-16.46	0.000	-.0199466	-.0157025
log_ingreso	.132468	.0149632	8.85	0.000	.1031406	.1617953
enf_cronicas	-.0326656	.0027589	-11.84	0.000	-.0380729	-.0272583
_cons	-.2297079	.1334526	-1.72	0.085	-.4912703	.0318545
dmdu						
edad	.0020038	.0010927	1.83	0.067	-.0001379	.0041455
log_ingreso	.1212519	.0142512	8.51	0.000	.09332	.1491838
enf_cronicas	.0347111	.0028908	12.01	0.000	.0290452	.0403771
_cons	-1.032527	.1290517	-8.00	0.000	-1.285464	-.7795907
/athrho	.0282258	.022827	1.24	0.216	-.0165142	.0729658
rho	.0282183	.0228088			-.0165127	.0728366

```
LR test of rho=0: chi2(1) = 1.5295                        Prob > chi2 = 0.2162
```

Probit Bivariado - Estimación

- Fijese que el modelo estima ρ
- En este caso el $p - valor$ es 0.2162. Por lo tanto, **no podemos rechazar la hipotesis nula** que $\rho = 0$
- En otras palabras parece que **no necesitamos un modelo probit bivariado**
- De hecho si hacemos dos modelo probit por separado vamos a encontrar resultados similares