Inferencia Causal

Tobit y Heckman (Dos Etapas)

Angelo Díaz

Universidad de Santiago de Chile

November 10, 2026

Contexto

- Vamos a estudiar casos donde:
  1. La variable dependiente es incompletamente observada:
     - **Truncada**,
     - **Censurada**
  2. Truncamiento provoca que la variable dependiente es observada, pero para una reducida muestra:
     - **Sample selection**
- En estos casos la estimación de MCO de la media condicional poblacional es inconsistente, ya que **no es representativa de la población**

Contexto: truncamiento

- **Data truncada:** no hay algunas observaciones en la variable dependiente y las variables independientes (**no se observa ni Y ni X**). Es decir, no hay datos completos.
- Por ejemplo, si el **ingreso** es la variable dependiente, podría ser que solo tengamos información de personas con bajos ingresos.
- Una muestra está truncada si los datos sólo están disponibles para un subconjunto de la población total. Los valores de las variables explicativas X sólo se observan cuando se observa Y.
- Otro ejemplo: El gasto médico de una muestra de pacientes entrevistados después de someterse a un tratamiento dental. En este caso, sólo observamos a personas con gasto mayor que cero.

Gasto médico: ¿selección o truncamiento?

Contexto: Gasto médico después de tratamiento dental.

Selección muestral (Sample selection)

- **X** observada para *todos*.
- Y (gasto) observada sólo si $s{=}1$ (hubo tratamiento).
- **Modelo:** Heckman (dos etapas) + restricción de exclusión en **Z**.

Truncamiento (muestra recortada)

- Sólo se incluyen tratados: no existen en la base los no tratados.
- Faltan Y *y* **X** de no tratados.
- **Modelo:** Regresión truncada (likelihood condicional a "estar en la muestra").

Contexto: censura

- **Data censurada:** Todas las observaciones son incluidas, pero la variable dependiente se observa **dentro de un rango**. Por ejemplo, podría ser que todos los ingresos estén considerados en la muestra, pero por temas de confidelidad se coloque 2 millones de pesos mensuales para las personas con mayores ingresos.
- Una muestra está censurada si los datos se **recodifican** para un subconjunto de la población. En una muestra censurada, observo las X de toda la población, pero el valor de la Y se desconoce para un subconjunto de la población.
- Oferta de trabajo: si las personas trabajan, sabemos el número de horas que ofrecen, pero a los que no trabajan les asignamos cero horas.... Sin embargo, podría ser que su oferta de trabajo fuese de 3 horas por semana, pero no encuentra ningún empleo con esas características.

Censura vs. Selección vs. Truncamiento

Caso	¿X para todos?	¿Y para todos?	¿Qué ves cuando "no pasa"?	Modelo
Censura	Sí	Sí (pero *recodificada*)	Un **0** o un **tope** (p.ej., top-coding)	Tobit / Two-part
Selección	Sí	Solo si $s=1$	**Missing** en Y (la fila existe, falta Y)	Heckman (2 etapas)
Truncamiento	**No**	**No**	**No hay fila** (no entra a la muestra)	Regresión truncada

Ejemplo

- Sea y^* la variable incompletamente observada.
- Porque y^* es truncada, y^* es solo observada si y^* excede un umbral.
- Por simplicidad digamos que ese umbral es cero.
- Por lo tanto, obserbamos $y = y^*$, si $y^* > 0$.
- Por lo tanto, valores negativos no aparecen en la muestra. Lo que implica que la media truncada, será mayor que la media de y^*.
- Para variables censuradas, y^* es no observada cuando $y^* \leqslant 0$, pero si es conocido que $y^* > 0$ y por simplicidad se establece que $y = 0$.
- Ya que valores negativos son transformados a cero, nuevamente en este caso, tenemos una situación donde la media censurada es mayor que la media de y^*.
- Por lo tanto, debemos realizar un ajuste.

Ejemplo

- Sea y^*: las horas deseadas de trabajar.
- w: salario.
- Considere el siguiente proceso generador de datos.

$$y^* = -2500 + 1000 ln\ w + \epsilon$$

$$\epsilon \sim N[0, 1000^2]$$

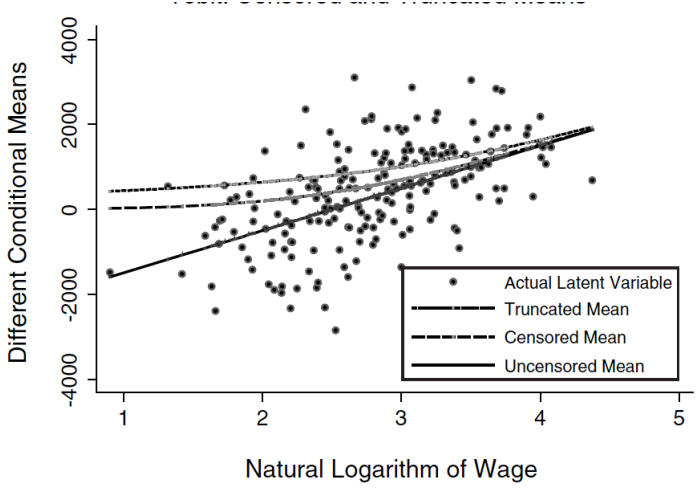
$$ln\ w \sim N[2.75, 0.60^2]$$

- Numero de observaciones: 200.

Ejemplo

- Negativos valores de y^* se cambian por cero (censurar), porque gente que desea negativamente, no va a trabajar.
- También se puede truncar la base y sacar todas las observaciones cuando y^* es negativo.
- El segundo ejercicio va a incrementar un poco la media condicional, ya que no considera ceros.
- Medias condicionales truncadas y censuradas podrían no ser lineales en x.

Ejemplo


Different Conditional Means
4000
2000
0
-2000
-4000
1
2
3
4
5
Natural Logarithm of Wage
Actual Latent Variable
Truncated Mean
Censored Mean
Uncensored Mean

Censura

- Las variables pueden estar censuradas por arriba o por abajo.
- Siempre observamos los regresores x, observamos completamente y^* para un subconjunto de los posibles valores de y^*, y observamos y de manera incompleta para los posibles valores restantes de y^*.
- Censurada por abajo.
  - Por ejemplo, se puede muestrear a todos los consumidores, algunos con gastos positivos en bienes duraderos ($y^* > 0$) y otros con gastos ceros ($y^* \leqslant 0$)
- Censurada por arriba.
  - los datos de ingresos anuales pueden codificarse en I = 2.000.000.

Truncamiento

- Igualmente puede haber truncamiento por arriba y por debajo.
- Truncada por abajo.
  - Por ejemplo, **solo podemos observar** los consumidores con gastos positivos en bienes duraderos.
- Truncada por arriba.
  - **Solo podemos observar** los datos de ingresos anuales inferiores a $I = 2.000.000$.

Censura por debajo

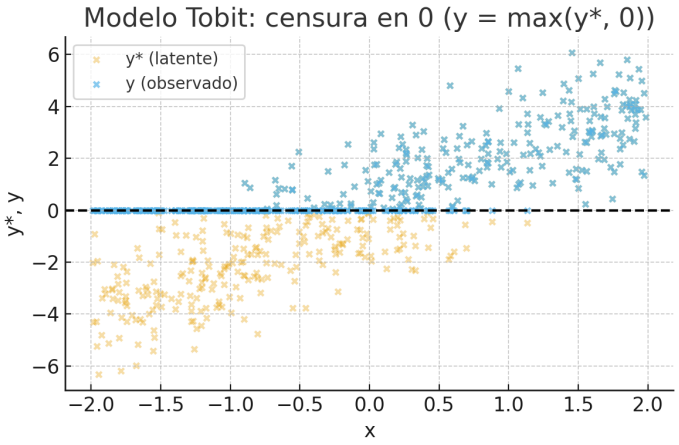
Censura por debajo:

$$y = y^* \text{ si } y^* > L \text{ y } y = L \text{ si } y^* \leq L$$

Por ejemplo:

- L=0 en una encuesta de ingresos
- Si $y^* \leq L$, entonces y toma el valor de L. Si $y^* > L$, entonces $y = y^*$

Intuición visual



Puntos por debajo de 0 en y^* se observan como $y = 0$.

Censura por encima

Censura por encima:

$$y = y^* \ si \ y^* \leq U \ y \ y = U \ si \ y^* > U$$

Por ejemplo:

- U=2 millones en una encuesta de ingresos
- Si $y^* > U$, entonces y toma el valor de U. Si $y^* \leq L$, entonces $y = y^*$

Censura: Función de densidad

Censura por debajo:

- Para los valores $y > L$, la densidad de y es la misma que la densidad de y^*

$$f(y|x) = f^*(y|x, \theta) \; si \; y > L$$

- Para $y \leq L$, la densidad de y se concentra en el punto L:

$$f(y|x) = P(y^* \leq L|x, \theta) = F^*(L|x, \theta) \; si \; y = L$$

sea $F^*(L|x, \theta)$ la función de distribución acumulada (cdf) de y^* evaluada en L

Censura inferior en L: verosimilitud

Definición: Observamos $y = \max\{L,\, y^*\}$, con densidad latente $f^*(y^* \mid x, \theta)$ y CDF $F^*(\cdot \mid x, \theta)$.

Contribución individual a la verosimilitud (obs. i):

$$L_i(\theta) = \begin{cases} f^*(y_i \mid x_i, \theta), & \text{si } y_i > L, \\ F^*(L \mid x_i, \theta), & \text{si } y_i = L. \end{cases}$$

Forma compacta usando $d_i = \mathbb{I}(y_i > L)$:

$$L_i(\theta) = \left[f^*(y_i \mid x_i, \theta)\right]^{d_i} \left[F^*(L \mid x_i, \theta)\right]^{1-d_i}.$$

Log-verosimilitud muestral:

$$\ell(\theta) = \sum_{i=1}^{n} \Big\{ d_i \cdot \ln f^*(y_i \mid x_i, \theta) \;+\; (1 - d_i) \cdot \ln F^*(L \mid x_i, \theta) \Big\}.$$

Modelo Tobit

- Este es un modelo donde solo positivos outcomes son completamente observados (Por ejemplo, los otros outcomes son reemplazados por ceros).
- Lleva el nombre de Tobit por Tobin (1958).
- También es llamado modelo de regresión normal censurado.
- Este es un modelo que es **censurado por abajo**. (Aunque hay modificaciones y puede ser censurado por arriba.)
- Generalmente se dice que el modelo es demasiado restrictivo, ya que se supone que el error se distribuye normal y se asume homocedasticidad.
- De todas formas es un modelo ampliamente usado y la base de la intuición de otros modelos que son formas modificadas.

Modelo de probabilidad lineal (MPL) v/s Tobit

- Si tenemos una variable "y" limitada, donde tenemos muchos ceros. Por ejemplo: El gasto en alchool.
- Un modelo MPL nos podría entregar valores ajustados negativos, además el efecto parcial sobre constante sobre $E(y|x)$ no es tan creíble.
- EL modelo Tobit, nos entrega valores predichos no negativos y además los efectos marginales no son constantes.

Modelo Tobit

- En el modelo tobit existe una variable latente que es lineal en su regresores, con un error que es normalmente distribuido y homocedastico.

$$y^* = x'\beta + \epsilon$$

$$\epsilon \sim N[0, \sigma^2]$$

- Por lo tanto, σ^2 es constante a través de las observaciones (Homocedasticidad).
- $y^* \sim N[x'\beta, \sigma^2]$

Modelo Tobit

- La variable y se observa cuando:

$$y = \begin{cases} y^* & \text{si } y^* > 0 \\ 0 & \text{si } y^* \leqslant 0 \end{cases}$$

- La densidad censurada tiene la siguiente expresión:

$$f(y) = \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{ -\frac{1}{2\sigma^2}(y - \mathbf{x}'\boldsymbol{\beta})^2 \right\} \right]^d \left[1 - \Phi\left(\frac{\mathbf{x}'\boldsymbol{\beta}}{\sigma} \right) \right]^{1-d}$$

- Donde d es un indicador, que es igual a 1 si $y > 0$

Modelo Tobit

- Luego, la función de verosimilitud censurada es:

$$\ln \mathrm{L}_N(\boldsymbol{\beta}, \sigma^2) = \sum_{i=1}^{N} \left\{ d_i \left(-\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \left(y_i - \mathbf{x}_i' \boldsymbol{\beta} \right)^2 \right) + (1 - d_i) \ln \left(1 - \Phi \left(\frac{\mathbf{x}_i' \boldsymbol{\beta}}{\sigma} \right) \right) \right\},$$

- Al maximizar la función de MV. Obtenemos $\hat{\theta}_{MLE} = (\hat{\beta}', \hat{\sigma}^2)$

Tobit: Ejemplo

- La variable dependiente es: gasto ambulatorio (ambexp)
- Las variables independientes son: edad, mujer, educ, black o hispano, total de condiciones cronicas, seguro.
- Veamos el descriptivo de la variable:

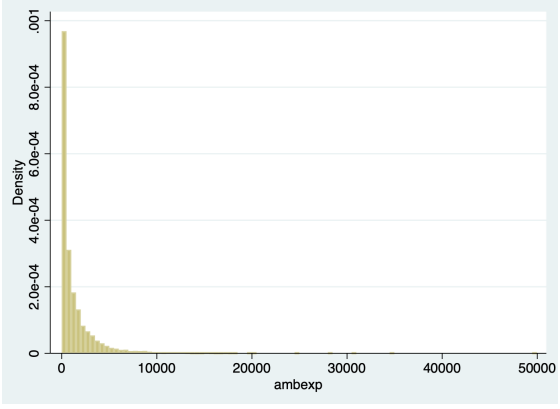
```
. sum ambexp
```

Variable	Obs	Mean	Std. Dev.	Min	Max
ambexp	3,328	1386.519	2530.406	0	49960

- Observamos que el minimo valor es cero, pero nadie puede gastar cero (si es que ocupó el servicio)

Tobit: Ejemplo

- Hitograma



Tobit: Ejemplo

- Percentiles

ambexp

	Percentiles	Smallest		
1%	0	0		
5%	0	0		
10%	0	0	Obs	3,328
25%	113	0	Sum of Wgt.	3,328
50%	534.5		Mean	1386.519
		Largest	Std. Dev.	2530.406
75%	1618	28269		
90%	3585	30920	Variance	6402953
95%	5451	34964	Skewness	6.059491
99%	11985	49960	Kurtosis	72.06738

Tobit: Estimación

```
. tobit ambexp age female educ blhisp totchr ins, ll(0) nolog

Tobit regression                                  Number of obs     =      3,328
                                                  Uncensored        =      2,802
Limits: lower = 0                                 Left-censored     =        526
        upper = +inf                              Right-censored    =          0

                                                  LR chi2(6)        =     694.07
                                                  Prob > chi2       =     0.0000
Log likelihood = -26359.424                       Pseudo R2         =     0.0130
```

ambexp	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
age	314.1479	42.63366	7.37	0.000	230.557	397.7388
female	684.9918	92.85464	7.38	0.000	502.9337	867.0498
educ	70.8656	18.57365	3.82	0.000	34.44865	107.2825
blhisp	-530.311	104.2669	-5.09	0.000	-734.7448	-325.8772
totchr	1244.578	60.51376	20.57	0.000	1125.93	1363.226
ins	-167.4714	96.46088	-1.74	0.083	-356.6002	21.65734
_cons	-1882.591	317.4305	-5.93	0.000	-2504.971	-1260.212
var(e.ambexp)	6635296	179247.7			6292994	6996217

Tobit: Interpretación de los coeficientes

- Observe que β mide los efectos parciales de X's sobre la variable latente. $[y^* = x'\beta + \epsilon]$
- Pero la variable que se quiere explicar es y, ya que es el resultado que se observa.
- ¿Cómo estimar el valor esperado de y en función de x?

$$E(y|x) = P(y > 0) * E(y|y > 0, x) = \Phi(x\beta/\sigma) * E(y|y > 0, x)$$

- Se puede mostrar que:

$$E(y|y > 0, x) = x\beta + \sigma\lambda(x\beta/\sigma)$$

- Donde $\lambda(c) = \phi(c)/\Phi(c)$ es llamado la razón inversa de Mills (Mills ratio). Que es la división entre la pdf y la cdf de una normal estándar, cada una evaluada en c.

Tobit: Interpretación de los coeficientes

- Juntando las ecuaciones anteriores obtenemos:

$$E(y|x) = P(y > 0) * E(y|y > 0, x) = \Phi(x\beta/\sigma)[x\beta + \sigma\lambda(x\beta/\sigma)] = \Phi(x\beta/\sigma)x\beta + \sigma\phi(x\beta/\sigma)$$

- Importante:
  - Lo veremos más adelante, pero la razón inversa de Mills es una variable omitida en MCO. Lo que hace que MCO no sea consistente.
  - De la ecuación anterior se observa que: $E(y|x)$ es una función **no lineal** de x y también de β.

Tobit: Efectos marginales

- Los efectos marginales (EM) son más complicados que MCO.
- La maginitud de los efectos depende depende de los valores de todas las variables explicativas , parámetros y σ.
- Si x_j es continua:

$$\frac{\partial E(y|y>0,x)}{\partial x_j} = \beta_j + \beta_j \frac{\partial \lambda}{\partial x_j}(x\beta/\sigma)$$

- Por otro lado tenemos que

$$\frac{\partial P(y>0|x)}{\partial x_j} = (\beta_j/\sigma)\phi(x\beta/\sigma)$$

Tobit: Efectos marginales

- Luego, si queremos calcular los EM:

$$\frac{\partial E(y|x)}{\partial x_j} = \frac{\partial P(y > 0|x)}{\partial x_j} * E(y|y > 0, x) + P(y > 0|x) * \frac{\partial E(y|y > 0, x)}{\partial x_j}$$

- Además, usando que $P(y > 0|x) = \Phi(x\beta/\sigma)$
- Se puede mostrar que:

$$\frac{\partial E(y|x)}{\partial x_j} = \beta_j \Phi(x\beta/\sigma)$$

- Nota: Hemos omitido varios pasos para llegar a los EM.
- Los efectos parciales de MCO y Tobit son similares cuando hay pocas observaciones con $y = 0$

Efectos marginales en Tobit: qué miden y cómo obtenerlos

En un Tobit (censura inferior en 0) existen tres tipos de efectos marginales posibles:

Objetivo	**Efecto marginal teórico**	**Comando en Stata**
Probabilidad de ser positivo	$\frac{\partial P(y>0 \mid x)}{\partial x_j} = \varphi(c)\frac{\beta_j}{\sigma}$	`margins, dydx(xj)` `predict(pr(0,.))`
Media condicional	$\frac{\partial E[y \mid y>0,x]}{\partial x_j} = \beta_j\{1 - \lambda(c)[\lambda(c)-c]\}$	`margins, dydx(xj)` `predict(e(0,.))`

Media incondicional	$\frac{\partial E[y \mid x]}{\partial x_j} = \beta_j\,\Phi(c)$	`mfx compute,`
		`predict(ystar(0,.))` (MEM)
		`margins, dydx(xj)`
		`predict(ystar(0,.))` (AME)

Donde $c = \frac{x'\beta}{\sigma}$, Φ es la CDF y φ la PDF normal estándar, $\lambda(c) = \varphi(c)/\Phi(c)$ es la razón inversa de Mills. El resultado anterior sí es un EM (evaluado at means), pero del tipo **condicional**. Si quieres el EM sobre la media incondicional o sobre la probabilidad de estar activo, debes cambiar la opción `predict(...)`.

ME

- marginal effects at means (MEM)
- Otro comando: margins, dydx(*) predict(ystar(0,.)). Para promediar efectos individuo a individuo (AME)

```
. mfx compute, predict(ystar(0,.))

Marginal effects after tobit
      y  = E(ambexp*|ambexp>0) (predict, ystar(0,.))
         =  1647.8507
```

variable	dy/dx	Std. Err.	z	P>|z|	[	95% C.I.	]	X
age	207.526	28.205	7.36	0.000	152.244	262.808		4.05688
female*	451.6399	61.029	7.40	0.000	332.026	571.254		.508413
educ	46.81378	12.266	3.82	0.000	22.7738	70.8537		13.4056
blhisp*	-342.4803	65.757	-5.21	0.000	-471.361	-213.6		.308594
totchr	822.1678	40.61	20.25	0.000	742.573	901.763		.483173
ins*	-110.0883	63.117	-1.74	0.081	-233.795	13.6188		.365084

(*) dy/dx is for discrete change of dummy variable from 0 to 1

Interpretación: Media incondicional

- Comando: `mfx compute, predict(ystar(0,.))|  (MEM, at means)`.
- Lectura: en el punto de evaluación $x = \bar{x}$, un aumento de 1 unidad en age aumenta el gasto ambulatorio esperado entre quienes gastan $E[y \mid x]$ en 207.5 unidades monetarias, considerando tanto a quienes realizan gastos como a quienes tienen gasto cero.
- Si prefieres AME para este objeto: `margins, dydx(age) predict(ystar(0,.))|`.

```
. mfx compute, predict(ystar(0,.))

Marginal effects after tobit
      y  = E(ambexp*|ambexp>0) (predict, ystar(0,.))
         =  1647.8507
------------------------------------------------------------------------------
variable |      dy/dx    Std. err.      z    P>|z|   [    95% C.I.   ]       X
---------+--------------------------------------------------------------------
     age |    207.526     28.205     7.36   0.000    152.244   262.808   4.05688
  female*|    451.6399    61.029     7.40   0.000    332.026   571.254    .508413
    educ |    46.81378    12.266     3.82   0.000    22.7738   70.8537   13.4056
  blhisp*|   -342.4803    65.757    -5.21   0.000   -471.361    -213.6    .308594
  totchr |    822.1678    40.61     20.25   0.000    742.573   901.763    .483173
     ins*|   -110.0883    63.117    -1.74   0.081   -233.795   13.6188    .365084
------------------------------------------------------------------------------
(*) dy/dx is for discrete change of dummy variable from 0 to 1
```

Interpretación: Media condicional (entre quienes gastan)

- Comando: `margins, dydx(age) predict(e(0,.))|  (AME)`.
- `Lectura: un aumento de 1 unidad en age aumenta el gasto ambulatorio esperado` $E[y \mid y > 0, x]$ `en 147.8 unidades monetarias. (promedio en la muestra).`

```
. margins, dydx(age) predict(e(0,.))

Average marginal effects                                  Number of obs = 3,328
Model VCE: OIM

Expression: E(ambexp|ambexp>0), predict(e(0,.))
dy/dx wrt:  age

------------------------------------------------------------------------------
             |            Delta-method
             |      dy/dx   std. err.      z    P>|z|     [95% conf. interval]
-------------+----------------------------------------------------------------
         age |    147.796   20.14716     7.34   0.000     108.3083    187.2838
------------------------------------------------------------------------------
```

Interpretación del resultado anterior (Tobit con `mfx compute`)

En el resultado anterior se muestra la salida de:

```
magins, dydx(age) predict(e(0,.))
```

¿Qué está mostrando?

- Efectos marginales de la **media condicional**:

$$E[y \mid y > 0, x]$$

- Calculados **en la media muestral** (**MEM**, at means).
  La última columna **X** muestra los valores de $x = \bar{x}$ donde se evaluaron.

Cómo se lee:

- Si x_j es continua: aumentar x_j en 1 unidad cambia $E[y \mid y > 0, x]$ en `dy/dx`.
- Si x_j es una dummy: cambio de 0 a 1 manteniendo el resto de las variables en sus medias.

Importante: esto no es el efecto marginal sobre la probabilidad $P(y > 0 \mid x)$ ni sobre la media incondicional $E[y \mid x]$. Es un EM de un objeto diferente.

Interpretación: Probabilidad de gasto positivo

- Comando: `margins, dydx(age) predict(pr(0,.))` (AME).
- Lectura: un aumento de 1 unidad en age incrementa la probabilidad de tener gasto ambulatorio positivo $P(y > 0 \mid x)$ en 0.0416 (aprox. 4.16 puntos porcentuales).
- Mide participación (estar activo), no el monto entre los activos.

```
. margins, dydx(age) predict(pr(0,.))

Average marginal effects                                  Number of obs = 3,328
Model VCE: OIM

Expression: Pr(ambexp>0), predict(pr(0,.))
dy/dx wrt:  age

------------------------------------------------------------------------------
             |            Delta-method
             |      dy/dx   std. err.      z    P>|z|     [95% conf. interval]
-------------+----------------------------------------------------------------
         age |    .041645   .0055873     7.45   0.000      .030694     .052596
------------------------------------------------------------------------------
```

Problemas con modelo Tobit

- El modelo Tobit depende totalmente de sus supuestos.
  - Normalidad de la variable latente,
  - Homocedasticidad.
- Si los supuestos fallan no se sabemos muy bien que está estimando el modelo.
- Estos supuestos se pueden testear. No es tan fácil, no existe un comando directo para hacerlo (que yo sepa).

Sample selection: Heckman Two-Step Estimator

- Siempre se observa la variable x_j, pero se observa la variable explicativa y para un subconjunto de la población.
- Ejemplo: Supongamos que la variable y es igual al $log(salario^o)$ que es la oferta salarial o el salario por hora para un individuo que está en el mercado laboral.
- Si la persona está trabajando, entonces se observa esta oferta salarial (el salario).
- Para las personas que no están trabajando no se observa $log(salario^o)$.
- Se dice que el truncamiento de y es incidental, ya que depende de otra variable. En este caso, depende de la participación en la fuerza laboral.

Modelo

- El modelo poblacional es:

$$y = x\beta + u$$

$$E(u|x = 0)$$

$$s = 1[z\gamma + v \geq 0]$$

- $s = 1$ si se observa y, y es igual a cero de otra forma.
- Se supone que los elementos de x y z siempre se observan y se escriben:

$$x\beta = \beta_0 + \beta_1 x_1 + ... + \beta_k x_k$$

$$z\gamma = \gamma_0 + \gamma_1 z_1 + ... + \gamma_m x_m$$

Modelo

- Nosotros estamos interesado en estimar βs. (Se podría hacer a través de MCO si tuvieramos toda la información.)
- A la ecuación $s = 1[z\gamma + v \geq 0]$ se le conoce como ecuación de selección. La cual depende de las variables observables z y de un error inobservable v.
- Supuesto:

$$E(u|x, z) = 0$$

- Para que las ecuaciones funcionen bien, se **requiere** que x sea un subconjunto estricto de z. Es decir z contienen al menos una variable más que x.

Modelo

- La **correlación** entre u y v ocasiona problemas de selección muestral.
- Veamos por qué.
- Suponga que u y v son independientes de z.
- Ya que z es independiente de (u, v)

$$E(y|z, v) = x\beta + E(u|z, v) = x\beta + E(u|v)$$

- Si u y v se distribuyen conjuntamente normal (con media cero), entonces $E(u|v) = \rho v$ para algún parámetro ρ.

$$E(y|z, v) = x\beta + E(u|z, v) = x\beta + \rho v$$

- No se observa v, pero se puede calcular $E(y|z, s)$ y después filtrar esto en s=1

$$E(y|z, s) = x\beta + \rho E(v|z, s)$$

Modelo

- Ya que s y v están relacionados, y v tiene una distribución normal estándar, se puede mostrar que $E(v|z,s)$ es la razón inversa de Mills, $\lambda(z\gamma)$, cuando $s = 1$
- Luego,

$$E(y|z,s=1) = x\beta + \rho\lambda(z\gamma)$$

- La ecuación anterior nos dice que el valor esperado de y, dado z, es igual a $x\beta$, **más un término adicional** que depende de la razón inversa del Mills evaluada en $z\gamma$
- Como el objetivo es estima β, la ecuación anterios nos dice que se puede estimar β usando sólo la muestra seleccionada (sample selection), siempre y cuando se incluya la razón inversa del Mills evaluada en $z\gamma$ como regresor.
- Fijese que si u y v no están correlacionadas, entonces $\rho = 0$ y podemos estimar $E(y|z,s=1)$ con MCO. El problema es cuando $\rho \neq 0$
- En la práctica casi siempre u y v están correlacionadas.

Modelo

- Como se desconoce γ, no es posible evaluar la razón inversa del Mills para cada i. Pero se pueden estimar los γ a través de un modelo probit.

$$P(s = 1|z) = \Phi(z\gamma)$$

- Usando la muestra entera, se estiman los γ's.
- A este proceso se le conoce como **método Heckit**, por Heckman(1976).

Método Heckit: En práctica

1. Usar las n observaciones para estimar el modelo probit de s_i sobre z_i y se obtienen las estimaciones de $\hat{\gamma}$.
2. Calcula la razón inversa de Mills: $\hat{\lambda}_i = \lambda(z_i\hat{\gamma})$ para cada i.
3. Tomar $\hat{\lambda}$ para los i con $s = 1$.
4. Usar la muestra seleccionada, es decir, las observaciones para las cuales $s_i = 1$ y ejecutar la regresión:

$$y_i \text{ sobre } x_i,\ \hat{\lambda}$$

- Los β's son consistentes y se distribuyen aproximadamente normal.

Método Heckit: En práctica

- Fácilmente se puede hacer una prueba se sesgo de selección.
- Test:

$$H_0 : \rho = 0$$

- Es decir, bajo la hipotesis nula no existe un problema se sample selection.

Método Heckit: En práctica

- Importante
  - x debe ser un subconjunto estricto de z. En la práctica incluir todos los elementos de x en z no es costoso, pero excluirlos puede causar problemas si es que no se deberían excluir.
  - Al menos un elemento de z no debe estar en x. En otra palabras, se necesita una variable que afecta la selección, pero que no tenga un efecto parcial en y.
- El segundo punto es super importante, ya que si $x = z$, luego $\hat{\lambda}$ puede estar muy correlacionado con los elementos de x. Esto implica que los errores estándar serán muy altos para los $\hat{\beta}$ estimados.

Ejemplo

- Suponga que queremos ver el como las variables explicativas: *educ*, $educ^2$,*exper* y $exper^2$ Afectan el salario.
- Si obervamos los datos nos damos cuenta que 325 observaciones tienen missing values del logaritmo del salario.

```
. tabmiss lwage
    Variable |      Obs       Missings    Feq.Missings       NonMiss    Feq.NonMiss
-------------+-----------------------------------------------------------------------
       lwage |      753            325           43.16           428          56.84
```

- Por lo tanto, estaríamos en un caso de sample selection.

Ejemplo

- Primero vamos a estimar la probabilidad de participar en la fuerza laboral. Con el siguiente modelo.

probit inlf educ exper expersq nwifeincage kidsge6 kidslt6

- Luego vamos a generar la razón inversa de Mills. Lo llamaremos **InvmillR**
- Finalmente estimaremos:

reg inlf educ exper expersq InvmillR

Ejemplo

- Estimación:

```
. reg lwage educ exper expersq InvmillR
```

Source	SS	df	MS		
Model	35.0479487	4	8.76198719	Prob > F	0.0000
Residual	188.279492	423	.445105182	R-squared	0.1569
				Adj R-squared	0.1490
Total	223.327441	427	.523015084	Root MSE	.66716

lwage	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
educ	.1090655	.0156096	6.99	0.000	.0783835	.1397476
exper	.0438873	.0163534	2.68	0.008	.0117434	.0760313
expersq	-.0008591	.0004414	-1.95	0.052	-.0017267	8.49e-06
InvmillR	.0322619	.1343877	0.24	0.810	-.2318889	.2964126
_cons	-.5781032	.306723	-1.88	0.060	-1.180994	.024788

Ejemplo

- Note que no podemos rechazar la hipotesis nula $H_0 := 0$
- Por lo tanto, esto nos dice que no hay evidencia de problemas de sample selection.
- De hecho si estimamos el modelo sin considerar la correción por sample selection, los resultados son similares.
- A las variables: nwifeinc age kidsge6 kidslt6 se les llama exclusion restrictions. Básicamente se asume que estas variables afectan la participación en el mercado laboral, pero **no** tienen efecto sobre la oferta salarial.
- También se puede usar el siguiente comando para realizar la estimación:
  heckman lwage educ exper expersq, select(inlf= educ exper expersq nwifeinc age kidsge6 kidslt6) twostep

Ejemplo

- Estimación sin considerar la correción por sample selection

```
. reg lwage educ exper expersq
```

Source	SS	df	MS		
				Number of obs	= 428
				F(3, 424)	= 26.29
Model	35.0222967	3	11.6740989	Prob > F	= 0.0000
Residual	188.305144	424	.444115906	R-squared	= 0.1568
				Adj R-squared	= 0.1509
Total	223.327441	427	.523015084	Root MSE	= .66642

lwage	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
educ	.1074896	.0141465	7.60	0.000	.0796837	.1352956
exper	.0415665	.0131752	3.15	0.002	.0156697	.0674633
expersq	-.0008112	.0003932	-2.06	0.040	-.0015841	-.0000382
_cons	-.5220406	.1986321	-2.63	0.009	-.9124667	-.1316144